FIAP ON

DATA INGESTION

ARQUITETURA DE DW AVANÇADA: GUIA DE BOAS PRÁTICAS

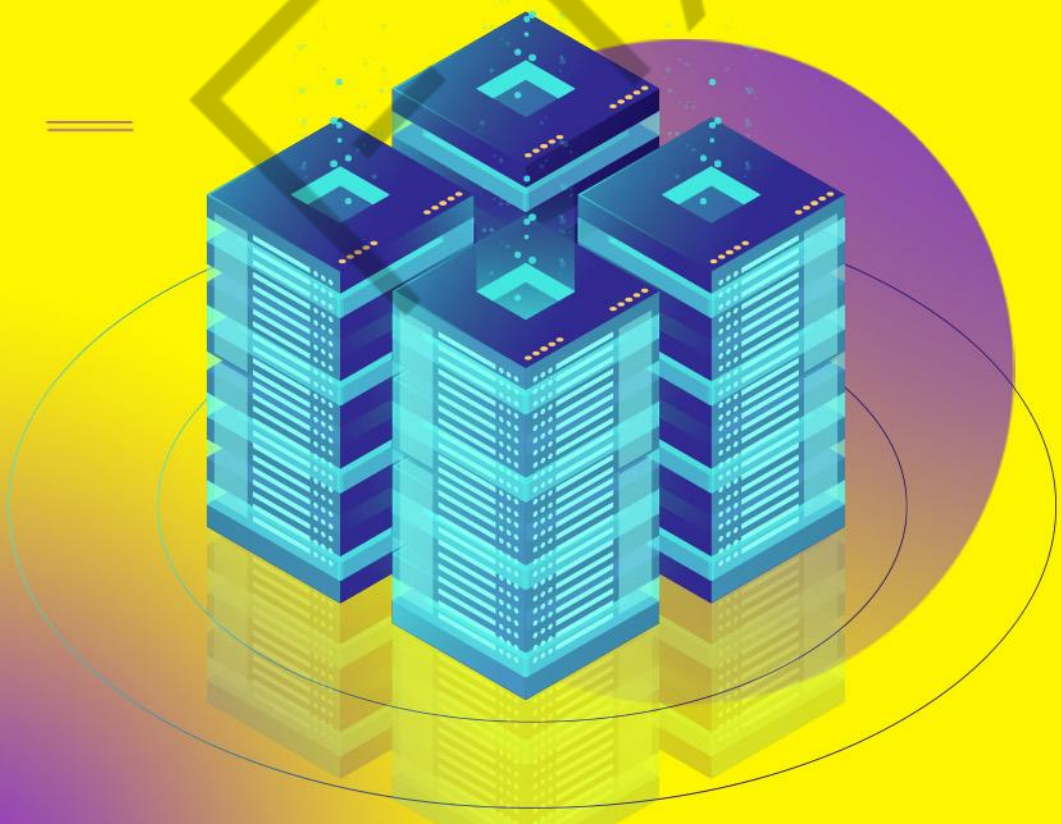

2

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1– Exemplo de Dimensão Data Populada 8
Figura 2 – Exemplo de Dimensão Data para SQL Server 10
Figura 3 – Exemplo do relacionamento entre D_D e F_VENDAS 11
Figura 4 – Exemplo do relacionamento entre D_FUNCIONARIO e F_VENDAS 14
Figura 5 – Exemplo da categoria de exceção populada na D_FUNCIONARIO 14
Figura 6 – Exemplo da tabela F_VENDAS populada com categorias de exceção no campo SK_FUNC_MOTOBOY 15
Figura 7 – Exemplo da Junk Dimension D_FORMA_STATUS_PAGAMENTO 17
Figura 8 – Exemplo de dados da Junk Dimension D_FORMA_STATUS_PAGAMENTO 18

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE QUADROS

Quadro 1 – Exemplo de Dimensão Data 6

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 ARQUITETURA DE DATA WAREHOUSING AVANÇADA: GUIA DE BOAS PRÁTICAS.....5
1.1 A Dimensão Data em Modelos Dimensionais.....5
1.2 Atributos da Dimensão Data.....5
1.3 A essencialidade da Dimensão Data.....9
1.4 Lidando com várias datas diferentes no mesmo Data Mart.....10
2 CATEGORIAS DE EXCEÇÃO.....13
2.1 Mantendo a simplicidade das consultas ao DW.....13
2.3 Outros exemplos de categorias de exceção.....15
3 DIMENSÃO DEGENERADA.....16
3.1 Atributos de cabeçalho na própria tabela de fatos.....16
4 JUNK DIMENSION (DIMENSÃO BUGIGANGA).....17
4.1 Combinando categorias e descrições.....17
5 ATIVIDADE NÃO AVALIATIVA.....19

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 ARQUITETURA DE DATA WAREHOUSING AVANÇADA: GUIA DE BOAS PRÁTICAS

1.1 A Dimensão Data em Modelos Dimensionais

Podemos afirmar que a Dimensão Data, que também pode ser chamada de Dimensão Calendário, Dimensão Tempo ou Dimensão Período, é uma dimensão especial, pois, certamente, fará parte de todos os data marts de seu DW, uma vez que, praticamente, qualquer processo de negócio de sua organização terá suas métricas atreladas a uma série temporal para efeitos de performance: suas vendas, estoques, saldos, seu headcount (contagem de pessoal), suas receitas, despesas, seu resultado, sua quantidade de clientes etc.

Em suma, qualquer métrica de seu DW deverá ser medida ao longo do tempo.

Segundo Ralph Kimball, na sua obra The Data Warehouse Toolkit, ao contrário da maioria das outras dimensões, a dimensão de data pode ser construída com antecedência. Você pode incluir na tabela linhas representando dias individuais para os próximos 10 ou 20 anos, abrangendo assim seu histórico armazenado e vários anos no futuro. Mesmo considerando 20 anos de dados, a dimensão de data terá apenas cerca de 7.300 linhas, o que é relativamente pequeno.

Dica: ao iniciar um projeto de DW, faça com que a primeira dimensão a ser construída seja a Dimensão Data.

1.2 Atributos da Dimensão Data

Tenha em mente que o principal objetivo da dimensão data é facilitar as análises, exigindo ou mesmo eliminando a necessidade de, nas consultas ao DW, usarmos fórmulas, cálculos e transformações complexas relacionadas às datas. Dessa forma, a dimensão data ideal é aquela cujos atributos poderão resolver virtualmente todas as necessidades de análise relativas às séries temporais pertinentes ao seu negócio. Por exemplo, devemos poder analisar

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

nossos indicadores por ano, semestre, trimestre, mês, semana, dia da semana, ano fiscal, mesmo período do ano anterior versus período do ano corrente etc. Devemos ter atributos numéricos, como o número do ano, número do mês, número do ano e mês, número do dia no mês etc., e atributos textuais, como a descrição do semestre, trimestre, ano, dia, bem como descrições abreviadas.

Vejamos abaixo um exemplo de dimensão Data e seus atributos:

COLUNA	DATATYPE	NOME LÓGICO	EXEMPLO
SK_DATA (PK)	inteiro	Surrogate Key da Data	20240226
DT_REFERENCIA	date	Data de Referência	2024-02-26
NR_ANO	inteiro	Número do Ano	2024
NR_SEMESTRE	inteiro	Número do Semestre	1
DS_SEMESTRE_ANO	varchar	Descrição do Semestre/Ano	1º SEMESTRE/2024
DS_SEMESTRE	varchar	Descrição do Semestre	1º SEMESTRE
NR_TRIMESTRE	inteiro	Número do Trimestre	1
DS_TRIMESTRE_ANO	varchar	Descrição do Trimestre/Ano	1º TRIMESTRE/2024
DS_TRIMESTRE	varchar	Descrição do Trimestre	1º TRIMESTRE
NR_MES	inteiro	Número do Mês	2
NR_ANO_MES	inteiro	Número do Ano e Mês	202402
DS_MES_ANO	varchar	Descrição do Mês/Ano	FEVEREIRO/2024
DS_MES	varchar	Descrição do Mês	FEVEREIRO
DS_ABV_MES	char	Descrição Abreviada do Mês	FEV
DS_ABV_MES_ANO	varchar	Descrição Abreviada do Mês/Ano	FEV/2024
DS_DIA_SEMANA	varchar	Descrição do Dia da Semana	SEGUNDA-FEIRA
DS_DATA	varchar	Descrição da Data	26/02/2024
NR_DIA_MES	inteiro	Número do Dia do Mês	26
NR_DIA_SEMANA	inteiro	Número do Dia da Semana	2
NR_DIA_ANO	inteiro	Número do dia no Ano	57
DS_DIA_UTIL_FERIADO	varchar	Descrição Dia Útil/Feriado	DIA ÚTIL
DS_FIM_SEMANA	varchar	Descrição Fim de Semana	DIA DE SEMANA
DS_DATA_EXTENSO	varchar	Descrição da Data por Extenso	Segunda Feira, 24 de fevereiro de 2024.
DT_CRIACAO_RGT	datetime	Data/Hora da Criação do Registro	2024-01-25 14:12:46.580

Quadro 1 – Exemplo de Dimensão Data
Fonte: Elaborado pelo autor (2024)

Perceba que cada coluna na tabela de dimensão de data deriva do dia específico que a linha representa. A Surrogate Key da Dimensão Data, ao contrário de outras dimensões, não é um mero valor sequencial, mas é a própria representação da data no formato YYYYMMDD. Por isso, a chamamos também de "smart key".

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Os diversos atributos como as colunas de semestre, trimestre e mês são úteis para construção de análises temporais que comparam o desempenho dos negócios entre períodos.

Para relatórios e painéis facilita muito ter na dimensão data rótulos longos e abreviados. Por exemplo, você poderia ter um atributo "nome do mês" com valores como "FEVEREIRO" e outro como “FEV”.

Colunas numéricas, como "Número do Ano e Mês”, no formato YYYYMM, são extremamente úteis na construção de prompts e ordenação dos atributos descritivos em relatórios.

A coluna "Número do Dia do Mês" começa com 1 no início de cada mês e vai até 28, 29, 30 ou 31, dependendo do mês. Essa coluna é útil para comparar o mesmo dia de cada mês. Da mesma forma, você pode ter um “Número do Mês” (1, ..., 12). Todos esses números inteiros permitem cálculos simples com datas por meio de limites de ano e mês, além de facilitar muito a filtragem das consultas.

A coluna "Descrição do Dia da Semana" contém o nome do dia, como "Segunda-feira". Essa coluna seria usada para criar relatórios comparando o desempenho dos negócios entre os diversos dias da semana. Colunas descrevendo feriados, dias úteis, finais de semana etc. também são valiosas em certos contextos de negócio.

Conforme a necessidade do negócio, muitas empresas incluem colunas semelhantes para os períodos fiscais, caso sejam diferentes dos períodos do calendário, bem como categorias adicionais do negócio, como YTD (Year to Date), LYTD (Last Year to Date), L12M (Last 12 months) e P12M, (Previous 12 months).

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SK_DATA	DT_REFERENCIA	NR_ANO	NR_SEMESTRE	DS_SEMESTRE_ANO	DS_SEMESTRE	NR_TRIMESTRE	DS_TRIMESTRE_ANO	DS_TRIMESTRE	NR_MES	NR_ANO_MES	DS_MES_ANO	DS_MES	DS_ABV_MES	DS_ABV_MES_ANO	DS_DIA_SEMANA	DS_DATA	NR_DIA_MES	NR_DIA_SEMA	NR_DIA_ANO	DS_DATA_EXTENSO
-2	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	NULL	
20170101	2017-01-01	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	DOMINGO	01/01/2017	1	1	1	DOMINGO, 1º DE JANEIRO DE 2017
20170102	2017-01-02	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	SEGUNDA-FEIRA	02/01/2017	2	2	2	SEGUNDA-FEIRA, 2 DE JANEIRO DE 2017
20170103	2017-01-03	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	TERÇA-FEIRA	03/01/2017	3	3	3	TERÇA-FEIRA, 3 DE JANEIRO DE 2017
20170104	2017-01-04	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	QUARTA-FEIRA	04/01/2017	4	4	4	QUARTA-FEIRA, 4 DE JANEIRO DE 2017
20170105	2017-01-05	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	QUINTA-FEIRA	05/01/2017	5	5	5	QUINTA-FEIRA, 5 DE JANEIRO DE 2017
20170106	2017-01-06	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	SEXTA-FEIRA	06/01/2017	6	6	6	SEXTA-FEIRA, 6 DE JANEIRO DE 2017
20170107	2017-01-07	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	SÁBADO	07/01/2017	7	7	7	SÁBADO, 7 DE JANEIRO DE 2017
20170108	2017-01-08	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	DOMINGO	08/01/2017	8	1	8	DOMINGO, 8 DE JANEIRO DE 2017
20170109	2017-01-09	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	SEGUNDA-FEIRA	09/01/2017	9	2	9	SEGUNDA-FEIRA, 9 DE JANEIRO DE 2017
20170110	2017-01-10	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	TERÇA-FEIRA	10/01/2017	10	3	10	TERÇA-FEIRA, 10 DE JANEIRO DE 2017
20170111	2017-01-11	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	QUARTA-FEIRA	11/01/2017	11	4	11	QUARTA-FEIRA, 11 DE JANEIRO DE 2017
20170112	2017-01-12	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	QUINTA-FEIRA	12/01/2017	12	5	12	QUINTA-FEIRA, 12 DE JANEIRO DE 2017
20170113	2017-01-13	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	SEXTA-FEIRA	13/01/2017	13	6	13	SEXTA-FEIRA, 13 DE JANEIRO DE 2017
20170114	2017-01-14	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	SÁBADO	14/01/2017	14	7	14	SÁBADO, 14 DE JANEIRO DE 2017
20170115	2017-01-15	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	DOMINGO	15/01/2017	15	1	15	DOMINGO, 15 DE JANEIRO DE 2017
20170116	2017-01-16	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	SEGUNDA-FEIRA	16/01/2017	16	2	16	SEGUNDA-FEIRA, 16 DE JANEIRO DE 2017
20170117	2017-01-17	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	TERÇA-FEIRA	17/01/2017	17	3	17	TERÇA-FEIRA, 17 DE JANEIRO DE 2017
20170118	2017-01-18	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	QUARTA-FEIRA	18/01/2017	18	4	18	QUARTA-FEIRA, 18 DE JANEIRO DE 2017
20170119	2017-01-19	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	QUINTA-FEIRA	19/01/2017	19	5	19	QUINTA-FEIRA, 19 DE JANEIRO DE 2017
20170120	2017-01-20	2017	1	1º SEMESTRE/2017	1º SEMESTRE	1	1º TRIMESTRE/2017	1º TRIMESTRE	1	201701	JANEIRO/2017	JANEIRO	JAN	JAN/2017	SEXTA-FEIRA	20/01/2017	20	6	20	SEXTA-FEIRA, 20 DE JANEIRO DE 2017

Figura 1– Exemplo de Dimensão Data Populada
Fonte: Elaborado pelo autor (2024)

No exemplo acima, você pode estar se perguntando: o que significa aquele registro com a Surrogate Key igual a -2, com os demais atributos nulos? Nesse caso, esse registro significa a categoria de exceção a ser utilizada no caso de datas nulas (não preenchidas) na origem dos dados. Essa categoria de exceção garantirá que as consultas aos Data Marts de nosso DW sejam resolvidas, 100%, com inner joins em vez de left joins. Ainda neste capítulo, trataremos com mais detalhe as categorias de exceção.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1.3 A essencialidade da Dimensão Data

Alguns arquitetos de dados podem questionar a necessidade de uma tabela de dimensão data. Uma vez que os atributos de data já existem nas tabelas de fatos, por que não usar as próprias fórmulas do SQL para tratar as categorias de data? Kimball refutou esse argumento:

1. A Dimensão Data simplifica consultas: embora a data "bruta" esteja presente, manipulá-la para agrupar por mês, trimestre, final de semana ou feriados fica complicado, especialmente para usuários não técnicos. Uma tabela dedicada organiza essas informações, tornando as consultas mais fáceis e eficientes.
2. Ela suporta atributos não-padrão: funções SQL padrão não cobrem tudo. Precisa filtrar por semanas fiscais, temporadas, feriados, fechamentos? Uma dimensão data dedicada permite armazenar e filtrar esses atributos facilmente.
3. A Dimensão Data melhora a usabilidade: usuários de negócios não precisam ser especialistas em SQL para analisar dados por períodos específicos. A dimensão data fornece rótulos claros e agrupamentos intuitivos.
4. Centraliza a lógica de calendário: em vez de espalhar cálculos complexos por diferentes aplicativos, a dimensão data centraliza toda a lógica relacionada a datas e calendários, facilitando a manutenção e evitando inconsistências.

Em resumo, a dimensão data não é um luxo, é uma necessidade para modelos dimensionais eficazes e fáceis de usar. Ela simplifica consultas, suporta atributos não-padrão, melhora a usabilidade e centraliza a lógica de calendário, tornando a análise de dados mais produtiva e precisa.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

D	D_DATA	
P *	SK_DATA	INTEGER
	DT_REFERENCIA	DATE
	NR_ANO	INTEGER
	NR_SEMESTRE	INTEGER
	DS_SEMESTRE_ANO	VARCHAR (20)
	DS_SEMESTRE	VARCHAR (20)
	NR_TRIMESTRE	INTEGER
	DS_TRIMESTRE_ANO	VARCHAR (20)
	DS_TRIMESTRE	VARCHAR (20)
	NR_MES	INTEGER
	NR_ANO_MES	INTEGER
	DS_MES_ANO	VARCHAR (20)
	DS_MES	VARCHAR (20)
	DS_ABV_MES	CHAR (3)
	DS_ABV_MES_ANO	VARCHAR (20)
	DS_DIA_SEMANA	VARCHAR (20)
	DS_DATA	VARCHAR (20)
	NR_DIA_MES	INTEGER
	NR_DIA_SEMANA	INTEGER
	NR_DIA_ANO	INTEGER
	DT_CRIACAO_RGT	DATETIME
D_DATA_PK (SK_DATA)		

Figura 2 – Exemplo de Dimensão Data para SQL Server
Fonte: Elaborado pelo autor (2024)

1.4 Lidando com várias datas diferentes no mesmo Data Mart.

Quando um fato de determinado Data Mart do DW possui mais de uma data, como devemos tratar a modelagem?

A resposta parte de uma premissa que devemos sempre seguir: em um Data Warehouse Corporativo, devemos manter as dimensões em conformidade. Isso quer dizer que, sempre que o contexto de negócio permitir, devemos usar a mesma dimensão em diferentes Data Marts. Logo, a Dimensão Data será única para os diferentes Data Marts do DW. Por obviedade, se a tabela de fatos de um Data Mart possuir mais de uma data relacionada, devemos usar a mesma tabela de Dimensão, jamais replicá-la fisicamente.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Veja o modelo de Vendas da nossa Hamburgueria DBurger. Cada registro da fato de vendas representa um item de um pedido que, por sua vez, possui a Data do Pedido e a Data da Previsão de Entrega. Nesse caso, a tabela Fato receberá duas FKs (Foreign Keys) da tabela de dimensão. Veja como fica o modelo:

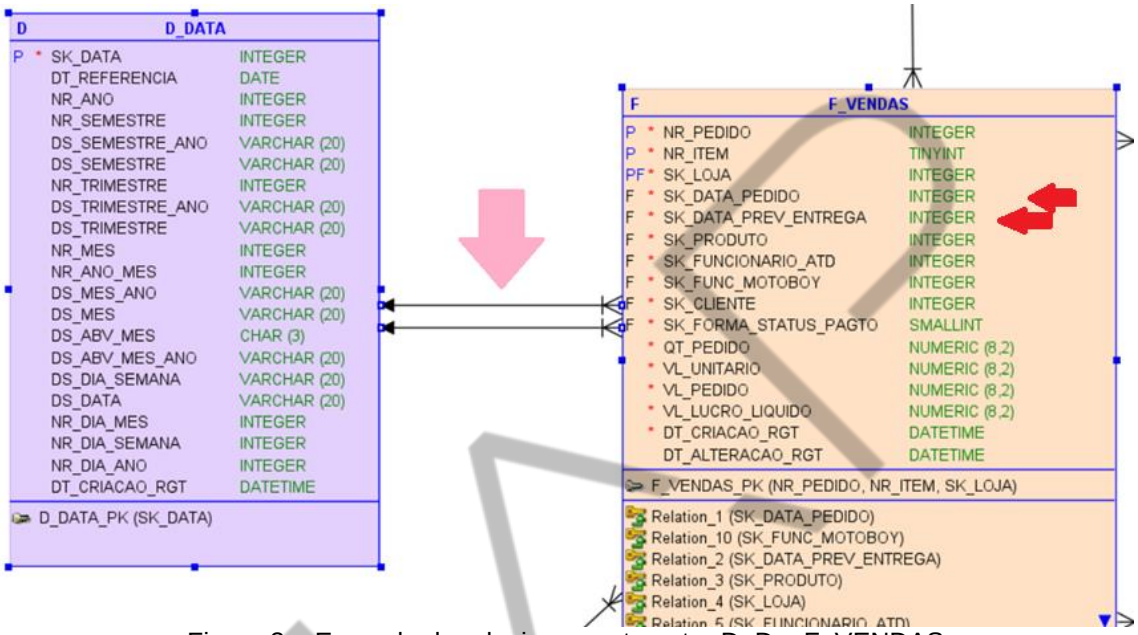

Figura 3 – Exemplo do relacionamento entre D_D e F_VENDAS
Fonte: Elaborado pelo autor (2024)

Ao realizarmos uma consulta ao modelo, a tabela D_DATA entrará duas vezes na consulta apenas com apelidos diferentes. Logicamente, ela se comportará como duas dimensões distintas, a dimensão data do pedido e a dimensão data da previsão da entrega, mas, fisicamente, teremos apenas uma tabela no banco.

Veja o script de exemplo abaixo:

```
--Script
--Consulta ao DM de Vendas da Hamburgueria
SELECT
F_VENDAS.NR_PEDIDO,
F_VENDAS.NR_PEDIDO,
D_LOJA.NR_LOJA,
D_DATA_PEDIDO.DS_DATA AS DATA_PEDIDO,
D_DATA_PREV_ENTREGA.DS_DATA AS DATA_PREV_ENTREGA,
D_PRODUTO.DS_PRODUTO
FROM
F_VENDAS,
D_DATA AS D_DATA_PEDIDO,
D_DATA AS D_DATA_PREV_ENTREGA,
D_PRODUTO,
```

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
D_LOJA
WHERE D_DATA_PEDIDO.SK_DATA        = F_VENDAS.SK_DATA_PEDIDO
AND   D_DATA_PREV_ENTREGA.SK_DATA  = F_VENDAS.SK_DATA_PREV_ENTREGA
AND   D_PRODUTO.SK_PRODUTO         = F_VENDAS.SK_PRODUTO
AND   D_LOJA.SK_LOJA               = F_VENDAS.SK_LOJA
AND   F_VENDAS.NR_PEDIDO = 931
AND   D_LOJA.NR_LOJA = 21
```

Código-fonte 1 – SCRIPT – Consulta ao DM de Vendas da Hamburgueria
Fonte: Elaborado pelo autor (2024)

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 CATEGORIAS DE EXCEÇÃO

2.1 Mantendo a simplicidade das consultas ao DW

Quando Ralph Kimball elaborou o modelo estrela dimensional, ele deixou claro que um dos objetivos da modelagem dimensional era manter as consultas aos data marts do DW o mais simples possível para usuários não técnicos. Dessa forma, consultas aos data marts devem ser feitas com inner joins entre fatos e dimensões. Mas o que fazer quando uma determinada categoria não está preenchida na origem? Por exemplo, no nosso modelo da Hamburgueria, temos dois relacionamentos entre a fato de vendas e a dimensão calendário, um para a data do pedido e outro para a data da previsão de entrega. Caso a data de previsão de entrega na origem dos dados esteja nula, como isso será tratado na fato?

Segundo Kimball, para garantir que as consultas aos data marts se resolvam apenas com inner joins, nunca devemos popular as surrogate keys nas tabelas fato (que no caso são foreign keys) com nulos. A resposta, portanto, está nas categorias de exceção. As dimensões devem conter pelo menos um registro padrão (com sua respectiva surrogate key) para lidar com situações como essa. Esses registros compõem as categorias de exceção.

No caso da Dimensão Data, apresentada acima, inserimos da Dimensão um registro com a surrogate key (-2) para tratar as situações em que a data é nula na origem. Dessa maneira, garantimos que o inner Join sempre resolverá os relacionamentos entre fato e dimensão, pois eliminamos a possibilidade de haver uma correspondência na fato que não corresponda a um registro de dimensão (restrição referencial).

Ainda no exemplo do data mart de vendas Hamburgueria, temos dois relacionamentos entre a tabela de fato e a dimensão funcionário. Um se refere ao funcionário atendente e outro ao funcionário da entrega, o motoboy.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

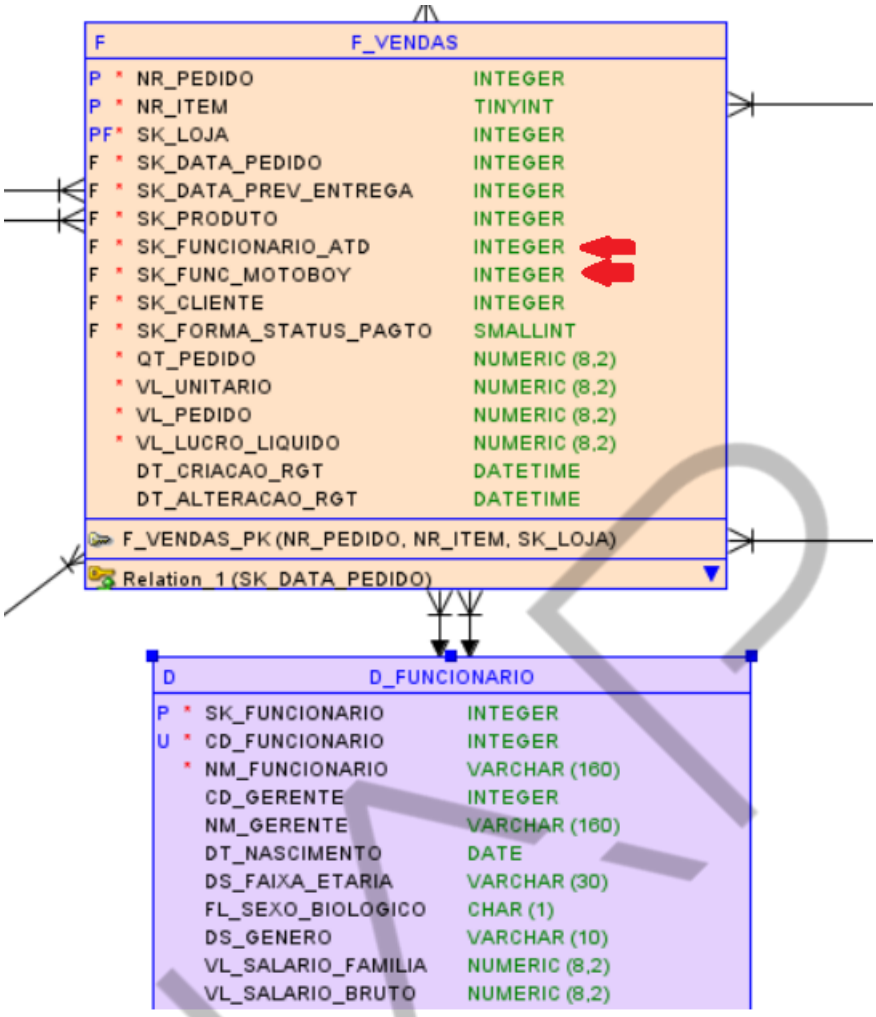

Figura 4 – Exemplo do relacionamento entre D_FUNCIONARIO e F_VENDAS
Fonte: Elaborado pelo autor (2024)

SK_FUNCIONARIO	CD_FUNCIONARIO	NM_FUNCIONARIO	DT_NASCIMENTO	DS_FAIXA_ETARIA	DS_GENERO	VL_SALARIO_BRUTO	DS_FAIXA_SALARIAL
-2	-2	NÃO INFORMADO	NULL	NÃO INFORMADO	NULL	NULL	NULL
1	1	Mauro Soares Simão	1999-11-18	21 A 30 ANOS	MASCULINO	11781.51	ACIMA DE 10.000
2	4	Felipa Tutti	1994-03-31	21 A 30 ANOS	FEMININO	13292.47	ACIMA DE 10.000
3	7	William José Barcellos	1998-01-03	21 A 30 ANOS	MASCULINO	11651.21	ACIMA DE 10.000
4	10	João Carlos Evangelista	1995-04-18	21 A 30 ANOS	MASCULINO	9362.45	5.000 A 10.000
5	13	Silvana Lindsttly	1991-03-21	31 A 40 ANOS	FEMININO	11760.91	ACIMA DE 10.000
6	16	Anderson Nascimento Rangghy	1990-11-29	31 A 40 ANOS	MASCULINO	12467.36	ACIMA DE 10.000
7	19	Daniele Pimenta Monteiro	1992-08-07	31 A 40 ANOS	FEMININO	9217.03	5.000 A 10.000
8	22	Hellyson Costa Neto	1993-07-23	21 A 30 ANOS	MASCULINO	12064.86	ACIMA DE 10.000
9	25	Leticia Pompeo	1999-05-17	21 A 30 ANOS	FEMININO	10994.93	ACIMA DE 10.000
10	28	Rafael Cirillo	1999-02-27	21 A 30 ANOS	MASCULINO	11074.64	ACIMA DE 10.000
11	31	Edilene Araras Santiago	1996-03-22	21 A 30 ANOS	FEMININO	10769.04	ACIMA DE 10.000
12	34	Osvaldo Bertolini	1995-10-19	21 A 30 ANOS	MASCULINO	11519.08	ACIMA DE 10.000
13	37	Giulia Braga	1996-08-18	21 A 30 ANOS	FEMININO	10201.39	ACIMA DE 10.000
14	40	Paolla Oliveira	1998-04-09	21 A 30 ANOS	FEMININO	10392.49	ACIMA DE 10.000
15	43	Rita Maria Botelho	1993-02-25	21 A 30 ANOS	FEMININO	8640.05	5.000 A 10.000
16	46	Yanna Fonfosa	1999-09-02	21 A 30 ANOS	FEMININO	11434.38	ACIMA DE 10.000

Figura 5 – Exemplo da categoria de exceção populada na D_FUNCIONARIO
Fonte: Elaborado pelo autor (2024)

Entretanto, nem todas as vendas são delivery, logo, nem sempre o usuário da entrega está preenchido. Nesse caso, em vez de preencher o campo

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SK_FUNC_MOTOBOY com nulo (o que estaria errado do ponto de vista da modelagem dimensional), nós o preencheríamos com -2.

NR_PEDIDO	NR_ITEM	SK_LOJA	SK_DATA_PEDIDO	SK_DATA_PREV_ENTREGA	SK_PRODUTO	SK_FUNCIONARIO_ATD	SK_FUNC_MOTOBOY	SK_CLIENTE
1	1	1	20180102	20180102	70	121	-2	589
1	1	2	20180102	20180102	59	137	134	318
1	1	3	20180102	20180102	63	254	-2	1477
1	1	4	20180102	20180102	96	79	-2	2743
1	1	5	20180102	20180102	110	102	99	2602
1	1	6	20180102	20180102	63	114	-2	1040
1	1	7	20180102	20180102	51	158	155	382
1	1	8	20180102	20180102	67	198	-2	859
1	1	9	20180102	20180102	70	284	281	1727
1	1	10	20180102	20180102	76	163	-2	592

Figura 6 – Exemplo da tabela F_VENDAS populada com categorias de exceção no campo SK_FUNC_MOTOBOY
Fonte: Elaborado pelo autor (2024)

2.3 Outros exemplos de categorias de exceção

Conforme a necessidade do negócio, há outras categorias de exceção que podemos utilizar. Quando pertinente, devemos inserir esses registros, com suas respectivas surrogate Keys nas dimensões e tratar as exceções no contexto do ETL. Seguem alguns exemplos:

(-1) Não se aplica:

ssa categoria é utilizada para indicar que determinada dimensão não se aplica a um fato específico, por exemplo, a geografia do canal de vendas em caso de uma venda on-line.

(-2) Não Informado:

Indica que o valor de um atributo não foi preenchido na origem, por exemplo, uma data nula.

(-3) Não encontrado:

Essa categoria indica que a chave de um registro na dimensão não foi encontrada no processo de ETL. Na dimensão produto, por exemplo, um registro de venda pode referenciar um código de produto inexistente.

(-4) - Outros:

Essa categoria é utilizada para capturar valores atípicos ou excepcionais que não se encaixam nas categorias anteriores.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3 DIMENSÃO DEGENERADA

3.1 Atributos de cabeçalho na própria tabela de fatos

O conceito da dimensão degenerada está na utilização de atributos de cabeçalho na própria tabela de fato. O exemplo clássico é o do número da nota fiscal em uma fato de vendas. Perceba que uma nota fiscal pode possuir vários itens, por essa razão, o grão (menor nível de detalhe da informação), na fato de vendas, será o item da nota fiscal. Os itens, por sua vez, herdam todas as chaves estrangeiras das dimensões relacionadas à nota fiscal, deixando-a sem nenhum conteúdo exclusivo. No entanto, o número da fatura permanece como uma chave de dimensão válida para tabelas de fatos no nível de item de linha. O número da NF, dessa forma, será a dimensão degenerada e será colocada na tabela de fatos com o reconhecimento explícito de que não há uma tabela de dimensão associada (dimensão nota fiscal).

No nosso exemplo da hamburgueria, os atributos NR_PEDIDO e NR_ITEM podem ser considerados a dimensões degeneradas.

Observação 1: atributos descritivos, por exemplo, tipo de pedido, ou tipo de fatura, não devem estar na tabela de fatos, mas em uma dimensão separada, com sua respectiva surrogate key.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

4 JUNK DIMENSION (DIMENSÃO BUGIGANGA)

4.1 Combinando categorias e descrições

Processos de negócio transacionais normalmente geram uma variedade de descritivos e domínios diversos, com pouca variação de valores. São pequenos pedaços de informação que ajudam a descrever uma transação (exemplo: se o pagamento foi à vista ou a prazo, se o cliente era novo ou antigo etc.). Normalmente, são tipos ou status diversos das transações.

Em vez de criarmos dimensões separadas para cada marcador e atributo, podemos criar uma única "dimensão bugiganga" para juntar todos eles. Nessa dimensão, frequentemente chamada de "dimensão de perfil de transação", não há a necessidade de incluir todas as combinações possíveis de valores (crossjoin), mas apenas as combinações que realmente aparecem nos seus dados originais, economizando espaço e tornando as coisas mais simples.

Junk Dimensions evitam que você tenha um monte de dimensões pequenas que atrapalham a análise e dão flexibilidade na hora de fazer análises.

Ao analisarmos o banco transacional da hamburgueria, percebemos que os pedidos possuem status e forma de pagamento. Em vez de criarmos uma dimensão para os descritivos do status e outro para as formas de pagamento, podemos simplesmente combinar ambas as categorias em uma dimensão bugiganga.

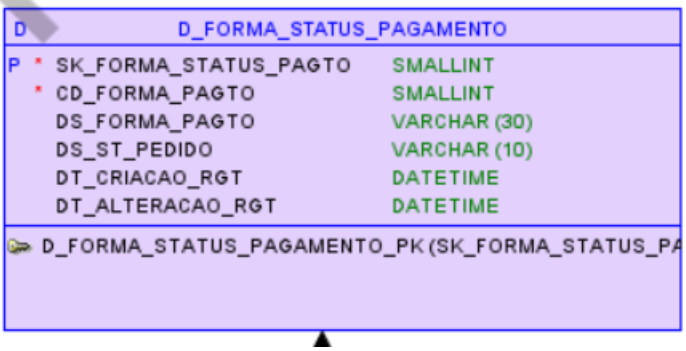

Figura 7 – Exemplo da Junk Dimension D_FORMA_STATUS_PAGAMENTO
Fonte: Elaborado pelo autor (2024)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SK_FORMA_STATUS_PAGTO	CD_FORMA_PAGTO	DS_FORMA_PAGTO	DS_ST_FORMA_PAGAMENTO	DS_ST_PEDIDO	DT_CRIACAO_RGT	DT_ALTERACAO_RGT
1	1	DINHEIRO	ATIVO	ATIVO	2023-08-31 17:50:54.253	2023-08-31 17:50:54.253
2	2	CHEQUE	INATIVO	ATIVO	2023-08-31 17:50:54.253	2023-08-31 17:50:54.253
3	3	CARTÃO DE CRÉDITO	ATIVO	ATIVO	2023-08-31 17:50:54.257	2023-08-31 17:50:54.257
4	4	CARTÃO DE DÉBITO	ATIVO	ATIVO	2023-08-31 17:50:54.257	2023-08-31 17:50:54.257
5	5	CORTESIA DA LOJA	ATIVO	ATIVO	2023-08-31 17:50:54.257	2023-08-31 17:50:54.257
6	6	PIX	ATIVO	ATIVO	2023-08-31 17:50:54.257	2023-08-31 17:50:54.257
7	1	DINHEIRO	ATIVO	INATIVO	2023-08-31 17:50:54.257	2023-08-31 17:50:54.257
8	2	CHEQUE	INATIVO	INATIVO	2023-08-31 17:50:54.257	2023-08-31 17:50:54.257
9	3	CARTÃO DE CRÉDITO	ATIVO	INATIVO	2023-08-31 17:50:54.260	2023-08-31 17:50:54.260
10	4	CARTÃO DE DÉBITO	ATIVO	INATIVO	2023-08-31 17:50:54.260	2023-08-31 17:50:54.260
11	5	CORTESIA DA LOJA	ATIVO	INATIVO	2023-08-31 17:50:54.260	2023-08-31 17:50:54.260
12	6	PIX	ATIVO	INATIVO	2023-08-31 17:50:54.260	2023-08-31 17:50:54.260

Figura 8 – Exemplo de dados da Junk Dimension D_FORMA_STATUS_PAGAMENTO
Fonte: Elaborado pelo autor (2024)

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

5 ATIVIDADE NÃO AVALIATIVA

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams.

Você lidera o time de modelagem dimensional no projeto de Data Warehousing da Hamburgueria e diversas questões lhe foram apresentadas. Escolha a técnica de modelagem dimensional mais adequada para cada uma das questões levantadas. Justifique sua escolha:

1. Nossos pedidos têm como atributo o funcionário que atendeu ao cliente e o funcionário que entregou o pedido (motoboy). Entretanto, quando o produto é consumido na loja, o campo do motoboy está nulo.

A) Utilizar o código do motoboy como dimensão degenerada na tabela de fatos.

B) Popular a surrogate key do motoboy com nulos na tabela de fatos.

C) Combinar os dois tipos de funcionário do fato (atendente e motoboy) em uma junk dimension (dimensão bugiganga), fazendo um crossjoin entre todos os funcionários.

D) Utilizar um registro de categoria de exceção na dimensão e popular a tabela de fatos com sua surrogate key quando o código do motoboy for nulo na origem.

E) Utilizar um registro de categoria de exceção na tabela de fatos, sem necessidade de populá-lo na dimensão.

Justificativa:

_____

_____

_____

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2. Necessitamos construir painéis que comparem o período atual do ano ao mesmo período do ano passado, mostrando a variação de nossas vendas.

A) Criar as categorias de YTD e LYTD como dimensão degenerada na própria tabela de fatos.

B) Configurar as categorias de YTD e LYTD na ferramenta de visualização.

C) Utilizar uma cláusula “CASE WHEN” nas consultas, tratando as categorias de YTD e LYTD.

D) Criar as categorias de YTD e LYTD como atributos dos registros de data na dimensão Data e configurar uma regra de atualização no processo de ETL.

E) Criar as categorias YTD e LYTD como registros adicionais na dimensão data, de forma que não haverá necessidade de alterações no processo de ETL.

Justificativa:

_____

_____

_____

3. Temos de analisar nossas vendas por forma de pagamento, atributo que possui 5 categorias e status do pedido, com 3 categorias.

A) Criar os atributos descritivos de forma de pagamento e status do pedido como atributos de uma dimensão degenerada na tabela de fatos.

B) Criar flags da forma de pagamento e status do pedido como atributos de uma dimensão degenerada na tabela de fatos.

C) Combinar os atributos descritivos de forma de pagamento e status do pedido possíveis em uma dimensão bugiganga.

D) Criar duas dimensões independentes, uma para forma de pagamento e outra para o status do pedido.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

E) Criar duas dimensões independentes, uma para forma de pagamento e outra para o status do pedido.

Justificativa:

_____

_____

_____

4. Nossas vendas podem ser analisadas pela data do pedido e pela data da entrega.

A) Criamos uma dimensão data do pedido e uma dimensão data da entrega no modelo.

B) Criamos uma única dimensão data para todo o data warehouse, com diversos relacionamentos para as tabelas de fatos que possuírem mais datas.

C) Criamos duas datas (dimensões degeneradas) na tabela de fatos.

D) Criamos duas views da dimensão data relacionadas à tabela de fatos.

E) Para a data do pedido, que é a data mais importante, usamos uma SK relacionada à Dimensão Data, para a data da entrega, menos importante, usamos um atributo de data (dimensão degenerada) na tabela de fatos.

Justificativa:

_____

_____

_____

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com