FIAP ON

DATA INGESTION

CONECTIVIDADE ETL COM O SISTEMA HADOOP (SQOOP)

14

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 - Macro arquitetura Apache Sqoop 7
Figura 2 - Arquitetura função de importação do Apache Sqoop. 9
Figura 3 - Arquitetura função de exportação do Apache Sqoop. 10
Figura 4 - Arquitetura do Apache Sqoop 11
Figura 5 - Windows PowerShell 13
Figura 6 - Usuário e IP da máquina virtual no Oracle Cloud. 14
Figura 7 - Checando status do MySQL 16
Figura 8 - Acessando o MySQL. 16
Figura 9 - Select na tabela fornecedores. 18
Figura 10 - Checando versão do Java 19
Figura 11 - Checa o caminho do Java..... 19
Figura 12 - Adiciona o usuário hadoop..... 20
Figura 13 - Alteração do arquivo hadoop-env.sh..... 22
Figura 14 - Conteúdo do arquivo core-site.xml..... 23
Figura 15 - Conteúdo do arquivo mapred-site.xml 24
Figura 16 - Conteúdo do arquivo yarn-site.xml..... 24
Figura 17 - Iniciando o serviço do Hadoop 25
Figura 18 - Adicionando export Sqoop_home no arquivo bashrc..... 26
Figura 19 - Checando versão do Sqoop..... 26

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE TABELAS

Tabela 1 - Comparativo entre Apache Sqoop e Flume. 12

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 - Navegando até a pasta downloads..... 14
Código-fonte 2 - Conexão ssh com Ubuntu 14
Código-fonte 3 - Update nos pacotes do Ubuntu 15
Código-fonte 4 - Instalação do mysql. 15
Código-fonte 5 - Iniciando serviço do mysql..... 15
Código-fonte 6 - Checando o serviço do mysql..... 15
Código-fonte 7 - Acessando o mysql..... 16
Código-fonte 8 - Alterando senha do root no mysql. 16
Código-fonte 9 - Saindo do mysql. 17
Código-fonte 10 - Conectando no mysql com root. 17
Código-fonte 11 - Cria banco de dados fiapon. 17
Código-fonte 12 - Usa o banco de dados fiapon. 17
Código-fonte 13 - Script DDL para criação da tabela fornecedores. 17
Código-fonte 14- Insert na tabela fornecedores. 18
Código-fonte 15 - Insert na tabela fornecedores. 18
Código-fonte 16 - Insert na tabela fornecedores 18
Código-fonte 17 - Insert na tabela fornecedores 18
Código-fonte 18 - Insert na tabela fornecedores 18
Código-fonte 19 - Instalação do JDK 11..... 19
Código-fonte 20 - Identifica o diretório do JAVA_HOME..... 19
Código-fonte 21 - Cria o usuário hadoop 19
Código-fonte 22: Troca conexão do usuário Ubuntu para hadoop. 20
Código-fonte 23 -: Gera chave de conexão ssh para o usuário hadoop. 20
Código-fonte 24 - Copia a chave pública para authorized_keys. 20
Código-fonte 25 - Baixa os binários do Hadoop 3.3.6 21
Código-fonte 26 - Descompacta os binários do Hadoop 3.3.6. 21
Código-fonte 27 - Altera o arquivo bashrc..... 21
Código-fonte 28 - Atualiza o arquivo bashrc..... 22
Código-fonte 29 -: Altera o arquivo hadoop-env.sh. 22
Código-fonte 30 - Cria os diretórios do datanode e namenode..... 22
Código-fonte 31 - Altera o arquivo core-site.xml 22
Código-fonte 32 - Altera o arquivo hdfs-site.xml..... 23
Código-fonte 33 - Altera o arquivo mapred-site.xml 23
Código-fonte 34 - Altera o arquivo Yarn-site.xml..... 24
Código-fonte 35 - Apresenta configurações de namenode 24
Código-fonte 36 - Iniciando os serviços do Hadoop 25
Código-fonte 37 - Baixa os binários do Sqoop 25
Código-fonte 38 - Descompacta os binários do Sqoop 25
Código-fonte 39 - Adiciona o SQOOP_HOME ao Bashrc 25
Código-fonte 40 - Atualiza o arquivo Bashrc 26
Código-fonte 41 - Checa versão do Sqoop 26
Código-fonte 42 - Sqoop Import conectado ao mysql 26
Código-fonte 43 - Sqoop Import conectado ao mysql direcionando dados para diretório do HDFS..... 27
Código-fonte 44 - Sqoop Import conectado ao mysql com clausula where..... 27

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 CONECTIVIDADE ETL (EXTRACT – TRANSFORM – LOAD) COM O SISTEMA HADOOP (SQOOP).....6
1.1 Introdução.....6
2 FEATURES DO APACHE SQOOP.....8
2.1 Funcionamento do Sqoop.....10
3 ARQUITETURA APACHE SQOOP.....11
4 HANDS-ON.....13
4.1 Instalando MySQL.....15
4.2 Instalação do Hadoop.....19
4.3 Configuração do Hadoop.....22
4.4. Iniciando o Hadoop.....24
4.5. Instalação do Sqoop.....25
4.6. ETL MySQL e Sqoop.....26
REFERÊNCIAS.....28

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 CONECTIVIDADE ETL (EXTRACT – TRANSFORM – LOAD) COM O SISTEMA HADOOP (SQOOP)

1.1 Introdução

O Sqoop é uma ferramenta projetada para transferência entre bancos de dados relacionais, HDFS e mainframes. Os dados podem vir de bancos de dados como MySQL, Oracle, SQL Server, serem transferidos para o HDFS (Hadoop Distributed File System), processá-los usando Map Reduce e, em seguida, levá-los de volta ao banco de dados relacional ou outro banco que seja para utilização em modelos de machine learning, dashboard e afins.

Por se tratar de um mecanismo de Big Data, Sqoop também pode ser usado para transformações de dados em larga escala, se beneficiando do MapReduce antes de inserir em um banco de dados relacional. Neste material, vamos abordar como funciona o Sqoop, sua arquitetura, recursos, casos de uso e, é claro, um Hands-On.

Uma das perguntas que deve estar permeando a cabeça do leitor deste material é: por que preciso do Sqoop? O que torna o Sqoop uma ferramenta diferente do que temos em outras ferramentas para ETL é que o Sqoop foi feito para uma movimentação massiva de dados, extraindo dados de bancos de dados ou mainframes e gravando-os diretamente no HDFS como arquivos sequenciais ou arquivos formato AVRO.

Um fluxo de trabalho típico com Sqoop é onde os dados são enviados para o Hive para que tarefas intermediárias de processamento e transformação possam ser executadas no Apache Hadoop. Após a conclusão do processamento, os dados podem ser exportados de volta para o banco de dados relacional.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

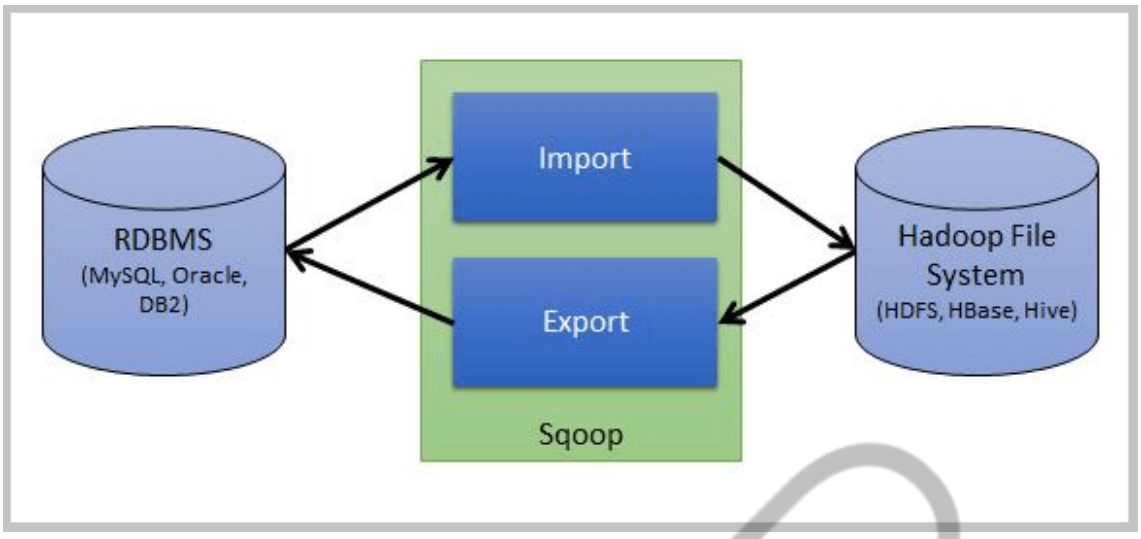

Figura 1 - Macro arquitetura Apache Sqoop
Fonte: https://www.guru99.com/introduction-to-flume-and-sqoop.html

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 FEATURES DO APACHE SQOOP

Importação e exportação paralela – Essa é a ferramenta Sqoop Big Data e usa a estrutura do Yarn para importar e exportar dados. O Sqoop trabalha sua tolerância a falhas com paralelismo.

Importar resultados de queries SQL – O Sqoop nos permite importar os dados resultantes de uma query escrita em linguagem SQL para HDFS.

Conectores para os principais bancos de dados relacionais de mercado – O Sqoop possui diversos conectores nativos para conexão com os mais populares bancos de dados de mercado.

Cargas Full e Incrementais – Com Sqoop, temos as opções de carregar desde tabelas inteiras e dados resultantes de queries a estratégias de cargas full e incrementais.

Importação Sqoop – O Sqoop importa todas as tabelas do banco de dados relacional para o HDFS. Cada registro de uma tabela é tratado como um registro no HDFS. Todos os registros são então salvos como formato texto delimitado (CSV) ou como dados binários em arquivos Avro ou Sequencial.

Abaixo, temos um exemplo de arquitetura do componente de importação do Sqoop. Nesse exemplo, no passo 1, os dados são recebidos do banco de dados relacional ou DW. No segundo passo, o Sqoop cria a classe Produtos. No terceiro e último passo, a função Map é executada para inserir os dados da classe produtos em arquivos de dados e os registros são separados em grupos de registros em arquivos separados.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

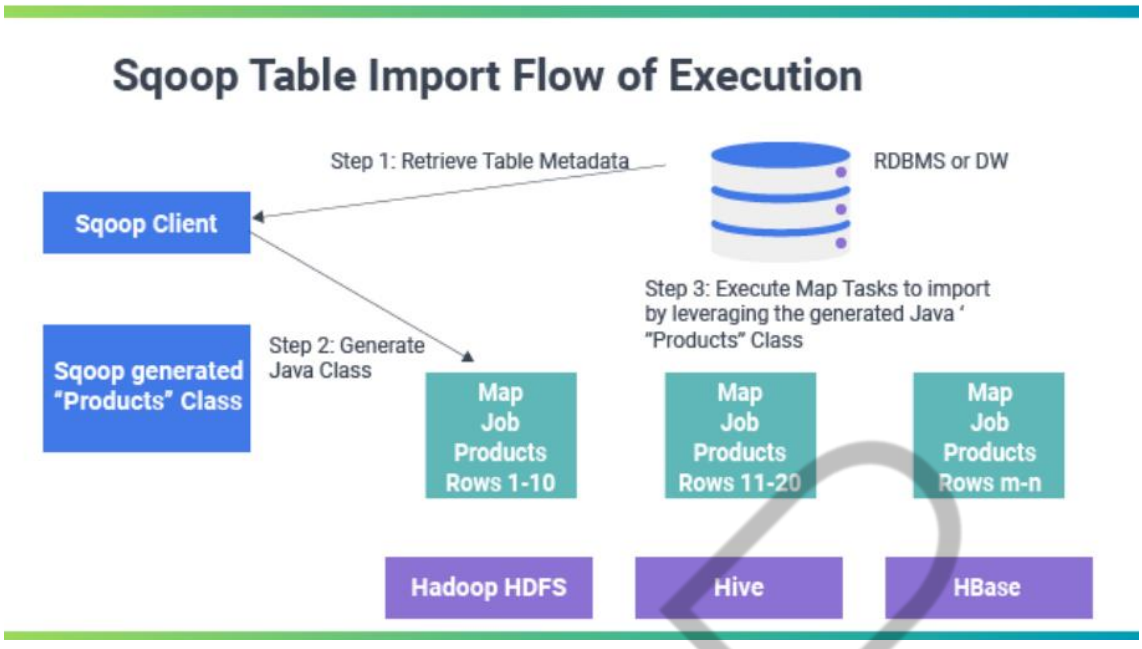

Figura 2 - Arquitetura função de importação do Apache Sqoop.
Fonte: https://www.guru99.com/introduction-to-flume-and-sqoop.html

Exportação Sqoop – O Sqoop exporta arquivos de dados do HDFS de volta para o banco de dados relacional, os dados são lidos do HDFS e esses registros são separados por um delimitador especificado pelo próprio usuário, como por exemplo, separado por ponto e vírgula (;).

Dois processos estão envolvidos na exportação de dados: o primeiro é pesquisar metadados no banco de dados e o segundo é mover os dados.

Abaixo, temos um exemplo de arquitetura da tarefa de exportação do Sqoop, onde o job do Sqoop é acionado e captura os dados do Hadoop e envia ao banco de dados Oracle.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

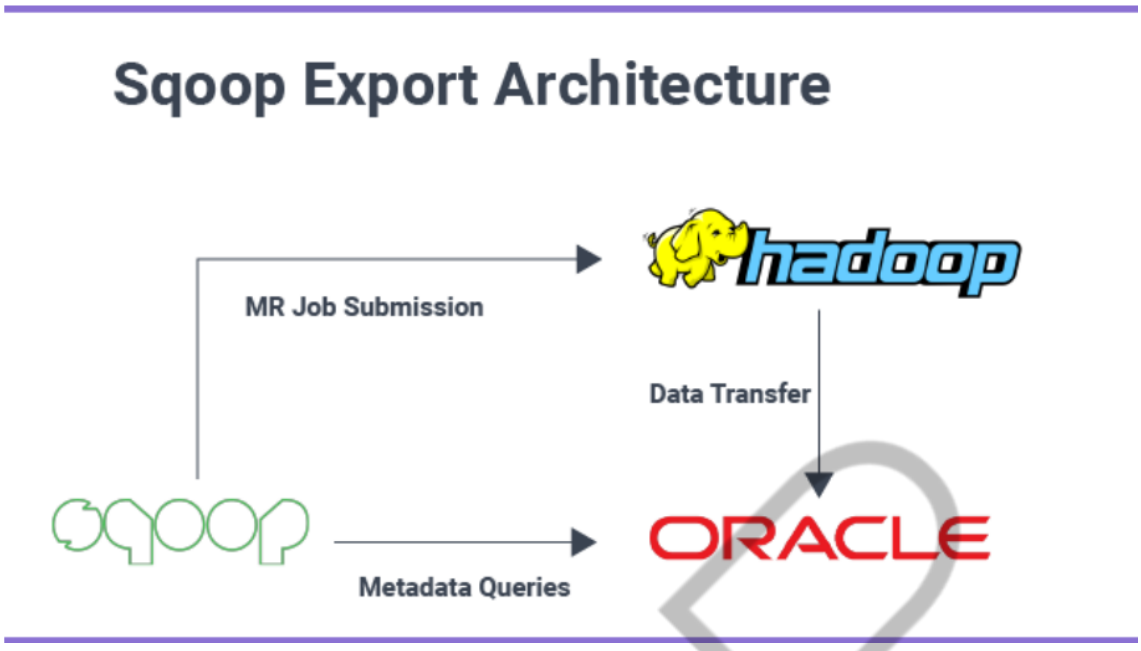

Figura 3 - Arquitetura função de exportação do Apache Sqoop.
Fonte: https://www.guru99.com/introduction-to-flume-and-sqoop.html

2.1 Funcionamento do Sqoop

O Sqoop executa comandos do usuário por meio de uma interface de linha de comando. Os conectores auxiliam na transferência de dados de qualquer fonte de dados externa para o HDFS. Os conectores também isolam as tabelas de produção no caso de alguma corrupção de dados por alguma falha no Job. A tarefa MAP preenche as tabelas e mescla com a tabela de destino para transmissão dos dados.

Nesse ponto, podemos usar conectores especializados e otimizados para sistemas externos, o que traz ganho de desempenho nos eventos de importação e exportação.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3 ARQUITETURA APACHE SQOOP

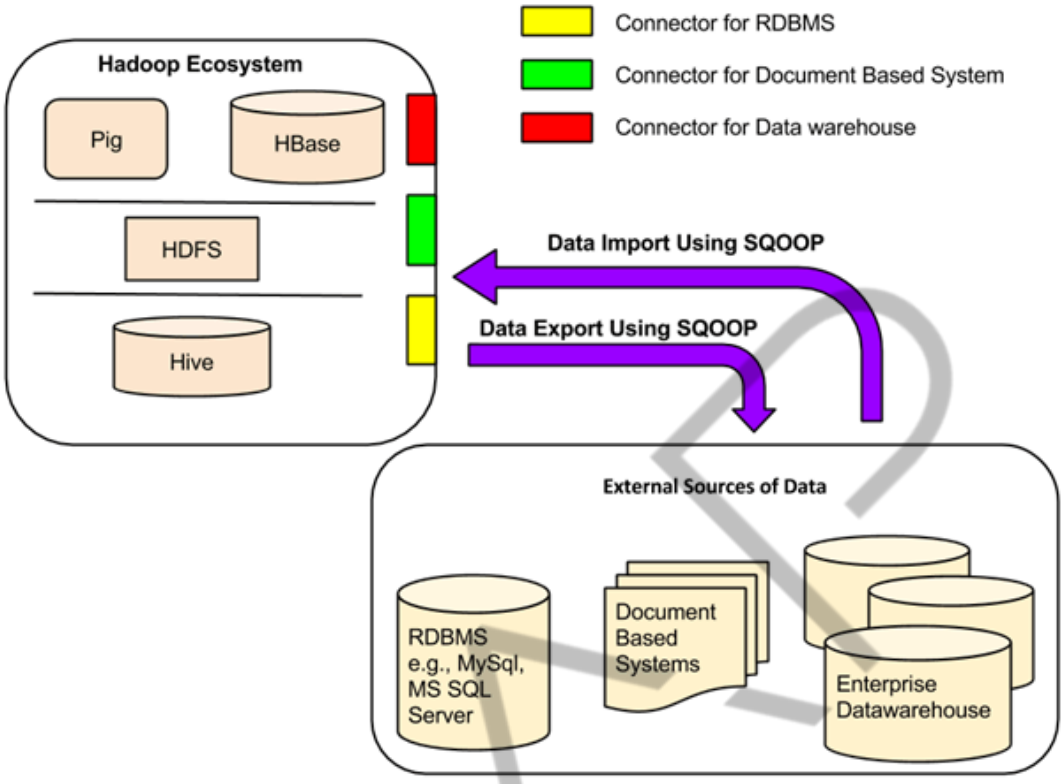

Figura 4 - Arquitetura do Apache Sqoop
Fonte: https://www.guru99.com/introduction-to-flume-and-sqoop.html

Como já foi dito, o Sqoop traz uma facilidade na migração de dados entre Hadoop e bancos de dados relacionais por meio de conectores nativos como MySQL, PostgreSQL, Oracle, SQL Server e DB2, além de permitir a conexão por conectores JDBC com outras fontes de dados que permitam essa conexão via JDBC. Além disso, o Sqoop oferece conectores especializados otimizados para PostgreSQL e MySQL, aproveitando APIs específicas de banco de dados para melhorar o desempenho.

Temos também conectores de terceiros que podem se conectar com bancos de dados NoSQL, Data Warehouses, Neteza, Teradata, Couchbase etc. Mas para usar esses conectores, é preciso baixá-los separadamente e integrá-los à sua instalação do Sqoop, pois eles não estão incluídos no pacote Sqoop padrão.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

O funcionamento do Sqoop em back-end é bastante simples. O conjunto de dados de entrada é dividido em várias partições e uma tarefa de MAP é criada com mapeadores distintos encarregados de transferir cada partição de dados. O Sqoop usa as informações do banco de dados de origem para identificar o data type de cada dado manipulando cada registro de dados de maneira segura.

Para muitos de vocês, pode ter vindo à mente o seguinte questionamento: por que usar Sqoop uma vez que temos o Apache Flume, que também faz parte do ecossistema do Hadoop? Vale ressaltar que apesar de ambas serem ferramentas de ingestão de dados, existem propósitos diferentes. Veja a tabela comparativa abaixo:

Apache Sqoop	Apache Flume
Usado para importação e exportação de dados estruturados entre bancos de dados relacionais, mainframes e o HDFS.	Usado para ingestão de dados STREAMING para o HDFS.
Sqoop possui uma arquitetura baseada em conectores. Os conectores sabem como se conectar à respectiva fonte de dados e buscar os dados.	O Flume possui uma arquitetura baseada em agentes. Nesse caso, é escrito um código que cria um agente com as especificações do que ele deve buscar acerca dos dados.
HDFS é o destino dos dados por meio das importações via conectores.	HDFS é o destino dos dados por meio de um ou mais canais.
Carga de dados do Sqoop não é orientada a eventos, mas sim por demanda (batch).	A carga de dados do Flume é orientada por eventos (stream).
Sqoop lida melhor com dados estruturados, seus conectores de bancos de dados relacionais sabem como interagir e capturar os dados dessas origens de dados.	Flume lida bem com dados provenientes de eventos, como postagens em redes sociais, logs e afins. Os agentes do Flume lidam bem com esse tipo de dado e comportamento.

Tabela 1 - Comparativo entre Apache Sqoop e Flume.
Fonte: https://www.guru99.com/introduction-to-flume-and-sqoop.html

Ambas as ferramentas oferecem um grande potencial e flexibilidade para trabalhar, o que vai nos direcionar de fato será o escopo e as necessidades do projeto que uma ferramenta deverá atender de forma mais adequada que outra.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

4 HANDS-ON

Vamos iniciar nosso hands-on, não deixe de consultar o How to VM linux, onde é demonstrado como criar uma máquina virtual com ubuntu que usaremos neste material. Para aqueles que tem uma máquina virtual ou utilizam ubuntu versão 20+, podem seguir com a sua própria.

Começaremos conectando a máquina virtual usando ssh, ou seja, uma conexão remota na máquina linux a partir da nossa máquina Windows. Para fazer isso, vá no ícone de pesquisa do seu windows e digite powershell, aparecerão algumas opções, a correta é windows powershell.

A tela a seguir será apresentada.

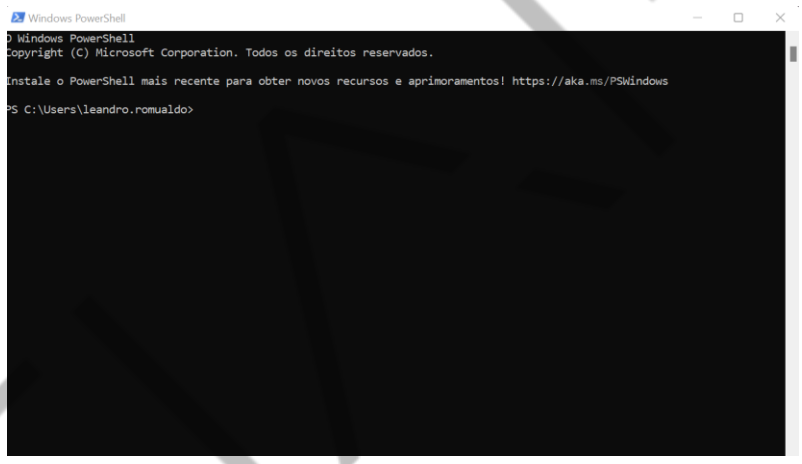

Figura 5 - Windows PowerShell
Fonte: Elaborado pelo autor

Ao criar a máquina virtual, criamos um arquivo ssh-key para conexão remota na máquina Linux. O meu arquivo está salvo na pasta downloads do meu Windows, portanto, vou navegar até essa pasta. Para quem está com Linux na máquina física, pode pular essa parte e ir para o código 3; para quem possui uma máquina virtual com Ubuntu, conecte-se nela da forma como costuma conectar-se via ssh.

Para chegar à pasta downloads, eu digitei o comando abaixo:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
cd downloads
```

Código-fonte 1 - Navegando até a pasta downloads
Fonte: Elaborado pelo autor

Dentro da pasta downloads, vamos digitar o código abaixo para conectar a nossa máquina com ubuntu. ssh é o comando para conexão, passamos o arquivo ssh-key que foi gerado na criação da máquina virtual; o usuário, no meu caso, é ubuntu@. Você deve mudar o ip da máquina e colocar o da sua, colocar o nome do seu arquivo, mudar o nome do usuário e colocar o que você criou.

Para localizar o ip e o usuário que você definiu, abra as instâncias de computação da oracle cloud e clique na sua máquina. Aparecerá a tela a seguir, onde pode ser localizado o ip e usuário.

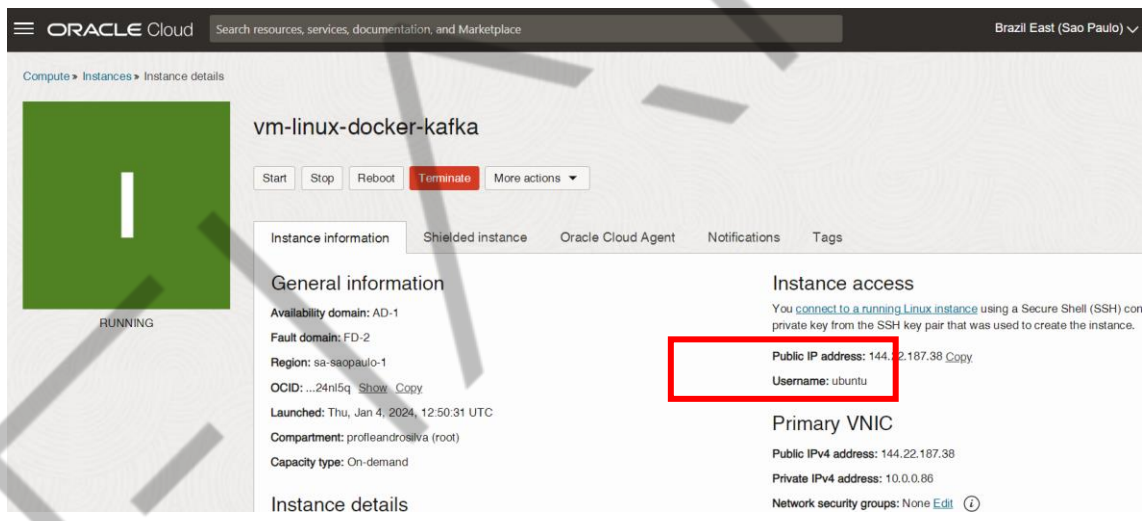

Figura 6 - Usuário e IP da máquina virtual no Oracle Cloud.
Fonte: Elaborado pelo autor.

```
ssh -i .\ssh-key-2024-01-04.key ubuntu@144.22.187.38
```

Código-fonte 2 - Conexão ssh com Ubuntu
Fonte: Elaborado pelo autor.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

4.1 Instalando MySQL

Conectado a máquina virtual, vamos rodar um apt get update para atualizar os pacotes do Linux.

```
sudo apt get update
```

Código-fonte 3 - Update nos pacotes do Ubuntu
Fonte: Elaborado pelo autor

Vamos começar instalando o mysql. Para isso, basta rodar o código abaixo.

```
sudo apt install mysql-server
```

Código-fonte 4 - Instalação do mysql.
Fonte: Elaborado pelo autor

Após a instalação do mysql, vamos iniciar o serviço do mysql com o comando abaixo.

```
sudo systemctl start mysql.service
```

Código-fonte 5 - Iniciando serviço do mysql.
Fonte: Elaborado pelo autor

Agora vamos checar se o serviço está ativo A saída deve ser igual a apresentada na Figura 7.

```
sudo systemctl status mysql.service
```

Código-fonte 6 - Checando o serviço do mysql
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
ubuntu@vm-linux-docker-kafka:~$ sudo systemctl status mysql.service
● mysql.service - MySQL Community Server
     Loaded: loaded (/lib/systemd/system/mysql.service; enabled; vendor preset: enabled)
     Active: active (running) since Tue 2024-01-16 17:56:34 UTC; 40s ago
    Process: 4564 ExecStartPre=/usr/share/mysql/mysql-systemd-start pre (code=exited, status=0/SUCCESS)
   Main PID: 4572 (mysqld)
     Status: "Server is operational"
      Tasks: 38 (limit: 9430)
     Memory: 365.7M
        CPU: 1.027s
     CGroup: /system.slice/mysql.service
             └─4572 /usr/sbin/mysqld

Jan 16 17:56:33 vm-linux-docker-kafka systemd[1]: Starting MySQL Community Server...
Jan 16 17:56:34 vm-linux-docker-kafka systemd[1]: Started MySQL Community Server.
```

Figura 7 - Checando status do MySQL
Fonte: Elaborado pelo autor

Agora vamos acessar o mysql com o comando abaixo.

```
sudo mysql
```

Código-fonte 7 - Acessando o mysql.
Fonte: Elaborado pelo autor

Notem que mudamos o nome da máquina e usuário no canto do terminal para o nome mysql; estamos dentro do mysql agora.

```
ubuntu@vm-linux-docker-kafka:~$ sudo mysql
Welcome to the MySQL monitor.  Commands end with ; or \g.
Your MySQL connection id is 8
Server version: 8.0.35-0ubuntu0.22.04.1 (Ubuntu)

Copyright (c) 2000, 2023, Oracle and/or its affiliates.

Oracle is a registered trademark of Oracle Corporation and/or its
affiliates. Other names may be trademarks of their respective
owners.

Type 'help;' or '\h' for help. Type '\c' to clear the current input statement.

mysql>
```

Figura 8 - Acessando o MySQL.
Fonte: Elaborado pelo autor.

Com o comando abaixo, mudamos a senha de acesso ao mysql pelo usuário root.

```
ALTER USER 'root'@'localhost' IDENTIFIED WITH mysql_native_password BY 'password';
```

Código-fonte 8 - Alterando senha do root no mysql.
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Agora vamos sair do mysql para testar o acesso pelo usuário root

```
exit
```

Código-fonte 9 - Saindo do mysql.
Fonte: Elaborado pelo autor

Vamos nos conectar ao mysql novamente com root.

```
mysql -u root –p
```

Código-fonte 10 - Conectando no mysql com root.
Fonte: Elaborado pelo autor

Vamos criar nosso banco de dados chamado fiapon com o script abaixo.

```
create database fiapon;
```

Código-fonte 11 - Cria banco de dados fiapon.
Fonte: Elaborado pelo autor

Vamos começar a usar o banco de dados fiapon com o comando abaixo.

```
use fiapon;
```

Código-fonte 12 - Usa o banco de dados fiapon.
Fonte: Elaborado pelo autor

Agora criaremos nossa tabela de fornecedores com o script sql abaixo.

```
CREATE TABLE FORNECEDORES(
        -> CODIGO INT(4) AUTO_INCREMENT,

        -> NOME VARCHAR(30) NOT NULL,
        -> EMAIL VARCHAR(50)
        -> PRIMARY KEY (CODIGO)
        -> );
```

Código-fonte 13 - Script DDL para criação da tabela fornecedores.
Fonte: Elaborado pelo autor

Com a tabela criada, vamos inserir alguns registros com os scripts sql abaixo:

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
INSERT INTO fornecedores(codigo, nome, email) VALUES (null, "XPTO Empreendimentos",
"contratos@xpto.com.br");
```

Código-fonte 14- Insert na tabela fornecedores.
Fonte: Elaborado pelo autor

```
INSERT INTO fornecedores(codigo, nome, email) VALUES (null, "OKR Consulting",
"faleconosco@okr.com.br");
```

Código-fonte 15 - Insert na tabela fornecedores.
Fonte: Elaborado pelo autor

```
INSERT INTO fornecedores(codigo, nome, email) VALUES (null, "Fast Supplier",
"financeiro@fadstsupplier.com.br");
```

Código-fonte 16 - Insert na tabela fornecedores
Fonte: Elaborado pelo autor

```
INSERT INTO fornecedores(codigo, nome, email) VALUES (null, "D&D Advogados associados",
"atendimento@d&d.com.br");
```

Código-fonte 17 - Insert na tabela fornecedores
Fonte: Elaborado pelo autor

```
INSERT INTO fornecedores(codigo, nome, email) VALUES (null, "World Center Associates",
"financeiro@WCA.com.br");
```

Código-fonte 18 - Insert na tabela fornecedores
Fonte: Elaborado pelo autor

Ao término dos inserts, vamos rodar um select * from fornecedores; o resultado deve ser igual ao apresentado abaixo.

```
mysql> select * from fornecedores;
+--------+--------------------------+--------------------------------+
| codigo | nome                     | email                          |
+--------+--------------------------+--------------------------------+
|      1 | XPTO Empreendimentos     | contratos@xpto.com.br          |
|      2 | OKR Consulting           | faleconosco@okr.com.br         |
|      3 | Fast Supplier            | financeiro@fadstsupplier.com.br |
|      4 | D&D Advogados associados | atendimento@d&d.com.br         |
|      5 | World Center Associates  | financeiro@WCA.com.br          |
+--------+--------------------------+--------------------------------+
5 rows in set (0.00 sec)
```

Figura 9 - Select na tabela fornecedores.
Fonte: Elaborado pelo autor.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

4.2 Instalação do Hadoop

Agora temos nosso mysql instalado e populado com uma tabela e 4 registros. Vamos instalar o Hadoop e Sqoop para movimentar esses dados.

Nosso primeiro passo é a instalação do jdk11 com o comando abaixo.

```
sudo apt update && sudo apt install openjdk-11-jdk
```

Código-fonte 19 - Instalação do JDK 11
Fonte: Elaborado pelo autor

Ao término da instalação, vamos executar um java –version e a saída deve ser como a da figura abaixo.

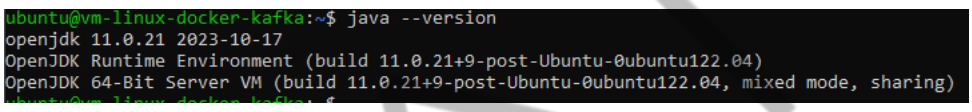

Figura 10 - Checando versão do Java
Fonte: Elaborado pelo autor.

Execute o comando abaixo para identificar o caminho que está o diretório do JAVA_HOME; guarde a saída desse comando, pois usaremos mais adiante.

```
dirname $(dirname $(readlink -f $(which java)))
```

Código-fonte 20 - Identifica o diretório do JAVA_HOME
Fonte: Elaborado pelo autor

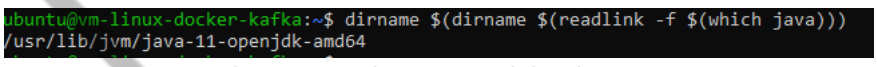

Figura 11 - Checa o caminho do Java
Fonte: Elaborado pelo autor

Agora vamos criar um usuário Hadoop para usarmos no Hadoop.

```
sudo adduser Hadoop
```

Código-fonte 21 - Cria o usuário hadoop
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Serão pedidas algumas informações como e-mail, telefone e afins, não precisam ser preenchidas, somente a senha, que é a primeira solicitada.

```
ubuntu@vm-linux-docker-kafka:~$ sudo adduser hadoop
Adding user `hadoop' ...
Adding new group `hadoop' (1003) ...
Adding new user `hadoop' (1003) with group `hadoop' ...
Creating home directory `/home/hadoop' ...
Copying files from `/etc/skel' ...
New password:
Retype new password:
passwd: password updated successfully
Changing the user information for hadoop
Enter the new value, or press ENTER for the default
        Full Name []: hadoop
        Room Number []:
        Work Phone []:
        Home Phone []:
        Other []:
Is the information correct? [Y/n] y
ubuntu@vm-linux-docker-kafka:~$
```

Figura 12 - Adiciona o usuário hadoop
Fonte: Elaborado pelo autor

Agora vamos trocar a conexão do usuário Ubuntu para o usuário Hadoop.

```
su – Hadoop
```

Código-fonte 22: Troca conexão do usuário Ubuntu para hadoop.
Fonte: Elaborado pelo autor

Vamos criar uma chave de conexão ssh para o usuário Hadoop.

```
ssh-keygen-t rsa
```

Código-fonte 23 -: Gera chave de conexão ssh para o usuário hadoop.
Fonte: Elaborado pelo autor

Vamos copiar a chave pública de conexão ssh do usuário Hadoop para o arquivo de chaves autorizadas e mudarmos as permissões do arquivo para permitir a leitura dele.

```
Cat ~/.ssh/id_rsa.pub >> ~/.ssh/authorized_keys
chmod 640 ~/.ssh/authorized_keys
```

Código-fonte 24 - Copia a chave pública para authorized_keys.
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Vamos baixar os binários do Hadoop 3.3.6 por meio do comando wget abaixo.

```
wget https://dlcdn.apache.org/hadoop/common/hadoop-3.3.6/hadoop-3.3.6.tar.gz
```

Código-fonte 25 - Baixa os binários do Hadoop 3.3.6
Fonte: Elaborado pelo autor

Finalizado o download, vamos descompactar o arquivo, conforme código abaixo.

```
tar xzf hadoop-3.3.6.tar.gz
```

Código-fonte 26 - Descompacta os binários do Hadoop 3.3.6.
Fonte: Elaborado pelo autor

Agora vamos configurar o Hadoop. O primeiro passo é definir algumas variáveis de ambiente no arquivo bashrc; utilize o comando abaixo para acessá-lo e após isso, digite a tecla i para editar.

```
vim ~/.bashrc
```

Código-fonte 27 - Altera o arquivo bashrc
Fonte: Elaborado pelo autor

Adicione o texto abaixo no final do arquivo.

```
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
export HADOOP_HOME=/home/hadoop/hadoop
export HADOOP_INSTALL=$HADOOP_HOME
export HADOOP_MAPRED_HOME=$HADOOP_HOME
export HADOOP_COMMON_HOME=$HADOOP_HOME
export HADOOP_HDFS_HOME=$HADOOP_HOME
export HADOOP_YARN_HOME=$HADOOP_HOME
export HADOOP_COMMON_LIB_NATIVE_DIR=$HADOOP_HOME/lib/native
export PATH=$PATH:$HADOOP_HOME/sbin:$HADOOP_HOME/binexport
HADOOP_OPTS="-Djava.library.path=$HADOOP_HOME/lib/native"
```

Ao término, digite ***:wq*** e ***enter*** para sair do arquivo salvando as alterações feitas.

Ao sair do arquivo, retornaremos ao terminal do usuário hadoop, execute o source bashrc conforme abaixo para atualizar a leitura do arquivo.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
source ~/.bashrc
```

Código-fonte 28 - Atualiza o arquivo bashrc
Fonte: Elaborado pelo autor

Agora vamos alterar outro arquivo adicionando o caminho do nosso java jdk que guardamos alguns passos atrás.

```
vim $HADOOP_HOME/etc/hadoop/hadoop-env.sh
```

Código-fonte 29 -: Altera o arquivo hadoop-env.sh.
Fonte: Elaborado pelo autor

Ao acessar o arquivo, digite i para alterar o arquivo e localize a linha com o export JAVA_HOME e altere o caminho para o caminho que você salvou alguns passos anteriores.

```
export JAVA_HOME=/usr/lib/jvm/java-11-openjdk-amd64
```

Figura 13 - Alteração do arquivo hadoop-env.sh.
Fonte: Elaborado pelo autor

4.3 Configuração do Hadoop

Vamos começar a configurar nossos named nodes e datanodes do hadoop criando os diretórios para cada um.

```
mkdir -p ~/hadoopdata/hdfs/{namenode,datanode}
```

Código-fonte 30 - Cria os diretórios do datanode e namenode
Fonte: Elaborado pelo autor

Vamos alterar o arquivo core-site.xml com o comando abaixo.

```
vim $HADOOP_HOME/etc/hadoop/core-site.xml
```

Código-fonte 31 - Altera o arquivo core-site.xml
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Adicione este texto dentro do arquivo e salve com :wq e enter.

```
<PROPERTY>
        <NAME>FS.DEFAULTFS</NAME>
                <VALUE>HDFS://LOCALHOST:9000</VALUE>
</PROPERTY>
```

```
<configuration>
        <property>
                <name>fs.fiapFS</name>
                <value>hdfs://localhost:9000</value>
        </property>
</configuration>
```

Figura 14 - Conteúdo do arquivo core-site.xml

Fonte: Elaborado pelo autor

Vamos alterar o arquivo hdfs-site.xml e adicionar o conteúdo abaixo.

```
vim $HADOOP_HOME/etc/hadoop/hdfs-site.xml
```

Código-fonte 32 - Altera o arquivo hdfs-site.xml
Fonte: Elaborado pelo autor

```
<CONFIGURATION>
        <PROPERTY>
                <NAME>DFS.REPLICATION</NAME>
                <VALUE>1</VALUE>
        </PROPERTY>
        <PROPERTY>
                <NAME>DFS.NAME.DIR</NAME>
                <VALUE>FILE:///HOME/HADOOP/HADOOPDATA/HDFS/NAMENODE</VALUE
        </PROPERTY>
        <PROPERTY>
                <NAME>DFS.DATA.DIR</NAME>
                <VALUE>FILE:///HOME/HADOOP/HADOOPDATA/HDFS/DATANODE</VALUE
        </PROPERTY>
</CONFIGURATION>
```

Também vamos alterar o arquivo de configuração do mapreduce, conforme abaixo.

```
vim $HADOOP_HOME/etc/hadoop/mapred-site.xml
```

Código-fonte 33 - Altera o arquivo mapred-site.xml
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
<CONFIGURATION
        <PROPERTY>
                <NAME>MAPREDUCE.FRAMEWORK.NAME</NAME>
                <VALUE>YARN</VALUE
        </PROPERTY>
</CONFIGURATION>
```

```
<configuration>
        <property>
                <name>mapreduce.framework.name</name>
                <value>yarn</value>
        </property>
</configuration>
```

Figura 15 - Conteúdo do arquivo mapred-site.xml
Fonte: Elaborado pelo autor

Agora alteramos o nosso arquivo de configuração do yarn.

```
vim $HADOOP_HOME/etc/hadoop/yarn-site.xml
```

Código-fonte 34 - Altera o arquivo Yarn-site.xml
Fonte: Elaborado pelo autor

```
<CONFIGURATION>
        <PROPERTY>
                <NAME>YARN.NODEMANAGER.AUX-SERVICES</NAME>
                <VALUE>MAPREDUCE_SHUFFLE</VALUE>
        </PROPERTY>
</CONFIGURATION>
```

```
<configuration>
    <property>
        <name>yarn.nodemanager.aux-services</name>
        <value>mapreduce_shuffle</value>
    </property>
</configuration>
```

Figura 16 - Conteúdo do arquivo yarn-site.xml
Fonte: Elaborado pelo autor

4.4. Iniciando o Hadoop

Com o hadoop instalado e configurado, é hora de iniciar os serviços do hadoop com o comando abaixo.

```
hdfs namenode –format
```

Código-fonte 35 - Apresenta configurações de namenode
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Com o start-all.sh, iniciamos o hadoop e estamos prontos para instalar e configurar nosso Sqoop.

```
start-all.sh
```

Código-fonte 36 - Iniciando os serviços do Hadoop
Fonte: Elaborado pelo autor

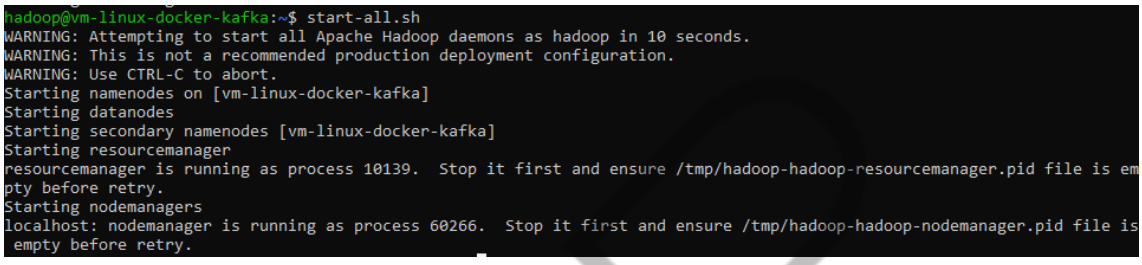

Figura 17 - Iniciando o serviço do Hadoop
Fonte: Elaborado pelo autor

4.5. Instalação do Sqoop

Para instalação do Sqoop conectado com o usuário hadoop, vamos baixar os binários do Sqoop com comando wget abaixo.

```
wget https://archive.apache.org/dist/sqoop/1.4.7/sqoop-1.4.7.bin__hadoop-2.6.0.tar.gz
```

Código-fonte 37 - Baixa os binários do Sqoop
Fonte: Elaborado pelo autor

Com o arquivo baixado, vamos descompactar o arquivo.

```
tar -xvzf sqoop-1.4.7.bin__hadoop-2.6.0.tar.gz
```

Código-fonte 38 - Descompacta os binários do Sqoop
Fonte: Elaborado pelo autor

Vamos alterar novamente o arquivo bashrc e adicionar o caminho do SQOOP_HOME e PATH conforme imagem abaixo.

```
vim .bashrc
```

Código-fonte 39 - Adiciona o SQOOP_HOME ao Bashrc
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Adicione o caminho dos binários do seu Sqoop.

```
export SQOOP_HOME="/home/hadoop/sqoop-1.4.7.bin__hadoop-2.6.0"
export PATH=$PATH:$SQOOP_HOME/bin
```

Figura 18 - Adicionando export Sqoop_home no arquivo bashrc
Fonte: Elaborado pelo autor

Atualize o arquivo bashrc com o comando abaixo.

```
source ~/.bashrc
```

Código-fonte 40 - Atualiza o arquivo Bashrc
Fonte: Elaborado pelo autor

Podemos checar a versão do Sqoop com o comando abaixo.

```
sqoop version
```

Código-fonte 41 - Checa versão do Sqoop
Fonte: Elaborado pelo autor

```
hadoop@vm-linux-docker-kafka:~$ sqoop version
Warning: /home/hadoop/sqoop-1.4.7.bin__hadoop-2.6.0/../hbase does not exist! HBase imports will fail.
Please set $HBASE_HOME to the root of your HBase installation.
Warning: /home/hadoop/sqoop-1.4.7.bin__hadoop-2.6.0/../hcatalog does not exist! HCatalog jobs will fail.
Please set $HCAT_HOME to the root of your HCatalog installation.
Warning: /home/hadoop/sqoop-1.4.7.bin__hadoop-2.6.0/../accumulo does not exist! Accumulo imports will fail.
Please set $ACCUMULO_HOME to the root of your Accumulo installation.
Warning: /home/hadoop/sqoop-1.4.7.bin__hadoop-2.6.0/../zookeeper does not exist! Accumulo imports will fail.
Please set $ZOOKEEPER_HOME to the root of your Zookeeper installation.
2024-01-18 15:11:54,906 INFO sqoop.Sqoop: Running Sqoop version: 1.4.7
Sqoop 1.4.7
git commit id 2328971411f57f0cb683dfb79d19d4d19d185dd8
Compiled by maugli on Thu Dec 21 15:59:58 STD 2017
hadoop@vm-linux-docker-kafka:~$
```

Figura 19 - Checando versão do Sqoop
Fonte: Elaborado pelo autor

4.6. ETL MySQL e Sqoop

Com o Sqoop instalado e configurado, podemos fazer o ETL dos dados do mysql para o HDFS com o Sqoop import. Veja um exemplo simples onde conectamos no mysql via jdbc, passamos o banco de dados fiapon, o usuário e qual tabela faremos o etl. Nesse caso, a tabela fornecedores.

```
sqoop import --connect jdbc:mysql://localhost/fiapon --username root --table fornecedores
```

Código-fonte 42 - Sqoop Import conectado ao mysql
Fonte: Elaborado pelo autor

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Podemos mudar o script passando um local específico para os resultados serem salvos no HDFS com o parâmetro target-dir

```
sqoop import --connect jdbc:mysql://localhost/fiapon --username mysql --table fornecedores -
-m 1 --target-dir /fornecedores
```

Código-fonte 43 - Sqoop Import conectado ao mysql direcionando dados para diretório do HDFS
Fonte: Elaborado pelo autor

E também aplicar filtros na tabela origem antes de salvar em um diretório específico do HDFS.

```
hadoop@vm-linux-docker-kafka:~$ sqoop import --connect jdbc:mysql://localhost/fiapon --
username mysql --table fornecedores --m 3 --where "codigo > 4" --target-dir /forneced

ores_filtrado
```

Código-fonte 44 - Sqoop Import conectado ao mysql com clausula where
Fonte: Elaborado pelo autor

Neste hands-on, passamos por bastante coisas, instalamos uma máquina virtual com Ubuntu na Oracle Cloud, acessamos ela via SSH, instalamos o MySQL, criamos e populamos uma tabela, instalamos e configuramos o Hadoop, Sqoop, fizemos uma carga de dados do MySQL Local para o HDFS usando o Sqoop.

A partir desses scripts de ETL do Sqoop, podem ser criados Jobs para executar a carga de dados com recorrência e podem ser muito mais complexos dependendo dos dados a serem movimentados.

Espero que tenham gostado do nosso material, até a próxima.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

APACHE Sqoop Docs; **Apache ORG**, 2023. Disponível em: <https://sqoop.apache.org/docs/1.4.6/SqoopUserGuide.html#_introduction>. Acesso em: 12 jan. 2024.

APACHE Sqoop **Tutorial – Import/Export Data Between HDFS and RDBMS. 2023**; Disponível em: <https://www.edureka.co/blog/apache-sqoop-tutorial/>. Acesso em: 21 jan.2024.

HOW to InstallMySQL on Ubuntu 22.04. **Digital Ocean**, 2022. Disponível em: <https://www.digitalocean.com/community/tutorials/how-to-install-mysql-on-ubuntu-22-04>. Acesso em: 16 jan. 2024.

INSTALLING Apache Sqoop on Ubuntu. **Projects Based Learning**, 2022. Disponível em: <https://projectsbasedlearning.com/bigdata-hadoop/installing-apache-sqoop-on-ubuntu/>. Acesso em: 21 jan. 2024.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com