FIAP ON

DATA INGESTION

ARMAZENAMENTO DE DADOS PARA SERVIDORES E ESCALABILIDADE

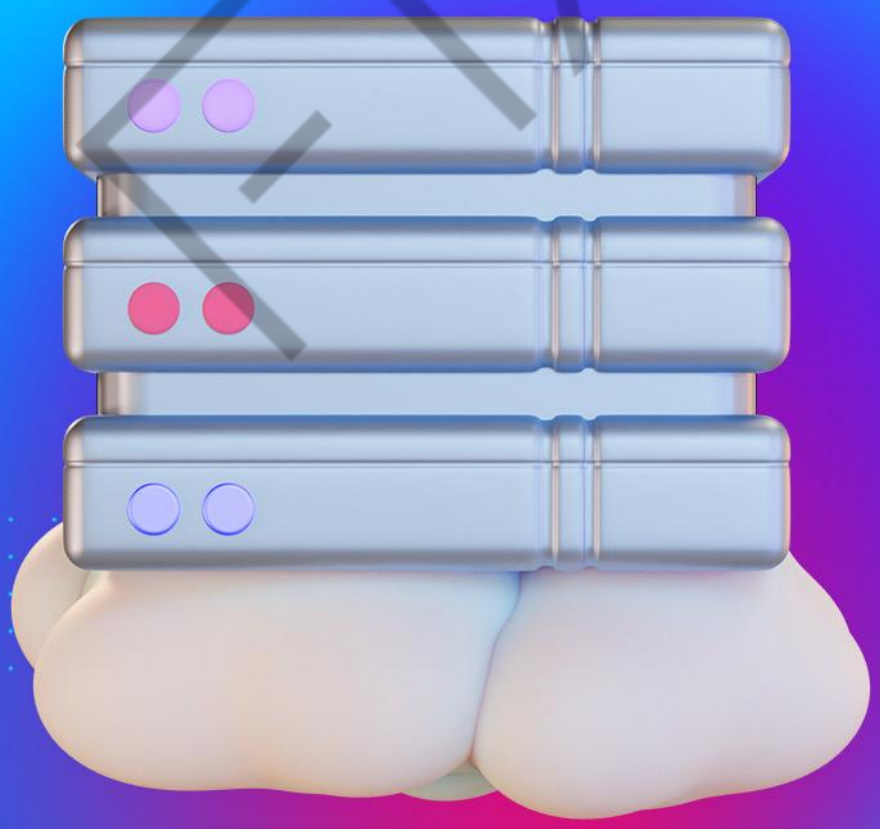

15

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1: RAID 0 11
Figura 2: RAID 1 13
Figura 3 - RAID 5 14
Figura 4 - RAID 6 16
Figura 5 - RAID 10 18
Figura 6: RAID 50: 20
Figura 7: RAID 60 21
Figura 8: Tipos de storage 23

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE TABELAS

Tabela 1: Comparativo DAS, NAS e SAN: 26

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 Armazenamento de dados para servidores e escalabilidade.....5
2 O que é um dado e como é armazenado.....6
3 Hard disk.....7
4 Segurança dos discos.....9
5 Storage.....22
Conclusão.....26
Referências…….28

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 ARMAZENAMENTO DE DADOS PARA SERVIDORES E ESCALABILIDADE

Em um projeto de dados, seja ele na modelagem de um banco de dados, que vai atender um novo sistema na empresa, um Data Warehouse, um pipeline de dados para um modelo de Machine Learning, ou até mesmo para o treinamento de um modelo de Deep Learning, pensamos em armazenamento de dados.

Isso, porque sem o armazenamento adequado, perdemos performance e isso pode ocasionar um tempo inaceitável para finalizar uma transação em um sistema, em muito tempo de processamento de um relatório de dados e até mesmo um gasto excessivo de recurso computacional ao realizar uma simples query SQL.

Modelar nossos dados otimizando esses pontos é de suma importância, e nesse cenário, vai desde como armazenamos os dados nas tabelas, pensando em modelagem, até as configurações de discos que escolhemos para evitar perda de dados e otimização de performance.

A quantidade de dados vem crescendo exponencialmente, de diversos formatos, oriundos de diferentes origens e características distintas. Junto com tudo isso, outras tecnologias vêm crescendo, como o uso de IA e automação.

Essas tecnologias muitas vezes precisam de acesso a dados de forma rápida, simples e eficiente para tomar decisões ou automatizar ações.

Neste capítulo, vamos desbravar diferentes cenários olhando para configurações de discos, armazenamento de dados e funcionamento de discos em clusters de máquinas visando ganhar performance e dar escala em diferentes projetos de dados.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 O QUE É UM DADO E COMO É ARMAZENADO

Um dado pode ser um registro em uma tabela, um conjunto de informações em formato XML ou Json, textos capturados de um sistema de pesquisa ou da internet, imagem de um satélite ou vídeo de uma campanha no YouTube. Temos três tipos de dados distintos entre si; aqui vai uma breve descrição de cada tipo:

- **Dados Estruturados** – Dados formatados, tabulares, como um arquivo Excel com linhas e colunas, ou seja, há uma definição clara do que são e como devem ser os dados;
- **Dados Não-Estruturados** – São dados não formatados e sem uma definição clara de como devem ser, podem vir de tamanhos e formatos diferentes, como imagens, textos, vídeo e afins;
- **Dados semiestruturados** – São dados que apesar de não serem estruturados possuem um formato pré-definido, são arquivos Json, XML, YAML por exemplo.

Sabemos como são os dados que podemos receber em nossos projetos. Agora, como eles serão armazenados de fato? Isso vai depender muito da ferramenta escolhida. Bancos de dados relacionais geralmente possuem um armazenamento organizado em arquivos de dados armazenados em disco que são lidos apenas por suas respectivas ferramentas. Por exemplo, o SQL Server e Oracle possuem seus métodos próprios de armazenar esses dados em arquivos, e estes são lidos pelo próprio SGBD (Sistema gerenciador de banco de dados).

Podemos ter dados de diferentes tipos, de diferentes características em um único projeto, como um CDP (customer data profile) ou Datalake, onde unificamos dados de diferentes origens para conseguirmos ter uma visão unificada e centralizada de clientes, produtos e da própria companhia.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Uma coisa é unânime quando falamos em bancos de dados: sempre que precisamos ir buscar dados em disco, podemos enfrentar lentidão em nossas consultas. Os SGBDs já são equipados com funções muito bem desenvolvidas para otimizar o consumo dos dados usando memória RAM, ou seja, mantendo os dados em memória, o que descarta a necessidade de ir buscar os dados em disco. Incluisve, existem SGBDs totalmente voltados para trabalhar em memória RAM. Mas esse é um cenário que não conseguimos fazer para qualquer banco de dados, depende do tamanho e das características de consumo. Por isso otimizar as consultas em disco é um dos pontos de melhoria em projetos de dados.

Está muito enganado quem pensa que esse tipo de problema é apenas de engenheiros de dados e administradores de banco de dados. Em treinamento de modelos de visão computacional, usamos alocação de memória para “ir menos” em disco buscar novas imagens para treinamento e, desta forma, evitar desperdício de tempo no treinamento de uma rede neural convolucional.

3 HARD DISK

Agora vamos falar sobre o funcionamento do armazenamento dos dados em discos, Storage e afins. Começaremos pelos HDs (hard disk) ou disco rígido, que é onde muitas informações são armazenadas em servidores. O papel dos HDs é armazenar o sistema operacional, binários de aplicações instaladas no servidor, dados e afins.

Um HD é composto por um ou mais pratos conectados a um eixo que os gira juntos a uma velocidade angular fixa especificada por Rotações por Minuto – RPM. Os dados são gravados em trilhas concêntricas, geralmente em ambos os lados de um prato. As trilhas com o mesmo raio constituem um cilindro e podem ser acessadas juntas pelas cabeças de leitura/gravação (Read and Write) em um braço de disco. Por essa razão, os arquivos grandes são geralmente gravados sequencialmente em trilhas de disco sucessivas no mesmo cilindro antes de prosseguir para o próximo. O tempo que leva para mover o braço do

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

disco para o cilindro apropriado a partir de sua posição atual é chamado de Seek Time ou tempo de busca, em português.

Os dados são lidos em blocos e essa operação pode resultar em buscar dados que componham esse bloco em vários discos, operação conhecida como I/O (Input/Output).

Medimos a capacidade do nosso sistema de discos por meio da densidade de IO, que é uma medida de IO gerada em uma determinada capacidade de armazenamento. Em outras palavras, mede quanto de IO conseguimos fazer nesse armazenamento. Uma única unidade de disco que forneça 7.2 Mil RPM pode fornecer cerca de 50 IOPS com um tempo de resposta de até 20 ms (Thomasian, 2022).

Podemos encontrar discos de 1TB a 8TB com 7.2 Mil RPM, mas isso não aumenta sua capacidade de IOPS, pelo contrário, reduz, oferecendo um declínio nesses números, por isso, é preciso entender qual será o comportamento da aplicação, como ela será demandada para saber quais discos usar e qual configuração de RAID usar para garantir a performance e a segurança necessária.

Um relatório da NetApp separa em três níveis de serviço o IOPS/TB que as aplicações precisam:

- Value: cargas de trabalho de serviços que exigem performance até 512 IOPS/TB;
- Performance: cargas de trabalho de serviços que exigem performance entre 512 e 2048 IOPS/TB;
- Extreme: cargas de trabalho de serviços que exijam performance entre 2048 e 8192 IOPS/TB.

Visto o cenário acima, em alguns casos, podemos impor limites ao IO aos volumes (discos) para evitar que aplicações interfiram nos recursos de desempenho de outras aplicações que estejam compartilhando o mesmo armazenamento.

Agora vamos entender como funciona o acesso aos blocos de dados no HD.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

O HD possui braço de disco móvel e uma cabeça de I/O (leitura e escrita) por superfície de disco. Existe um tempo de movimentar a cabeça de leitura da posição em que ela se encontra até alcançar a trilha onde os dados serão escritos ou lidos.

O tempo para os blocos de dados necessário girarem até a cabeça de I/O no braço do disco é chamado de atraso rotacional ou, mais popularmente, latência. Para acesso a pequenos blocos de dados, a latência é mais baixa, o tempo médio é de metade do tempo de rotação do disco.

Todas essas informações parecem não ser relevantes no cenário isolado de um servidor com um ou dois discos que atenda uma aplicação e um banco de dados por exemplo, mas quando vamos para cenários maiores com Storage, alta disponibilidade e recuperação de desastre, essas informações começam a causar problemas se mal dimensionadas e mal interpretadas.

Vamos conferir mais à frente como funcionam os discos em Storage.

4 SEGURANÇA DOS DISCOS

Sempre que lidamos com armazenamento de dados e segurança, aparece uma palavra chamada RAID. Essa pequena palavra, que vem de “Redundant Array of Independent Disks” ou, em português, Matriz de discos independentes, se trata de uma tecnologia que agrupa dois ou mais discos em arranjos de forma que trabalhem juntos em servidores, Storage NAS ou outros sistemas de armazenamento de dados.

Ao criar esse arranjo de HDs eles formam uma única unidade lógica e os mesmos dados disponíveis em um disco do arranjo estarão disponíveis nos demais também. Em outras palavras, em nosso servidor, por exemplo, poderemos observar a unidade ***E:***, que para nós será uma unidade como qualquer outra pois logicamente é uma unidade como qualquer outra, mas no storage, ela é composta por mais de um disco físico.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

A montagem desses arranjos de discos físicos vem da proposta de oferecer mais performance ou segurança, para evitar perda de dados em sistemas de armazenamento.

Por exemplo: em caso de falha de um dos discos de um arranjo, os demais continuam em pleno funcionamento mantendo os dados e evitando a interrupção do serviço da aplicação, seja ela de dados ou não.

Dito isso, vamos analisar quais são os tipos de RAID disponíveis para utilizarmos em nossos sistemas de armazenamento.

Cada tipo de arranjo de discos físicos possui características próprias e suprem necessidades especificas; fique atento, pois cada uma possui requisitos mínimos de hardware e software para funcionar conforme o esperado.

Os tipos de RAID que vamos ver, são: RAID 0, RAID 1, RAID 5, RAID 6, RAID 10, RAID 50 e RAID 60.

RAID 0 (Zero) – Stripping array ou fracionamento

O arranjo de discos RAID 0, trata-se de um Stripping array, ou seja, fraciona os dados disponíveis em pequenos blocos que são distribuídos pelos discos.

Utiliza dois ou mais discos rígidos com o propósito de oferecer o desempenho máximo ao armazenar e acessar os dados, isso, porque, nas tarefas de leituras e escrita de dados, ambas ocorrem de forma paralela, sem a necessidade de cálculo para geração de paridade, entrega o maior desempenho e libera a capacidade total do arranjo de discos para armazenamento, ou seja, se temos quatro discos de 2 terabytes cada, com RAID 0, temos 8 terabytes no total, conforme imagem abaixo:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

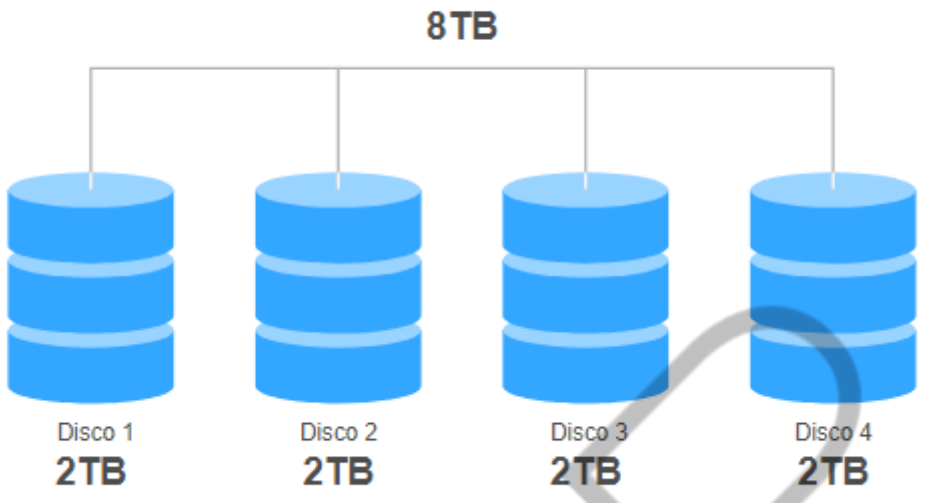

Figura 1: RAID 0
Fonte: https://www.datastorage.com.br/post/tudo-sobre-raid

Mas como nem tudo são flores, na configuração do RAID 0, não temos tolerância a falhas, ou seja, caso tenhamos alguma falha em um disco, os dados estarão comprometidos. O foco do RAID 0 é entregar performance e muita capacidade de armazenamento, aplicações que precisamos de agilidade e volume, mas podemos ser flexíveis quanto à perda de dados em caso de falha.

RAID 0 – Pontos positivos:

- Agilidade no acesso às informações;
- Alta capacidade de armazenamento;
- Alta capacidade de comunicação entre discos.

RAID 0 – Pontos negativos:

- Não tem suporte a espelhamento;
- Não tem suporte à paridade de disco;
- Não fornece alta segurança aos dados.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

RAID 1 – Mirroring Espelhamento de discos

Conhecido como espelhamento de discos, o RAID 1 é ideal para pequenas empresas e até mesmo soluções domésticas, pois requer apenas um par de discos rígidos.

Em um arranjo de discos usando RAID 1, temos a sua capacidade afetada, pois o conteúdo armazenado no disco 1 será espelhado para o disco 2, dessa forma, se tivermos dois discos de 2 terabytes cada, temos um arranjo de 2 terabytes e não 4, como seria no RAID 0.

Esse tipo de RAID é importante, pois caso haja perda de um dos discos, o outro tem uma cópia dos dados e estará pronto para assumir o lugar do disco defeituoso, garantindo que os serviços estejam no ar independente de falhas que possam ocorrer.

Ao implantar um RAID 1, precisamos estar cientes que a capacidade bruta do nosso arranjo de discos será reduzida, uma vez que os dados estarão duplicados. Asegurança proporcionada por esse tipo de arranjo é um ótimo incentivo a sua adoção, mas precisamos observar pela ótica de performance também, um RAID 1 é mais lento que outros tipos de arranjo de discos, pois escrevem simultaneamente em dois discos.

Podemos observar a imagem abaixo que demonstra o funcionamento do RAID 1.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

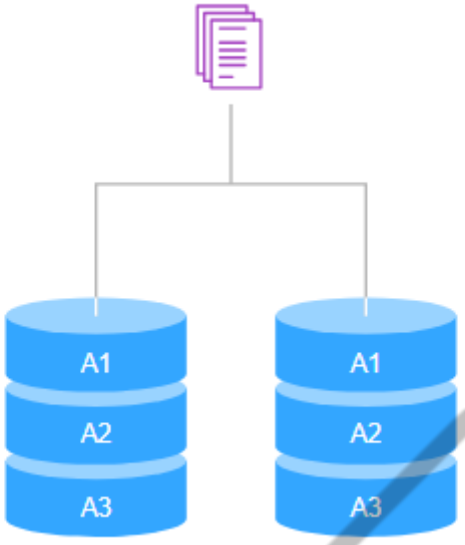

Figura 2: RAID 1
Fonte: https://www.datastorage.com.br/post/tudo-sobre-raid

RAID 1 – Pontos positivos:

- Ótima segurança de dados em caso de falha;
- Caso haja falha de algum setor do disco (perda parcial), é possível recuperar copiando do disco espelho.

RAID 1 – Pontos negativos:

- Leva mais tempo em operações de escrita em disco;
- Reduz a capacidade bruta do arranjo.

RAID 5 – Strip Set com Paridade

Método conhecido por oferecer um nível de segurança aos dados por meio de um disco que faz parte de uma camada de redundância de dados, e, para isso, necessita de uma quantidade mínima de três discos para montar esse arranjo.

Essa configuração cria bits de paridade e os grava juntamente com um dos bytes. Esses bits de paridade são a segurança do sistema para usar em

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

caso de falha de algum dos HDs. Por meio destes bits, é possível identificar as partes faltantes, possibilitando a reconstrução dos dados sem perda de informação.

Como RAID 5 usa bits de paridade, eles são calculados e gerados durante o processo de escrita no disco, assim, podemos notar uma leve queda na performance nesse tipo de arranjo. Os bits de paridade são gerados e escritos juntamente com os dados originais.

O RAID 5 é indicado sua utilização com até oito discos, cada disco do arranjo terá um espaço destinado à segurança dos dados e terá a mesma quantidade de espaço cedida para paridade, conforme imagem abaixo:

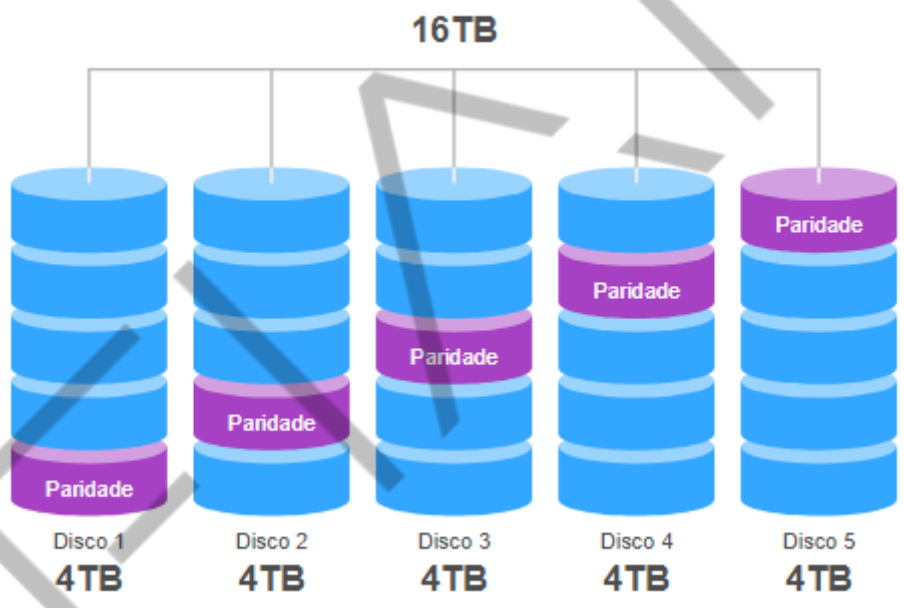

Figura 3 - RAID 5
Fonte: https://www.datastorage.com.br/post/tudo-sobre-raid

RAID 5 – Pontos positivos:

- Maior velocidade para identificar erros e falhas;
- Maior rapidez em operações de leitura;
- Maior segurança dos dados.

RAID 5 – Pontos negativos:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

- Maior lentidão em operações de escrita;
- Maior complexidade no controle de discos;

RAID 6 – Dupla paridade

O arranjo de disco do tipo RAID 6 funciona de forma muito semelhante ao RAID 5 mas com um adicional de um disco para contingência, ou seja, uma dupla paridade.

Com essa dupla paridade, a solução entrega menos performance em operações de escrita, pois agora temos que gerar e escrever não uma, mas duas paridades junto com os dados originais, além de sacrificar parte da capacidade, oferendo menor capacidade de armazenamento comparado com outros arranjos que usam paridade.

Para esse tipo de arranjo é recomendado partir de uma configuração de quatro discos, visto que a paridade consumirá a capacidade proporcional de dois discos para armazenar os bits de paridade, restando apenas o equivalente a dois discos inteiros como armazenamento livre.

Como no RAID 5, os bits de paridade visam promover a segurança dos dados armazenados, não apenas em casos de falha do disco todo, mas caso ele perca partes de informação, usando a recuperação parcial, pois os dados estarão garantidos em outros discos.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

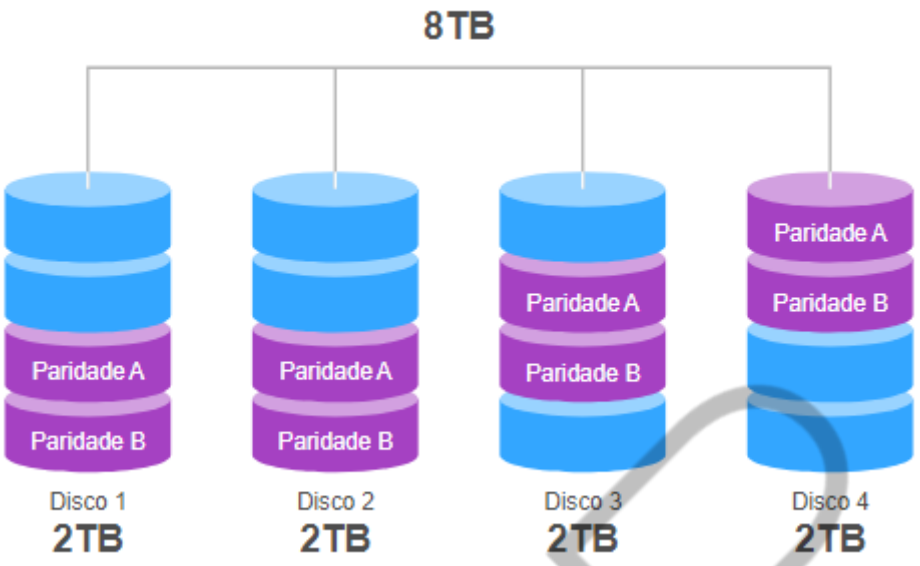

Figura 4 - RAID 6
Fonte: https://www.datastorage.com.br/post/tudo-sobre-raid

RAID 6 - Pontos positivos:

- Possibilidade de ter uma falha em dois discos ao mesmo tempo e não sofrer perda de dados;
- Maior segurança de dados se comparado ao RAID 5.

RAID 6 – Pontos negativos:

- Lentidão em operações de escrita;
- Sistema para controles de disco mais complexo.

RAID 10 ou RAID 1+0

Nessa configuração de arranjo de discos, unimos a segurança do espelhamento de informações do RAID 1 com a gravação em alta performance do RAID 0, por isso, RAID 1+0.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Para implantar um RAID 10, precisamos de ao menos quatro discos onde criamos combinações de dois ou mais arranjos RAID 1 para escrita simultânea, formando assim um RAID 0.

Confuso, não é? Explicaremos de outra forma. Na implantação de um RAID 10 em um storage NAS, será necessário criar ao menos dois subgrupos de discos configurados em RAID 1 (espelhados), que deverão ser agregados em um único pool RAID 0 (distribuído).

A formação desse arranjo RAID 10 permite que os dados sejam gravados em todos os discos ao mesmo tempo, mantendo cada subgrupo com um disco de produção e outro para espelhamento. Dessa forma, o arranjo oferece performance satisfatória em transferência de dados, mas não compromete a integridade dos dados caso tenhamos alguma falha em algum disco.

Vejamos a imagem abaixo para contextualizar melhor o que falamos sobre RAID 10. Observe que temos na verdade dois RAID 1 e, acima desses RAID 1, temos um RAID 0.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

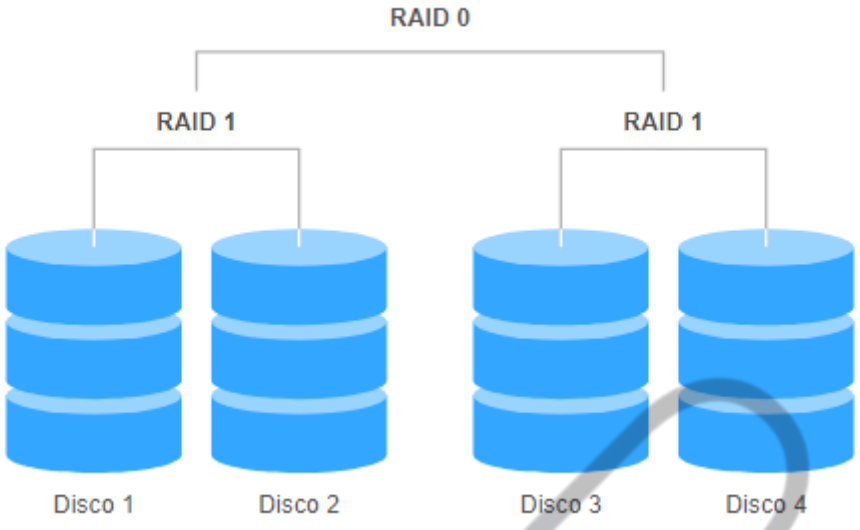

Figura 5 - RAID 10
Fonte: https://www.datastorage.com.br/post/tudo-sobre-raid

RAID 10 são utilizados normalmente em aplicações cuja performance seja um pré-requisito, mas sem deixar de lado a segurança das informações ali armazenadas. Podemos ver esse tipo de configuração de RAID em servidores de arquivos, servidores de bancos de dados, Hosts que armazenam máquinas virtuais e animações 3D.

Essa configuração é muito boa, mas é importante salientar que, metade da capacidade do arranjo sempre estará comprometida por conta do RAID 1 e, caso tenhamos falha em dois discos de um mesmo subgrupo de RAID 1, o sistema de armazenamento todo estará comprometido.

RAID 10 – Pontos positivos:

- Oferece boa segurança contra perda de dados;
- Pode lidar com falhas de até dois discos ao mesmo tempo, desde que não seja do mesmo subgrupo.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

RAID 10 – Pontos negativos:

- Exige um grande número de discos para formar o arranjo, se comparado aos demais arranjos;
- Os drivers devem permanecer em sincronismo de velocidade para ampliar a performance.

RAID 50 ou RAID 5+0

Bem como RAID 1+0, o RAID 5+0 também é produto da combinação de dois tipos de arranjos distintos, o RAID 5 (Strip set com paridade) e RAID 0 (Distribuído). Nesse cenário são necessários ao menos seis discos para implantação de um RAID 50, utilizando um disco de paridade em cada subgrupo do sistema.

Também é tolerante à falha de até dois discos simultaneamente, desde que sejam de subgrupos diferentes.

Como nesse arranjo possuímos ao menos seis discos, temos aqui uma boa performance em operações de escrita e leitura, pois justamente pela quantidade de discos ser maior, a taxa de leitura e escrita também aumenta. RAID 50 pode ser instalado em servidores de arquivos, servidores de banco de dados, armazenamento e backup de máquinas virtuais.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

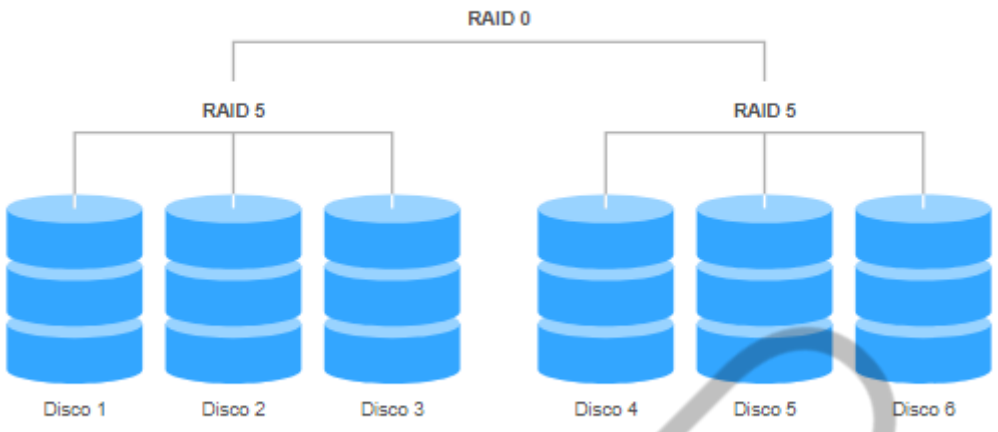

Figura 6: RAID 50:

Fonte: https://www.datastorage.com.br/post/tudo-sobre-raid

Observe a montagem do RAID 50 na imagem acima, temos seis discos divididos em dois subgrupos de RAID 5 e esses subgrupos estão em um RAID 0.

RAID 50 – Pontos positivos:

- Oferece alta segurança contra perda de dados;
- Tolerante à falha de até dois discos simultaneamente, mesmo não sendo do mesmo subgrupo.

RAID 50 – Pontos negativos:

- Quanto maior for o subgrupo em RAID 5, maior a probabilidade de dois discos falharem simultaneamente.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

RAID 60 ou RAID 6+0

Assim como o RAID 5+0, o RAID 6+0 é a derivação de uma combinação de dois tipos de arranjos, o RAID 6 e o RAID 0, operando como um único disco lógico. Para configurar esse arranjo, precisamos de ao menos oito discos, onde dois subgrupos de RAID 6 devem ser criados com dupla paridade por subgrupo. Dessa forma, é tolerada a falha de até dois discos por pool, obtendo uma segurança bem maior.

Ao implantar dupla paridade em subgrupos com poucos discos, podemos sofrer com a perda de performance e capacidade volumétrica disponível, principalmente se estivermos falando de uma quantidade de até 16 discos.

Se tivermos uma instalação onde vários discos estão sendo usados no mesmo subgrupo, o RAID 60 pode se tornar uma alternativa vantajosa. Esse tipo de arranjo de discos é muito utilizado em aplicações que tenham alta disponibilidade, geralmente serviços que operam 24x7.

Apreciem a imagem abaixo de uma implantação de RAID 60 usando 8 discos de 2TB cada.

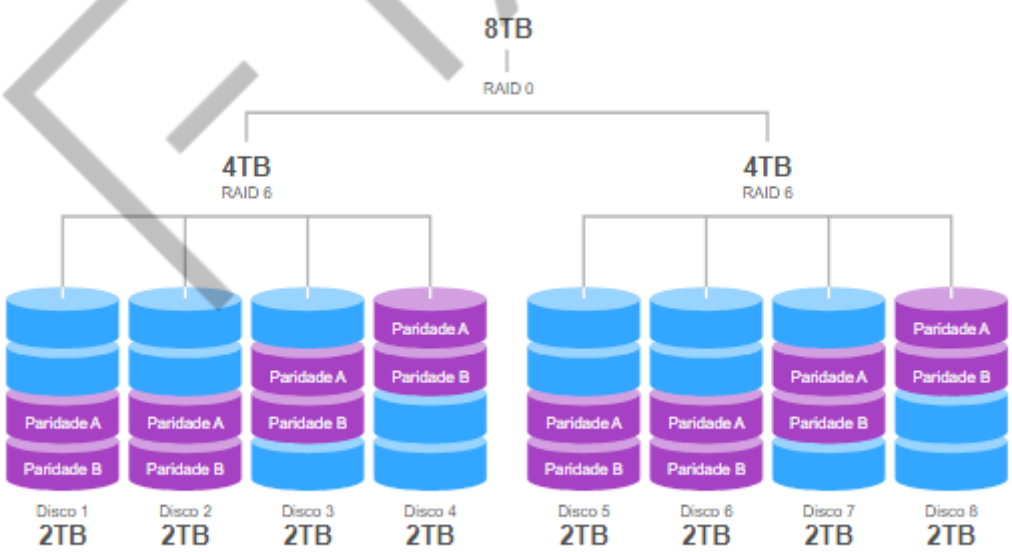

Figura 7: RAID 60
Fonte: https://www.datastorage.com.br/post/tudo-sobre-raid

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

RAID 60 – Pontos positivos:

- Oferece uma forte segurança contra perda de dados;
- Tolera falha de até dois discos simultaneamente no mesmo pool.

RAID 60 – Pontos negativos:

- Performance pode ser um gargalo nesse arranjo.

5 STORAGE

Vamos começar do início: o que é um storage? Storage é um equipamento voltado para armazenar dados de servidores, da rede local, aplicações e bancos de dados em empresas e, por que não, residenciais.

Os sistemas de armazenamento podem ser classificados como storages, e podem ser divididos entre três grandes grupos, DAS, NAS e SAN, onde são diferenciados pela forma de conexão com o host ou servidor, e essas unidades de armazenamento possuem diferentes finalidades e recursos. Vamos conhecer cada um dos tipos:

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

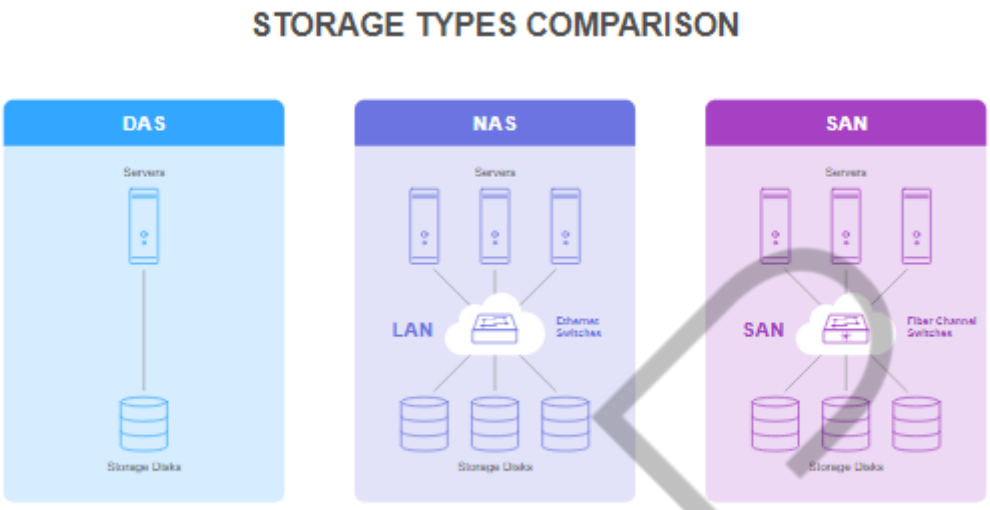

Figura 8: Tipos de storage
Fonte: https://networkwalks.com/storage-types-das-nas-san/

DAS – Direct Attached Storage

O armazenamento tipo DAS, é qualquer armazenamento conectado diretamente a computadores, servidores, estações de trabalho e afins.

Esse armazenamento, ao ser conectado ao host, se torna um disco adicional, por exemplo, você pode ter uma máquina com Windows Server e automaticamente temos a unidade C:, onde temos o sistema operacional instalado, diretórios como Documentos, Downloads, desktop e afins. Ao ter um DAS nessa máquina, teríamos uma nova unidade que, por exemplo, pode ser o D:, onde podemos direcionar a outros fins específicos como armazenar arquivos de dados de sistema gerenciador de banco de dados, log, entre outros.

Um exemplo bem simples de DAS é um HD externo conectado via USB em um host. Esse é o cenário independente de ser um driver ou 24 drivers conectados em um host físico, só não seria via cabo USB, pois não oferece performance suficiente para DAS de grandes volumes.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

O DAS é geralmente indicado para empresas de pequeno e médio porte, onde quantidades suficientes de armazenamento podem ser configuradas com um custo baixo e acessível, geralmente com um controlador RAID interno baseado em PCI para a conexão entre servidor e armazenamento.

DAS - Pontos positivos

- Simples de instalar e configurar;
- Econômico;
- Não utiliza endereços IP;
- Mais fácil de lidar de modo geral.

DAS – Pontos negativos

- Os recursos de armazenamento são dedicados a um ÚNICO servidor;
- Não há economia de escala compartilhando armazenamento;
- Não é possível gerenciar o DAS por meio da rede;
- DAS precisa de uma conexão de hardware especial.

NAS – Network Attached Storage

Diferente do DAS, o NAS é um sistema de armazenamento conectado diretamente na rede local, onde funciona como um HD em rede, que centraliza e armazena dados de forma mais organizada. Qualquer servidor com unidades de disco suficiente pode ser um servidor de arquivos na rede.

Nesse cenário, é possível compartilhar e gerenciar dados, arquivos e diretórios armazenados para todos os usuários de rede, utilizando segurança de rede como Active Directory e afins.

O NAS é perfeito para pequenas e médias organizações que precisam de um sistema de armazenamento confiável, flexível e com manutenção baixa, mas que ainda assim possa ser rapidamente ampliado conforme necessário para acomodar novos usuários ou dados crescentes.

NAS – Pontos positivos

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

- É uma maneira econômica de fornecer armazenamento compartilhado para muitas pessoas e hosts;
- É bem mais fácil de instalar e configurar do que SAN;
- Forma fácil de fornecer redundância RAID para uma grande quantidade de usuários;
- Permite configurar permissões por usuário, privilégios de diretório, acesso restrito etc.

NAS – Pontos negativos

- Requer endereços de IPS e ocupa espaço na rede;
- Tem latência mais lenta e problemas potencialmente máximos de transferência de dados;
- O desempenho pode ser afetado pelo status da rede.

SAN – Storage Area Network

SAN vem de área de armazenamento em rede, geralmente uma solução comumente utilizada em empresas de médio a grande porte, principalmente pelo valor do investimento ser maior que os demais.

SAN requer controladoras de disco, switches SAN, adaptadores de barramento de host e cabos de fibra. Com certeza estamos falando do melhor cenário de armazenamento; um dos principais benefícios do SAN é a capacidade de compartilhar matrizes de armazenamento entre servidores. Isso permite configurar a capacidade de armazenamento conforme a necessidade, tarefa geralmente feita por um administrador SAN dedicado.

Um ambiente SAN confere níveis mais altos de desempenho e disponibilidade por meios das unidades de armazenamento e controladoras de disco redundantes. SAN é um tipo de sistema utilizado em grandes empresas em data centers ou ambientes de computação virtual, pois oferece a velocidade do DAS com o compartilhamento junto com a flexibilidade e confiabilidade do NAS. O SAN é uma opção sofisticada normalmente destinada a oferecer suporte a aplicações complexas, de alta disponibilidade e missão crítica.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SAN – Pontos positivos

- Possui economia de escala semelhante ao NAS;
- Possui maior utilização de hardware, semelhante ao NAS;
- Possui velocidade semelhante ou comparável ao DAS;
- Permite ambientes virtuais, computação em nuvem etc.

SAN – Pontos negativos

- O desempenho pode ser afetado por outros usuários;
- O desempenho é limitado pela rede se configurado incorretamente;
- Requer vários endereços de IP estático.

E agora, qual tipo de armazenamento é o ideal para sua rede? Veja o comparativo abaixo e reflita sobre qual melhor te atende.

	DAS	NAS	SAN
Protocolos	SATA, SAS	SMB (CIFS), NFS	iCSCI, Fiber Channel
Tipo	File Storage	Block Storage	Block Storage
Velocidade	5/10 ms	5/10 ms	20/50 ms
Forma de transmissão	IDE/SCSI	Ethernet, TCP/IP	Fiber Channel
Complexidade	Easy	Moderate	Complex
Gerenciamento de custos	High	Moderate	Low
Suporta compartilhamento	No	Yes	Yes
Conexão via rede	No	Yes	Yes
Escalabilidade	Low	Medium	High

Tabela 1: Comparativo DAS, NAS e SAN:
Fonte: Elaborado pelo autor.

CONCLUSÃO

Neste capítulo, aprendemos as características de armazenamento de dados, sejam em discos únicos ou em arranjos de discos para oferecer melhor performance/segurança aos nossos dados, e a escolher o melhor tipo de armazenamento no Storage.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Apesar de ser uma tarefa bastante voltada para administradores de sistemas, redes e bancos de dados, o papel de analista e cientista de dados também sofre com acesso a dados em disco, portanto, a configuração de ambiente de armazenamento de dados precisa ser bem planejada, implantada e monitorada. Gostaria de ver um exemplo interessante?

Você está fazendo uma consulta de banco de dados no SQL Server para gerar alguns indicadores para seu diretor; o dado precisa ser enviado o quanto antes, seu diretor está te pressionando pedindo esses dados, quando você aciona o administrador do ambiente de banco de dados, ele vê o que está rodando no servidor.

Sempre que precisamos ir em discos, buscar dados não é o melhor cenário, o ideal é que os dados estejam em memória RAM, dessa forma, a consulta será mais rápida.

Mas voltando no nosso cenário da consulta para o diretor, nossa consulta com Wait Type “PAGEIOLATCH”, indica que o SQL Server está buscando as páginas de dados no disco, por isso a demora. Pode ocorrer também um Wait type “IO_COMPLETITION”, que indica que a consulta foi estimada errada pelo banco de dados e agora está sem memória para fazer um Order BY, por exemplo, aí o recurso usado para isso é o disco.

Você pode estar se perguntando no que isso te impacta. Tudo. Se a configuração do disco não estiver sido pensada, planejada e executada visando as necessidades do projeto, podemos prejudicar diversas áreas que consomem esses dados, seja para análise, relatórios, dashboard, modelos de machine learning e afins.

Espero que tenham gostado do conteúdo, até a próxima.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

THOMASIAN**, Alexander; Storage Systems**: Organizations, Performance, Coding, Reability, and Their Data Processing; Cambridge; Elsevier; 2022.

TUDO SOBRE RAID. DATASTORAGE, **São Paulo**. Disponível em: <https://www.datastorage.com.br/post/tudo-sobre-raid>. Acesso em: 29 de jan. de 2024.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com