BUSINESS INTELLIGENCE & ANALYTICS

PROCESSO DE TOMADA DE DECISÃO E METODOLOGIA DE PESQUISA CIENTÍFICA QUANTITATIVA

9

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 – Os três pilares da ciência de dados 9
Figura 2 – Processo caixa-preta de tomada de decisão 10
Figura 3 – Etapas do processo de KDD 12
Figura 4 – Fases CRISP-DM.....14
Figura 5 – Classificação de dados quantitativos 19

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE QUADROS

Quadro 1 – Comparação KDD e CRISP-DM.....17
Quadro 2 – Métodos de pesquisa versus coleta de dados.....22

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 PROCESSO DE TOMADA DE DECISÃO E METODOLOGIA DE PESQUISA CIENTÍFÍCA QUANTITATIVA 5
1.1 É a vez dos dados 5
1.2 O que é Data Science 5
2 PILARES DA CIÊNCIA DE DADOS 7
2.1 Processos de tomada de decisão e descoberta do conhecimento 10
2.2 KDD – Knowledge Discovery in Databases 11
2.3 CRISP-DM 14
2.4 Comparação entre KDD e CRISP-DM 16
3 MÉTODOS DE PESQUISA 18
3.1 Pesquisa quantitativa 18
3.2 Dados quantitativos 19
3.3 Métodos de pesquisa quantitativa 20
ATIVIDADE - TREINO 24
REFERÊNCIAS 26

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 PROCESSO DE TOMADA DE DECISÃO E METODOLOGIA DE PESQUISA CIENTÍFÍCA QUANTITATIVA

1.1 É a vez dos dados

A área de ciência de dados não é novidade. Antigamente conhecida apenas por profissionais de estatística, tornou-se atraente no início do século 21 impulsionada por diversos fatores, como os avanços tecnológicos, aumento do poder de processamento dos computadores e a redução de custos para o armazenamento de dados. A adoção de métodos científicos para análise de dados, assim como tornar dados brutos em informações de valor para tomada de decisão de negócios, teve seu boom a partir da década de 2010.

Estamos vivendo a era da revolução baseada em dados, diz-se que os dados são o novo petróleo, pois são valiosos se, e somente se, bem tratados e refinados. A diferença entre eles é que o petróleo é uma fonte finita, que se esgota, e os dados infinita, pois podemos reutilizar os mesmos dados em análises e contextos de negócio diferentes.

Essa frase foi dita por Clive Humby, um matemático londrino especializado em ciência de dados. Diante desse panorama, empresas buscam encontrar vantagens competitivas e redução de custos ao aplicar metodologias de pesquisa científica quantitativa (baseada em dados) para tomadas de decisões rápidas e assertivas, tornando-se empresas orientadas por dados, *data driven*.

1.2 O que é Data Science

O conceito de ciência dos dados (Data Science) é bastante abrangente, mas temos que ter em mente que a palavra-chave não é “dados” e sim “ciência”. A ciência de dados só é útil quando os dados são usados para responder a uma pergunta de negócio.

A ciência de dados é uma extensão evolutiva da estatística, capaz de lidar com grandes quantidades de dados (Big Data), com a análise exploratória e o

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

processamento de dados de diferentes formatos, gerados a partir de diversas fontes e em velocidades diferentes.

Para isso, utiliza-se de métodos e ferramentas da tecnologia da informação, o repertório de técnicas estatísticas e matemáticas aplicadas ao contexto de negócio (business), para responder a uma pergunta para tomada de decisão de negócio.

Para saber mais:
https://www.tandfonline.com/doi/pdf/10.1080/10618600.2017.1384734?needAccess=true

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 PILARES DA CIÊNCIA DE DADOS

A ciência de dados é uma área multidisciplinar, nesse sentido, envolve diversos profissionais e áreas de conhecimento. Antes de falar sobres os três pilares fundamentais para ciência de dados, vamos compreender a diferença entre dados e informação.

Basicamente, dados são elementos, como: números, medidas, valores ou observações, que, de forma isolada, sem a presença de um contexto, não possuem significado claro, mas servem de matéria bruta para se obterem informações, que são os resultados interpretados após as análises dos dados (processamento) em algum contexto.

Vamos fazer um exemplo:

“Temperatura de 40 ºC”.

O que o dado temperatura significa? 40 ºC é quente ou frio? Não é possível dar uma resposta, pois não temos o contexto para fazer a análise do dado e gerar uma informação de valor, logo não é possível uma tomada de decisão.

Vamos aproveitar o exemplo acima adicionando um contexto para análise:

“Temperatura da criança é de 40 ºC”.

Agora sim! Conhecendo um pouco mais o contexto, ou seja, a origem dos dados e onde está sendo aplicado, já é possível obter alguma informação de valor a partir da análise do dado de temperatura. Neste nosso exemplo, a informação de valor obtida a partir do dado é de que se trata de uma criança com febre alta; sabendo disso, já é possível uma tomada de decisão do que deve ser feito a respeito.

Podemos compreender esse fluxo da seguinte forma:

DICA: Dados (brutos) → análise de dados (processamento) → informação (significado).

Uma forma de entender o que é a ciência de dados é por meio da compreensão da abrangência e profundidade inseridas em três áreas distintas do conhecimento que, juntas, formam os pilares da ciência de dados, são elas:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

- **Tecnologia da Informação:** em tempos de Big Data, em que temos grandes volumes de dados gerados de fontes, formatos e velocidades diferentes, o conhecimento em computação é importante para a criação de códigos e software de análise de dados. Conhecer lógica computacional, algoritmos e linguagem de programação é uma das habilidades que estão contidas nesse pilar. Comumente são utilizadas ferramentas como Java, Python, Hadoop, R, Julia (não se preocupe se você se sentir intimidado por essa lista, a maioria delas será introduzida gradualmente no curso, embora nos concentremos em Python), além de conhecimento em Cloud Computing, processamento paralelizado, versionamento e escalabilidade, como AWS, Azure, GCP, Docker, Kubernetes, Git e GitHub.
- **Matemática e Estatística:** a ciência de dados nasceu da estatística e, por essa razão, é fundamental a compreenssão de habilidades estatísticas para prever eventos futuros e descobrir padrões em dados, além de análises exploratórias *(exploratory data analysis*, ou EDA), plotagem e cálculos estatísticos e probabilísticos (gráficos de dispersão, frequência, quantis, Gaussiana, Poisson, entre outros) e modelagem para aprendizado de máquina *(machine learning)* supervisionado (classificação e regressão) e não supervisionado (agrupamento). O entendimento e a aplicação das técnicas estatísticas exigem conhecimento de matemática em tópicos básicos, como: geometria (cálculo de distância, como Manhattan ou euclidiana), matemática discreta (cálculo de probabilidade). Para tratar grandes quantidades de dados, são necessárias técnicas mais avançadas, logo é necessário o conhecimento de álgebra linear (para *machine learning* e redes neurais), cálculo de derivada/integral (otimização de modelos, gradiente).
- **Domínio do Negócio:** o terceiro pilar está relacionado ao entendimento do negócio. A ciência de dados existe para resolver problemas de negócio, logo, exige profundidade e abrangência do profissional de Data Science sobre os dados que estão sendo manipulados. Não conhecer bem ou não ter domínio do negócio implica não saber quais dados (variáveis e atributos) são importantes para a análise e quais perguntas relevantes devem ser

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

respondidas. Além disso, é importante saber expor e comunicar os resultados encontrados de forma visual, objetiva e clara.

O cientista de dados reúne conhecimentos e habilidades multidisciplinares, são diversas áreas do conhecimento. Muitas vezes, é comparado à figura de um unicórnio e a razão é simples: provavelmente você já ouviu falar que existe unicórnio, mas nunca viu um de verdade.

Encontrar um profissional de ciência de dados que reúna todas essas habilidades com excelência é muito difícil. Por esse motivo, projetos de ciência de dados comumente são realizados por meio de uma equipe multidisciplinar composta por profissionais com conhecimentos em computação, estatística e negócio.

A Figura “Os três pilares da ciência de dados” abaixo exibe o diagrama de Venn com os três pilares para a ciência de dados com as áreas de tecnologia da informação, estatística e domínio do problema.

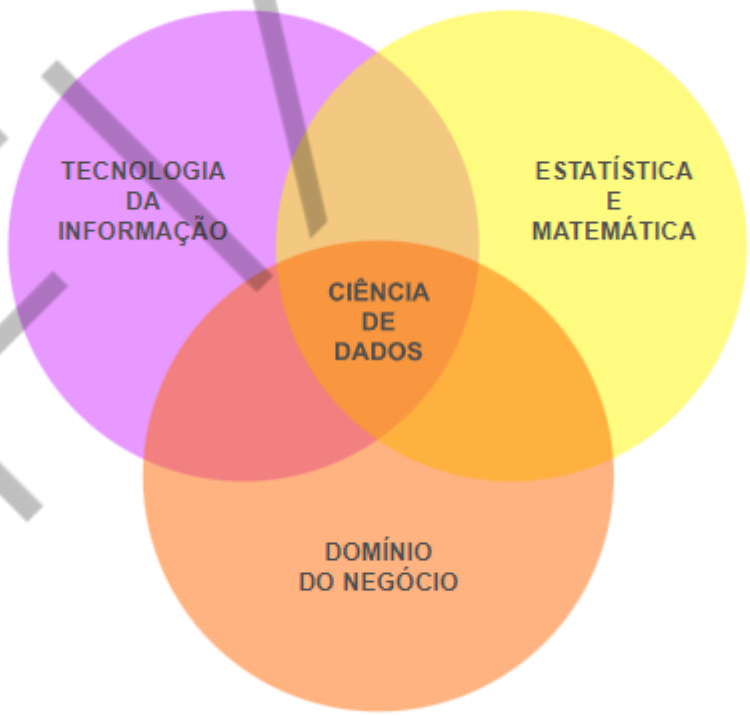

Figura 1 – Os três pilares da ciência de dados
Fonte: Elaborada pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2.1 Processos de tomada de decisão e descoberta do conhecimento

As tomadas de decisões são ações tomadas com base nos resultados obtidos da ciência de dados. Podemos utilizar diferentes técnicas para chegar a esses resultados e veremos neste capítulo algumas delas, mas primeiramente vamos dividir o problema de tomada de decisão em problemas menores. Para compreender esse processo da forma mais simples, vamos visualizar o problema como um sistema caixa-preta.

A Figura “Processo caixa-preta de tomada de decisão” abaixo exemplifica um processo caixa-preta para tomada de decisão. Nesse sistema, temos quatro etapas. Começamos à esquerda com uma pergunta de negócio e partindo dessa pergunta pulamos para a próxima etapa: os dados brutos (que possuem volume, variedade e velocidade diferentes) como entrada de sistema. São esses dados o combustível para realizar a etapa de ciência dos dados (responsável por extrair informações de valor dos dados) e, à direita, a ação de tomada de decisão baseada na resposta do sistema de Data Science.

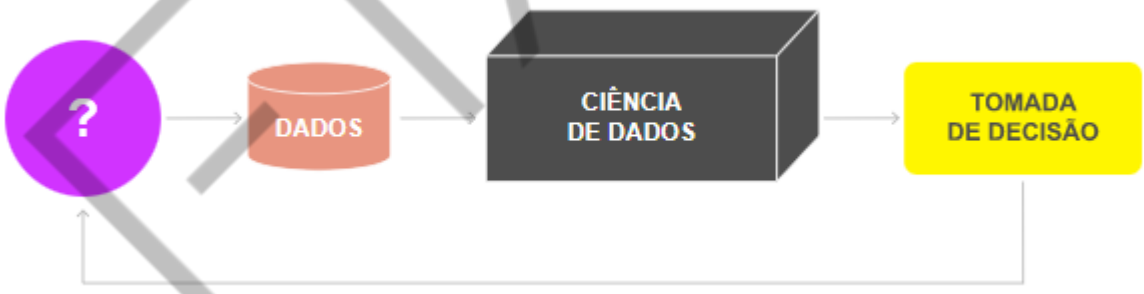

Figura 2 – Processo caixa-preta de tomada de decisão
Fonte: Elaborada pelo autor (2022)

Já sabemos que a ciência de dados existe para responder a uma pergunta de negócio e auxiliar na tomada de decisões, alinhando a melhor possibilidade de solução de problemas com as estratégias da organização, buscando maior eficiência e eficácia empresarial. A ciência de dados se utiliza do método científico com procedimentos e ferramentas para chegar a conclusões que possam ser úteis para a tomada de decisão.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Partindo desse simples sistema caixa-preta que elaboramos, diversas ferramentas foram criadas com o intuito de auxiliar no processo de descoberta do conhecimento em projetos de ciência de dados.

Vamos conhecer o KDD, SEMMA e CRISP-DM de forma detalhada, mas é importante compreender que não existe um método melhor que o outro para ser seguido e sim o que melhor se ajusta para as necessidades e o ciclo de vida do projeto de ciência de dados que está sendo desenvolvido.

2.2 KDD – Knowledge Discovery in Databases

É um termo que começou a ser utilizado em projetos de banco de dados no final dos anos 1980 por Piatetsky-Shapiro, sendo também utilizado para nomear o primeiro evento da área em 1989.

Já nos anos 1990, deu origem a um dos métodos mais populares para dados segundo os autores Fayyad, Piatetsky-Shapiro e Smyth, que desenvolveram o KDD Process e publicaram o artigo “From Data Mining to Knowledge Discovery in Databases”, em 1996. KDD se refere ao conjunto de passos e ou processos com o intuito da descoberta de conhecimento útil a partir dos dados.

São utilizadas técnicas de mineração de dados em um conjunto de dados (banco de dados) para extrair o que é considerado conhecimento útil, seguindo especificações previamente definidas e com aplicação de técnicas de pré-processamento, subamostragem e transformações nos dados do banco de dados. São consideradas cinco etapas do processo KDD, a Figura “Etapas do processo de KDD” abaixo ilustra cada etapa do processo.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

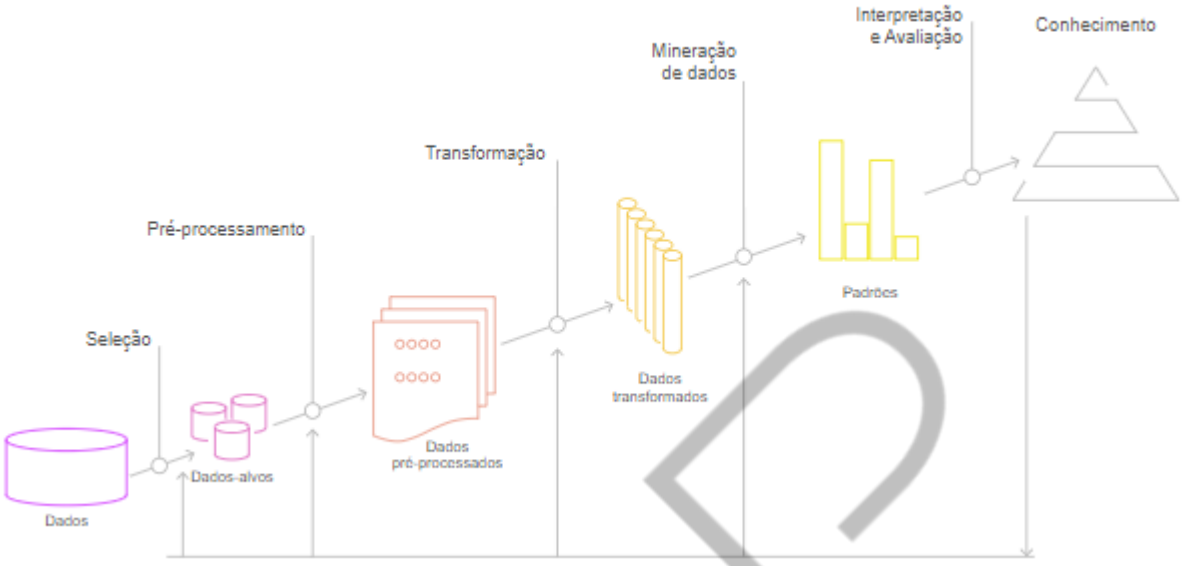

Figura 3 – Etapas do processo de KDD
Fonte: Fayyad *et al.* (1996)

1. **Seleção (Selection):** selecionar um conjunto ou subconjunto de dados para análise.

Nesta etapa é feita a pergunta: quais variáveis devem ser selecionadas? Essa resposta não é trivial e normalmente não é possível chegar a uma solução ótima na primeira tentativa, pois é necessário considerar diversos aspectos multidisciplinares, tais como: conhecimento do negócio (a qual pergunta de negócio você quer responder?) e técnicos, como: formatos, fontes, variedades dos dados (estruturados, não estruturados, planilhas, data warehouses, qualitativos, quantitativos...). Como resultado, obtemos Target Date (dados-alvos ou dados selecionados).

2. **Processamento (Preprocessing):** verificar e/ou assegurar a qualidade dos dados selecionados.

Nesta etapa é realizada uma revisão geral da estrutura e qualidade dos dados selecionados em que, por meio de técnicas estatísticas e técnicas de visualização de dados, é realizado o processo de limpeza, correção e/ou remoção de dados inconsistentes. É nessa etapa que são verificadas ocorrências de dados ausentes (missing values), além de identificar anomalias (outliers), que são dados coletados com erro de medição. Como resultado obtemos Preprocessed Data (dados pré-processados).

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3. **Transformação (Transformation):** aplicar técnicas de transformação de dados para converter dados brutos em uma forma-padrão de uso.

Nesta etapa são aplicadas técnicas, como: discretização (converter variáveis contínuas em variáveis categóricas), normalização, agregação, criação de novas variáveis, redução de dimensionalidade e sintetização dos dados. Como resultado, obtemos Transformed Data (dados transformados).

Até aqui vimos as etapas 1, 2 e 3 que, juntas, são chamadas de **preparação dos dados** dentro do ciclo de vida de um projeto de ciência dos dados. Na prática, a preparação dos dados pode consumir entre 60% e 80% do tempo do projeto de dados, pois as próximas etapas que veremos, embora sejam importantes quanto a preparação dos dados, pois envolvem a criação de modelos, interpretação de dados e tomada de decisão, normalmente são mais rápidas de serem implementadas uma vez definidos os métodos que serão utilizados.

4. **Mineração de Dados (Data Mining):** construir modelos e métodos estatísticos para extrair padrões de interesse.

Nesta etapa são aplicados diferentes algoritmos de modelos estatísticos referentes à mineração de dados, dependendo do objetivo do projeto. Veremos no curso alguns desses algoritmos que estão relacionados com aprendizagem de máquina *(machine learning).* Os algoritmos de mineração de dados podem ser classificados como modelos preditivos (classificação, regressão, agrupamento) e descritivos (que busca identificar relações entre os dados). Como resultado, obtemos Patterns (padrões).

5. **Interpretação e Avaliação (Interpretation/Evaluation):** avaliar a performance do modelo gerado e a interpretação dos resultados para tomadas de decisão.

Nesta etapa são aplicadas médias estatísticas e/ou avaliação dos profissionais de negócio para avaliar o desempenho do modelo. Como resultado, temos a descoberta de conhecimento para auxílio no processo de tomada de decisão. Como resíduo de um projeto de dados, podemos iniciar novos ciclos de vida de dados para aprimorar os resultados ou começar novos projetos de dados para novas perguntas de negócios.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Para saber mais:
https://ojs.aaai.org//index.php/aimagazine/article/view/1230

2.3 CRISP-DM

É o acrônimo de Cross Industry Standard Process for Data Mining. Trata-se de um framework de uso geral que pode ser aplicado em diversos tipos de projetos de dados, criado em meados dos anos 1990 por um consórcio de empresas, de forma gratuita e não proprietária, para definir um fluxo de trabalho de ciência de dados e atualmente é o mais utilizado pela indústria. Vamos ver que algumas etapas possuem relação com o modelo KDD que já estudamos.

O CRISP-DM é uma metodologia flexível. O ciclo de vida do projeto de dados possui seis fases que podem ser adaptadas em função do problema que está sendo atacado. Essa flexibilidade permite avançar e retroceder uma fase, caso seja necessário. A Figura “Fases CRISP-DM” abaixo ilustra cada etapa do processo.

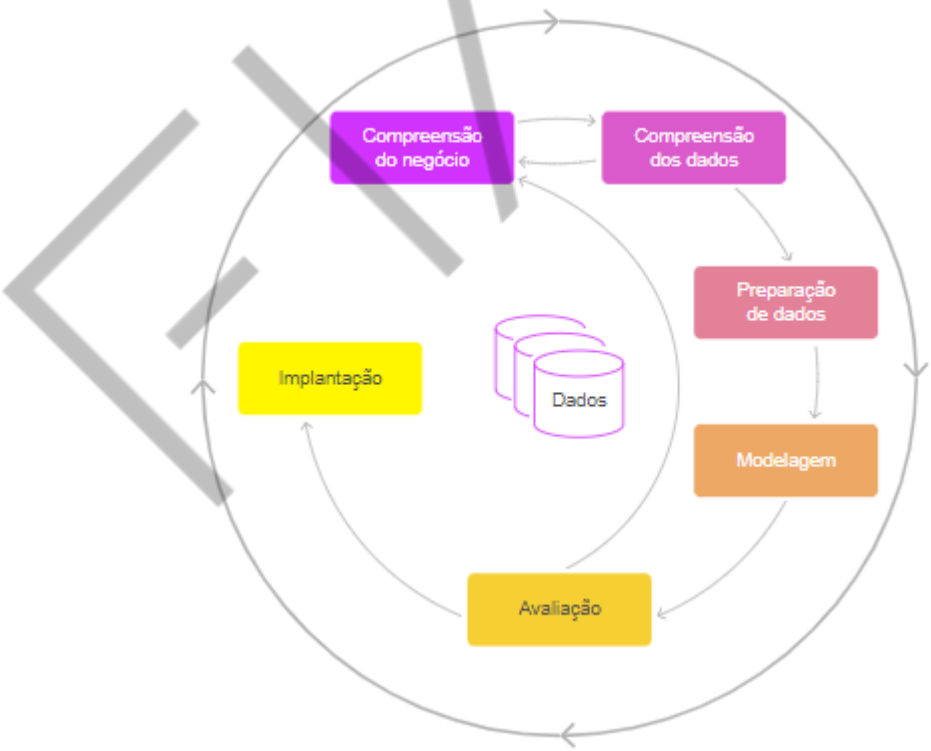

Figura 4 – Fases CRISP-DM
Fonte: CRISP-DM; Shearer (2000)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1. **Compreensão do Negócio (Business Understanding):** compreender o problema e o objetivo a ser resolvido do ponto de vista de negócio.

Nesta etapa é importante destacar que o problema de negócio raramente está bem definido e de forma clara, sendo necessário identificar o problema a ser atacado e estabelecer contato direto com especialistas em negócios e tomadores de decisão para reduzir possíveis falhas por má compreensão do negócio. Perguntas como: “O que queremos fazer exatamente?” ou “A qual pergunta de negócio queremos responder?” podem ajudar o cientista de dados nesta etapa. Normalmente não conseguimos uma resposta definitiva na primeira iteração, logo pode ser necessário voltarmos para esta fase a fim de refinar a compreensão do negócio.

2. **Compreensão dos Dados (Data Understanding):** compreende a captura, descrição, exploração e verificação da qualidade dos dados.

Nesta etapa, o foco é na identificação, coleta e análise de dados que auxiliarão a responder à pergunta de negócio identificada na fase anterior. É realizado um levantamento das bases de dados disponíveis e o entendimento de cada atributo e qualidade dos dados (existem muitos dados faltantes ou outliers?).

3. **Preparação dos dados (Data Preparation):** aplicar técnicas de transformação de dados para converter dados brutos em uma forma-padrão de uso.

Assim como a etapa de transformação do KDD Process, nesta etapa são aplicadas técnicas, como: discretização (converter variáveis contínuas em variáveis categóricas), normalização, agregação, criação de novas variáveis, redução de dimensionalidade e sintetização dos dados para criação de um conjunto de dados.

4. **Modelagem (Modeling):** construir modelos e métodos estatísticos para extrair padrões de interesse.

Nesta etapa são aplicados diferentes algoritmos de modelos estatísticos referentes à mineração de dados dependendo do objetivo do projeto. Caso seja necessário, é possível voltar para a fase anterior para adaptar a base de dados ao algoritmo que se deseja utilizar.

5. **Avaliação (Evaluation):** avaliar a performance do modelo gerado e a interpretação dos resultados para tomadas de decisão.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Nesta etapa são aplicadas médias estatísticas e/ou avaliação dos profissionais de negócio para avaliar o desempenho do modelo.

6. **Implantação (Deployment):** submeter o modelo validado para uso em produção, realizar a entrega do projeto.

Nesta etapa é realizada a entrega do projeto de ciência de dados realizado, disponibilizando os resultados, relatório e modelo no formato combinado para utilização de toda a empresa. Independente da implantação, a fase de avaliação gera novos insights e o processo retorna para a fase de entendimento do negócio.

Para saber mais: https://www.datascience-pm.com/wp-content/uploads/2021/08/CRISP-DM-for-Data-Science.pdf

2.4 Comparação entre KDD e CRISP-DM

Podemos compreender as semelhanças entre os métodos KDD e CRISP-DM pelo Quadro “Comparação KDD e CRISP-DM” abaixo, em que é possível identificar as etapas semelhantes entre os dois processos nas etapas de mineração de dados e avaliação.

Nota-se também que as etapas de Seleção e Processamento do KDD estão compreendidas na etapa de Compreensão dos Dados. As etapas 1, 2 e 3 de ambos os métodos compreendem a maior parte do tempo utilizado no projeto, normalmente entre 60% e 80%.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

KDD	CRISP-DM
	Compreensão do Negócio
Seleção/Processamento	Compreensão dos Dados
Transformação	Preparação dos dados
Mineração de Dados	Modelagem
Interpretação e Avaliação	Avaliação
	Implantação

Quadro 1 – Comparação KDD e CRISP-DM
Fonte: Elaborado pelo autor (2022)

Conheça outros métodos: Pesquise sobre outros métodos, como: SEMMA, Data Analytics Lifecycle, SAS Analytical Life Cycle, KDDS e Team Data Science Process

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3 MÉTODOS DE PESQUISA

Vimos até agora que um projeto de ciência de dados envolve conhecimentos multidisciplinares e muita pesquisa para formular hipóteses, testar e validar por meio de técnicas, como análise exploratória de dados e ferramentas estatísticas. E será que toda pesquisa é igual? A resposta é não, existem tipos de pesquisa com focos diferentes.

O método de pesquisa amplamente aplicado em Data Science é a pesquisa quantitativa, cujo resultado obtido pode ser utilizado no processo de tomada de decisão de negócio ou até mesmo auxiliar na relação de satisfação do cliente com produtos ou serviços.

3.1 Pesquisa quantitativa

A pesquisa quantitativa mantém foco em trabalhar na coleta e análise de dados que podem ser representados de forma numérica (quantizados), ou seja, deseja-se produzir indicadores numéricos e aplicar análises estatísticas. As seis características da pesquisa quantitativa são (GOERTZEN, 2017):

1) Lida com números para avaliar informações.
2) Esforça-se para ser objetivo.
3) Os dados podem ser medidos e quantificados.
4) Representa problemas complexos por meio de variáveis.
5) As descobertas podem ser avaliadas por meio de análise estatística.
6) Os resultados podem ser sumarizados, comparados ou generalizados.

Para saber mais: https://journals.ala.org/index.php/ltr/article/view/6325/8274

Exemplo: se queremos saber o número de televisores nas casas brasileiras entre os anos de 2010 e 2020. Ou se queremos que o resultado seja numérico, objetivo e direto, sem margens para interpretações subjetivas.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3.2 Dados quantitativos

Os dados presentes em variáveis do tipo métricas ou quantitativas estão relacionados com atributos que podem ser medidos ou contados com características numéricas, como exemplos: quantidade de filhos (0, 1, 2, 3...), a quantidade de senadores eleitos, a quantidade de carros fabricados por uma fábrica, temperatura, peso, altura ou salário de uma pessoa. E podem ser classificadas como discretas ou contínuas. Essa classificação pode ser visualizada na Figura “Classificação de dados quantitativos” a seguir.

Figura 5 – Classificação de dados quantitativos
Fonte: Elaborada pelo autor (2022)

Variável quantitativa contínua: pode assumir valores pertencentes a um intervalo de números reais e que resultam de uma mensuração métrica, por exemplo, temperatura, peso, altura ou salário de uma pessoa.

Variável quantitativa discreta: pode assumir um conjunto finito ou enumerável de valores que são provenientes, frequentemente, de uma contagem, como, por exemplo, a quantidade de filhos (0, 1, 2, 3...), a quantidade de senadores eleitos ou a quantidade de carros fabricados por uma fábrica.

Vale destacar que existe a pesquisa qualitativa que, embora não seja nosso objeto de estudo no momento, é tão importante quanto a pesquisa quantitativa. Nesse

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

caso, a variável qualitativa pode assumir valores nominais (ou categóricas, utilizadas para nomear ou atribuir rótulos ao dado, por exemplo, o estado civil de uma pessoa: solteiro, casado, viúvo, divorciado etc.; nas variáveis nominais não há um ordenamento de seus valores, não se pode dizer que “solteiro” é menor que “viúvo”, por exemplo) e ordinais (semelhante a nominais, mas as variáveis possuem ordenação, por exemplo, o nível de proficiência de um analista: Junior, Pleno, Sênior etc.; nesse caso a ordenação possui algum significado). O resultado de uma pesquisa qualitativa é de caráter subjetivo, em que se deseja compreender comportamentos, fenômenos e encontrar insights.

3.3 Métodos de pesquisa quantitativa

Os métodos de pesquisa quantitativa são baseados em análises de dados quantitativos (números), logo, devemos ter muita atenção ao levantamento dos dados a fim de obter um conjunto de dados vasto (necessário grande quantidade de dados para se obter significância estatística), confiável e de qualidade para a realização da descoberta do conhecimento e da tomada de decisão. Existem diversos métodos de pesquisa quantitativos de coletar dados, vamos conhecer alguns deles (experimental e levantamento).

- **Experimental:** a pesquisa experimental usa a análise estatística para provar ou refutar uma teoria. Seguindo de perto o desenho da pesquisa científica, deve incluir uma hipótese e variáveis relacionadas que possam ser controladas, calculadas, medidas e comparadas. São realizados experimentos controlados (em laboratório ou em campo), projetados de forma a produzir os dados necessários para análise posterior. A pesquisa experimental pode ter caráter exploratório, descritivo ou explicativo. Um exemplo é provar uma afirmação como certa ou errada: “A qualidade do nível de sinal da operadora de telefonia A é melhor do que a da operadora B”.
- **Levantamento (Survey):** as pesquisas de levantamento (questionários) continuam sendo a ferramenta mais popular usada nesta metodologia. Uma série de perguntas estruturadas é feita a um grupo-alvo, quantificando as respostas (predefinidas) a fim de analisá-las. O levantamento pode ser

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

realizado tanto de forma presencial como de forma on-line, que contribui para um menor custo, maior volume de dados e rapidez na coleta de dados. É usado para quantificar conceitos abstratos, como atitude ou comportamento em relação a um assunto, tópico, marca etc., porém pouco indicado no estudo de problemas referentes a relações e estruturas sociais complexas.

Entre as principais vantagens dos levantamentos estão (GIL, 2017):

a) Conhecimento direto da realidade: à medida que as próprias pessoas informam acerca de seu comportamento, crenças e opiniões, a investigação torna-se mais livre de interpretações calcadas no subjetivismo dos pesquisadores.

b) Economia e rapidez: desde que se tenha uma equipe de entrevistadores, codificadores e tabuladores devidamente treinados, torna-se possível a obtenção de grande quantidade de dados em curto espaço de tempo. Quando os dados são obtidos mediante questionários, os custos tornam-se relativamente baixos.

c) Quantificação: os dados obtidos mediante levantamento podem ser agrupados em tabelas, possibilitando sua análise estatística. As variáveis em estudo podem ser quantificadas, permitindo o uso de correlações e outros procedimentos estatísticos. À medida que os levantamentos se valem de amostras probabilísticas, torna-se possível até mesmo conhecer a margem de erro dos resultados obtidos.

Entre as principais limitações dos levantamentos estão:

a) Ênfase nos aspectos perceptivos: os levantamentos recolhem dados referentes à percepção que as pessoas têm acerca de si mesmas. Ora, a percepção é subjetiva, o que pode resultar em dados distorcidos. Há muita diferença entre o que as pessoas fazem ou sentem e o que elas dizem a esse respeito. Existem alguns recursos para contornar esse problema. É possível, em primeiro lugar, omitir as perguntas que sabidamente a maioria das pessoas não sabe ou não quer responder. Também se pode, mediante perguntas indiretas, controlar as respostas dadas pelo informante. Todavia, esses

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

recursos, em muitos dos casos, são insuficientes para sanar os problemas considerados.

b) Pouca profundidade no estudo da estrutura e dos processos sociais: mediante levantamentos, é possível a obtenção de grande quantidade de dados a respeito dos indivíduos. Como, porém, os fenômenos sociais são determinados sobretudo por fatores interpessoais e institucionais, os levantamentos mostram-se pouco adequados para a investigação profunda desses fenômenos.

c) Limitada apreensão do processo de mudança: o levantamento, de modo geral, proporciona visão estática do fenômeno estudado. Oferece, por assim dizer, uma espécie de fotografia de determinado problema, mas não indica suas tendências à variação e muito menos as possíveis mudanças estruturais. Como tentativa de superação dessas limitações, vêm sendo desenvolvidos com frequência crescente os levantamentos do tipo painel, que consistem na coleta de dados da mesma amostra ao longo do tempo. Muitas informações importantes têm sido obtidas mediante esses procedimentos, particularmente em estudos sobre nível de renda e desemprego. Entretanto, os levantamentos do tipo painel apresentam séria limitação, que é a progressiva redução da amostra por causas diversas, tais como mudança de residência e fadiga dos respondentes.

Vimos dois métodos de pesquisa quantitativos, com características e propósitos distintos de aplicação. Cada método possui suas particularidades e limitações e o cientista de dados deve fazer a escolha com base no problema que se deseja atacar. O Quadro “Métodos de pesquisa versus coleta de dados” abaixo exibe as técnicas utilizadas para coleta de dados quantitativos para análise posterior.

Método de pesquisa	Coleta de dados
Experimental	Experimentos
Levantamento	Questionários

Quadro 2 – Métodos de pesquisa versus coleta de dados
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Para saber mais: https://www.opuspesquisa.com/blog/tecnicas/pesquisa-quantitativa/

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

ATIVIDADE - TREINO

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams

Atividade 1

1. Sobre KDD Process e CRISP-DM, descreva com suas próprias palavras:

I - As principais vantagens e desvantagens das metodologias;

II – Cite exemplos de caso de uso dessas metodologias.

a) KDD Process

b) CRISP-DM

Atividade 2

2. Uma indústria de metalurgia busca se alinhar as novas tecnologias e deseja criar maturidade para se tornar uma empresa orientada a dados. Trata-se de um processo longo de mudança de cultura e transformação digital, nesse sentido, você foi contratado como consultor(a) para auxiliar neste processo.

Você deve realizar um levantamento dos pontos que podem ser melhorados por meio de metodologia de pesquisa quantitativa. Com o objetivo de avaliar a produtividade da empresa, responda:

a) Qual metodologia de pesquisa quantitativa pode ser utilizada para coleta de dados sobre produtividade das máquinas desta indústria de metalurgia? Por quê?

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Atividade 3

3. Um estudante de banco de dados deseja realizar uma pesquisa quantitativa online via Google Forms com o objetivo de ajudar para a melhoria contínua do curso de banco de dados. Ajude esse aluno elaborando pelo menos 6 questões quantitativas envolvendo variáveis contínuas e discretas.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

ALMEIDA, A. R. Construção de questionários. *In:* BOTELHO, D.; ZOUAIN, D. M. (Org.). **Pesquisa quantitativa em Administração.** São Paulo: Atlas, 2006.

BARBETTA, P. A. **Estatística aplicada às ciências sociais.** São Paulo: Atlas, 2010.

BRANTLEY, B. Elaboração de questionários e formulários. *In:* MALHOTRA, N. K. **Pesquisa em marketing:** uma orientação aplicada. 4. ed. Porto Alegre: Bookman, 2006.

CRESWELL, J. W. **Projeto de pesquisa:** métodos qualitativo, quantitativo e misto. 3. ed. Porto Alegre: Artmed, 2010.

GIL, A. C. **Como elaborar projetos de pesquisa.** São Paulo: Atlas, 2017.

GOERTZEN, M. J. **Introduction to Quantitative Research and Data.** Chicago, IL 60611-2795 USA: Library Technology Reports, 2017.

VERGARA, S. C. **Métodos de coleta de dados no campo.** São Paulo: Atlas, 2009.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com