FIAP ON

BUSINESS INTELLIGENCE & ANALYTICS

KDD - PROCESSOS DE DESCOBERTAS DO CONHECIMENTO

10

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 – Processo KDD.....3
Figura 2 – Diagrama de Venn para campos de estudos em dados.....6
Figura 3 – Data warehouse 9
Figura 4 – ETL e ELT 10
Figura 5 – Junções de tabelas (Join) 11
Figura 6 – Tipos de amostras.....12
Figura 7 – Exemplo de aplicação de PCA.....13
Figura 8 – Exemplo de *binning* (faixas de valores).....14
Figura 9 – Exemplo de preenchimento de valor fixo 0 para valores não existentes..14
Figura 10 – Exemplo de criação de duas variáveis Dummies *(Married, Divorced)* ...15
Figura 11 – Exemplo de aplicação das técnicas de padronização e normalização do tipo Max-Min (como resultado valores entre 0 e 1) 16
Figura 12 – Técnicas de *undersampling* e *oversampling* para correção de prevalência.....17
Figura 13 – Exemplo de partições de dados para aplicação de algoritmos 17

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 PROCESSOS DE DESCOBERTAS DO CONHECIMENTO 3
1.1 Introdução 3
1.2 Breve histórico de KDD 5
2 O PROCESSO DE KDD 8
2.1 Seleção, pré-processamento e transformação 8
2.1.1 Técnicas de seleção de dados 10
2.1.2 Técnicas de pré-processamento de dados 14
2.1.3 Técnicas de transformação de dados 16
2.2 Data Mining 18
3 CRISP-DM, UMA PROPOSTA DE METODOLOGIA PARA KDD 23
ATIVIDADE NÃO AVALIATIVA - ACESSANDO O AMBIENTE COLAB 25
ATIVIDADE NÃO AVALIATIVA - UM POUCO MAIS SOBRE KDD 26
ATIVIDADE NÃO AVALIATIVA - TÉCNICAS DE AMOSTRAGEM 27
REFERÊNCIAS 28

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 PROCESSOS DE DESCOBERTAS DO CONHECIMENTO

1.1 Introdução

O termo KDD foi utilizado pela primeira vez por Gregory Piatetsky-Shapiro em 1989 para descrever como podemos obter conhecimento a partir de bancos de dados. Naquela época, ter muitos dados já era um problema. Nos dias atuais, fala-se que não adianta ter muitos dados se não soubermos como utilizá-los, não soubermos extrair valor dos dados. E KDD se preocupa justamente com isso.

Assim como outras disciplinas de dados, o ponto de partida é obter os dados, prepará-los, o que significa muitas vezes limpá-los, remover duplicatas, organizar de forma diferente, transformar os dados até que possamos utilizá-los de fato. Dentro de um processo de KDD, após essas etapas estarem concluídas, como vemos na Figura "Processo KDD [FAYAD 96]", inicia-se a etapa de Data Mining com vistas à descoberta de padrões nos dados. Esses padrões podem levar a algum conhecimento aplicável em algum campo de estudo.

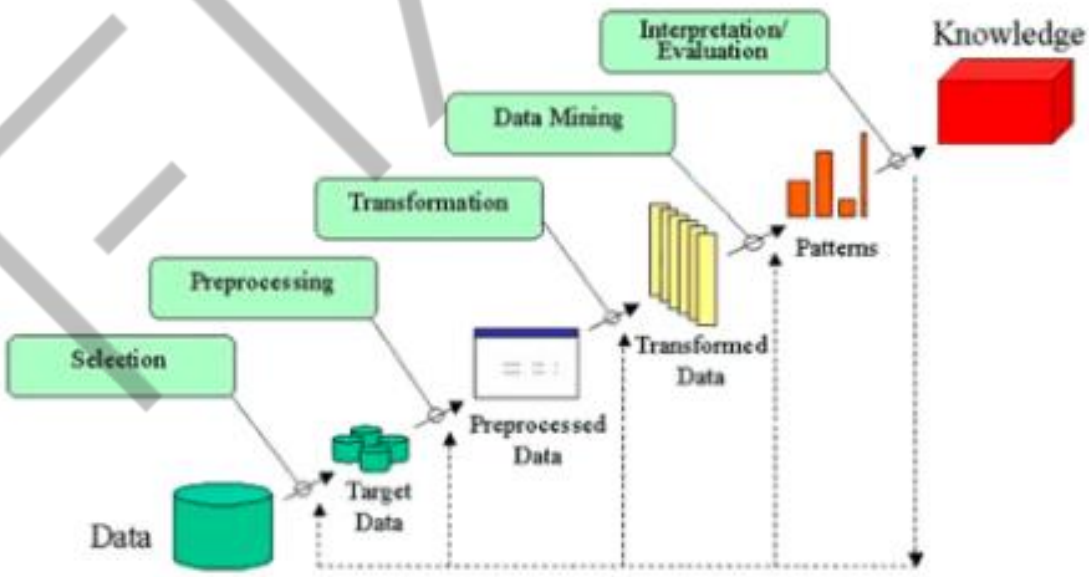

Figura 1 – Processo KDD
Fonte: Fayad *et al*. (1996)

Ou seja, é possível observar nesse diagrama que:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1. São necessárias etapas de tratamento de dados para uso posterior, na figura acima, as três primeiras etapas.
2. KDD diz respeito a todo o processo de descoberta de conhecimento, utilizando bancos de dados.
3. Data Mining é uma etapa do processo de KDD.
4. Reconhecimento de padrões (Pattern Recognition) é uma das etapas geradas após um processo de Data Mining.

Importante: Vale ressaltar que Pattern Recognition não é considerado por todos os autores como uma subárea de um processo de KDD. Existem atividades de Pattern Recognition que não fazem parte do campo de estudo de Data Mining/KDD.

Portanto é muito provável que a literatura por vezes use de forma indistinta, até intercambiando os termos entre KDD, Data Mining e Pattern Recognition. Quanto às etapas anteriores do processo de KDD resumidas na figura, como Selection, Preprocessing and Transformation, também podem ser incluídas previamente atividades como processos de construção de um DW (Data Warehouse), em que utilizamos o acrônimo ETC (Extract, Transform e Load) para denominá-los.

É possível existir KDD sem um DW previamente construído? Sim, é possível. Mas de alguma forma devem-se selecionar dados, processá-los e transformá-los, com ou sem um DW e ETL previamente. E se temos de fazer essas etapas de qualquer forma, por que não as orientar de uma forma estruturada e que disponibilize os dados para outros usos, por meio de um ETL e DW?

Mais recentemente, com o cenário de Big Data, tem se utilizado um conjunto de técnicas e ferramentas de uma nova geração, denominando o processo de Data Ingestion (ingestão de dados), com alguns modelos de arquitetura de tratamento de dados que em diversas situações são mais adequados, como o uso de ELT (em vez de ETL), tecnologias e métodos para tratamento de dados em tempo real, entre outros (MEHAN *et al.,* 2017). A própria concepção do DW tem sido discutida em arquiteturas como Data Lake ou, ainda mais recentemente, Delta Lake.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1.2 Breve histórico de KDD

Desde o início da década de 1990, com o surgimento do KDD e de um evento anual para discussões acerca do tema, os dez anos seguintes foram de uma grande explosão nas pesquisas, utilizações comerciais (com a disponibilização de cada vez mais ferramentas do tipo comercial) e também o aumento dramático no poder computacional de processamento.

Grandes bancos de dados se denominavam aqueles com alguns Megabytes e passaram a gerenciar Terabytes de informações dez anos depois. FAYAD *et. al.* (1996) faz uma interessante reflexão com alguns avanços observados e outras áreas que não avançaram muito.

A área de pesquisa de Data Mining que teve grande expressividade em meados da década de 1990 até os anos 2000 foi Text Mining, ou seja, mineração de dados de textos. Isso se deu muito em função do largo advento da Internet e da necessidade de compreender dados textuais gerados nessa plataforma. Muitas técnicas desenvolvidas no tratamento de dados textuais acabaram evoluindo para trabalhar com dados semiestruturados, aqueles muitas vezes encontrados na Internet ou grandes arquivos de logs de aplicações, dando origem ao chamado Structure Data Mining, do qual fazem parte Text Mining e Graph Mining.

Para dados estruturados, nos anos 2000, o que se viu, na prática, foi o advento cada vez maior de novos algoritmos, como foi o caso do SVM, Support Vector Machines, com objetivos de descobrir conhecimentos baseados em dados.

Muitos pesquisadores das áreas de IA, ML e Data Science passaram a discutir seus papers em eventos relacionados a KDD e Data Mining. Pudemos observar então uma convergência dessas áreas. O evento anual de KDD, chamado SIGKDD Conference, em sua 28ª edição, está recheado de papers sobre Data Science e IA.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

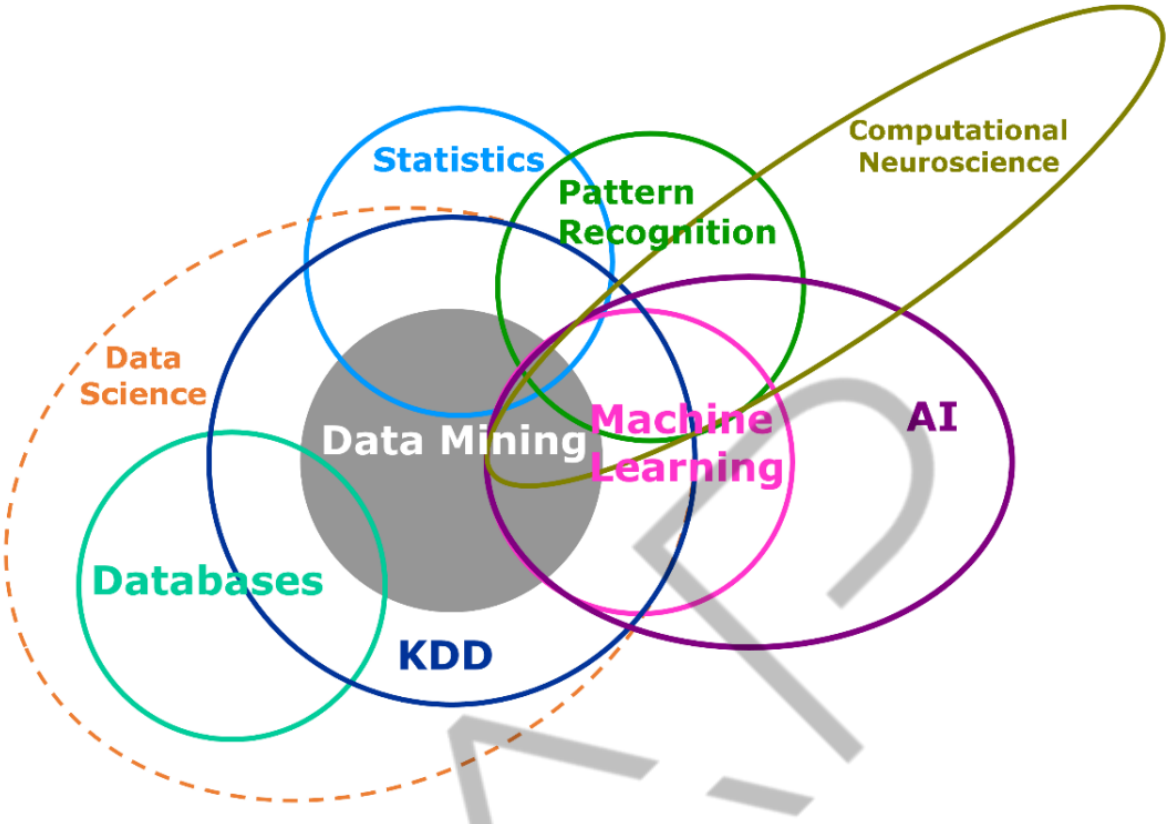

Figura 2 – Diagrama de Venn para campos de estudos em dados
Fonte: HALL *et al.* (2014)

A Figura “Diagrama de Venn para campos de estudos em dados” nos dá uma ideia das áreas de sobreposição dos campos de estudo de KDD, Data Mining (novamente apresentando Data Mining contido em KDD), mas apresenta também o processo de KDD inserido dentro de um contexto de Data Science, e com grande área de intersecção com IA. Castro (2015) também traz essas intersecções como “diferentes nomenclaturas”, citando IA e Machine Learning. Portanto, observamos uma convergência dessas áreas de conhecimento nos anos recentes.

Podemos tentar resumir da seguinte forma:

- **IA:** está mais direcionada a desenvolver métodos de aprendizagem, imitando os seres humanos, porém aplicando esses aprendizados por meio de algoritmos de máquina.
- **Machine Learning:** está mais direcionada a desenvolver métodos e algoritmos para resolver problemas de previsões e aprendizado baseado em dados.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

- **KDD:** está mais direcionada no conhecimento gerado a partir da aprendizagem baseada em dados, que por sua vez se utiliza de Data Mining como uma de suas etapas.
- **Data Mining:** está mais direcionada no uso de algoritmos, na aplicação deles, sejam eles oriundos de pesquisas geradas em Data Mining, sejam em IA ou ainda em ML.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 O PROCESSO DE KDD

2.1 Seleção, pré-processamento e transformação

Em qualquer projeto de dados, seja um estudo pontual, seja a construção de um algoritmo de previsão ou ainda de um dashboard para visualização de indicadores, é estritamente necessário que tenhamos dados preparados com qualidade para uso. Em projetos ou estudos de Data Mining não é diferente.

Podemos pensar que, em uma organização, seja de natureza empresarial, acadêmica, na área de saúde, governamental ou qualquer outra, na grande maioria das vezes há necessidade de reutilização de dados para novos usos, validações, atualizações de estudos, entre outros.

Daí a importância de avaliar se o conjunto básico de dados que será utilizado pode também servir a outros usos, além da atividade de Data Mining, para que se proponha alguma construção centralizada, como Data Warehouse, Data Lake ou algo do tipo.

Mas é importante ressaltar que as etapas de tratamento de dados para um Data Mining não são exclusivamente uma etapa de ETL ou Data Ingestion; há uma série de atividades de preparação de dados que são atividades intrínsecas ao Data Mining e/ou algoritmo que está sendo utilizado, ou ainda exclusivas ao projeto, necessitando de um tratamento de dados bem específico.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

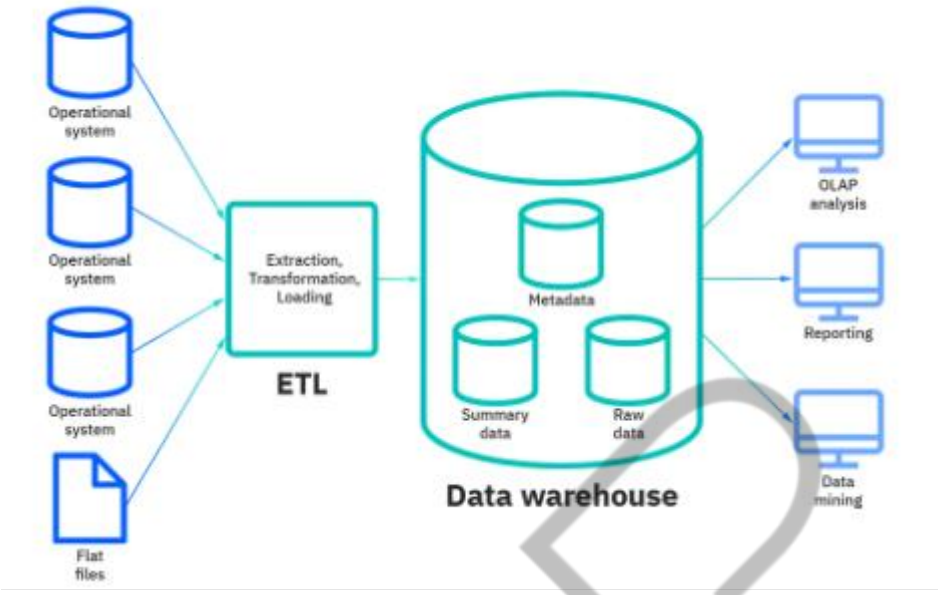

Figura 3 – Data warehouse
Fonte: IBM Cloud Education (2020)

Por exemplo, podemos utilizar dados de clientes e transações de compras que já estão inseridos em um DW ou Data Lake, porém para um estudo específico de RFV. Necessitamos calcular métricas específicas dos clientes e atribuí-las a eles, classificando-os, e pode ser que essas métricas sejam utilizadas somente no projeto de RFV.

Saiba mais: RFV significa Recência, Frequência e Valor, sendo um tipo de abordagem comum em marketing para segmentação de clientes.

Na Figura “Data warehouse”, vemos uma arquitetura tradicional de Data Mining que se utiliza de uma infraestrutura de Data Warehouse. Dentro da “caixinha” de Data Mining, ainda assim temos as etapas de seleção, pré-processamento e transformação de dados, mesmo sendo esses oriundos de um Data Warehouse (onde se presume que já houve um tratamento de dados prévio). A Figura “Data warehouse” também pode nos levar à incorreta conclusão de que só se faz Data Mining a partir de um Data Warehouse, o que não é uma verdade. Podemos tentar generalizar a figura da forma expressa na Figura “ETL e ELT”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

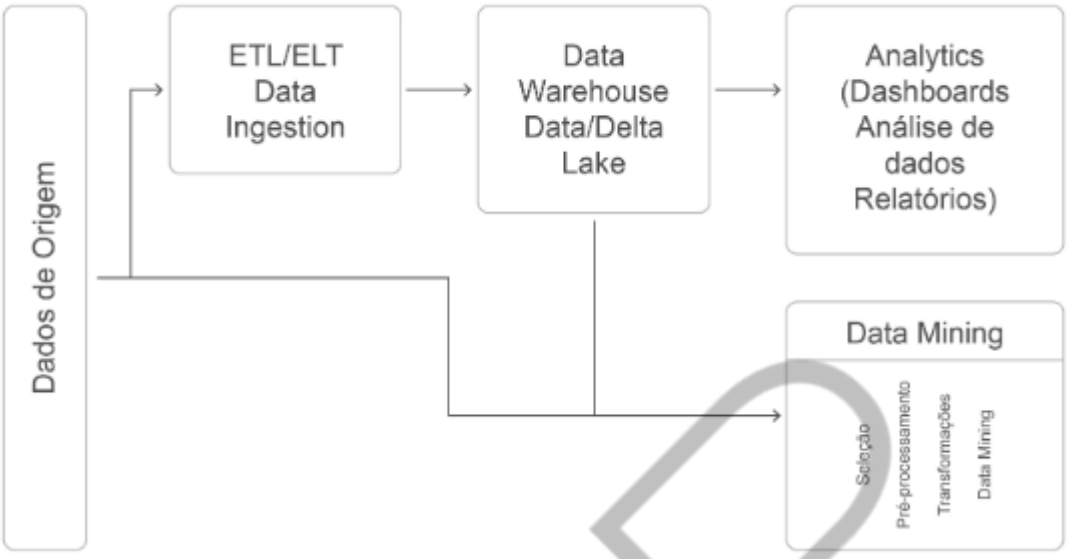

Figura 4 – ETL e ELT
Fonte: Elaborado pelo autor (2022)

Muitas vezes as técnicas de seleção, pré-processamento e transformações (e até as de Data Mining) acabam por se confundir, pois suas semânticas representam várias ações. Por exemplo, uma tarefa de Data Mining de uma tarefa pode ser utilizada como etapa de seleção de dados de uma nova tarefa, demonstrando que essas tarefas, apesar de se apresentarem em sequência, muitas vezes acabam por gerar ciclos (se você voltar a observar com atenção a Figura “Processo KDD [FAYAD 96]”, vai reparar que há uma seta saindo da etapa de interpretação dos dados e podendo levar a qualquer uma das etapas anteriores, gerando o ciclo).

Também é interessante ressaltar que algumas atividades de Seleção, Pré-Processamento, Transformações e Data Mining, que detalharemos em seguida, podem ter sido tratadas previamente nas etapas de ETL/ELT/Data Ingestion, facilitando o trabalho da etapa de Data Mining.

2.1.1 Técnicas de seleção de dados

Para escolha de quais dados trataremos na etapa de Data Mining, é importante entender inicialmente qual é o problema que estamos procurando resolver. Feito isso, teremos condições de definir onde podemos encontrar dados relacionados ao problema para análise.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

As atividades envolvidas na seleção de dados podem ser:

- Seleção de dados em tabelas.
- Junções, uniões de dados: unir tabelas e informações relacionadas (como uma tabela de clientes e outra de transações de vendas deles).

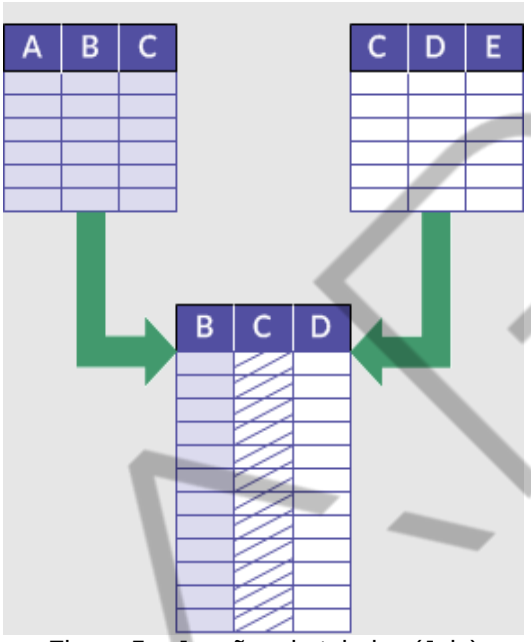

Figura 5 – Junções de tabelas (Join)
Fonte: Galvaníze (2021)

- Definição de amostras de trabalho: nem sempre é necessário e nem indicado trabalhar com todos os dados disponíveis em uma tabela. Existem diversas técnicas para se trabalhar com amostragens de dados, que também se chamam de redução de dados horizontal.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

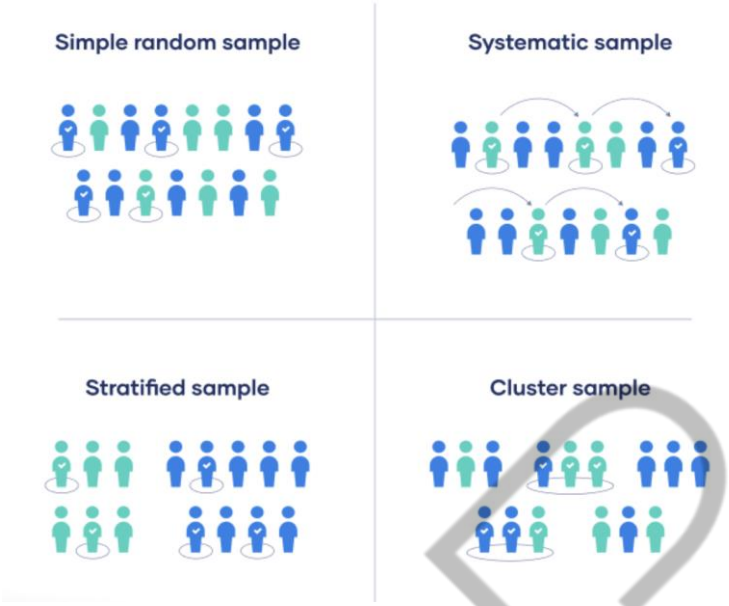

Figura 6 – Tipos de amostras
Fonte: Scribbr (2019)

- Redução de dados vertical: além da mais óbvia, que seria não utilizar todos os campos ou colunas de uma tabela de dados, temos algumas técnicas, como:
  - Análise de componente principal, que atua como uma espécie de compressão de dados de colunas.
  - Podemos utilizar resultados de algoritmos de Data Mining para se realizarem reduções de dados verticais, o que se denomina na literatura *wrapper*.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

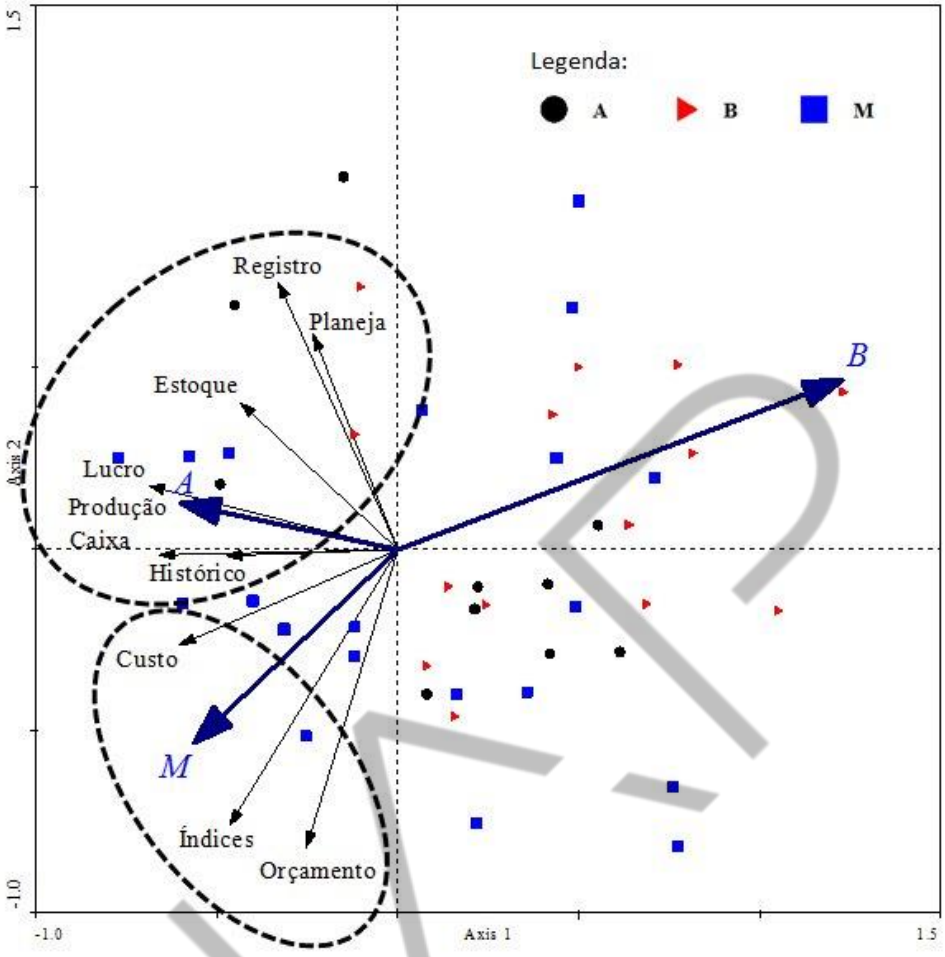

Figura 7 – Exemplo de aplicação de PCA
Fonte: ResearchGate (2015)

- Redução de valores: existem várias técnicas para reduzirmos valores dentro de um campo ou uma coluna de uma tabela, com diversos propósitos, como, por exemplo:
  - Identificação de hierarquias nos dados.
  - Arredondamento de valores.
  - Definições de faixas de valores (por exemplo, faixas etárias ou faixas fixas por quantidades relativas ou percentuais).

Importante: Também se utilizam os termos *encaixotamento* ou *binning*

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

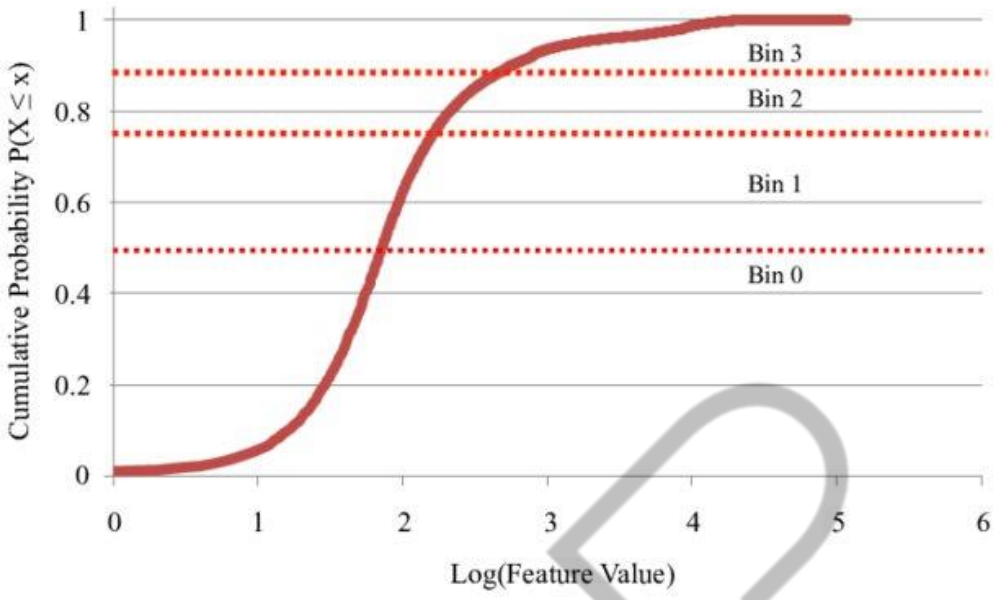

Figura 8 – Exemplo de *binning* (faixas de valores)
Fonte: ResearchGate (2011)

2.1.2 Técnicas de pré-processamento de dados

Na grande maioria das vezes, os dados, após selecionados, não estão ainda prontos para serem utilizados por uma variedade grande de razões, como erros de entrada de dados, problemas na transmissão dos dados, inexistência de valores, entre tantas outras. Abaixo vemos algumas das possíveis tarefas de pré-processamento:

- Limpeza de valores ausentes: com exclusão das linhas da tabela.
- Preenchimento de valores ausentes: com entrada manual de dados, valores fixos, medidas estatísticas ou resultados de métodos de Data Mining (mais uma vez vemos aqui o caráter cíclico dessas atividades).

	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	NaN
1	9	NaN	9.0	0	7.0
2	19	17.0	NaN	9	NaN

df.fillna(0) →

	col1	col2	col3	col4	col5
0	2	5.0	3.0	6	0.0
1	9	0.0	9.0	0	7.0
2	19	17.0	0.0	9	0.0

Figura 9 – Exemplo de preenchimento de valor fixo 0 para valores não existentes
Fonte: BADR (2019)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

- Tratamento de inconsistências: que podem ser valores não aceitos para determinado campo, como uma idade de uma pessoa superior a 150 ou 200 anos, gerando uma eliminação da linha ou correção do valor.
- Codificação de dados: os algoritmos tratam essencialmente com cálculos e, para realizarem cálculos, necessitam de números. É bem verdade que muitos algoritmos já têm uma etapa de pré-processamento incorporada no próprio algoritmo para transformar, por exemplo, uma coluna com dados categóricos em dados numéricos. Mas não é o caso em todos os algoritmos e, ainda assim, muitas vezes não se tem um controle exato do que o algoritmo está executando. O tipo mais comumente utilizado é a criação do que chamamos de variáveis Dummy.

Importante: Uma variável Dummy é uma representação binária, do tipo 0 ou 1 para alguma característica presente ou não.

Income	Age	Marital Status
$45,000	23	Single
$48,000	25	Single
$54,000	24	Single
$57,000	29	Single
$65,000	38	Married
$69,000	36	Single
$78,000	40	Married
$83,000	59	Divorced
$98,000	56	Divorced
$104,000	64	Married
$107,000	53	Married

→

Income	Age	Married	Divorced
$45,000	23	0	0
$48,000	25	0	0
$54,000	24	0	0
$57,000	29	0	0
$65,000	38	1	0
$69,000	36	0	0
$78,000	40	1	0
$83,000	59	0	1
$98,000	56	0	1
$104,000	64	1	0
$107,000	53	1	0

Figura 10 – Exemplo de criação de duas variáveis Dummies *(Married, Divorced)*
Fonte: Statology (2021)

- Enriquecimento de dados: utilizar-se de dados externos muitas vezes pode significar o sucesso ou fracasso de um estudo de dados. Podemos utilizar, por exemplo, dados climáticos para entender como se comportam as vendas, podem variar em dias de chuva ou não.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2.1.3 Técnicas de transformação de dados

Como citado anteriormente, algumas técnicas podem ser classificadas como pré-processamento de um determinado ponto de vista e transformação de outro ponto de vista. Alguns autores apresentam, também, classificações um pouco diferenciadas. Ainda assim, pouco diverge no resultado final.

Podemos citar:

- Tarefas de padronização e normalização de dados: existem diversos tipos de normalizações que, em suma, significam que transformaremos uma coluna com valores numéricos originais em valores dentro de um novo intervalo. É similar à atividade de mudança de escala de valores. Muitos algoritmos simplesmente necessitam de dados normalizados para operarem de forma adequada, como, por exemplo, o K-Means.

Standardisation

	Age	Salary
0	0.758874	7.494733e-01
1	-1.711504	-1.438178e+00
2	-1.275555	-8.912655e-01
3	-0.113024	-2.532004e-01
4	0.177609	6.632192e-16
5	-0.548973	-5.266569e-01
6	0.000000	-1.073570e+00
7	1.340140	1.387538e+00
8	1.630773	1.752147e+00
9	-0.258340	2.937125e-01

Max-Min Normalization

	Age	Salary
0	0.739130	0.685714
1	0.000000	0.000000
2	0.130435	0.171429
3	0.478261	0.371429
4	0.565217	0.450794
5	0.347826	0.285714
6	0.512077	0.114286
7	0.913043	0.885714
8	1.000000	1.000000
9	0.434783	0.542857

Figura 11 – Exemplo de aplicação das técnicas de padronização e normalização do tipo Max-Min (como resultado valores entre 0 e 1)
Fonte: KD Nuggets (2020)

- Construção de atributos: o cálculo da idade de uma pessoa baseado na data de nascimento é um exemplo simples.
- Correção de prevalência: alguns algoritmos que trabalham, por exemplo, com classificação necessitam de um número mínimo de observações (linhas ou casos) de cada classe para conseguirem ser executados de forma

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

adequada. Quando há um desbalanceamento grande (ou seja, um % muito pequeno em relação a outro), pode ser necessário equilibrar essas proporções.

Figura 12 – Técnicas de *undersampling* e *oversampling* para correção de prevalência
Fonte: ResearchGate (2020)

- Partição de conjunto de dados: quando estamos construindo um algoritmo para, por exemplo, realizar uma previsão, é útil que tenhamos uma forma de avaliar se a previsão é bem-sucedida antes de utilizarmos na prática nossas previsões. Para isso, podemos “guardar” uma amostra não utilizada na construção do algoritmo com fins de validação ou teste do algoritmo posteriormente.

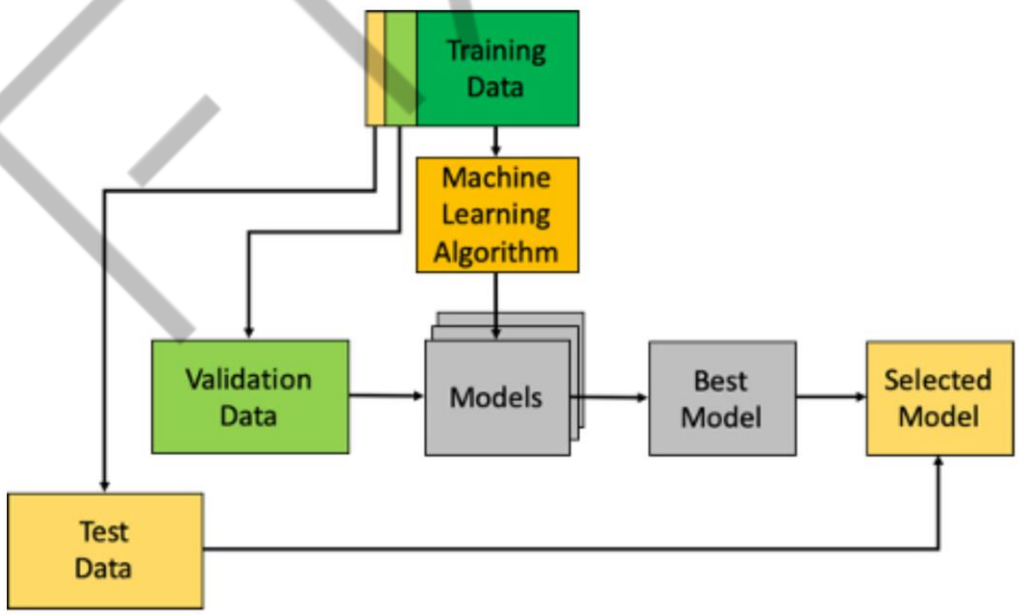

Figura 13 – Exemplo de partições de dados para aplicação de algoritmos
Fonte: ODSC (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2.2 Data Mining

Como vimos na Figura “Processo KDD [FAYAD 96]”, Data Mining é uma etapa de processo de KDD, aplicada após as etapas de seleção, pré-processamento e transformação dos dados. As chamadas “tarefas primárias” de KDD, aplicadas dentro da etapa de Data Mining, podem ser descritas (GOLDSCHMIDT, 2015) como:

1. Regras de associação: baseia-se em encontrar subconjuntos de dados que possam ocorrer de forma simultânea e frequente. Uma das aplicações de mercado em varejo é o que chamamos de análise de cestas, em que encontramos itens que são vendidos de forma frequente simultaneamente. Isso pode ser útil para orientar a disposição de mercadores em uma loja ou supermercado, por exemplo.
2. Sequências: é uma extensão da tarefa de regra de associação, quando há uma sequência que se está estudando. Por exemplo, um produto na cesta leva à compra de um outro produto por consequência. Ou uma ordem de compras de cestas em dias diferentes que pode sugerir um padrão de consumo.
3. Classificação: esta tarefa parte da premissa de que temos um conjunto de dados observados com várias características, é uma característica específica que queremos analisar. Este é o caso de transações de um site de Web Commerce, após classificarmos as transações como fraudulentas e não fraudulentas.
4. Regressão: ao se utilizar uma tarefa de regressão, estamos procurando analisar uma relação de dependência, de causa e consequência, na qual a consequência é a variável que se está estudando como alvo e as causas são as outras características dos dados. Um bom exemplo é uma previsão de vendas horária *(forecasting)* baseada no histórico recente de vendas, tipos de produtos, sazonalidades diárias, semanais e horárias, preço e promoção, entre outros fatores.
5. Sumarização: tarefa que busca descrever os dados de forma sumarizada, isto é, resumida, mas com um entendimento, uma explicação deles. Ela pode ser a resposta, por exemplo, das características dos clientes de um

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

determinado produto e que residam em determinada região, e teria como resposta algo do tipo: “São mais de 73% dos clientes com faixa de renda entre R$ 5.000,00 e R$ 7.500,00, nível superior completo e que possuem residência própria”.

6. Clusterização: esta tarefa consiste em aglomerar observações ou objetos que possam ser similares entre si. Buscam definir algumas características básicas relevantes e utilizam técnicas apropriadas para formação dos clusters ou aglomerados.

Na literatura, utilizam-se muitas vezes do termo “agrupamento”, porém há discordâncias quanto ao uso desse termo, visto que um cluster ou aglomerado pode reunir objetos que, após uma análise detalhada, se entende que não faça muito sentido. Também pode ser que consigamos formar um grupo a partir de um cluster (aqui se utilizando da palavra grupo como uma coleção de objetos com características bem definidas), mas isto não é sempre verdade.

Podemos formar aglomerados de clientes que têm tíquete de compra alto e frequência de compra alta. Esses clientes poderiam ser considerados como VIPs e, portanto, receberem alguma promoção especial.

7. Previsão de séries temporais: como o nome sugere, é uma tarefa de previsão (futura) de dados, mas com a característica específica de tratar com dados classificados como sendo “séries temporais”. Existem algumas características específicas que precisamos observar nos dados para podermos caracterizá-los como uma série temporal. Uma previsão de série temporal utiliza-se de técnicas de regressão, sendo muitas vezes, portanto, classificada como um subconjunto de regressão.

8. Detecção de desvios: quando temos uma característica bem conhecida em nossos dados e temos uma certa ideia de grandes variações além dos valores usuais, isso pode denotar algum tipo de anomalia, utilizam-se tarefas de detecção de desvios para encontrar ou monitorar esses desvios além do esperado. Isso pode acontecer no monitoramento de temperatura de um sensor de IoT aplicado em um determinado equipamento. Se a temperatura subir demasiadamente em um intervalo curto, pode denotar um problema iminente ou risco.

Além disso, temos os métodos de mineração de dados, descritos como:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1. **Métodos tradicionais:**
    a. KNN: em português, também é chamado de vizinho mais próximo. É como se tentássemos identificar características de um objeto pelo objeto mais próximo a ele conhecido e assumirmos a premissa de que deve ser parecido. Pensando em geografia, por exemplo, podemos imaginar que a renda de pessoas de um mesmo bairro deve ser próxima, visto que os preços de terrenos e custo de vida naquele bairro não deve divergir muito.

    b. Classificador Bayesiano: como o nome sugere, utiliza-se por base o Teorema de Bayes, em que se aplicam os conceitos de probabilidade condicional. Aplicações desse algoritmo em classificação de texto, como algoritmos para definir o que é um e-mail spam ou não, tiveram sucesso.

    c. K-Means: em português, também é chamado de k-médias e tem um grau de similaridade com o KNN. A diferença é que não temos uma característica-alvo que estamos buscando espelhar (que, no exemplo citado acima, foi renda). Simplesmente encontramos objetos que estão próximos e depois temos a tarefa de descobrir o que fazer com isso.

    d. Apriori: é dos métodos associativos mais aplicados em mineração de dados. Observam-se os itens mais frequentes em conjuntos de dados, sendo que uma das aplicações mais notáveis é em análise de cestas de consumo. Mas as aplicações desse algoritmo não se restringem a esse tipo de aplicação, sendo possível aplicar em outros segmentos, como, por exemplo, em análise de qualidade, buscando associações entre falhas (mais frequentes).

    e. C4.5: talvez uma das grandes contribuições dos algoritmos de árvores de decisão seja sua facilidade em comunicar resultados de dados. O algoritmo C4.5 é uma implementação de árvores de decisão feita por John Ross Quinlan, que teve bastante repercussão dada sua simplicidade de implementação e utilização prática.

Saiba mais em: https://link.springer.com/content/pdf/10.1007/BF00993309.pdf.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Posteriormente, Quinlan lançou a versão C5, porém uma evolução nítida desse tipo de algoritmo é o CART, um acrônimo para Classification And Regression Trees, que está implementado praticamente em todos os softwares open-source ou comerciais no mercado atualmente.

f. Máquinas de Vetores de Suporte (SVM): desenvolvido inicialmente por um grupo de pesquisadores da Bell Laboratories, o SVM evoluiu a partir de meados da década de 1990 e ganhou notoriedade quando aplicado em conjunto com o classificador bayesiano na implementação de soluções antispam. O nome se deve ao método utilizado em seu cálculo, Support Vector Machines. Estudos recentes, a partir de 2010, como o de Samsudin *in* Journal of Applied Sciences, 2010, demonstraram sua versatilidade – criado inicialmente como um classificador, sua implementação como regressor demonstrou uma performance muito boa em aplicações de *forecasting* (séries temporais).

2. Métodos Bioinspirados:

a. Redes neurais: a ideia básica de uma rede neural é simular o comportamento de células nervosas (neurônios) humanas em formato de rede. O campo de estudo de redes é muito vasto, existem dezenas de tipos de redes (cada qual com um algoritmo específico). Nos anos recentes, as redes de aprendizagem profunda (Deep Learning) têm ganhado muita notoriedade devido a suas aplicações em tratamento de imagens (por exemplo, carro autônomo ou direção assistida), sons, entre outras aplicações de sucesso.

b. Algoritmos genéticos: o nome desta classe de algoritmos deriva do princípio de Darwin para evolução das espécies. São algoritmos adaptativos com diversas aplicações, entre elas, problemas de otimização, em que buscamos ajustes de parâmetros.

c. Lógica Nebulosa (Fuzzy): a lógica booleana (0 e 1) é amplamente aceita e aplicada (com sucesso) em diversos segmentos, inclusive em Data Mining (por exemplo, árvores de decisão booleanas, classificadores binários etc.). A proposição da Lógica Fuzzy, de forma resumida, é que

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

possamos ter valores intermediários entre o 0 e 1. Temos diversas aplicações desse tipo de lógica em Data Mining, sendo que em mineração de textos seus resultados ficam mais evidentes.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3 CRISP-DM, UMA PROPOSTA DE METODOLOGIA PARA KDD

Em 2000 foi lançada uma metodologia de aplicação de Data Mining padrão para o mercado, denominada CRIPS-DM. O acrônimo significa Cross-Industry Standard Process for Data Mining, ou em uma tradução livre, Processo Padrão Interindústrias para Data Mining.

O CRISP-DM foi proposto por um consórcio de empresas de tal forma que existisse somente um processo independentemente da empresa (indústria) que fosse aplicá-lo.

O artigo original foi publicado no *Journal of Data Warehousing*, outono de 2000. Acesse em: https://web.archive.org/web/20060624054212/http://www.crisp-dm.org/News/86605.pdf

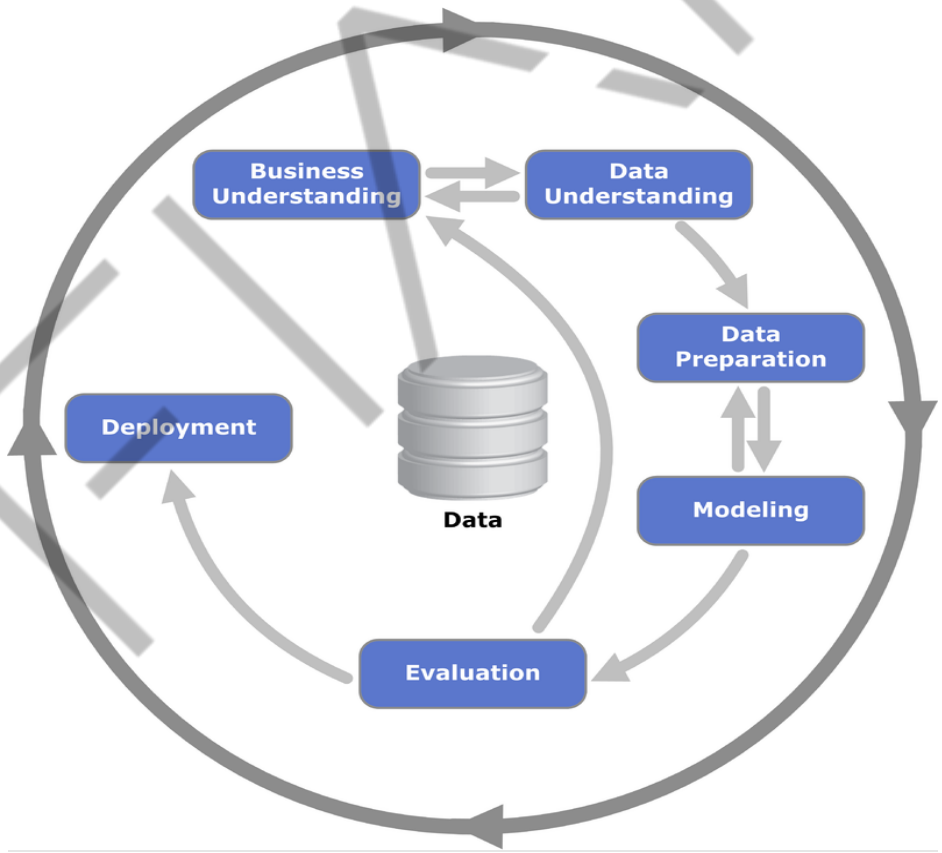

Figura 11 – CRISP-DM
Fonte: Journal of Data Warehousing (2000)

O CRISP-DM passou a ser utilizado como referência na indústria a partir de então. Se compararmos com a Figura “Processo KDD [FAYAD 96]”, podemos ver que há uma série de similaridades, porém com algumas diferenças, como o foco inicial em

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

entendimento do negócio ao qual estamos aplicando, bem como a etapa de deployment, ou entrega, que dá ares de conclusão, se o objeto for uma análise pontual, ou ainda um software em execução (produção), se o objeto for alguma solução que deva ser executada continuamente.

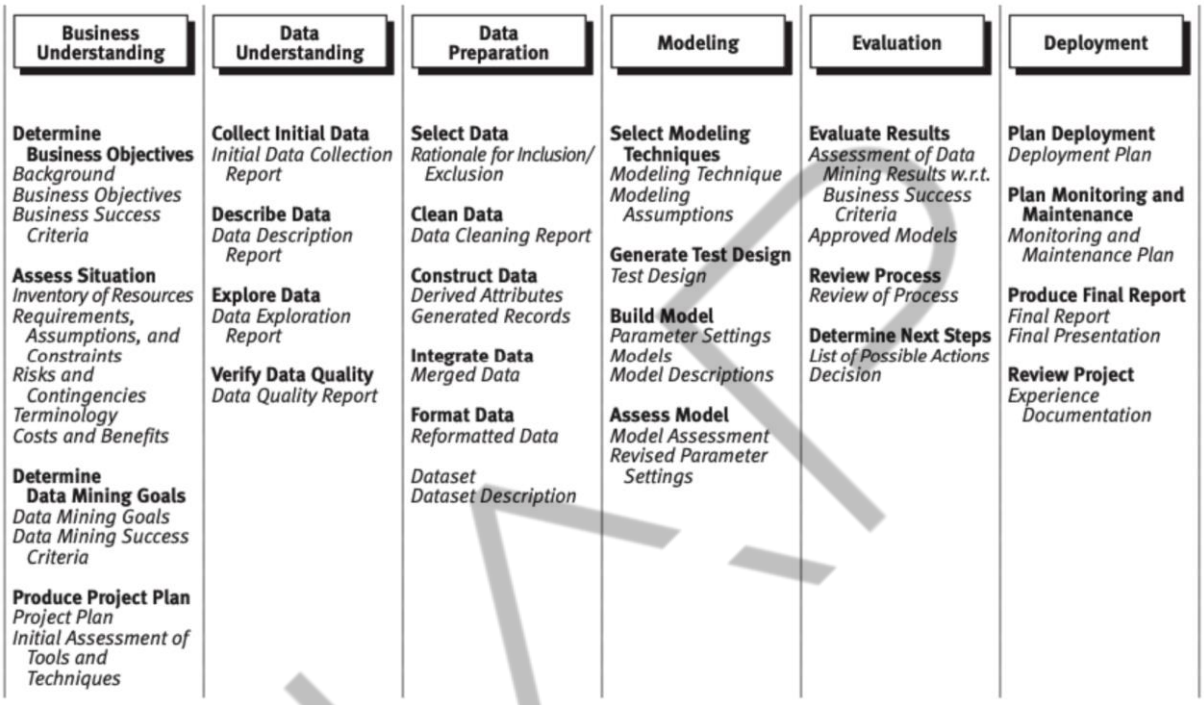

Figura 12 – CRISP-DM – Processos
Fonte: Journal of Data Warehousing (2000)

Existem outras metodologias ou frameworks além do CRISP-DM, porém a ideia básica não fica muito distante do aqui exposto. Portanto, ao compreender bem uma dessas metodologias, certamente a adaptação a outras será relativamente trivial, com alguns ajustes de nomenclatura.

Utilizar-se de uma metodologia ou um framework é especialmente interessante, pois serve como um guia ou orientação para alguns pontos que podem ser observados no projeto em que se está trabalhando.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

ATIVIDADE NÃO AVALIATIVA - ACESSANDO O AMBIENTE COLAB

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams

Esta é a hora de botar a mão na massa para conhecer o ambiente Google Colab! Este ambiente nada mais é do que um site na cloud da Google onde podemos executar códigos Python e outras linguagens, com a facilidade de não ser necessário nenhuma instalação ou configuração de ambiente.

É simples: faça o login com algum conta google (pode ser no seu gmail), depois aponte seu browser para: https://colab.research.google.com/.

Para conhecer o ambiente, execute alguns dos próprios códigos que já aparecem na página ou então alguns dos exemplos do capítulo.

Registre seus experimentos:

Comandos que executei	Salvar
1.	
2.	
3.	

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

ATIVIDADE NÃO AVALIATIVA - UM POUCO MAIS SOBRE KDD

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams

Uma excelente forma de fixar conhecimentos é realizar um resumo do nosso entendimento sobre determinado tópico. Após o estudo do capítulo, registre um resumo dos principais pontos (5 ao menos) que mais te chamaram a atenção neste capítulo.

Registre seus experimentos.

Comandos que executei	Salvar
1.	
2.	
3.	
4.	
5.	

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

ATIVIDADE NÃO AVALIATIVA - TÉCNICAS DE AMOSTRAGEM

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams

Neste capítulo, discorremos sobre uma série de técnicas de KDD, sendo que uma delas, a amostragem, é essencial para darmos início a projetos de forma mais bem estruturada. Faça uma breve pesquisa na internet e cite 3 pontos relevantes do porquê da sua importância.

Resumo do capítulo	Salvar
1.	
2.	
3.	

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

CASTRO, L. N.; FERRARI, D. G. **Introdução à Mineração de Dados**. São Paulo: Saraiva, 2016.

FAYAD, U. M.; PIATETSKY-SHAPIRO, G.; SMYTH, P. **Advances in Knowledge Discovery and Data Mining.** Menlo Park, CA: AAAI Press/The Mit Press, 1996.

GOLDSCHMIDT, R.; PASSOS, E.; BEZERRA, E. **Data Mining:** conceitos, técnicas, algoritmos, orientações e aplicações. Rio de Janeiro: Campus/Elsevier, 2015.

MEEHAN, J. *et al.* Data Ingestion for the Connected World. Biennial Conference on Innovative Data Systems Research, 8., 2017, Chaminade, CA, USA. **Online Proceedings** […]. Chaminade, CA, USA, 2017. Disponível em: www.cidrdb.org. Acesso em: 28 abr. 2022.

SAMSUDIN, R.; A. SHABRI, A.; SAAD, P. A Comparison of Time Series Forecasting using Support Vector Machine and Artificial Neural Network Model. **Journal of Applied Sciences**, v. 10, p. 950-958, 2010. Disponível em: https://scialert.net/fulltext/?doi=jas.2010.950.958. Acesso em: 13 mar. 2022.

THE DATA WAREHOUSING INSTITUTE. The CRISP-DM Model: The New Blueprint for Data Mining. **Journal Of Data Warehousing,** Volume 5, Number 4, 2000 Disponível em: https://web.archive.org/web/20060624054212/http://www.crisp-dm.org/News/86605.pdf. Acesso em: 05 mar. 2022.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com