FIAP ON

BUSINESS INTELLIGENCE & ANALYTICS

ANÁLISE DESCRITIVA COM PYTHON

11

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 – Média aritmética 7
Figura 2 – Média valores ausente 8
Figura 3 – Exemplo média e mediana (1) 8
Figura 4 – Exemplo média e mediana (2) 9
Figura 5 – Moda 10
Figura 6 – Exemplo moda 10
Figura 7 – Tamanho da TV na sala 12
Figura 8 – Exemplo amplitude total 13
Figura 9 – Diferença std 14
Figura 10 – Cálculo std 15
Figura 11 – Head titanic 16
Figura 12 – Dados age 16
Figura 13 – Dados age outliers 17
Figura 14 – Titanic describe 17

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Exemplo de média aritmética.....6
Código-fonte 2 – Exemplo média valores ausente.....7
Código-fonte 3 – Exemplo média e mediana.....9
Código-fonte 4 – Exemplo moda.....10
Código-fonte 5 – Exemplo tamanho TV na sala.....12
Código-fonte 6 – Exemplo amplitude total.....13
Código-fonte 7 – import dataset titanic.....16

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 ANÁLISE DESCRITIVA COM PHYTON.....5
1.1 Introdução 5
2 MEDIDAS DE TENDÊNCIA CENTRAL.....6
2.1 Média aritmética, mediana e moda 6
2.1.1 Média aritmética 6
2.1.2 Mediana.....8
2.1.3 Moda 9
2.2 Exemplo de aplicação 11
3 MEDIDAS DE DISPERSÃO E VARIABILIDADE.....13
3.1 Amplitude total.....13
3.2 Desvio-padrão 14
3.3 Variância 15
3.4 Exemplo de aplicação 15
ATIVIDADE TREINO.....19
REFERÊNCIAS.....21

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 ANÁLISE DESCRITIVA COM PHYTON

1.1 Introdução

Em projetos de ciência de dados, a análise descritiva é a fase inicial de estudo dos dados coletados, é nessa fase que organizamos, resumimos, descrevemos características e comparamos tais características entre dois ou mais dos conjuntos de dados. Como resultados possíveis dessa etapa, temos a identificação de anomalias como outliers, dados ausentes, registros errados, dispersos, tendência do conjunto de dados (padrões) e insights.

Diferente do que você imagina, utilizamos as ferramentas de análise descritiva a todo o momento em nosso dia a dia. São elas que dão suporte ao entendimento do problema e à tomada de decisão. Por exemplo, nas matérias em jornais, noticiários ou na internet, é frequente o uso de gráficos, tabelas, índices, porcentagens e médias para dar entendimento a dados sobre a temperatura, taxa de desemprego, inflação, entre outros.

É por meio de métodos estatísticos e com o auxílio de recursos computacionais que realizamos a análise descritiva de conjuntos de dados ou banco de dados, o objetivo da análise de dados é:

- identificar e comparar comportamentos médios e discrepantes, além de investigar interdependência entre variáveis, revelar tendências, etc.;
- compilar e exibir de forma eficiente a informação contida nos dados e permitir novos insights para o entendimento do problema de negócio e apoiar a tomada de decisão de forma consciente.

Para nos ajudar nesta etapa, vamos utilizar algumas bibliotecas de Python que são amplamente utilizadas para realizar análises de dados e que fazem parte do “kit básico” de todo cientista de dados, algumas são: Pandas, Matplotlib, NumPy, SciPy, Seaborn e existem outras. Nas próximas seções, serão introduzidos alguns conceitos matemáticos e estatísticos para extrair informações significativas dos dados brutos e paralelamente realizaremos algumas análises em conjuntos de dados do mundo real.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 MEDIDAS DE TENDÊNCIA CENTRAL

2.1 Média aritmética, mediana e moda

É possível, em um conjunto de dados de variável quantitativa, ou seja, numérica, extrair medidas de centralidade que, em outras palavras, representam um valor típico em torno dessa variável. Sendo as mais conhecidas dessas medidas de centralidades: a média aritmética, a mediana e a moda.

2.1.1 Média aritmética

A média aritmética de um conjunto de dados é definida pela soma dos elementos dividida pela quantidade de elementos do conjunto, como é demonstrada pela equação 1.

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n} = \frac{\sum_{i=1}^{n} \bar{x}_i}{n} \tag{1}$$

Vamos realizar essa operação utilizando um conjunto de dados e as bibliotecas do Python, certifique-se de ter as bibliotecas instaladas, caso contrário, faça a instalação com o comando: pip install nome_pacote. Neste exemplo, vamos calcular o valor médio de salário, o resultado esperado é de média de 3825, como exibe a Figura “Média aritmética” abaixo, com a saída do notebook.

```
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca Pandas.


# Cria array.
salario =
np.array([1000,1000,2400,900,16000,5000,600,9000,4000,1000,3000,2000])

# cria um dataframe a partir da ndarray
df=pd.DataFrame(salario,columns=['salario'])

# Calcula a média de salário
df['salario'].mean()
```

Código-fonte 1 – Exemplo de média aritmética
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
In [2]: import numpy as np        # Importa biblioteca numpy.
        import pandas as pd


        salario = np.array([1000,1000,2400,900,16000,5000,600,9


        df=pd.DataFrame(salario,columns=['salario']) # cria um


        df['salario'].mean()# Calcula a média de salario

Out[2]: 3825.0
```

Figura 1 – Média aritmética
Fonte: Elaborado pelo autor (2022)

Em situações reais, trabalhamos com conjuntos de dados mais complexos que possuem diversas variáveis e, muitas vezes, dados faltantes, ou seja, por algum motivo, o conjunto de dados não está completo. Em situações como essa, o cientista de dados deve tomar a decisão de qual a melhor abordagem para esse problema, uma solução trivial que pode ser adotada é desconsiderar os valores não preenchidos e usar os demais valores disponíveis. No exemplo abaixo, criamos um dataframe bidimensional com alguns valores faltantes e vamos calcular o valor da média ignorando os valores ausentes. O resultado esperado pode ser visto na Figura “Média valores ausente” abaixo.

```
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca Pandas

# Cria o dataframe
df =
pd.DataFrame({"salario":[1000,None,2400,900,None,5000,600,None,None,1000,300
0,None],
                    "despesa":[100,2000,300,None,1500,None,None,200,500,500,N
one,999]})

# Calcula a média sem considerar os valores "None"
df.mean(skipna = True)
```

Código-fonte 2 – Exemplo média valores ausente
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
# Cria o dataframe
df = pd.DataFrame({"salario":[1000,None,2400,900,None,5000,600,None,None,1000,3000,None],
                   "despesa":[100,2000,300,None,1500,None,None,200,500,500,None,999]})

# Calcula a média sem considerar os valores "None"
df.mean(skipna = True)
```

```
Out[26]: salario    1985.714286
         despesa     762.375000
         dtype: float64
```

Figura 2 – Média valores ausente
Fonte: Elaborado pelo autor (2022)

2.1.2 Mediana

A mediana de um conjunto de dados corresponde ao valor da posição central do conjunto de dados ordenado, ou seja, dado um conjunto de dados com valores em ordem crescente, o valor que estiver na posição central será a mediana, caso o conjunto de dados tenha valor par, é realizada a média entre os dois valores na posição central, como demonstra a Figura "Exemplo média e mediana (1)" e o respectivo código em Python.

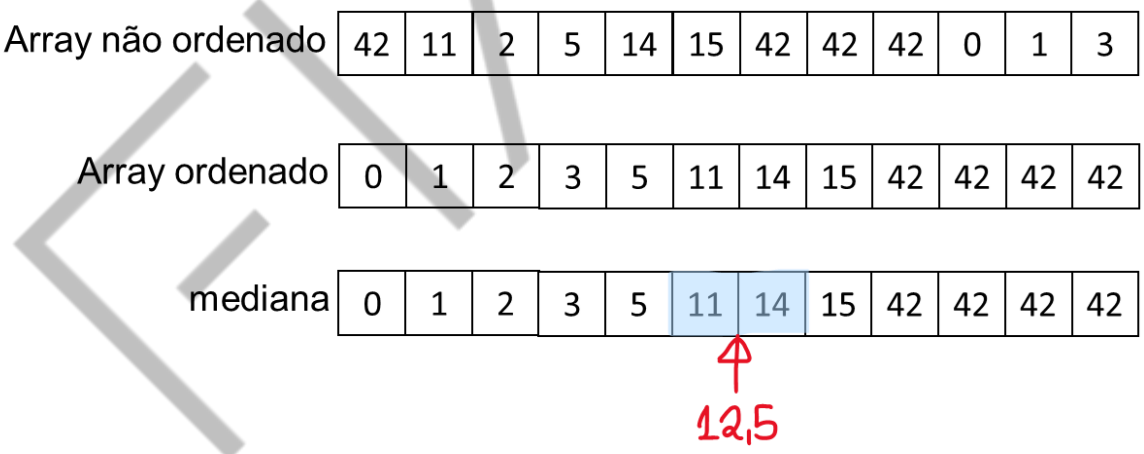

Figura 3 – Exemplo média e mediana (1)
Fonte: Elaborado pelo autor (2022)

```
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca Pandas


# Cria o dataframe
df = pd.DataFrame({"array":[42,11,2,5,14,15,42,42,42,0,1,3]})

# Calcula média e mediana
```

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
print('média', df['array'].mean())
print('mediana',df['array'].median())
```

Código-fonte 3 – Exemplo média e mediana
Fonte: Elaborado pelo autor (2022)

Repare que os resultados de média e mediana deste exemplo são diferentes, é necessário ter atenção para saber quando aplicar cada um dos métodos. Na Figura "Exemplo média e mediana (2)", é observado que o valor da média é superior ao da mediana. A mediana é o valor que representa a posição central do conjunto de dados, logo, metade dos dados possui valores acima de 12,5 e a outra metade possui valores abaixo de 12,5. Quando mais próximos os valores de mediana e média, há um indicativo de que os dados possuem alguma simetria em torno do valor central, o que pode ser verificado graficamente em um histograma.

```
# Cria o dataframe
df = pd.DataFrame({"array":[42,11,2,5,14,15,42,42,42,0,1,3]})

# Calcula mediana
print('média', df['array'].mean())
print('mediana',df['array'].median())
```

```
média 18.25
mediana 12.5
```

Figura 4 – Exemplo média e mediana (2)
Fonte: Elaborado pelo autor (2022)

2.1.3 Moda

A moda é correspondente ao valor do conjunto de dados que aparece com maior frequência. Podemos ter distribuições com um valor modal (unimodal), dois valores (bimodal) ou com muitos valores (multimodal), dependendo do conjunto de dados. A moda ajuda a encontrar tendências (padrões) nos dados, como é demonstrado no exemplo abaixo, na Figura "Exemplo Moda", é possível notar que dependendo do array utilizado, é devolvido o valor (conjunto de valores) de maior frequência, como mostra a Figura "Moda".

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

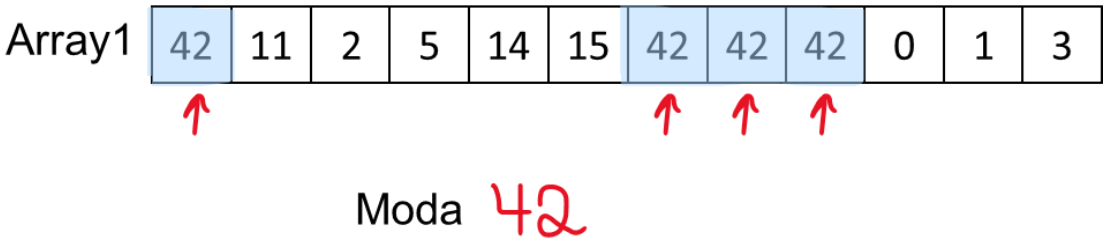

Figura 5 – Moda
Fonte: Elaborado pelo autor (2022)

```
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca Pandas


# Cria o dataframe
df = pd.DataFrame({"array1":[42,11,2,5,14,15,42,42,42,0,1,3],
                   "array2":[42,1,1,3,14,15,42,42,42,1,1,3],
                   "array3":[42,1,3,1,3,3,42,42,42,1,1,3]})

# Calcula moda

print('moda array1:\n',df['array1'].mode())
print('\n moda array2:\n',df['array2'].mode());
print('\n moda array3:\n',df['array3'].mode());
```

Código-fonte 4 – Exemplo moda
Fonte: Elaborado pelo autor (2022)

```
print('moda array1:\n',df['array1'].mode())
print('\n moda array2:\n',df['array2'].mode());
print('\n moda array3:\n',df['array3'].mode());
```

```
moda array1:
 0    42
dtype: int64

 moda array2:
 0     1
1    42
dtype: int64

 moda array3:
 0     1
1     3
2    42
dtype: int64
```

Figura 6 – Exemplo moda
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2.2 Exemplo de aplicação

Neste exemplo, vamos realizar uma análise descritiva aplicando medidas de centralidades: a média aritmética, a mediana e a moda. O problema é: uma empresa de marketing realizou uma entrevista com 30 pessoas para ajudar na definição de novos produtos. Uma das perguntas foi: “Qual tamanho você considera ideal para uma televisão na sala de estar?” As respostas coletadas estão no dataframe do Pandas na série “tamanho tv”.

Vamos realizar nossas análises:

Primeira análise: vamos utilizar a média e a mediana. O resultado obtido é 43.3 polegadas para média e 41 polegadas para a mediana. Os resultados apresentam valores próximos entre si e próximos ao valor de padrão de 42 polegadas.

Segunda análise: vamos utilizar a moda para analisar. O resultado obtido será bimodal, com valores em 32 e 55 polegadas. Diante desse resultado, vamos utilizar um apoio visual para compreender os dados, um gráfico de barra é uma boa opção e, neste caso, podemos observar os resultados na Figura “Tamanho da TV na sala”, onde fica claro observar que os usuários possuem mais interesse nas TVs de 32 e 55 polegadas com oito respostas para cada uma das alternativas.

Note que os entrevistados não possuem interesse em TV de 42 polegadas na sala, pois essa categoria obteve apenas uma resposta.

```
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca Pandas


# Cria o dataframe com as respostas dos entrevistados
df = pd.DataFrame({'tamanho
tv':[26,32,32,32,32,55,55,55,55,60,60,26,32,55,52,32,60,55,37,50,50,37,32,32
,26,37,55,55,40,42]})
tv = df['tamanho tv']

"""
Calcula média, mediana
"""
print('média:\n',tv.mean())
print('\n mediana:\n',tv.median());

"""
```

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
Criando um diagrama de barras para os totais de tamanho da TV
"""
tv_sum = tv.value_counts()    #realiza a contagem de valores unicos
tv_sum = tv_sum.sort_index()  #ordena os valores

x = tv_sum.index
y = tv_sum

#plota o gráfico de frequência
plt.bar(x, y)
plt.title('Tamanho da TV na sala')
plt.xlabel('polegadas')
plt.ylabel('Quantidade')
plt.xticks(x);

"""
Calcula média, mediana
"""
print('\n moda:\n',tv.mode());
```

Código-fonte 5 – Exemplo tamanho TV na sala
Fonte: Elaborado pelo autor (2022)

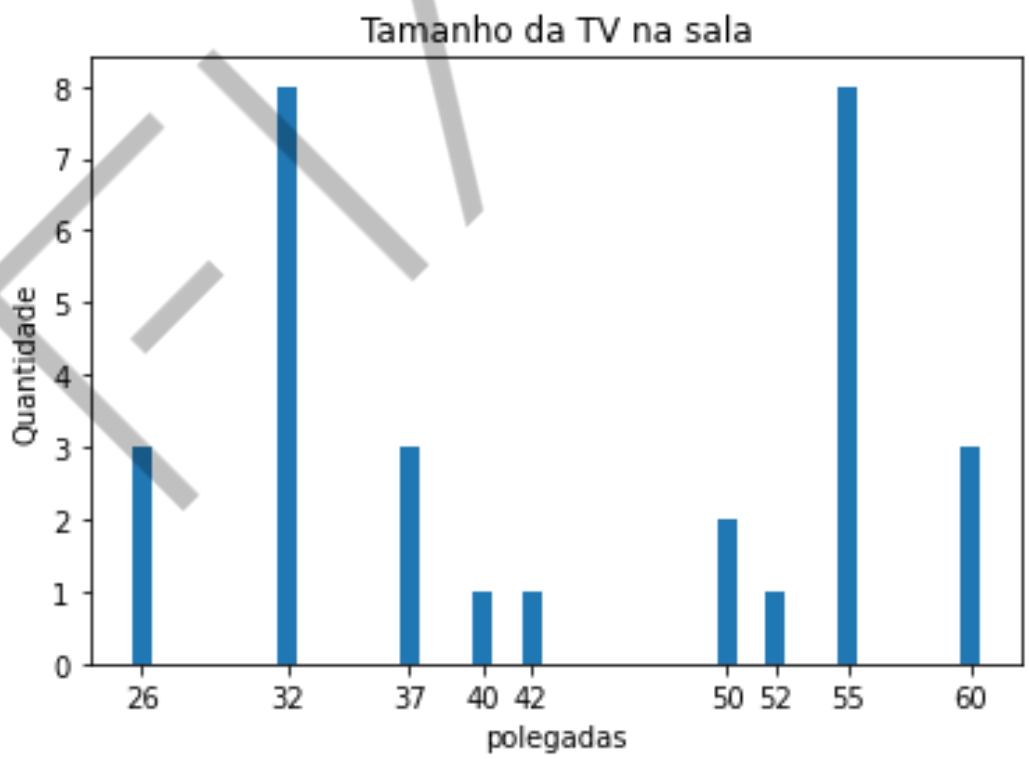

Figura 7 – Tamanho da TV na sala
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3 MEDIDAS DE DISPERSÃO E VARIABILIDADE

3.1 Amplitude total

A medida de amplitude total é a diferença entre o valor máximo e o mínimo de um conjunto de dados. No Python, podemos realizar de forma simples, como no exemplo abaixo.

```
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca Pandas


# Cria o dataframe
df =
pd.DataFrame({"salario":[1000,None,2400,900,None,5000,600,None,None,1000,300
0,None],
                    "despesa":[100,2000,300,None,1500,None,None,200,500,500,N
one,999]})

# Calcula variação simples
deltaSal= df['salario'].max() - df['salario'].min()
deltaDesp = df['despesa'].max() - df['despesa'].min()

print('Variação salário', deltaSal)
print('Variação despesa', deltaDesp)
```

Código-fonte 6 – Exemplo amplitude total
Fonte: Elaborado pelo autor (2022)

```
deltaSal= df['salario'].max() - df['salario'].min()
deltaDesp = df['despesa'].max() - df['despesa'].min()

print('Variação salário', deltaSal)
print('Variação despesa', deltaDesp)
```

```
Variação salário 4400.0
Variação despesa 1900.0
```

Figura 8 – Exemplo amplitude total
Fonte: Elaborado pelo autor (2022)

Trata-se de uma medida simples que pode ser utilizada para auxiliar na análise da dispersão de um conjunto de dados, o cientista de dados deve tomar cuidado para não enviesar sua análise usando apenas essa técnica, é sugerido o uso dessa técnica concomitante com outras técnicas de análise descritiva.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3.2 Desvio-padrão

O desvio-padrão é uma medida de dispersão que considera todos os valores do conjunto de dados. Diferente da medida de amplitude total que considera apenas os extremos, o desvio-padrão indica o grau de espalhamento dos valores da amostra em torno da medida da média. O cálculo é simples, consiste na raiz quadrada do somatório quadrado da diferença entre a amostra e a média do conjunto dividido pela soma total do conjunto menos 1 (n-1), este cálculo já está implementado na bibliotecas do Python, basta usar o método **std().**

Destaco um ponto importante, pode existir diferença de resultado dependendo da biblioteca escolhida, vamos analisar o resultado do desvio-padrão para o conjunto de dados que usamos acima usando as bibliotecas Numpy e Pandas como mostra a Figura “Diferença std” abaixo.

```
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca Pandas


# Cria o dataframe
df = pd.DataFrame({'tamanho tv':[26,32,32,32,32,55,55,55,55,60,60,26,32,55,52,32,60,55,37,50,50,37,32,32,26,37,55,55,40,42]})

"""
Criando um diagrama de barras para os totais de tamanho da TV
"""
tv = df['tamanho tv']

"""
Calculando o desvio padrão
"""

print('desvio padrão - Pandas: ',tv.std())
print('desvio padrão - Numpy: ',np.std(tv))
```

```
desvio padrão - Pandas:  11.960134931772588
desvio padrão - Numpy:  11.759109943642278
```

Figura 9 – Diferença std
Fonte: Elaborado pelo autor (2022)

Note a diferença no resultado: no Pandas, 11,96, e na Numpy, 11,75. A razão está em como é realizado o cálculo, basicamente, a Numpy usa por padrão o cálculo do desvio-padrão da POPULAÇÃO, e o Pandas realiza o cálculo do desvio-padrão da AMOSTRA. A diferença do cálculo está relacionada ao grau de liberdade e não entrarei em mais detalhes de conceito, mas o cientista de dados deve ter conhecimento se a base de dados trata com população ou amostra. Na prática, é mais habitual trabalhar com amostras de uma população. Em ambas as bibliotecas, é possível realizar a alteração do parâmetro do grau de liberdade para realizar o cálculo corretamente, como mostra a Figura “Cálculo std” abaixo, em que foi adicionado o argumento ddof=1 para a Numpy realizar o cálculo do desvio-padrão da amostra.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```python
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca Pandas


# Cria o dataframe
df = pd.DataFrame({'tamanho tv':[26,32,32,32,32,55,55,55,55,60,60,26,32,55,52,32,60,55,37,50,50,37,32,32,26,37,55,55,40,42]})

"""
Criando um diagrama de barras para os totais de tamanho da TV
"""
tv = df['tamanho tv']

"""
Calculando o desvio padrão
"""

print('desvio padrão - Pandas: ',tv.std())
print('desvio padrão - Numpy: ',np.std(tv, ddof=1))
```

```
desvio padrão - Pandas:  11.960134931772588
desvio padrão - Numpy:  11.960134931772588
```

Figura 10 – Cálculo std
Fonte: Elaborado pelo autor (2022)

Saiba mais em:
Amostra ou população?
https://www.youtube.com/watch?v=eIZD1BFfw8E&ab_channel=365DataScience .

3.3 Variância

A variância amostral é uma medida utilizada para avaliar discrepâncias de um conjunto de dados. Ele informa qual a distância que cada amostra do conjunto de dados está da média. O cálculo é bem simples e tem relação com o desvio-padrão: o desvio-padrão é igual à raiz quadrada da variância.

Uma grande variação indica que os valores do conjunto de dados estão longe da média e distantes um do outro. Uma pequena variância, por outro lado, indica que os números estão próximos da média e entre si. No limite, uma variação de 0 indicaria que todos os números do conjunto de dados são iguais.

Saiba mais em:
Desvio-padrão e variância: https://www.investopedia.com/ask/answers/021215/what-difference-between-standard-deviation-and-variance.asp#:~:text=Standard%20deviation%20is%20the%20spread,data%20points%20within%20a%20group.

3.4 Exemplo de aplicação

Neste exemplo, vamos realizar uma análise descritiva no dataset com dados dos passageiros do Titanic, começando importando o dataset e visualizando as primeiras linhas, como mostra a Figura “Head titanic”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
import numpy as np        # Importa biblioteca numpy.
import pandas as pd       # Importa biblioteca numpy.


df =
pd.read_csv('https://biostat.app.vumc.org/wiki/pub/Main/DataSets/titanic3.cs
v')

df.head()# exibe as 5 primeiras linhas do dataframe
```

Código-fonte 7 – import dataset titanic
Fonte: Elaborado pelo autor (2022)

	pclass	survived	name	sex	age	sibsp	parch	ticket	fare	cabin	embarked	boat	body	home.dest
0	1	1	Allen, Miss. Elisabeth Walton	female	29.00	0	0	24160	211.3375	B5	S	2	NaN	St Louis, MO
1	1	1	Allison, Master. Hudson Trevor	male	0.92	1	2	113781	151.5500	C22 C26	S	11	NaN	Montreal, PQ / Chesterville, ON
2	1	0	Allison, Miss. Helen Loraine	female	2.00	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON
3	1	0	Allison, Mr. Hudson Joshua Creighton	male	30.00	1	2	113781	151.5500	C22 C26	S	NaN	135.0	Montreal, PQ / Chesterville, ON
4	1	0	Allison, Mrs. Hudson J C (Bessie Waldo Daniels)	female	25.00	1	2	113781	151.5500	C22 C26	S	NaN	NaN	Montreal, PQ / Chesterville, ON

Figura 11 – Head titanic
Fonte: Elaborado pelo autor (2022)

Continuando, vamos realizar algumas análises descritivas com as medidas de média, variância e desvio-padrão para o atributo “age”, como mostra a Figura “Dados age”.

```
print ("Numero de passageiros", df.age.count())

print ("Idade média dos passageiros", df.age.mean())

print ("Variancia de Idade dos passageiros", df.age.var())

print ("Desvio Padrão de Idade dos passageiros", df.age.std())
```

```
Numero de passageiros 1046
Idade média dos passageiros 29.881137667304014
Variancia de Idade dos passageiros 207.74878655136447
Desvio Padrão de Idade dos passageiros 14.413493211271321
```

Figura 12 – Dados age
Fonte: Elaborado pelo autor (2022)

A idade média é de 29 anos, com um desvio-padrão aproximado de 14 anos para mais e para menos. Será que possui algum outlier de idade? Como podemos descobrir? Vamos calcular os outliers do conjunto de dados. Faremos isso da seguinte forma: sabemos que 95% da área de uma distribuição normal está dentro de 1,96 desvio-padrão da média. Desta forma, os valores de idade que estão fora desse limite

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

podem ser considerados outliers. Como mostra a Figura “Dados age outliers”, com o resultado de 65 passageiros com idade fora do desvio-padrão.

Saiba mais em:
Por que 1,96?:
https://onlinestatbook.com/2/estimation/mean.html#:~:text=The%20value%20of%201.96%20is,the%20mean%20for%20N%3D9.

```
# 1.96 vezes o desvio padrão da idade
df['1.96*std'] = 1.96*df['age'].std()

# Essa idade é um outlier se a diferença absoluta for > 1.96*std
df['Outlier'] = abs(df['age'] - df['age'].mean()) > df['1.96*std']

# conta apenas os valores outlier (true)
print ("Quantidade de idade outliers", df['Outlier'].value_counts()[True])

# Exi maior e menor idade
print ("\nIdade do passageiro mais jovem", df['age'].min())

print ("\nIdade do passageiro mais velho", df['age'].max())
```

```
Quantidade de idade outliers 65

Idade do passageiro mais jovem 0.17

Idade do passageiro mais velho 80.0
```

Figura 13 – Dados age outliers
Fonte: Elaborado pelo autor (2022)

Podemos obter informações estatísticas de forma muito simples sobre todo o nosso conjunto de dados utilizando o método “describe()” da biblioteca Pandas. De forma imediata, será exibido um remo contendo as principais informações estatísticas, como quantidade, mínimo, máximo, desvio-padrão, mediana e os percentis, como mostra a Figura “Titanic describe”.

```
df.describe()
```

	pclass	survived	age	sibsp	parch	fare	body	1.96*std
count	1309.000000	1309.000000	1046.000000	1309.000000	1309.000000	1308.000000	121.000000	1.309000e+03
mean	2.294882	0.381971	29.881138	0.498854	0.385027	33.295479	160.809917	2.825045e+01
std	0.837836	0.486055	14.413493	1.041658	0.865560	51.758668	97.696922	7.108143e-15
min	1.000000	0.000000	0.170000	0.000000	0.000000	0.000000	1.000000	2.825045e+01
25%	2.000000	0.000000	21.000000	0.000000	0.000000	7.895800	72.000000	2.825045e+01
50%	3.000000	0.000000	28.000000	0.000000	0.000000	14.454200	155.000000	2.825045e+01
75%	3.000000	1.000000	39.000000	1.000000	0.000000	31.275000	256.000000	2.825045e+01
max	3.000000	1.000000	80.000000	8.000000	9.000000	512.329200	328.000000	2.825045e+01

Figura 14 – Titanic describe
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Além das medidas de análise descritiva abordada neste capítulo, existem muitas outras que podem ser úteis nesta etapa de análise descritiva de dados.

Saiba mais em:
https://docs.python.org/3/library/statistics.html#

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

ATIVIDADE TREINO

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams

1. Com base no conjunto de dados IRIS dataset, disponibilizado em: https://archive.ics.uci.edu/ml/datasets/Iris. Responda as questões por meio de códigos e gráficos em python:

    a) Crie um Jupyter notebook e importe os dados disponibilizados no dataset Iris;
    b) Quantos atributos e entradas de dados possui o dataset?
    c) O dataset possui dados faltantes ou ausentes?
    d) Na média, qual espécie de flor possui o maior comprimento de pétala?
    e) Qual espécie de flor possui a maior variância?
    f) A espécie com o menor comprimento de pétala é a mesma espécie que possui a menor largura da sépala?

2. Com base no conjunto de Breast Cancer Data Set, disponibilizado em: https://archive.ics.uci.edu/ml/datasets/breast+cancer. Responda as questões por meio de códigos e gráficos em python:

    a. Crie um Jupyter notebook e importe os dados do dataset;
    b. Quantos atributos e entradas de dados possui o dataset?
    c. O dataset possui dados faltantes, ou ausentes?
    d. Qual a porcentagem de pessoas com tumor maligno e benigno?
    e. A incidência de tumor é maior qual faixa de idade?

3. O PNAD é Pesquisa Nacional por Amostra de Domicilios realizada pelo IBGE. Faça o download (https://www.kaggle.com/upadorprofzs/simple-exploratory-analysis-pinad-br/data) dos MICRODADOS e realize uma análise descritiva de dados em Python para responder as perguntas abaixo:

    a. Existe diferença entre a renda da população masculina e feminina?

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

b. Qual a altura média da população brasileira?
c. A renda é maior para quem tem mais escolaridade?
d. Quais estados possuem o maior e menor índice de escolaridade respectivamente?

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

MCKINNEY, W. **Python para análise de dados:** tratamento de dados com Pandas, NumPy e IPython. v. 2. São Paulo: Novatec Editora, 2019. f. 308, 616 p.

SEIFFERT, G. P. **Cálculo numérico aplicado à engenharia elétrica com PYTHON**. Florianópolis: Publicações do IFSC, 2021.

THE NUMPY COMMUNITY. **NumPy v1.21 Manua**l. 2022. Disponível em: https://numpy.org/doc/stable/. Acesso em: 12 jan. 2022.

THE SCIPY COMMUNITY. **SciPy documentation**. 2022. Disponível em: https://docs.scipy.org/doc/scipy/reference/. Acesso em: 12 jan. 2022.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com