FIAP ON

BUSINESS INTELLIGENCE & ANALYTICS

MODELOS SUPERVISIONADOS E NÃO SUPERVISIONADOS

12

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 - Data Science é multidisciplinar 5
Figura 2 - Diagrama de uma função.....7
Figura 3 – Diagrama de aprendizagem de máquina 8
Figura 4 - Evolução de IA para aprendizagem de máquina e aprendizagem profunda 9
Figura 5 – Algoritmo Page Rank 11
Figura 6 – Filtros colaborativos 12
Figura 7 – Traduções automáticas.....13
Figura 8 – Diagramas de representação de algoritmos de AM 15
Figura 9 – Representação de um modelo linear de AM 16
Figura 10 - Métricas de avaliação de algoritmos de AM.....17
Figura 11 - Tipos de aprendizagem.....20
Figura 12 – Diagrama de aprendizagem de máquina 22
Figura 13 24
Figura 14 – Retorno de uma função de AM não supervisionado.....24
Figura 15 – Explicação visual do sobreajuste por meio de um meme.....27

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Exemplo da técnica GridSearch aplicada a um algoritmo de SVM 18
Código-fonte 2 – Exemplo de uso de ajuste fino por meio da biblioteca Pycaret 19

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 MODELOS SUPERVISIONADOS E NÃO SUPERVISIONADOS 5
1.1 Introdução 5
1.1.1 Machine Learning, Inteligência Artificial, KDD 6
1.1.2 Breve história de aprendizagem de máquina 10
1.2 Aplicações de AM 10
1.2.1 Algoritmos de busca – Page Rank – uma nova era 11
1.2.2 Filtros colaborativos 12
1.2.3 Traduções automáticas 13
1.3 Principais conceitos sobre AM 14
1.3.1 Representação de um algoritmo de AM 14
1.3.2 Avaliação de um algoritmo de AM 16
1.3.3 Otimização de um algoritmo de AM 17
1.4 Tipos de algoritmos de AM 19
1.5 AM na prática 21
2 APRENDIZAGEM NÃO SUPERVISIONADA 22
3 APRENDIZAGEM SUPERVISIONADA 26
3.1 A função perda *(loss function)* 26
3.2 Sobreajuste *(overfitting)* 26
ATIVIDADE TREINO 1 - MÉTRICAS DE AVALIAÇÃO DE UM ALGORITMO DE MACHINE LEARNING 28
ATIVIDADE TREINO 2 - UM POUCO MAIS SOBRE MACHINE LEARNING 29
ATIVIDADE TREINO 3 – OVERFIT 30
REFERÊNCIAS 31

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 MODELOS SUPERVISIONADOS E NÃO SUPERVISIONADOS

1.1 Introdução

Temos presente em nosso dia a dia uma série de aplicações que se utilizam de conceitos de aprendizagem de máquina. Desde aplicativos de navegação, que utilizamos ao dirigir veículos para encontrar melhores rotas, até sites de compras, que recomendam produtos visando uma melhor experiência de compra.

Muitas vezes, o paradigma abordado pelos conceitos de aprendizagem de máquina se funde com outros campos de estudo próximos, como ciência de dados, KDD, inteligência artificial, entre outros. De fato, há uma região de intersecção dessas áreas de conhecimento que não é pequena. Algumas vezes é difícil, inclusive, dizer se estamos executando uma tarefa ou atividade de aprendizagem de máquina, de mineração de dados, de ciência de dados ou de inteligência artificial.

Kelleher e Tierney (2018), a partir de sua pesquisa, elaboraram um diagrama de Venn na tentativa de explicitar como essas áreas se relacionam.

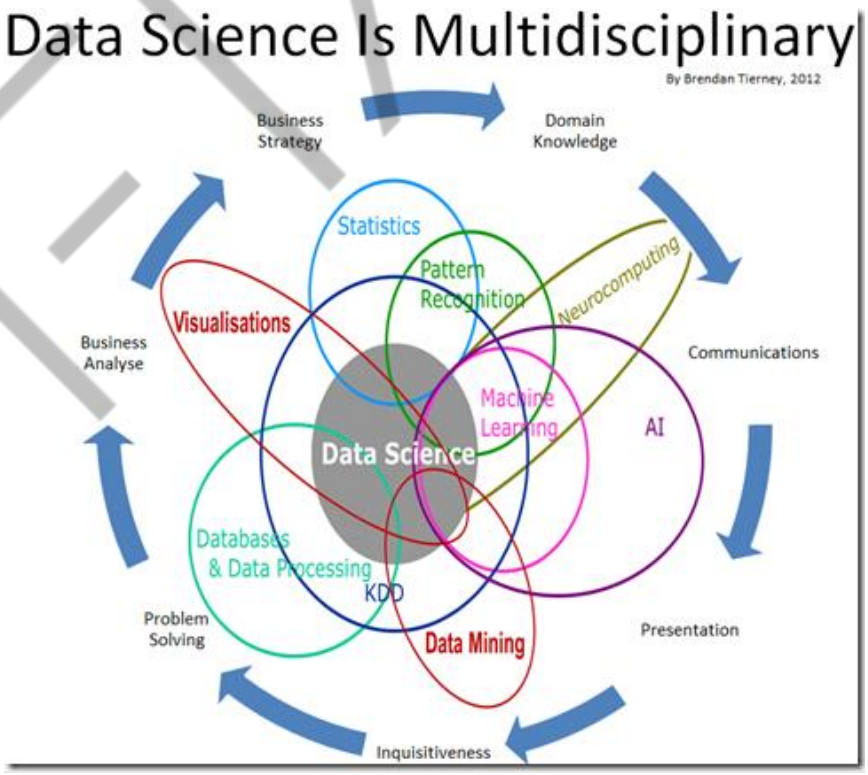

Figura 1 - Data Science é multidisciplinar
Fonte: ORALYTICS (2012)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Ou seja, é possível observar neste diagrama que:

1. Machine Learning é uma área que está inserida ou faz parte da inteligência artificial.
2. Há uma grande área de intersecção de aprendizagem de máquina com ciência de dados.
3. Também há uma intersecção grande entre AM (aprendizagem automática) e KDD (Knowledge Data Discovery).
4. Há outras tantas intersecções com: mineração de dados, reconhecimento de padrões, visualização e neurociência computacional.

Portanto é muito provável que os textos relacionados, livros e mesmo as disciplinas deste curso, que procuram tangenciar as áreas de conhecimento (evitar falar de um mesmo assunto repetidas vezes), acabem por ultrapassar algumas "fronteiras", talvez porque simplesmente não existam.

1.1.1 Machine Learning, Inteligência Artificial, KDD

Segundo o Prof. Ameet Talwalkar, da UCLA, a definição de aprendizagem de máquina seria: "Estudo e construção de métodos para aprender sobre dados e fazer previsões" (MOHRI M.; *et. al*., 2018).

AM é sobre minimizar a função perda, evitando o [fenômeno] do sobreajuste. Veremos mais a frente os conceitos de função perda *(loss function)* e sobreajuste *(overfitting).* Essa segunda definição é um pouco mais restritiva que a primeira, pois foca na segunda parte da frase do Prof. Ameet ("fazer previsões").

O que se descobriu, por meio de inúmeras pesquisas e aplicações, é que, muitas vezes, definir uma função é uma tarefa que nós, humanos, não fazemos tão bem, principalmente quando temos muitos dados para analisar. Descobrimos como definir a função velocidade, que nada mais é do que a variação de deslocamento em função da (ou seja, dividido por) a variação de tempo.

Veja a entrevista de Andre Ng com Geoffrey Hinton, Preserve Knowledge (2018), neste vídeo: https://www.youtube.com/watch?v=-eyhCTvrEtE

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

$$v_t = \Delta_s / \Delta_t. \qquad (1)$$

$$onde$$

$$\Delta_s = \Delta_{s1} - \Delta_{s0}$$

$$\Delta_t = \Delta_{t1} - \Delta_{t0}$$

Esta função possui quatro entradas (de dados) e uma saída. Sua construção (ou fórmula) foi estabelecida a partir de observações (empíricas) de fenômenos da natureza, em que dados foram coletados e, a partir da observação e análise desses dados, foram aplicados conceitos matemáticos. Isso aconteceu há bastante tempo.

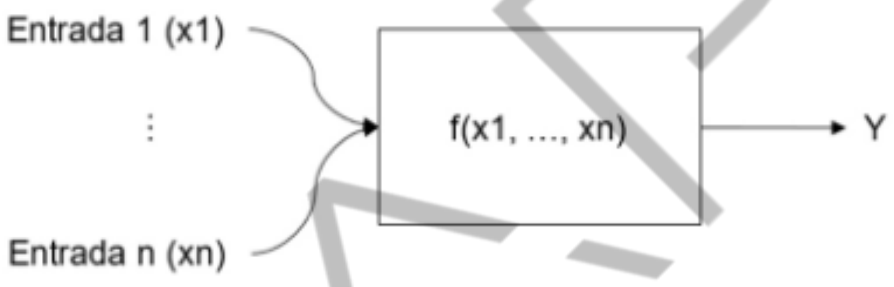

Figura 2 - Diagrama de uma função
Fonte: Elaborado pelo autor (2022)

Podemos definir uma função de uma forma geral como:

$$y = f(x1, \ldots, xn) \qquad (2)$$

Atualmente estamos inundados de dados por todos os lados, fenômeno descrito pelos conceitos de *Big Data*. Um artigo da Harvard Business Review (2017) relata que pouco se utiliza dos dados disponíveis na construção de soluções. Entre outras tantas razões, uma delas é a dificuldade em se analisar tantos dados.

Saiba mais em: https://hbr.org/2017/05/whats-your-data-strategy

E aí é que as técnicas de aprendizagem de máquina ganham espaço. Em aprendizagem de máquina, utilizamos uma série de técnicas e abordagens para preparar adequadamente os dados (y, x1, … xn) de forma que possam servir de insumos para descobrirmos qual é a função.

Dessa forma, podemos enxergar o seguinte diagrama:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

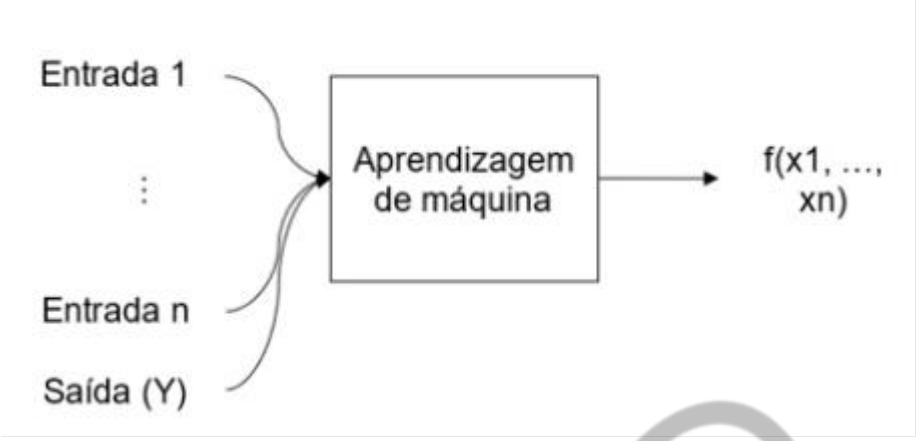

Figura 3 – Diagrama de aprendizagem de máquina
Fonte: Elaborado pelo autor (2022)

O que a máquina, então, aprende? Dizemos que “treinamos algoritmos" ou "treinamos modelos” para que eles representem um determinado fenômeno, uma determinada situação ou um problema que queremos resolver repetidamente. A ideia de aprendizagem de máquina (assim como para seres humanos) é que seja um processo contínuo, que este aprendizado vá evoluindo conforme os dados (x1, …, xn, Y) mudam. Ou seja, o algoritmo (ou função) que a máquina “aprendeu” pode (e deve) ser continuamente “treinado” para incorporar novos dados (que podem gerar conhecimento).

Podemos também dizer de outra forma: uma função é um programa de computador. Logo, podemos dizer que:

- Em programação tradicional, criamos um programa, entramos com os dados (inputs ou x1,..., xn) e temos uma saída (output ou Y).
- Em AM, criamos um algoritmo que recebe as entradas e saídas de dados, e temos como retorno um programa. Isso mesmo. A máquina “aprende” um novo programa, que pode então ser utilizado no paradigma de programação tradicional, recebendo novas entradas e produzindo saídas.

Podemos agora abordar o tema inteligência artificial, que remonta aos anos 1950, para entender a relação entre IA e AM. De uma forma geral, o termo Inteligência Artificial designa qualquer imitação feita por máquinas (computadores) de comportamentos humanos. Segundo Anyoha em um artigo para a Harvard University (2017), entre as décadas de 1950 e 1960, pesquisadores propuseram a solução de

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

problemas simples para seres humanos, como jogar jogos, conversar, entre outros. Uma primeira aplicação imaginada foi, claramente, a robótica.

Saiba mais em: https://sitn.hms.harvard.edu/flash/2017/history-artificial-intelligence/

Um dos pioneiros nessa área reconhece-se hoje como sendo Alan Turing. Entre outras contribuições, Turing propôs um teste (hoje chamado de teste de Turing) em que uma máquina deveria interagir com um ser humano, tendo como objetivo que ela se parecesse o máximo possível com um ser humano, de tal forma que não possa ser identificado que não é um ser humano. Podemos pensar IA então, de uma forma mais ampla. Aprendizagem de máquina, como conhecemos hoje, se delineou como uma derivação de IA a partir, principalmente, da década de 1980.

Bem mais recentemente, a partir dos anos 2010, vimos emergir um novo campo de estudos extremamente promissor “dentro” de AM (que por sua vez está “dentro” de IA): o aprendizado profundo. Tomou-se muita notoriedade a partir de aplicações muito realísticas, como carro autônomo, tradutores de textos em estado da arte, entre outras tantas aplicações. Mas este será um tema para outro momento.

Podemos observar esta evolução no diagrama da Figura “Evolução de IA para aprendizagem de máquina e aprendizagem profunda”.

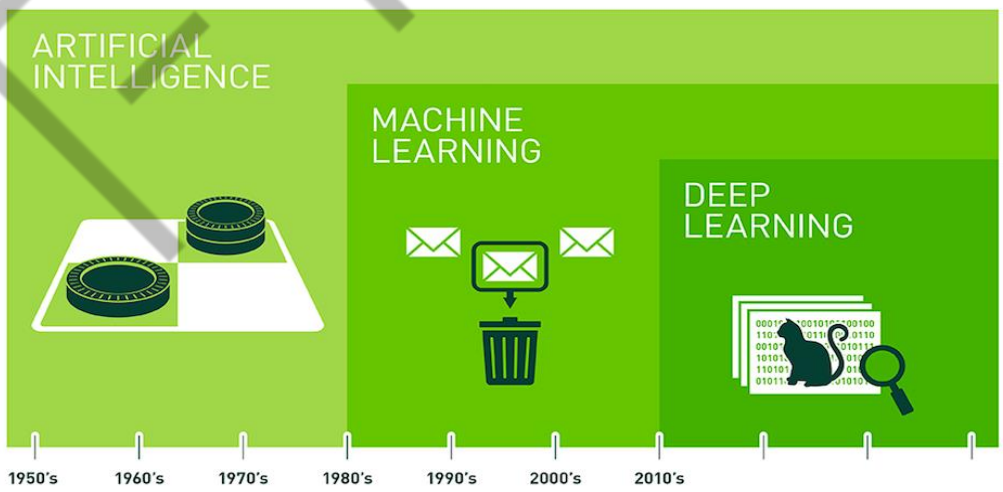

Figura 4 - Evolução de IA para aprendizagem de máquina e aprendizagem profunda
Fonte: NVIDIA (2016)

Como já vimos a definição de KDD no capítulo, fica mais fácil entender sua evolução e áreas de intersecção com AM.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1.1.2 Breve história de aprendizagem de máquina

A primeira menção que se tem registro do termo aprendizagem de máquina foi de Arthur Samuel, então funcionário da IBM, que o utilizou em 1952 para definir o processo de aprendizagem de seu algoritmo ao “treinar” para participar do jogo no papel de um jogador.

Em 1957, Frank Rosenblatt, em um laboratório aeronáutico de Cornell, realizou a primeira implementação do conceito de perceptron (Mark I), proposto originalmente por Donald Hebb, como uma espécie de imitação de uma célula cerebral humana. O objetivo de Frank era trabalhar com reconhecimento de imagens.

Um novo passo relevante foi dado em 1967, com a proposição do amplamente conhecido hoje algoritmo do “vizinho mais próximo”. A ideia básica desse algoritmo foi procurar o “vizinho mais próximo” conhecido de um determinado objeto (que não conhecemos) e utilizar as características do vizinho como premissa de que também o valham para o objeto. As premissas desse algoritmo se basearam, por exemplo, na ideia de que, em um mesmo bairro, a faixa de renda entre os moradores deve ser próxima, visto os custos com terreno serem próximos.

A partir da década de 1970, o desenvolvimento das pesquisas relacionadas com aprendizagem de máquina se distanciou um pouco de IA: esta seguiu com aplicações lógicas e conceituais, enquanto as aplicações de algoritmos foram aprofundadas e desenvolvidas em AM. Podemos dizer, então, de forma resumida, que AM é a parte de IA que se desenvolve por meio do uso de algoritmos.

1.2 Aplicações de AM

Atualmente, o campo de aplicações de AM é tão vasto que certamente os exemplos listados abaixo são meramente elucidativos, não procurando de forma alguma ser uma cobertura completa e extensiva de tudo que se faz e aplica hoje em AM.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1.2.1 Algoritmos de busca – Page Rank – uma nova era

Quem não utiliza, várias vezes ao dia, o site do Google (ou seus derivados) para localizar alguma coisa? Praticamente, quase tudo que queremos, buscamos por meio de seu mecanismo de busca. Mas por que fazemos isso, atualmente, com tanta frequência? Foi a internet que ficou “grande” e permitiu que encontrássemos tudo que queremos? Foram os computadores que ficaram rápidos para responder quando perguntamos? Foi o computador pessoal (ou o celular, mais recentemente) que tornou fácil o acesso a esses dados?

A resposta é sim para todas as perguntas acima, porém todos esses elementos sem uma forma fácil de indexar, de organizar os dados, de encontrar facilmente aquilo que estamos buscando, talvez não nos trouxesse tamanha presença em nosso cotidiano. E é aí que entra o algoritmo Page Rank. Ele foi talvez um dos maiores elementos para o sucesso de mecanismos de busca, tal como o Google.

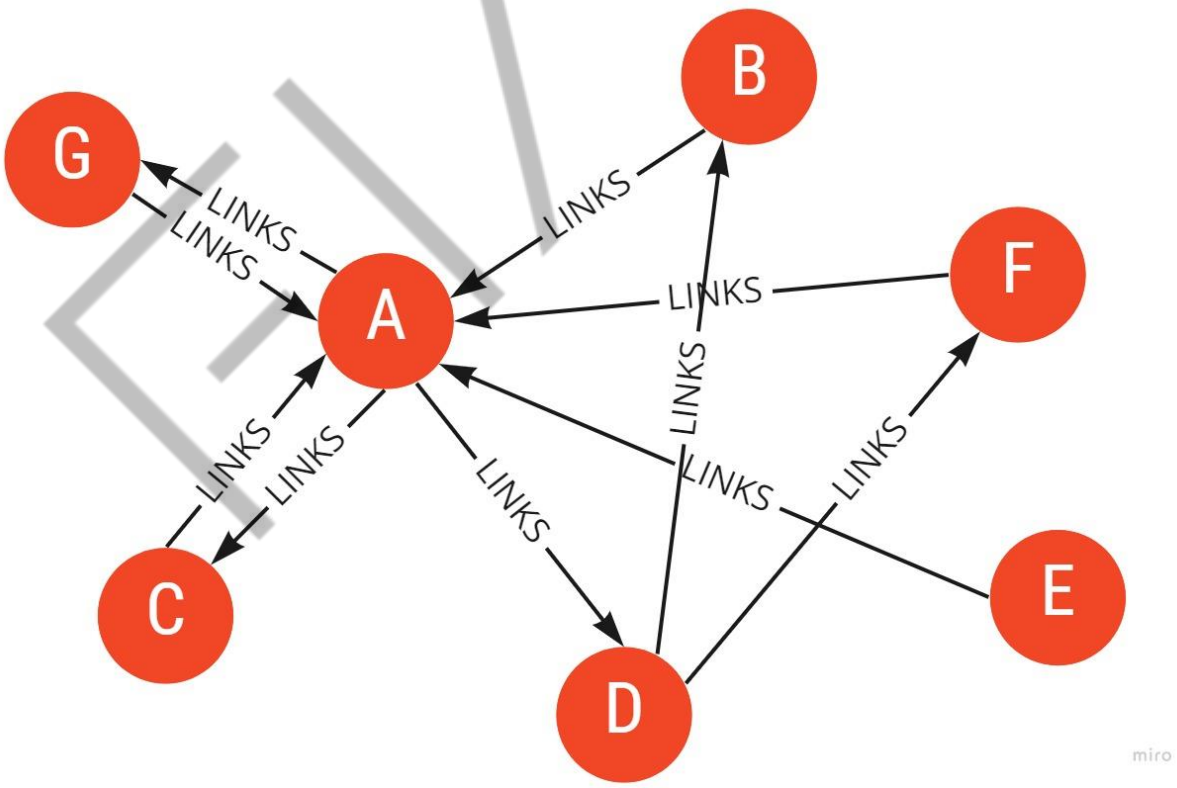

Figura 5 – Algoritmo Page Rank
Fonte: NetworkX Guide (2022)

Sua ideia básica é que quanto mais sites recomendarem algum site (ou seja, tem um hyperlink “apontando” para), então o site referenciado deve ser importante. É

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

uma conclusão bastante óbvia para acadêmicos que leem artigos constantemente e constatam que, se um artigo foi referenciado por outros, deve ter sido lido, validado e, portanto, recomendado.

1.2.2 Filtros colaborativos

O comércio eletrônico foi de uma promessa a uma preferência em muitos países. Há ainda um espaço enorme para crescimento mundial, porém podemos observar a velocidade com que vem sendo adotado ao redor do mundo. Se no Japão temos 94,5% da população usando internet, na China, o país mais populoso do mundo, esse número é de 68,5% em 2021.

Acesse em: https://www.statista.com/statistics/281668/internet-penetration-in-southeast-asian-countries/

Faça o cálculo: 24% de uma população de 1,4 bilhão de pessoas deverão ingressar na internet nos próximos anos (há cerca de 20 anos a China era um país prioritariamente agrícola): são 336 milhões de pessoas. E a adoção do comércio eletrônico segue crescendo em taxas altas também, a reboque da conectividade.

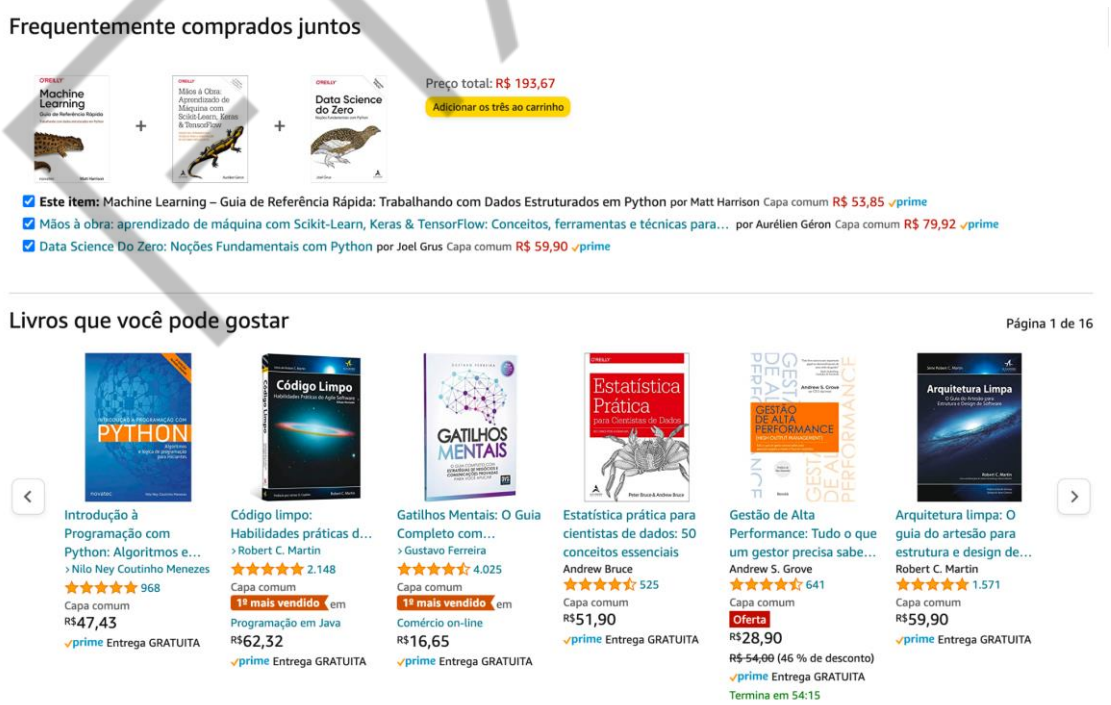

Figura 6 – Filtros colaborativos
Fonte: Amazom.com (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Ter uma boa experiência de consumo também diz respeito a encontrar o que se busca. Aí é que entram as seções de recomendações de produtos em sites especializados de compras. A Amazon foi quem difundiu amplamente, por meio das ferramentas aplicadas em seus sites, esses conceitos. É um problema parecido com o que o Page Rank se propunha a resolver; porém com aplicações diferentes, mas principalmente com técnicas diferentes e mais adequadas para este caso.

1.2.3 Traduções automáticas

A barreira de linguagem é um problema encarado por diversas civilizações há centenas de anos. Existem centenas de línguas desenvolvidas em uso atualmente ao redor do mundo. A língua portuguesa aparece somente na nona posição, atrás dos mais óbvios: inglês, chinês (mandarim), francês, espanhol, mas também atrás do russo e, veja só, do bengali, língua oficial de Bangladesh.

Figura 7 – Traduções automáticas
Fonte: Livesalesman (2019)

Durante décadas, do campo de pesquisa da linguística se originaram diversas tentativas de se proporem soluções para o problema da barreira de linguagem por meio de inúmeras técnicas de tradução automática. Porém, com o advento de técnicas de Machine Learning neste campo, observou-se um salto de eficiência até então buscado com dificuldade.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1.3 Principais conceitos sobre AM

Agora que sabemos que AM diz respeito à parte da IA que trata de algoritmos, podemos nos perguntar: mas quais são esses algoritmos? Existem centenas de algoritmos que foram criados desde o século passado. Normalmente o processo diz respeito a uma pesquisa que propõe a resolução de um determinado tipo de problema de uma forma específica. Após a publicação do resultado da pesquisa, quando as aplicações começam a serem feitas, notadamente os algoritmos que produzem maior impacto acabam se tornando mais conhecidos e acabam por estampar páginas de livros, sites especializados, redes sociais específicas etc. Não existe (ainda) um catálogo mundial centralizado.

Podemos dizer em geral que todo algoritmo de AM tem três componentes:

1. Representação.
2. Avaliação.
3. Otimização.

1.3.1 Representação de um algoritmo de AM

Cada algoritmo utiliza uma ou mais técnicas para criar a saída, ou a função (programa). Existem centenas de técnicas aplicadas e cada uma tem uma particularidade em função do método proposto pelo autor e dos cálculos utilizados. É comum utilizarmos diagramas para representar os algoritmos, pois uma imagem auxilia e muito na análise dos dados do algoritmo, bem como para entender seu funcionamento.

Vejamos abaixo alguns exemplos de representações de algoritmos de:

a. Vizinho mais próximo (KNN).
b. Clusterização com K-médias (K-Means).
c. Máquinas de Vetores de Suporte (SVM, Support Vector Machines).
d. Florestas Randômicas (RF, Random Forest).
e. Redes neurais (Neural Networks).

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

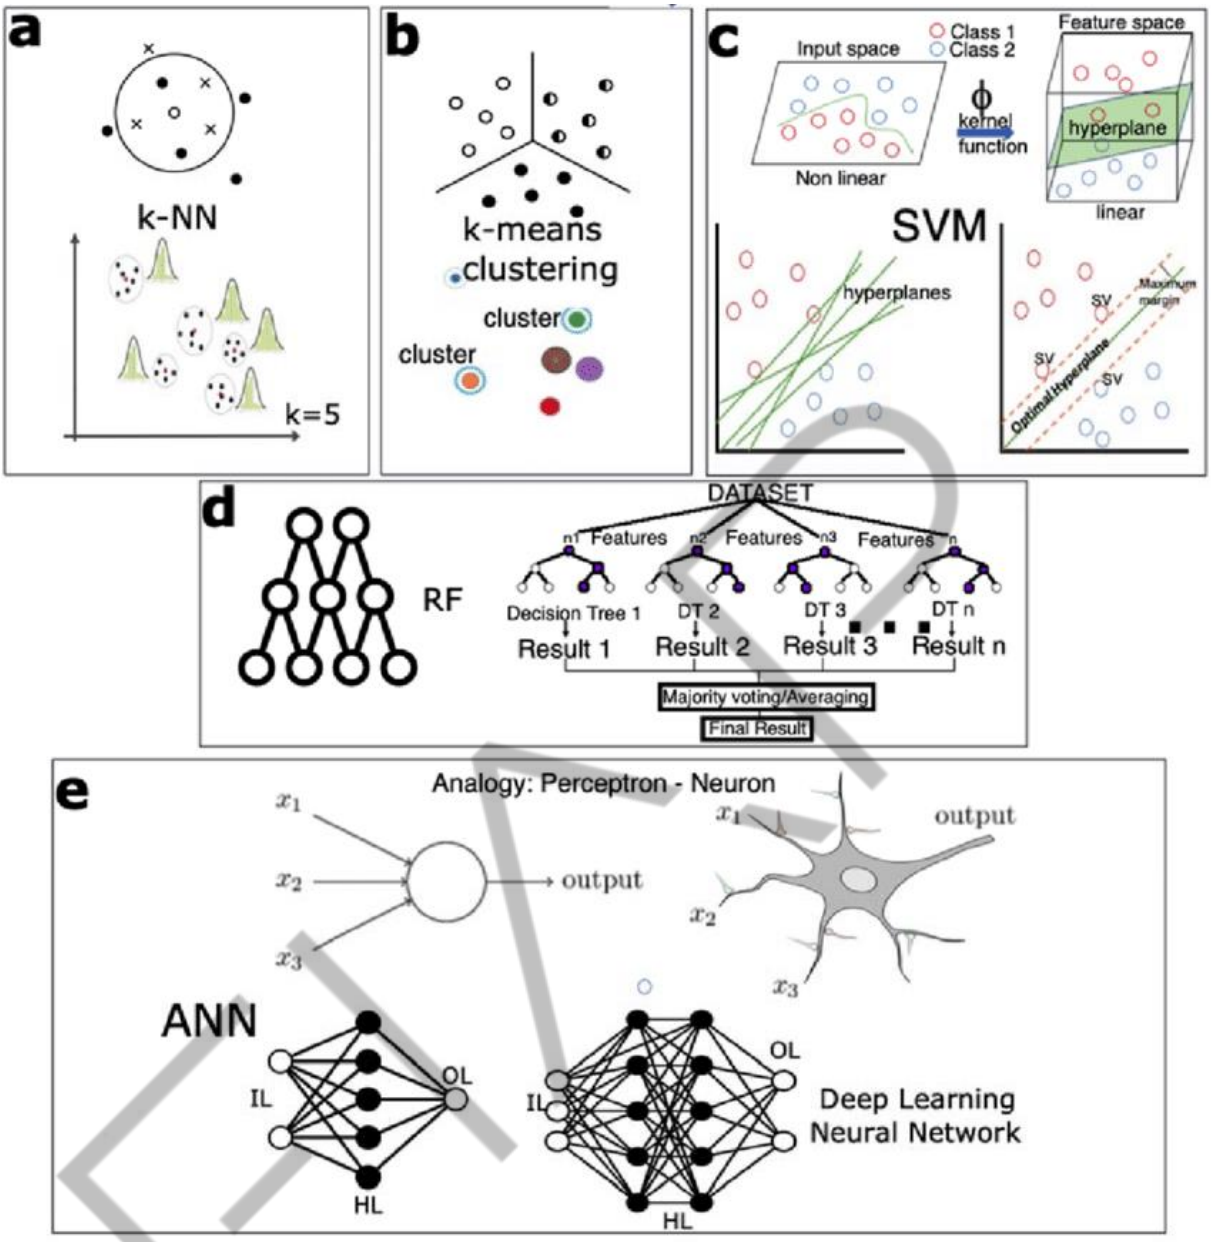

Figura 8 – Diagramas de representação de algoritmos de AM
Fonte: Researchgate (2021)

A representação gráfica por meio de diagramas é extremamente útil, porém precisamos também entender como é o funcionamento do nosso **modelo**. O conceito de modelo aplicado a Machine Learning deriva tanto do conceito de **modelo matemático** quanto do conceito de **modelo estatístico**, que praticamente (também) é uma variante ou aplicação do conceito de modelo matemático.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Diz-se que um **modelo matemático** é a representação simplificada da realidade, por meio de conceitos mentais ou experimentais. É como se utilizar de equações, funções matemáticas e afins.

Diz-se que um **modelo estatístico** é um conjunto de hipóteses sobre dados observados, por meio da análise das relações entre variáveis aleatórias e as demais.

Vemos a seguir um exemplo de representação de um modelo linear por meio de equações:

Hypothesis: $h_\theta(x) = \theta_0 + \theta_1 x$

Parameters: θ_0, θ_1

Cost Function: $J(\theta_0, \theta_1) = \frac{1}{2m} \sum_{i=1}^{m} \left(h_\theta(x^{(i)}) - y^{(i)}\right)^2$

Goal: $\underset{\theta_0, \theta_1}{\text{minimize}}\ J(\theta_0, \theta_1)$

Figura 9 – Representação de um modelo linear de AM
Fonte: Analytics (2020)

1.3.2 Avaliação de um algoritmo de AM

Durante a etapa de construção dos algoritmos de AM, é necessário que avaliemos se esse algoritmo está representando bem o fenômeno (ou problema) que estamos tentando “modelar”. George E. P. Box, um estatístico inglês, lançou uma frase que ficou muito conhecida no meio: “Todos os modelos são ruins, mas alguns podem ser utilizados”.

Mas qual é o nosso conceito de “ruim” para um algoritmo de AM (que representa um modelo)?

Cada tipo de algoritmo e, na maioria das vezes, cada algoritmo específico tem uma forma de ser avaliado em sua função, isto é, se ele está conseguindo representar bem o problema em questão, se ele está resolvendo bem o problema que se propunha. Nas seções e nos capítulos seguintes, mergulharemos em algumas dessas métricas citadas na Figura “Métricas de avaliação de algoritmos de AM”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

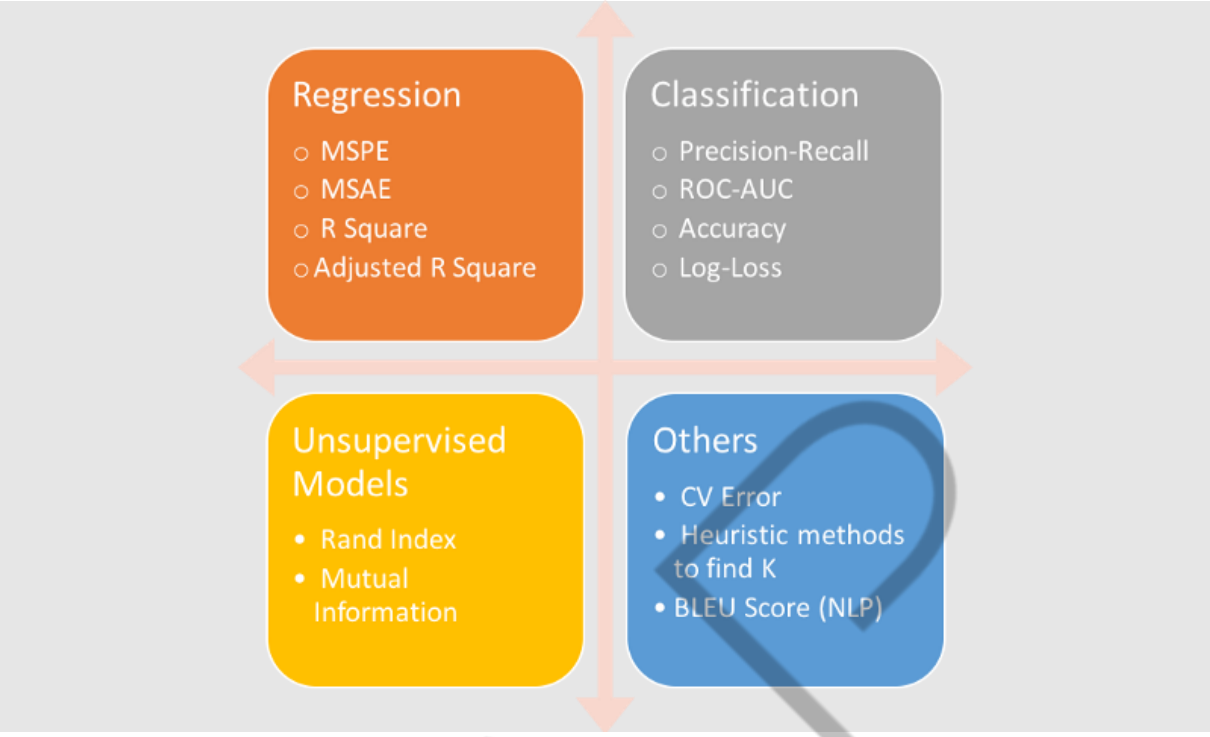

Figura 10 - Métricas de avaliação de algoritmos de AM
Fonte: KD Nuggets (2022)

1.3.3 Otimização de um algoritmo de AM

Computadores são ferramentas extremamente úteis quando queremos repetir tarefas, trabalhar com muitos cálculos e simular cenários. É exatamente o que ocorre logo após construirmos um algoritmo de AM: queremos otimizar, ajustar de forma a "melhorar" tanto a representação do modelo em relação aos quantos quanto os resultados destes. A esta etapa chamamos de otimização, no sentido de encontrar a melhor solução, a qual chamaremos de solução ótima.

Como estamos trabalhando com modelos probabilísticos, isto é, estamos tentando representar um fenômeno antes dele ocorrer (ou se repetir), não é adequado dizer que procuramos uma solução "correta". Não há, de fato, uma solução certa. O que encontramos são soluções que podem nos ser úteis ou que se aproximam disso. Utilizar-se do computador para simular diversos cenários e sugerir a solução ótima é, sem dúvida, uma abordagem eficaz.

Utiliza-se também o termo "hyperparameter optimization" ou "hyperparameter tuning" ou simplesmente "tuning" para referir-se à atividade de otimização. Em

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

português, utiliza-se o termo “ajuste fino” como uma tradução. Muitos algoritmos atualmente já possuem alguma função de otimização implementada. Também existem alguns frameworks para otimização. Vejamos dois exemplos em Python, abaixo.

```
from sklearn.model_selection import GridSearchCV

# Definição dos intervalos dos parâmetros C, gamma e kernel
param_grid = {'C': [0.1, 1, 10, 100, 1000],
              'gamma': [1, 0.1, 0.01, 0.001, 0.0001],
              'kernel': ['rbf']}

grid = GridSearchCV(SVC(), param_grid, refit = True, verbose = 3)

# Ajuste fino do modelo por grid search
grid.fit(X_train, y_train)
```

Código-fonte 1 – Exemplo da técnica GridSearch aplicada a um algoritmo de SVM
Fonte: Elaborado pelo autor (2022)

No exemplo acima, o que acontece é que definimos inicialmente um intervalo de parâmetros possíveis para três parâmetros do algoritmo de SVM, que são o C, *gamma* e *kernel*. Veja, se fôssemos testar manualmente cada uma das combinações possíveis, precisaríamos executar muitas vezes o mesmo código, uma tarefa bem trabalhosa:

Número de parâmetros de C * Número de Parâmetros de Gama * Número de Parâmetros de kernel. Seriam: 5 * 5 * 1 = 25 tentativas.

A função que o GridSearch realiza é testar cada uma das 25 combinações possíveis (portanto, testar 25 modelos diferentes) e nos trazer como resultado o algoritmo que obteve as melhores métricas de avaliação, ou seja, o modelo ótimo.

No outro exemplo abaixo, utiliza-se a biblioteca Pycaret para automatizar o processo de ajuste fino de um modelo linear. Note que, em seis linhas de código, todas as atividades do processo de AM foram realizadas.

```
# carga de um dataset diretamente da biblioteca pycaret
from pycaret.datasets import get_data
boston = get_data('boston')

# carga das funç˜ões de regressão
from pycaret.regression import *
reg1 = setup(data = boston, target = 'medv')

# treinamento do modelo
dt = create_model('dt')

# ajuste fino do modelo
```

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
tuned_dt = tune_model(dt)
```

Código-fonte 2 – Exemplo de uso de ajuste fino por meio da biblioteca Pycaret
Fonte: Elaborado pelo autor (2022)

Parece muito simples, não é mesmo? Mas não se iluda. Esse tipo de framework auxilia sim o processo de descoberta de soluções, porém não é uma solução que se ajusta em todos os casos. Por “empacotar” uma série de atividades, normalmente realizadas com mais linhas de código, muitas vezes não conseguimos fazer um ajuste específico em um algoritmo, ou a solução “embarcada” no framework não é escalável, entre outras dificuldades. Ainda assim, o uso de frameworks desse tipo pode ajudar nos processos de AM, ainda que tenhamos de partir posteriormente para uma implantação sem ele.

1.4 Tipos de algoritmos de AM

Normalmente os algoritmos seguem uma primeira grande classificação de acordo com o tipo de “aprendizado” que se propõe entre quatro tipos:

1. Aprendizagem supervisionada (também chamada aprendizado indutivo): caracterizado pela presença da variável resposta (Y).
2. Aprendizagem não supervisionada: caracterizado pela presença somente das variáveis x1,...,xn (não há Y).
3. Aprendizagem semisupervisionada: aqui a característica é que possuímos poucos dados sobre a saída (Y é esparso).
4. Aprendizagem por reforço: há um ciclo de aprendizagem em que há um benefício recebido após uma sequência de ações.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

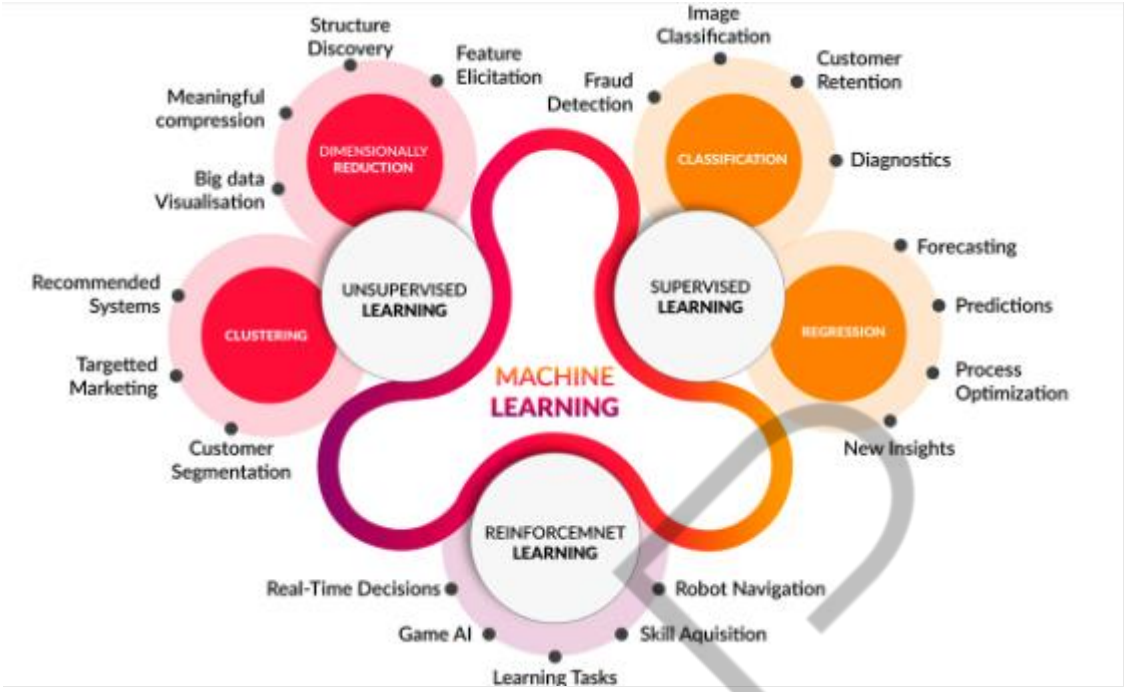

Figura 11 - Tipos de aprendizagem
Fonte: COGNUB (2021)

Dos quatro tipos, a área de aprendizagem supervisionada é a mais madura, que possui a maior quantidade de pesquisas, de resultados e de algoritmos. Muitos autores relatam que esse fato supostamente tem a ver com a natureza de como são estruturados os problemas de AM supervisionada: é mais fácil saber se estamos no caminho certo, pois há um alvo claro. No entanto, também há um consenso de que o aprendizado humano é muito mais parecido com os outros três tipos de aprendizagem que o aprendizado supervisionado. Veremos nas próximas duas seções com mais detalhes os aprendizados supervisionados e não supervisionados.

Ah, e você deve ter sentido falta, na Figura “Tipos de aprendizagem”, da aprendizagem semisupervisionada, certo? Alguns autores, segundo Browlee (2021), abrem esse um tipo de aprendizagem em uma classificação diferente, outros inserem-na nas aprendizagens supervisionada e não supervisionada.

Veja um exemplo aqui: https://machinelearningmastery.com/what-is-semi-supervised-learning/#:~:text=Semi%2Dsupervised%20learning%20is%20a%20type%20of%20machine%20learning.,make%20predictions%20on%20new%20examples

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1.5 AM na prática

Apesar do grande foco nos algoritmos, na prática, a execução dos algoritmos é uma parte relativamente pequena de um projeto em que se aplique AM. Vejamos uma visão geral do processo:

5. Aprendizagem supervisionada (também chamada aprendizado indutivo).
6. Aprendizagem não supervisionada.
7. Aprendizagem semisupervisionada.
8. Aprendizagem por reforço.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 APRENDIZAGEM NÃO SUPERVISIONADA

O campo de pesquisa de AM não supervisionada, segundo muitos autores, como é o caso de Geoffrey Hinton, é um mundo a ser explorado. Se compararmos com o AM supervisionado, entende-se que a forma que nós, seres humanos, aprendemos é muito mais parecida (e natural) com AM não supervisionada. Esta é só uma das razões para a afirmação de que deveremos ter muitas evoluções neste campo nos próximos anos.

A grande diferença em relação ao aprendizado supervisionado é que em AM não supervisionado não temos uma entrada do tipo Y. Isto é, a variável resposta não está presente. Imagine um aluno estudando (aprendendo) sobre um conceito em sala de aula. Quando lhe é solicitado que faça uma lista de exercícios, normalmente há um gabarito de respostas que ajuda o aluno e o guia pelo processo de aprendizado. O gabarito é a variável-alvo, o que se espera que o aluno deva atingir com um determinado conhecimento aplicado (seja qual for a área de conhecimento). Podemos dizer que o exercício com o gabarito é AM supervisionada.

Agora tire o gabarito e peça para o aluno resolver uma questão. Não há uma resposta que possa dar condições ao aluno de saber se ele “acertou”. Ele desenvolve o exercício, chega a um determinado ponto em que pensa ser o final, a resposta, uma conclusão. Ele precisa refletir se aquela resposta, aquela conclusão, realmente faz sentido, se é aplicável. Os problemas que temos normalmente nas empresas, nas profissões, são muito mais parecidos com este exemplo do que com um exercício com gabarito, não é mesmo?

Figura 12 – Diagrama de aprendizagem de máquina
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

A Figura “Diagrama de aprendizagem de máquina” nos mostra como ficaria o diagrama de um AM não supervisionado, sem a entrada Y.

Um outro exemplo que poderíamos utilizar: imagine um algoritmo para reconhecimento de imagens de frutas. Temos três tipos de frutas em nossa base de fotografias: laranjas, maçãs e bananas. Como seriam os tipos de aprendizagem:

- **supervisionado:** montamos uma tabela de dados com cada uma das frutas, registrando seu peso e também a classificação, isto é, se é uma laranja, maçã ou banana. A partir daí, treinamos um algoritmo para “responder” (variável-alvo, ou Y) se é uma maçã, banana ou laranja;
- **não supervisionado:** montamos uma tabela com cada uma das frutas, sem, no entanto, incluir a informação de qual tipo de fruta é. Registramos o peso, tamanho, cor etc. Ao executar o algoritmo, ele “marca” cada fruta como um tipo. Depois de observarmos os resultados, constatamos que, neste caso, a cor da fruta foi muito relevante e que tivemos três tipos de frutas aglomeradas. A grande questão é que não sabemos que maçãs são maçãs. Simplesmente teremos um punhado de frutas aglomeradas em três cantos distintos. Precisaremos descobrir o que fazer com isso e se é possível fazer algo.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

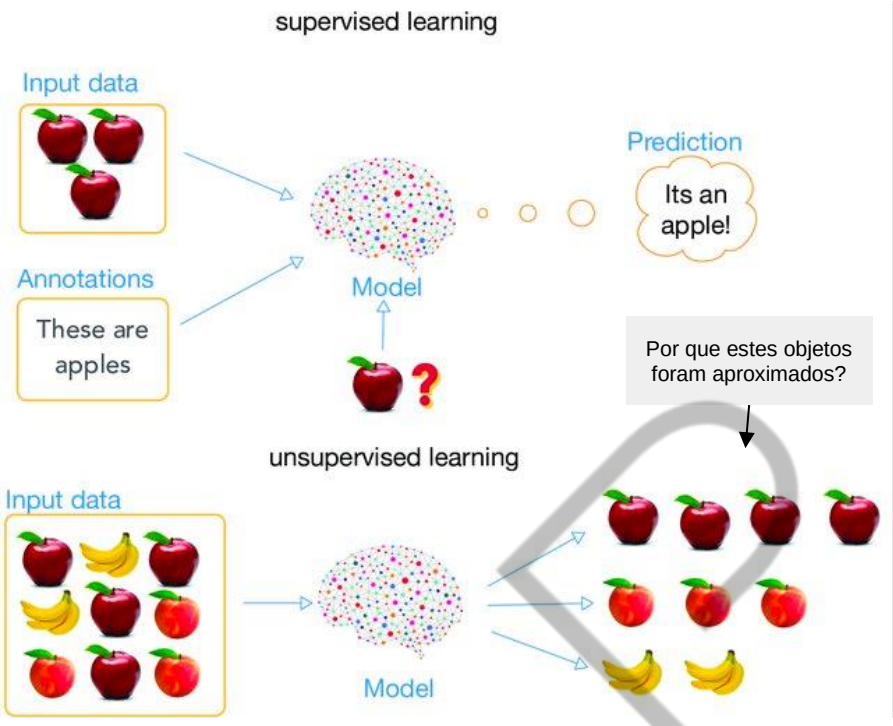

Figura 13 – Conceitos de AM supervisionada e não supervisionada
Fonte: Research Gate (2018), adaptada pelo autor (2022)

Por exemplo: por observação dos dados, ou seja, de algumas amostras das imagens, constatamos que a maioria das bananas está aglomerada entre si, assim como as maçãs e bananas. As exceções ocorreram para maçãs muito claras (não tão vermelhas) que foram confundidas com laranjas claras. Algumas laranjas mais amarelas também foram confundidas com bananas.

Mas se uma AM não supervisionada não gera um resultado tal como a supervisionada (ou seja, após construído, o algoritmo não gera como saída um Y), o que ela gera?

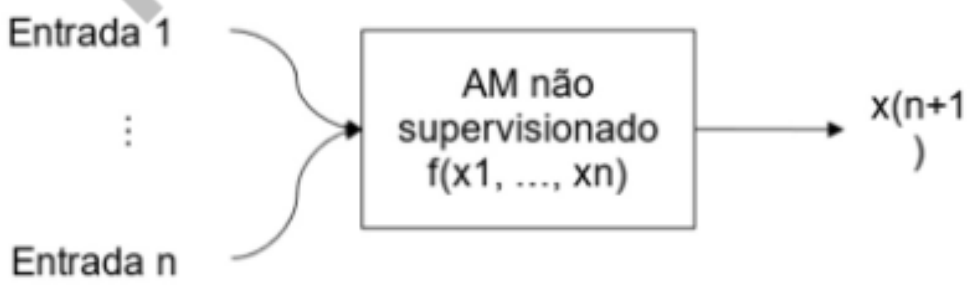

Figura 14 – Retorno de uma função de AM não supervisionado
Fonte Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Podemos ver acima que o retorno de uma AM não supervisionada não é um valor de Y, mas um novo valor de x que não está contido no conjunto (x1 … xn). Daí o chamarmos de x(n+1). Pois ele seria o enésimo+1 elemento do conjunto.

Quer ver um exemplo simples?

Digamos que tenhamos uma variável em um conjunto de dados que representa a idade das pessoas contidas em uma tabela. Após alguma técnica de AM aplicada, teremos uma nova variável que terá os valores 1 e 2, em que várias pessoas foram aglomeradas em duas regiões distintas, a quem nomeamos de 1 e 2. Após uma análise minuciosa dos dados das pessoas, em especial a idade, notamos que a grande maioria das pessoas marcadas como 1 na nova variável, é de crianças e adolescentes. Enquanto os adultos e idosos foram marcados como 2. Podemos chegar à conclusão de que nosso algoritmo tem esta capacidade, a de aproximar pessoas próximas no sentido da variável idade.

Se fôssemos utilizar uma técnica de AM supervisionada, no entanto, precisaríamos de uma variável Y de resposta, que neste caso seria Y = [adulto, criança]. E seria necessário que ela estivesse preenchida para boa parte das pessoas registradas na base de dados, para que pudéssemos criar um algoritmo que classifica pessoas entre uma dessas duas categorias.

Notaram a diferença?

Em uma AM supervisionada, estamos com um foco bem “fechado” em descobrir ou solucionar um determinado problema. Com AM não supervisionada, na maioria das vezes, estamos buscando encontrar algo, sem saber necessariamente o que é.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3 APRENDIZAGEM SUPERVISIONADA

Agora que estudamos AM não supervisionada, fica mais fácil definir o que é AM supervisionada: estamos tentando prever uma variável Y. Tão simples quanto isto. Nem tanto.

Na previsão da variável Y, ao utilizarmos as técnicas de avaliação e otimização, estamos buscando justamente melhorar ao máximo nossas previsões. Melhorar uma previsão implica reduzir (ou minimizar) erros de previsão. Ora, quando realizamos uma previsão, gostaríamos que essa previsão se realizasse ou, ao menos, ficasse muito próxima do real.

3.1 A função perda *(loss function)*

A primeira característica forte de uma AM supervisionada é a definição da função perda. Independentemente da definição da função, o objetivo sempre será o mesmo: minimizar a função perda.

$$min(L(y, \hat{y})) \qquad (2)$$

Esta função será definida de acordo com o tipo de algoritmo aplicada. A análise dos erros (resultados das funções perda) nos propiciam um método para descobrir diversas características dos dados e dos modelos.

3.2 Sobreajuste *(overfitting)*

A busca incessante pela minimização da função perda muitas vezes nos leva a um viés de aplicação do algoritmo. Ou seja, se temos um viés, significa que o algoritmo estará “enviesado” e, portanto, não responderá bem a tentativas de previsões quando tentarmos generalizar nossos problemas. A este fenômeno damos o nome de sobreajuste, *overfit* ou *overfitting*.

Podemos generalizar nosso conceito de AM baseado nestes dois conceitos: AM supervisionada é sobre minimização da função perda, evitando o sobreajuste.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Podemos pensar em um alfaiate quando está ajustando a roupa ao corpo do cliente. Se sobrar uma folga desproporcional em alguma parte, a roupa não ficará elegante. De forma inversa, se o ajuste for realizado em demasia, o cliente ficará desconfortável, a ponto de que, quanto mais ajustada, a roupa poderá romper.

Figura 15 – Explicação visual do sobreajuste por meio de um meme
Fonte: YouTube (2020)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

ATIVIDADE TREINO 1 - MÉTRICAS DE AVALIAÇÃO DE UM ALGORITMO DE MACHINE LEARNING

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams.

É fundamental que saibamos avaliar métricas, pois delas decorrem a análise de performance dos algoritmos. Faça uma breve pesquisa e coloque a seguir com suas palavras o entendimento das métricas de:

1. Acurácia (Accuracy)
2. Precisão (Precision)
3. Recall

	Salvar
1.	
2.	
3.	

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

ATIVIDADE TREINO 2 - UM POUCO MAIS SOBRE MACHINE LEARNING

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams.

Uma excelente forma de fixar conhecimentos é realizar um resumo do nosso entendimento sobre determinado tópico. Após o estudo do capítulo, registre um resumo dos principais pontos (5 ao menos) que mais te chamaram a atenção neste capítulo.

Comandos que executei	Salvar
1.	
2.	
3.	
4.	
5.	

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

ATIVIDADE TREINO 3 – OVERFIT

Essa atividade não é avaliativa, caso queira ter um feedback, entre em contato com seu tutor pelo Teams.

Um fenômeno que ocorre quando ajustamos algoritmos de Machine Learning é conhecido como *overfit* ou sobre ajuste. Há diversas formas de entender o overfit, especialmente por meio de gráficos com exemplos.

Após uma pesquisa na internet, cite 3 exemplos de overfit que podem ocorrer:

Problemas decorrentes de overfit	Salvar
1.	
2.	
3.	

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

ANYOHA, R. The History of Artificial Intelligence - Can Machines Think? 2017. **Harvard University**. Disponível em: https://sitn.hms.harvard.edu/flash/2017/history-artificial-intelligence/. Acesso em: 19 fev. 2022.

BROWNLEE, J. **What Is Semi-Supervised Learning**. 2021. Disponível em: https://machinelearningmastery.com/what-is-semi-supervised-learning/#:~:text=Semi%2Dsupervised%20learning%20is%20a%20type%20of%20machine%20learning.,make%20predictions%20on%20new%20examples. Acesso em: 19 fev. 2022.

DALLEMULE, L.; DAVENPORT, T. H. What's Your Data Strategy? 2017. **Harvard Business Review**. Disponível em: https://hbr.org/2017/05/whats-your-data-strategy. Acesso em: 19 fev. 2022.

KELLEHER J. D.; TIERNEY B. **Machine Learning.** New Jersey: MIT Press, 2018.

MOHRI M.; *et. al*. **Foundations of Machine Learning.** 2 ed. New Jersey: MIT Press, 2018.

PRESERVE KNOWLEDGE. Heroes of Deep Learning: Andrew Ng interviews Geoffrey Hinton. Youtube, 2018. Disponível em: https://www.youtube.com/watch?v=-eyhCTvrEtE. Acesso em: 19 fev. 2022.

SMOLA A.; VISHWANATHAN S. V. N. **Introduction to Machine Learning.** Cambridge: Cambridge University Press, 2008.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com