FIAP ON

DATA VIZ & DATA SCIENCE

EXPLORANDO RECURSOS ANALÍTICOS COM DATA VIZ E DATA SCIENCE

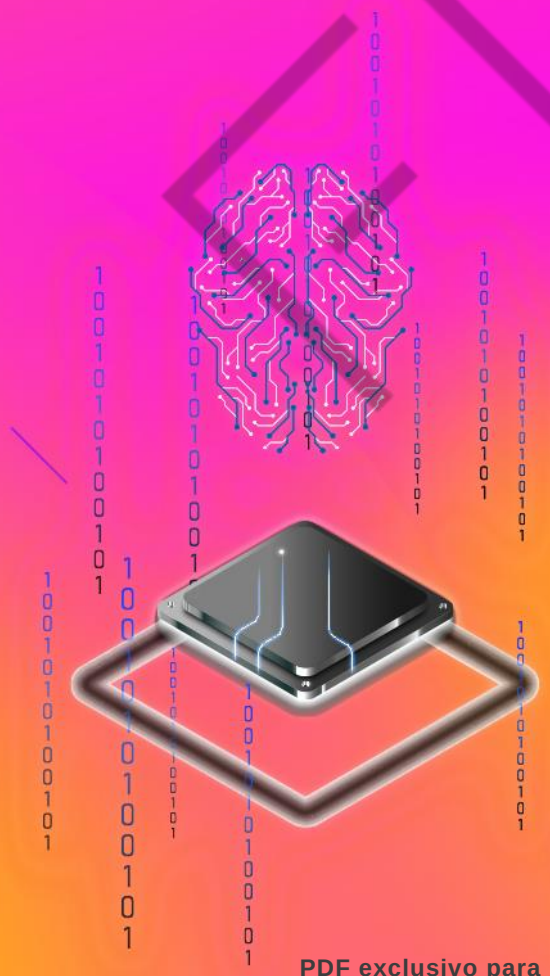

1

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 - Exemplo painel do google ADS 9
Figura 2 - Exemplo de resposta para o primeiro desafio.....11
Figura 3 - Exemplo de um código fonte Python envolvendo matriz de correlação....14
Figura 4 - Exemplo de componentes do grupo.....15

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE TABELAS

Quadro 1 - Colunas e uma breve descrição dos conteúdos da planilha vendas_linha_petshop_2024.csv 8
Quadro 2 - Colunas e uma breve descrição dos conteúdos da planilha Gastos_Publicidade_MelhoresCompras.xlsx 12

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

EXPLORANDO RECURSOS ANALÍTICOS COM DATA VIZ E DATA SCIENCE.....5
1.1 Contextualizado o momento atual 5
1.2 Primeiro desafio: Visualização de dados * Criando gráficos para apoiar a tomada de decisão estratégica 6
1.3 Segundo desafio: Explorando e Analisando Dados para uso em Ciência de Dados 9
1.4 Terceiro desafio: Apoiar a área de Marketing da empresa Melhores Compras com o método estatístico de regressão linear 11
2. ENTREGAS ESPERADAS.....15
1. Arquivo componentes.txt contendo o nome do Grupo, RM e nome dos Integrantes (em ordem alfabética).....15

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

EXPLORANDO RECURSOS ANALÍTICOS COM DATA VIZ E DATA SCIENCE

1 EMPRESA MELHORES COMPRAS

1.1 Contextualizado o momento atual

A jornada analítica que estamos vivenciando com o ambicioso projeto de transformação digital no e-commerce da renomada empresa Melhores Compras tem sido mais do que uma mera atualização tecnológica. Com o envolvimento da maior parte das pessoas das organizações, a cooperação entre os departamentos e a sinergia gerada para solução de incidentes está latente, fazendo com que as pessoas da empresa se sintam importantes, e todos estão com a visão do “olho do dono”, ou seja, tendem a se comportar de maneira mais responsável e eficiente em relação ao dia a dia da operação dentro da empresa.

Com a implementação das abordagens SSBI (Self Service Business Intelligence) e KDD (Knowledge Discovery in Databases), resultados significativos estão sendo alcançados, permitindo que cada indivíduo tenha autonomia sobre suas atividades, gerando um alto grau de engajamento.

Em uma nova reunião mensal onde Jobs esteve presente, foi solicitado que essa jornada siga em frente a passos largos, e agora chegou a hora de avançar para além do conhecido, mergulhando profundamente na parte de visualização de dados dentro da área de Business Intelligence. Nessa área, vamos nos deparar com uma vasta gama de tópicos significativos, desde os conceitos fundamentais até a aplicação prática utilizando ferramentas como o Power BI.

Adicionando novos conceitos, à medida que mergulhamos em nosso aprendizado, nos deparamos com o vasto campo das ciências de dados, onde agora será possível explorar diversas técnicas, desde a modelagem preditiva até a introdução às redes neurais artificiais, e que, agora, irão se torna- parte integrante da jornada da Melhores Compras.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Com o domínio dessas técnicas, esperamos explorar os dados de nossa organização com uma profundidade sem precedentes, gerando insights valiosos que servirão como alicerce para decisões fundamentadas.

Nossa meta é clara: demonstrar na prática que a ciência de dados não é apenas uma ferramenta, mas sim um catalisador que diferencia as empresas que apenas armazenam dados das que os utilizam para gerar conhecimento e fortalecer a cultura data-driven.

Agora, com esse contexto em mente, é hora de colocar em prática os 3 desafios que a equipe da Melhores Compras preparou para você.

1.2 Primeiro desafio: Visualização de dados * Criando gráficos para apoiar a tomada de decisão estratégica

Jobs sabe que Visualização de Dados (DataViz) é mais uma abordagem ou uma forma de trabalho do que uma tecnologia específica, e embora esse tema envolva o uso de ferramentas específicas de BI (Business Intelligence), como Tableau, Power BI, QlikSense, Looker ou qualquer outra tecnologia, seu foco principal está na democratização dos dados.

Os gráficos exibidos a partir de dados existentes têm um papel fundamental na comunicação e na satisfação do público-alvo, e com o uso de gráficos e painéis, conseguimos deixar a comunicação mais atrativa e agradável, trazendo grande interesse para as pessoas que se utilizam dessas informações para a tomada de decisão.

Nesse seu primeiro desafio, a área comercial da Melhores Compras disponibilizou 5 anos de movimento das vendas (arquivo vendas_linha_petshop_2020_2024.csv), entre 2020 até o ano de 2024, contendo informações significativas, onde temos aproximadamente 250.000 linhas que, se forem analisadas individualmente, dificilmente seria possível entender o comportamento do consumo feito pelos seus clientes.

O seu desafio será fazer a leitura desse arquivo em uma ferramenta onde seja possível gerar gráficos e dashboards (PowerBI, Tableau ou outra similar) simples ou combinados e criar um painel estratégico que deverá ser apresentado à área

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

comercial da Melhores Compras. Sinta-se livre para identificar um tema a partir dos conteúdos disponibilizados que permita trazer valor agregado à organização com o uso de dados.

Seu objetivo será analisar as informações disponibilizadas nesse painel e entender como as vendas estão se comportando nesse período de tempo e explicar essas informações por meio de uma análise exploratória. A explicação é uma entrega obrigatória e irá servir como orientação inicial para a área comercial aperfeiçoar suas decisões.

A planilha disponibilizada foi aprovada pela equipe técnica de Jobs para ser utilizada nesse primeiro desafio e, no Quadro 1, temos uma breve explicação de cada coluna para melhor entendimento.

Nome Coluna	**Breve Descrição**
Região País	Essa coluna representa a região do País onde ocorreu a venda. Os possíveis valores são: Centro-Oeste, Norte, Nordeste, Sul e Sudeste.
Produto	Essa coluna representa o nome do produto que foi vendido. Atualmente, a Melhores Compras possui mais de 50.000 SKU dentro de sua estrutura para atender aos mais diversos tipos de clientes.
Valor	Essa coluna representa valor unitário do produto no momento da venda realizada.
Quantidade	Essa coluna representa a quantidade vendida do produto em uma determinada data.
Valor Total Bruto	Essa coluna representa o cálculo de multiplicação entre a quantidade vendida e o valor unitário do produto no momento da venda realizada.
Data	Essa coluna representa a data completa em que foi gerado o Pedido proveniente do e-commerce Melhores Compras. Nessa data, temos o dia, mês, ano, hora e minuto feito pelo cliente.
Estado	Essa coluna representa o nome do Estado onde o cliente realizou a compra.
Forma Pagto	Essa coluna representa a forma de pagamento escolhida pelo cliente no momento da compra. Os possíveis valores são: Boleto Bancário; Cartão Crédito; Cartão Débito e Pix.
Centro Distribuição	Essa coluna representa o centro de distribuição de onde saiu o produto a ser entregue ao cliente.
ResponsavelPedido	Essa coluna representa a pessoa responsável pelo centro de distribuição de onde saiu o produto a ser entregue ao cliente.
Valor Comissão	Essa coluna representa o valor da comissão paga ao responsável pela venda.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Lucro Liquido	Essa coluna representa o lucro líquido alcançado pela Melhores Compras a partir da venda realizada (*valor já deduzido de impostos e despesas).
CategoriaProd	Essa coluna representa a categoria do produto associado ao produto vendido.

Quadro 1 - Colunas e uma breve descrição dos conteúdos da planilha vendas_linha_petshop_2024.csv
Fonte: Autor (2024)

Os dados disponibilizados nesse arquivo *.csv necessitam ser analisados e tratados justamente por estarem sendo transacionados em vários departamentos dentro da empresa e, consequentemente, sofrendo ajustes manuais.

Em resumo, neste primeiro desafio você deve importar e tratar o arquivo de vendas (vendas_linha_petshop_2020_2024.csv) em uma ferramenta de BI como Power BI ou Tableau, criar um painel estratégico com gráficos que revelem insights sobre o comportamento de consumo dos clientes nos últimos 5 anos e, por fim, apresentar uma análise exploratória escrita que explique os principais achados para apoiar a tomada de decisão da área comercial.

Entrega esperada do primeiro desafio (item 1.2):

Crie um arquivo Word (*.docx) contendo as imagens de sua visualização de dados e as variações possíveis, justificando a importância da informação gerada a partir dos dados.

Para cada imagem apresentada, não esquecer de colocar comentários significativos do que está sendo apresentado. A entrega desse item deve contemplar as diferentes visualizações geradas e o resultado alcançado pelo grupo.

Visando contribuir com sua entrega, temos a seguir uma imagem contendo um exemplo hipotético com o resultado da entrega do desafio.

Dashboard exemplo hipotético:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Figura 1 - Exemplo painel do Google ADS
Fonte: Autor (2024)

Exemplos de comentários esperados a respeito do seu dashboard:

- O tema principal abordado pelo seu dashboard.;
- Como o painel foi dividido? Justifique;
- Qual a informação em destaque do seu painel? Justifique;
- Quais gráficos combinados foram escolhidos para o seu tema? Justifique.

1.3 Segundo desafio: Explorando e Analisando Dados para uso em Ciência de Dados

No universo da ciência de dados, uma vez que temos os dados disponíveis para uso, diversas atividades precisam ser consideradas. Uma das mais importantes é aprender a analisar e utilizar as bases de dados, que são disponibilizadas das mais diversas maneiras e nos mais variados formatos, permitindo-nos criar modelos preditivos.

No projeto Melhores Compras, chegou o momento de vestir o chapéu de cientista de dados e aplicar a técnica de análise de dados utilizando o arquivo

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

vendas_linha_petshop_2020_2024.csv, que representa um conjunto de dados contendo algumas vendas do e-commerce durante o período entre 2020 e 2024.

Como sabemos, todo algoritmo de Machine Learning ou Deep Learning começa com a análise e exploração dos dados. Assumindo o papel de cientista de dados dentro da empresa Melhores Compras, sua tarefa será analisar profundamente a amostra de dados fornecida e responder às seguintes perguntas:

*dica: utilize a linguagem de programação Python como apoio para responder algumas dessas perguntas.

1) Qual seria sua estratégia para criar uma base de dados para treinamento, teste e validação? Escreva as proporções e justifique cada uma delas.
2) Explique qual é a diferença entre variável categórica e numérica. Analisando o conteúdo do arquivo vendas_linha_petshop_2020_2024.csv, quais variáveis podem ser consideradas numéricas e quais podem ser consideradas categóricas?
3) Analisando os dados do arquivo, qual a importância do código do pedido dentro de qualquer análise preditiva que você venha a fazer com esses dados?
4) A partir dos dados desse arquivo, identifique quantos registros foram identificados como outliers. Descreva qual foi a estratégia utilizada para identificar esses registros.
5) Dado que existem outliers identificados, qual seria a melhor estratégia para tratá-los?

Entrega esperada do segundo desafio (item 1.3):

Crie um arquivo word (*.docx) que responda as 5 perguntas feitas sobre o tema análise de dados para uso em modelo preditivo.

Visando contribuir com sua entrega, temos a seguir uma imagem contendo um exemplo hipotético com o resultado da entrega do terceiro desafio:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1) **Qual seria sua estratégia para criar uma base de dados para treinamento, teste e validação? Escreva as proporções e justifique cada uma delas?**

Para criar uma base de dados adequada para treinamento, teste e validação, é muito dividir o conjunto de dados de maneira que possamos avaliar e melhorar a performance do nosso modelo de deep learning de forma confiável. Para o projeto da instituição financeira BigMoney as proporções recomendadas são:

- 70% para Treinamento; Justificativa: O maior subconjunto de dados é reservado para treinamento, pois este conjunto irá permitir que ele aprenda padrões e relações presentes nos dados.
- 20% para Validação. Justificativa: Este subconjunto será usado durante o treinamento para ajustar necessário para obter eficiência no modelo e tomar decisões sobre sua arquitetura.
- 10% para Teste: Justificativa: Após o modelo estar treinado e validado, utilizamos o conjunto de teste para avaliar o desempenho final do modelo, fornecendo uma estimativa de como o modelo irá se comportar com dados reais e novos.

Figura 2 - Exemplo de resposta para o primeiro desafio
Fonte: Autor (2024)

1.4 Terceiro desafio: Apoiar a área de Marketing da empresa Melhores Compras com o método estatístico de regressão linear

O enorme sucesso alcançado com o uso da análise de dados fez brilhar os olhos dos executivos da área de Marketing da empresa Melhores Compras. Essa área é uma das mais importantes da empresa e está necessitando, nesse momento, compreender um pouco melhor suas campanhas publicitárias realizadas na linha do tempo e as que estão por vir.

Com o objetivo de maximizar o retorno sobre investimento *Return of Investment* (ROI) em publicidade, a equipe de Marketing gostaria de explorar o uso do método estatístico de regressão linear, tendo ciência que esse método permite estabelecer uma relação matemática entre os gastos com publicidade em diversos canais, como redes sociais, Jornal, Rádio e TV, e as vendas geradas a partir dessas campanhas.

É esperado que, ao aplicar a regressão sobre os dados históricos de gastos com publicidade e vendas, a equipe de marketing poderá prever com maior precisão o impacto das futuras campanhas publicitárias nas vendas da empresa.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Essa análise aprofundada permitirá que a Melhores Compras aloque de forma mais eficaz seu orçamento de publicidade, concentrando os recursos nos canais que demonstrarem maior retorno sobre investimento e, dessa forma, a empresa poderá impulsionar suas vendas e maximizar sua presença no mercado de e-commerce.

A planilha Gastos_Publicidade_MelhoresCompras.csv disponibilizada foi aprovada pela equipe técnica de Jobs para ser utilizada nesse desafio e, no Quadro 2, temos uma breve explicação de cada coluna para melhor entendimento.

Nome Coluna	**Breve Descrição**
Ano	Essa coluna representa o ano em que foi realizada a publicidade em determinado tipo de mídia.
Mês	Essa coluna representa o mês em que foi realizada a publicidade em determinado tipo de mídia.
Tipo de Mídia	Essa coluna representa o tipo de mídia utilizado pela área comercial para fazer publicidade. Os possíveis valores são: Páginas web, Redes sociais, TV, Jornal, Revista e Rádio. Em 2024, a mídia Instragram foi criada separadamente para trazer mais visibilidade na análise dos dados.
Gastos com Publicidade (em R$)	Essa coluna representa o valor investido durante o mês e ano em determinado tipo de mídia.
Previsão Inicial de Aumento de Vendas (em mil unidades)	Essa coluna representa uma previsão do aumento de vendas esperado para um determinado produto após a realização do investimento em publicidade em um dado período de tempo. Nesse modelo, essa coluna representa o ROI (Return on Investment).

Quadro 2 - Colunas e uma breve descrição dos conteúdos da planilha Gastos_Publicidade_MelhoresCompras.xlsx
Fonte: Autor (2024)

A área comercial está interessada em construir um modelo de regressão linear que relacione os gastos com publicidade em cada canal com o incremento das vendas futuras com base nessas variáveis, permitindo prever as vendas esperadas para os próximos meses e ajustar sua estratégia de publicidade de acordo com o resultado fornecido.

O objetivo da atividade é criar um modelo de regressão que explique o **aumento das vendas** com o menor erro possível, buscando o maior R^2 a partir dos dados fornecidos.

Logo, espera-se as seguintes informações:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Encontre o melhor R^2 possível: desenvolva um modelo de regressão que apresente o maior coeficiente de determinação (R^2), representando com precisão os fatores que influenciam o aumento das vendas.

1) Matriz de correlação: gere uma matriz de correlação entre as variáveis do conjunto de dados e comente os principais relacionamentos identificados, destacando variáveis que apresentem forte correlação com a variável de interesse.

2) Gráficos de dispersão: elabore gráficos de dispersão entre cada variável independente e a variável dependente (aumento de vendas). A partir deles, identifique e comente possíveis padrões, tendências ou outliers relevantes.

3) Análise explicativa para o time de marketing: escreva uma explicação textual clara e didática voltada a profissionais de marketing e outras áreas não técnicas. A análise deve destacar os principais resultados do modelo, incluindo uma conclusão sobre quais canais ou tipos de mídia apresentam o melhor ROI (Return On Investment) para orientar decisões estratégicas.

Dicas para obter o melhor modelo possível:

a) Observe que a coluna **Tipo de Mídia** não pode ser utilizada diretamente na sua regressão. Logo, será necessário transformá-la em uma **variável dummy.** Sem esse cuidado, é possível que você não obtenha o melhor resultado possível da sua regressão. Além disso, esse cuidado fará com que você possa informar ao time de marketing **qual o tipo de mídia que traz o melhor retorno**;

b) Perceba também que a coluna **Gastos com Publicidade (em R$)** possui informações de gasto de todas as mídias existentes. Ou seja, usá-la diretamente, sem tratamento algum, pode prejudicar a sua análise de que tipo de mídia traz o melhor retorno;

c) É esperado que a entrega seja feita utilizando regressões lineares. Contudo, não há prejuízo se o grupo decidir explorar a utilização de regressões polinomiais, basta ter cuidado com o *overfitting*.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

A entrega deve ser feita dentro de um único arquivo de notebook (*.i**pynb**) contendo todo o código-fonte utilizado e que permita ser reproduzido na íntegra pelo professor.

O arquivo csv original não deve, em hipótese alguma, ser alterado. Todas as transformações necessárias sobre o arquivo original devem ser feitas por meio de código Python no seu arquivo de notebook.

Entregas esperadas do terceiro desafio (item 1.4):

Um arquivo fonte Analise_ROI.ipynb: notebook com:

Exemplo de entrega:

```
# Importar as bibliotecas necessárias
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

# Carregar os dados
dados = pd.read_csv('seu_arquivo.csv') # Substitua 'seu_arquivo.csv' pelo nome do seu

# Calcular a matriz de correlação
correlation_matrix = dados.corr()

# Plotar a matriz de correlação
plt.figure(figsize=(10, 8))
sns.heatmap(correlation_matrix, annot=True, cmap='coolwarm', fmt=".2f", linewidths=0.
plt.title('Matriz de Correlação')
plt.show()
```

Figura 3 - Exemplo de um código fonte Python envolvendo matriz de correlação
Fonte: Google (2024)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2. ENTREGAS ESPERADAS

1. Arquivo componentes.txt contendo o nome do Grupo, RM e nome dos Integrantes (em ordem alfabética)

Veja uma imagem hipotética que representa um exemplo de entrega.

Componentes do Grupo #prosperidade (ordem alfabética)		
RM	**Nome**	**Representante**
78521	Adriana Dias Lopes	
78365	Gustavo Sakspildap	
78721	Maria Linda Souza	Sim
77125	Yuri Silva	

Figura 4 - Exemplo de componentes do grupo
Fonte: Autor (2024)

2 Item 1.2: Primeiro desafio: Visualização de dados * Criando gráficos para apoiar a tomada de decisão estratégica

Crie um arquivo Word (*.docx) contendo as imagens de sua visualização de dados e as variações possíveis, justificando a importância da informação gerada a partir dos dados. Para cada imagem apresentada, não esquecer de colocar comentários significativos do que está sendo apresentado. A entrega desse item deve contemplar as diferentes visualizações geradas e o resultado alcançado pelo grupo.

3 Item 1.3: Segundo desafio: Explorando e Analisando Dados para uso em Ciência de Dados

Crie um arquivo word (*.docx) contendo as respostas das 5 perguntas feitas sobre os dados disponibilizados dentro do arquivo vendas_linha_petshop_2020_2024.csv.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

4 Item 1.4: Terceiro desafio: Apoiar a área de Marketing da empresa Melhores Compras com o método estatístico de regressão linear

Entrega do arquivo notebook (*.ipynb) contendo todo o código-fonte utilizado e que permita ser reproduzido na íntegra pelo professor.

Recomendação Final

Gere um arquivo **<nome_grupo>_PBL_TSCO_2o_Ano_Fase5.zip**, agrupe os entregáveis acima e faça o upload conforme orientação da atividade.

Atenção: Não serão aceitas entregas por meio de links. A entrega deve ser realizada conforme instruções e anexo, conforme arquivos indicados.

Sucesso em sua jornada e não se esqueça: se precisar de algo, procure o seu tutor para pronto atendimento. A equipe da empresa Melhores Compras deseja um bom desafio ao grupo!

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com