FIAP ON

DATA VIZ & DATA SCIENCE

REGRESSÃO LINEAR: UM DOS PILARES PARA A ANÁLISE DE DADOS

11

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 – Ilustração da ideia básica de uma regressão linear 5
Figura 2 – Generalização de uma regressão linear.....6
Figura 3 – Erro de aproximação da reta de ajuste 7
Figura 4 – Regressão linear utilizada para previsão de vendas.....8
Figura 5 – Região de previsões e intervalo de confiança detalhados graficamente..8
Figura 6 – Dataset de PIB e tráfego mensal 10
Figura 7 – Gráfico de linha com a evolução dos Índices PIB e tráfego 11
Figura 8 – Matriz de correlação.....12
Figura 9 – Gráfico da matriz de correlação 13
Figura 10 – Exemplificação da reta de regressão 15
Figura 11 – Gráfico do erro quadrático e ponto de mínimo 17
Figura 12 – Estatísticas de uma Regressão Linear.....19
Figura 13 – Estatísticas de uma Regressão Linear Multivariada.....21
Figura 14 – P-valor ao simular um modelo complexo 23

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Carga e instalação de bibliotecas 10
Código-fonte 2 – Carga e instalação de bibliotecas 12
Código-fonte 3 – Pipeline de um algoritmo preditivo em *Python* utilizando Regressão Linear 18
Código-fonte 4 – Pipeline de um algoritmo preditivo em *Python* utilizando Regressão Linear para o PIB 19
Código-fonte 5 – Inclusão de mais variáveis preditoras, tornando um Modelo Multivariado 20
Código-fonte 6 – Simulação do Overfit.....22

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

REGRESSÃO LINEAR: UM DOS PILARES PARA ANÁLISE DE DADOS 5
1 INTRODUÇÃO 5
2 COMO É CALCULADA UMA REGRESSÃO LINEAR 9
2.1 Análise de Correlação das variáveis 10
2.2 Conceito de uma Regressão Linear 13
3 COMO CALCULAR UMA REGRESSÃO LINEAR EM PYTHON 18
4 REGRESSÃO LOGÍSTICA EM PYTHON 25
REFERÊNCIAS 27

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REGRESSÃO LINEAR: UM DOS PILARES PARA ANÁLISE DE DADOS

1 INTRODUÇÃO

Vamos, agora, nos aprofundar em modelos preditivos, em que a variável-alvo é do tipo numérica, o que chamamos de "regressores". Inicialmente, vamos conhecer uma técnica chamada regressão linear, que é útil para resolver problemas simples de análise de dados preditivas quando temos uma variável-alvo numérica. A importância de conhecer essa técnica é que suas bases ou conceitos são empregados em muitos dos modernos algoritmos de *Machine Learning*.

Uma regressão linear, basicamente, é uma técnica matemática de aproximação de um fenômeno por uma reta (por isso o nome linear). A partir disso, utilizamos técnicas estatísticas para estimar qual seria o erro aproximado se tentássemos utilizar aquela reta para prever o futuro. Vejamos o exemplo na Figura “Ilustração da ideia básica de uma regressão linear”.

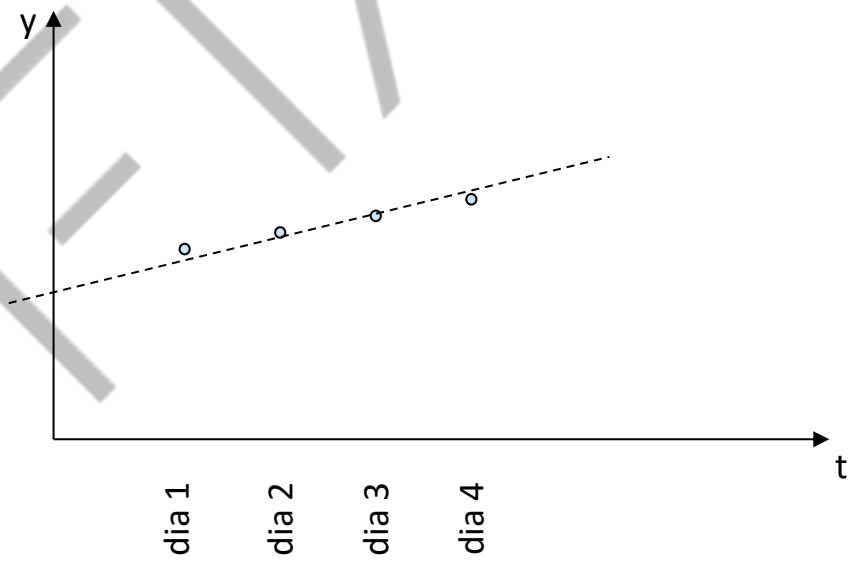

Figura 1 – Ilustração da ideia básica de uma regressão linear
Fonte: Elaborado pelo autor (2022)

Neste exemplo, utilizamos a unidade de tempo dia, porém poderíamos generalizar para qualquer unidade de tempo. No eixo vertical está a variável y, que chamamos de variável-alvo (ou variável dependente ou ainda variável endógena). Estamos analisando, portanto, a relação (neste caso linear) entre duas variáveis. O

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

exemplo utilizado acima demonstra possivelmente uma série temporal[1] da variável y ao longo do tempo t. Mas uma regressão linear é aplicável a qualquer problema em que tivermos uma variável-alvo numérica e, claro, tenhamos uma relação linear entre as variáveis. Repare essa generalização na Figura “Generalização de uma regressão linear”.

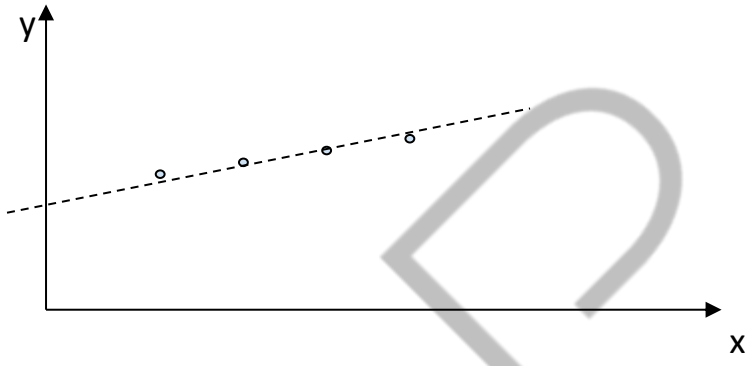

Figura 2 – Generalização de uma regressão linear
Fonte: Elaborada pelo autor (2022)

Em ambas as figuras, temos 4 pontos conhecidos num gráfico de dispersão que visualmente nos demonstram que os pontos estão "alinhados", não necessariamente com um alinhamento perfeito, mas com uma boa aproximação. E é basicamente este tipo de problema no qual conseguimos aplicar uma regressão linear. A reta tracejada é a idealização do que chamamos de modelo, ou seja, através dessa reta conseguimos representar os pontos.

Mas essa reta não passa exatamente sobre os pontos, ela é uma aproximação, uma tentativa de ajuste sobre os pontos. Sendo assim, a pequena distância observada entre a reta e o ponto, no sentido vertical (que é o mesmo sentido da variável-alvo) chamamos de erro de aproximação. Vejamos, na Figura “Erro de aproximação da reta de ajuste”, uma ampliação desta área marcando os erros de aproximação.

[1] Este conceito de série temporal é explorado em outras disciplinas e capítulos do curso.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

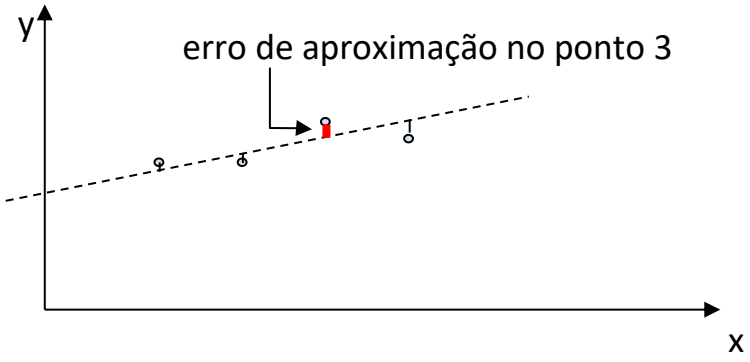

Figura 3 – Erro de aproximação da reta de ajuste
Fonte: Elaborada pelo autor (2022)

Cada um dos 4 pontos tem uma distância (no sentido vertical) entre a reta tracejada e o ponto em si, representando um erro de aproximação naquele ponto. Na figura, colocamos uma seta e demarcamos essa distância ou erro com uma cor diferente para melhor exemplificar o erro no ponto 3. Todos os pontos têm um erro de aproximação menor ou maior.

Como podemos utilizar essa reta no sentido de um modelo preditivo? Vamos buscar novamente o exemplo da Figura “Ilustração da ideia básica de uma regressão linear”, que poderia ser o caso de vendas diárias de uma empresa, e imaginar que gostaríamos de prever as vendas nos próximos 2 dias, utilizando a base de dados de vendas conhecidas nos 4 dias anteriores. A Figura “Regressão linear utilizada para previsão de vendas” nos dá uma ideia geral gráfica deste uso.

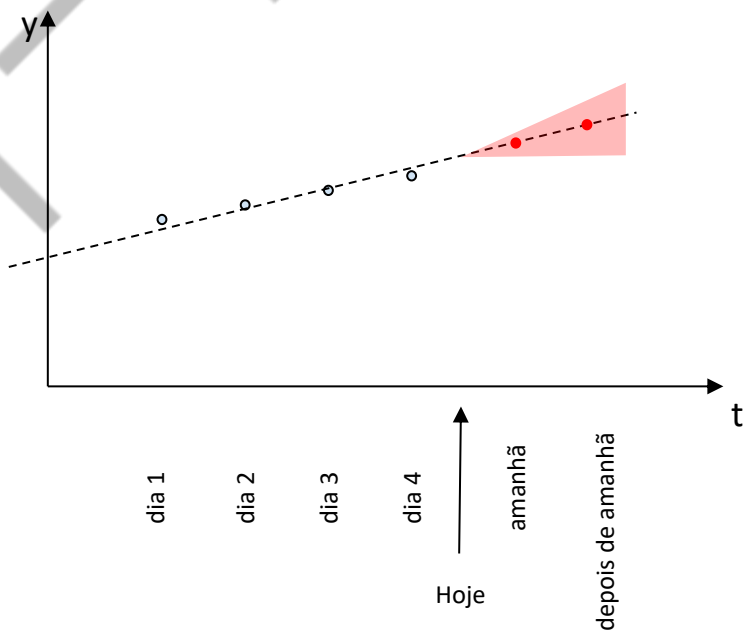

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Figura 4 – Regressão linear utilizada para previsão de vendas
Fonte: Elaborada pelo autor (2022)

Repare nos pontos que colocamos em amanhã e depois de amanhã, eles, diferentemente dos pontos dos dias 1 a 4, estão exatamente sobre a reta. Ora, quando realizamos a previsão, a reta é a nossa idealização do que aconteceria com a venda. Mas como temos a tal da incerteza sempre teremos um erro[2] quando fizermos uma previsão, por menor que queiramos e batalhemos para que ele seja muito pequeno, ele existe. Você também deve ter notado uma região hachurada em cor avermelhada ao fundo, certo? Essa região é uma exemplificação do que seria nosso intervalo de confiança[3] nas previsões que fazemos. É como se tivéssemos um histograma representando uma curva normal "dentro" daquela vermelha, sendo que cada lado da curva normal "cola no chão" onde termina a região vermelha.

Ficou difícil de visualizar? Veja se ajuda com a ilustração da Figura “Região de previsões e intervalo de confiança detalhados graficamente”.

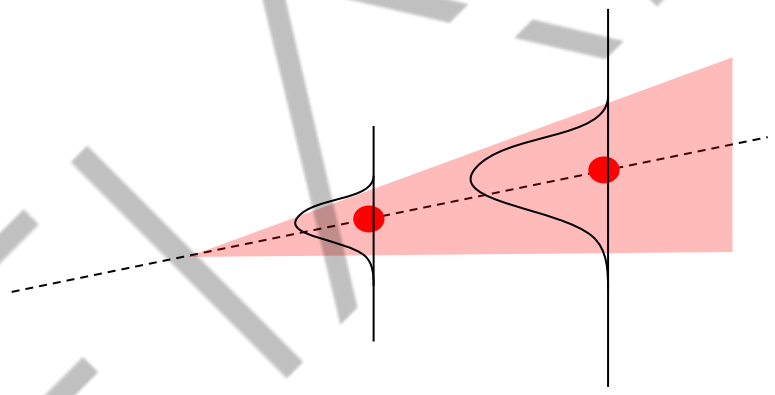

Figura 5 – Região de previsões e intervalo de confiança detalhados graficamente
Fonte: Elaborada pelo autor (2022)

A diferença desse gráfico e o que você está acostumado ver com a curva normal é que, corriqueiramente, a curva normal é apresentada com uma rotação de 90° e uma por vez.

[2] Falamos um pouco sobre erro de previsão em outro capítulo, quando citamos a métrica MSE, por exemplo.
[3] Falamos disso em outro capítulo, demonstrando como calcular.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 COMO É CALCULADA UMA REGRESSÃO LINEAR

A ideia básica da regressão linear passa pela premissa de que duas variáveis tenham uma relação linear entre si. Isso pode ser visto através de um gráfico de dispersão entre duas variáveis, como pudemos observar na seção anterior, mas também podemos gerar uma métrica (uma estatística) que nos ajude a entender a relação linear entre duas variáveis. Essa métrica é o coeficiente de correlação linear[4].

Para seguirmos com nossos estudos, vamos utilizar uma base de dados composta dos seguintes dados:

- ANO_MES: a referência ao ano e mês, no formato mmm/aa.
- PIB: é o índice (base referência inicial 100) relativo ao PIB naquele mês[5].
- BRL, BRP, BRT: dados mensais de tráfego nas rodovias pedagiadas do Brasil, computados pela Associação Brasileira de Concessionárias de Rodovias (ABCR), para veículos leves (BRL), veículos pesados (BRP) e totais (BRT).
- SPL, SPP, SPT: dados mensais de tráfegos, no mesmo formato dos dados do Brasil, porém segmentados para o estado de São Paulo.
- RJL, RJP, RJT: dados mensais de tráfegos, no mesmo formato dos dados do Brasil, porém segmentados para o estado do Rio de Janeiro.
- PRL, PRP, PRT: dados mensais de tráfegos, no mesmo formato dos dados do Brasil, porém segmentados para o estado do Paraná.

Nos exemplos apresentados neste capítulo, procuraremos analisar a evolução do PIB brasileiro e utilizaremos como variáveis preditoras (features, variáveis independentes ou variáveis exógenas) dados de tráfego de veículos. No Código-fonte “Carga e instalação de bibliotecas”, carregamos os dados no Colab e visualizamos uma amostra da tabela.

[4] Temos mais de um tipo de coeficiente de correlação linear, porém o mais comumente utilizado é o método de Pearson, aplicável a duas variáveis numéricas.
[5] Estes dados podem ser obtidos no site de séries econômicas calculadas pelo Itaú, em seu site: https://www.itau.com.br/itaubba-pt/analises-economicas/series-economicas, na seção "PIB Mensal Itaú Unibanco".

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
import pandas as pd

# Análise de correlação linear entre variáveis
df =
pd.read_csv("https://raw.githubusercontent.com/diogenesjusto/FIAP-On-
Line-Graduation/main/datasets/pib.csv")

df.head()
```

Código-fonte 1 – Carga e instalação de bibliotecas
Fonte: Elaborado pelo autor (2022)

A tabela gerada pode ser vista na Figura “Dataset de PIB e tráfego mensal”, na qual observamos que os dados começam no ano de 2004, a partir do mês de janeiro.

ANO_MES	PIB	BRL	BRP	BRT	SLP	SPP	SPT	PRL	PRP	PRT	RJL	RJP	RJT
jan/04	103.09	109.19	108.67	109.08	102.84	114.27	105.38	127.49	99.72	117.49	115.15	98.66	112.59
fev/04	102.05	95.65	104.52	97.63	90.76	109.83	94.99	96.6	99.24	97.55	102.4	90.2	100.51
mar/04	110.43	91.69	125.53	99.26	89.78	133.24	99.43	83.79	118.44	96.27	105.88	107.36	106.11
abr/04	106.77	95.36	118.34	100.49	94.58	123.55	101.02	91.79	117.25	100.96	105.64	99.25	104.65
mai/04	108.08	92.47	121.49	98.96	91.34	128.32	99.55	85.73	117.08	97.02	106.74	102.29	106.05
jun/04	109.19	89.25	119.93	96.11	87.79	128.51	96.83	84.0	112.53	94.28	103.06	100.74	102.7
jul/04	111.95	100.39	125.64	106.03	100.22	135.26	108.01	98.32	116.49	104.87	111.06	105.54	110.21
ago/04	110.92	94.2	129.67	102.13	93.66	139.38	103.81	87.53	124.59	100.88	106.74	107.29	106.82
set/04	110.18	95.54	126.7	102.5	94.93	138.84	104.68	91.66	111.49	98.8	106.18	105.65	106.09
out/04	109.71	99.46	124.85	105.14	98.58	136.18	106.93	93.66	107.63	98.69	111.41	105.84	110.55
nov/04	109.24	96.88	122.26	102.55	96.49	134.13	104.85	91.18	100.84	94.66	106.29	106.85	106.38
dez/04	111.53	114.6	124.11	116.72	112.92	134.31	117.67	120.85	102.47	114.23	119.2	114.07	118.4
jan/05	108.26	113.68	111.74	113.24	108.83	119.75	111.26	130.36	95.64	117.85	114.05	103.19	112.36
fev/05	105.52	96.36	107.86	98.93	93.41	116.18	98.47	99.42	98.16	98.96	99.13	92.93	98.17
mar/05	113.0	101.37	126.91	107.08	101.05	134.88	108.56	97.42	126.79	108.0	108.69	108.65	108.69
abr/05	111.39	95.79	120.34	101.27	97.23	130.91	104.71	86.92	108.39	94.65	105.23	103.31	104.94
mai/05	112.52	97.85	124.23	103.75	98.25	135.35	106.49	90.68	108.79	97.2	107.9	106.41	107.67
jun/05	113.43	92.27	125.26	99.64	92.04	137.16	102.06	82.38	108.76	91.88	104.79	106.35	105.03
jul/05	113.43	105.39	123.41	109.42	106.01	135.94	112.65	104.73	106.97	105.54	114.02	105.6	112.72
ago/05	114.97	98.47	129.87	105.48	98.78	143.76	108.77	92.84	111.56	99.58	110.16	107.11	109.68

Figura 6 – Dataset de PIB e tráfego mensal
Fonte: Elaborada pelo autor (2022)

2.1 Análise de Correlação das variáveis

Para conhecermos o comportamento (evolução) do PIB, podemos utilizar um gráfico de linha, como demonstrado na Figura “Gráfico de Linha com a evolução dos Índices PIB e tráfego”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
# Recortamos somente as colunas que iremos utilizar, ou seja, até a coluna 16
graf = df.iloc[:,2:5]
import matplotlib.pyplot as plt
plt.rcParams["figure.figsize"] = (15,4)

fig, ax = plt.subplots()

graf.plot(ax=ax)
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x7fdd942870d0>
```

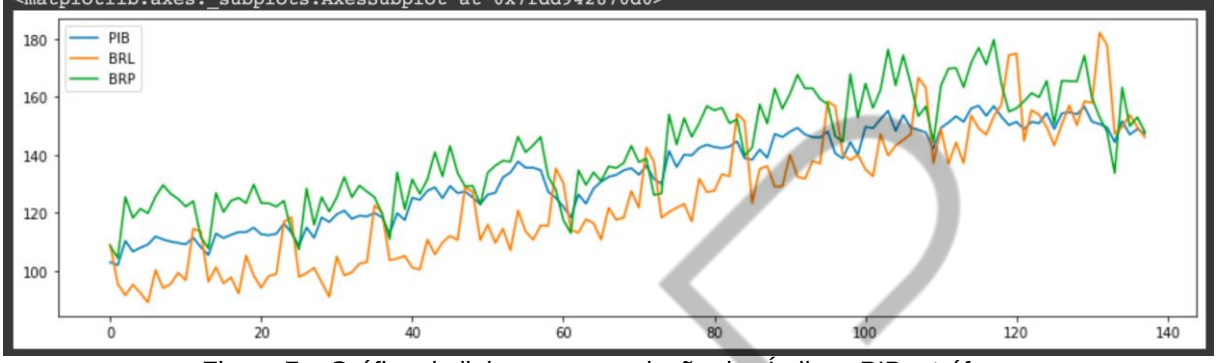

Figura 7 – Gráfico de linha com a evolução dos Índices PIB e tráfego
Fonte: Elaborada pelo autor (2022)

Nesse gráfico, podemos notar algumas características dos dados apresentados, alguns dos quais listamos abaixo:

- O PIB (linha do meio, azul) tem uma queda acentuada um pouco antes da metade da série, ou seja, mês 60. Como nosso dataset inicia em 2004, 60 meses após jan/04 seria o 5º ano, ou seja, 2008. Esta queda mais acentuada coincide com a crise econômica mundial ocorrida naquele ano, em que temos como evento inicial a quebra do banco Lehman Brothers[6].
- Aparentemente, temos uma característica (em todas as 3 séries) de repetição de um "padrão". Por exemplo, a linha referente ao tráfego de veículos leves no Brasil inicia caindo e, depois de 12 meses, tem uma alta. E se mantém assim por 2 a 3 meses e volta a cair. E esse padrão vai se repetindo a cada período de 12 meses. É o que chamamos de sazonalidade. E faz todo sentido, no final de um ano e início de um novo, ter uma alta; é o período de férias de verão no Brasil, quando muitas pessoas viajam.
- As linhas de BRP e BRL (ou seja, tráfego de veículos pesados e leves, respectivamente) parecem andar em um movimento inverso; quando uma cai a outra sobe e vice-versa. Isso também faz sentido, pois no período de

[6] Ver: https://agenciabrasil.ebc.com.br/economia/noticia/2018-09/marco-de-crise-global-quebra-do-lehman-brothers-completa-10-anos

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

férias de verão, quando as pessoas partem de férias, também é o período em que temos uma redução do tráfego de caminhões.

Podemos calcular, então, a matriz de correlação entre essas variáveis para analisarmos os coeficientes de correlação.

```
df_corr = df.iloc[:,2:15]
df_corr.corr()
```

	PIB	BRL	BRP	BRT	SLP	SPP	SPT	PRL	PRP	PRT	RJL	RJP	RJT
PIB	1.000000	0.875316	0.945026	0.923355	0.912627	0.940794	0.951017	0.733248	0.839292	0.825325	0.898519	0.942831	0.916856
BRL	0.875316	1.000000	0.767459	0.991358	0.993062	0.746181	0.972831	0.955565	0.718522	0.981076	0.979452	0.846981	0.970447
BRP	0.945026	0.767459	1.000000	0.844730	0.820792	0.995076	0.888951	0.592349	0.902659	0.723687	0.833051	0.964372	0.864668
BRT	0.923355	0.991358	0.844730	1.000000	0.996182	0.826268	0.993391	0.919659	0.782612	0.967285	0.987573	0.904601	0.986700
SLP	0.912627	0.993062	0.820792	0.996182	1.000000	0.802807	0.990845	0.919804	0.759298	0.961229	0.982256	0.881877	0.978191
SPP	0.940794	0.746181	0.995076	0.826268	0.802807	1.000000	0.875741	0.570393	0.866241	0.696353	0.811741	0.959666	0.845971
SPT	0.951017	0.972831	0.888951	0.993391	0.990845	0.875741	1.000000	0.875226	0.808810	0.936562	0.978696	0.931131	0.983231
PRL	0.733248	0.955565	0.592349	0.919659	0.919804	0.570393	0.875226	1.000000	0.556847	0.978079	0.905421	0.709462	0.886085
PRP	0.839292	0.718522	0.902659	0.782612	0.759298	0.866241	0.808810	0.556847	1.000000	0.717468	0.769610	0.828425	0.788056
PRT	0.825325	0.981076	0.723687	0.967285	0.961229	0.696353	0.936562	0.978079	0.717468	1.000000	0.952224	0.803776	0.940861
RJL	0.898519	0.979452	0.833051	0.987573	0.982256	0.811741	0.978696	0.905421	0.769610	0.952224	1.000000	0.907173	0.997570
RJP	0.942831	0.846981	0.964372	0.904601	0.881877	0.959666	0.931131	0.709462	0.828425	0.803776	0.907173	1.000000	0.934108
RJT	0.916856	0.970447	0.864668	0.986700	0.978191	0.845971	0.983231	0.886085	0.788056	0.940861	0.997570	0.934108	1.000000

Figura 8 – Matriz de correlação
Fonte: Elaborada pelo autor (2022)

Uma matriz de correlação com várias variáveis é difícil de analisar visualmente quando procuramos localizar valores mais altos ou menores. Aplicar recursos gráficos nessa matriz ajuda bastante na localização. Há vários exemplos ou formas de tornar essa matriz gráfica e escolhemos uma no Código-fonte “Carga e instalação de bibliotecas”, com o resultado na Figura “Gráfico da Matriz de Correlação”.

```
f = plt.figure(figsize=(8, 8))
plt.matshow(df_corr.corr(), fignum=f.number)
plt.xticks(range(df_corr.select_dtypes(['number']).shape[1]),
df_corr.select_dtypes(['number']).columns, fontsize=10, rotation=45)
plt.yticks(range(df_corr.select_dtypes(['number']).shape[1]),
df_corr.select_dtypes(['number']).columns, fontsize=10)
cb = plt.colorbar()
cb.ax.tick_params(labelsize=10)
plt.title('Correlation Matrix', fontsize=16);
```

Código-fonte 2 – Carga e instalação de bibliotecas
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

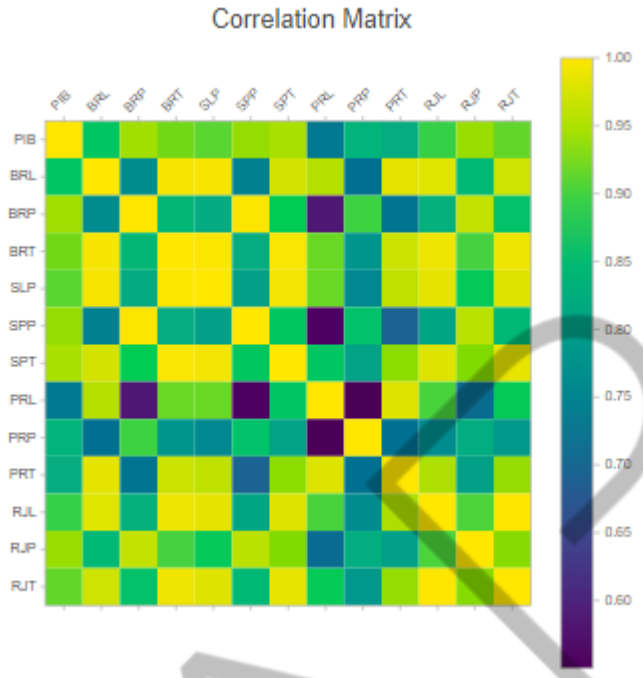

Figura 9 – Gráfico da matriz de correlação
Fonte: Elaborada pelo autor (2022)

Além de encontrar as relações mais fortes entre variáveis nas cores mais claras (amarelo) e mais fracas em escuro (azul), podemos avaliar que, se nosso objetivo é prever o PIB, nos fixamos na coluna 1 (ou linha 1), e podemos observar que as variáveis que têm maior correlação linear com PIB são: BRP, SPP, SPT e RJP (um duplo check nos valores da matriz numérica é importante).

Uma reflexão: se encontrarmos valores com um alto coeficiente de correlação, poderemos supor que um influencia em outro (relação causa-efeito). Assim sendo, a partir de estimativas futuras da variável independente, calcularemos a previsão da variável dependente.

2.2 Conceito de uma Regressão Linear

Parece ter sido algo parecido que Galton (primo de Charles Darwin) utilizou para propor a "Regressão a Média", baseado em estudos aplicados a área da saúde. O método estatístico da regressão (e suas variantes) é um dos mais utilizados para

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

análise de relacionamento de eventos em diversos campos de aplicação: saúde, política, economia[7], contabilidade, direito, entre outros.

No início do capítulo, vimos que estamos buscando uma reta que melhor se ajusta em um conjunto de pontos dados. E o que é uma reta? Se recapitularmos nossas aulas no ensino fundamental, em matemática, temos o estudo do que chamamos de equação da reta que é expressada por:

$$y = \lambda x + \beta$$

Onde:

y e x: valores dos pontos no sentido vertical e horizontal, respectivamente.

λ: coeficiente angular da reta, ou seja, este valor diz se uma reta está "apontando" para cima, para baixo e qual é a sua inclinação.

β: coeficiente linear ou de intercepto, que nada mais é do que o valor que a reta assume quando intercepta o eixo y (onde x=0).

Mas nem tudo são flores. Lá na Figura “Erro de aproximação da reta de ajuste”, vimos que a reta não passa pelos pontos, há um erro de aproximação associado a cada ponto. Então precisamos incluir esse erro na equação da acima.

Teremos então:

$$y = \lambda x + \beta + \varepsilon$$

Onde:

ε: erros de aproximação da reta associados a cada ponto.

Podemos deixar um pouco mais bem escrita essa equação para nos lembrarmos de que cada ε corresponde a um erro diferente associado aos pontos, ou seja, valores de x e y.

Ficaria assim:

$$y_i = \lambda x_i + \beta + \varepsilon_i$$

Onde:

[7] Em Economia, a disciplina se chama Econometria; em Contabilidade, chama-se Contabilometria; e, em direito, o nome é Jurimetria.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

i, é o índice, a indicação da i-ésima linha do dataset ou conjunto de dados.

Vamos desenhar novamente o gráfico com um pouco mais de detalhes sobre a nossa reta, que pode ser vista na Figura “Exemplificação da reta de regressão”.

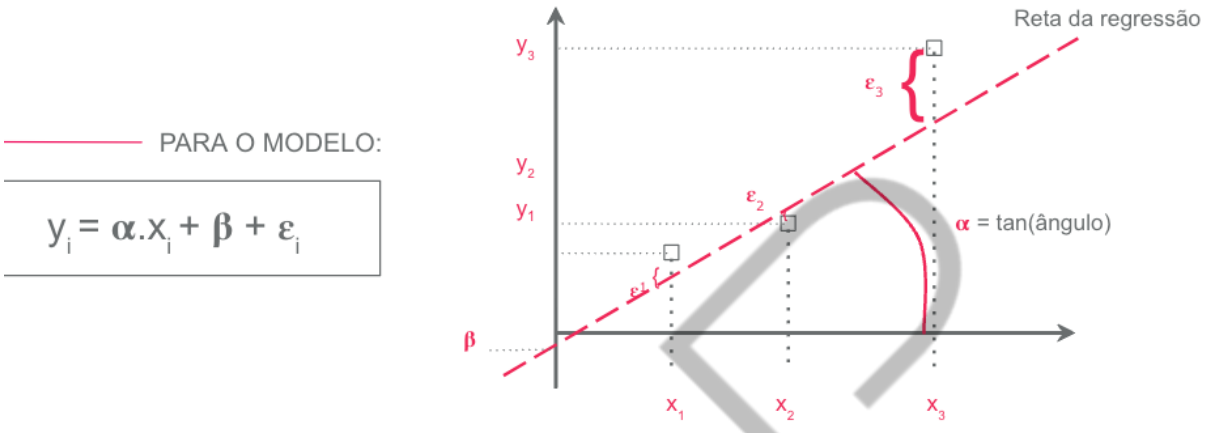

Figura 10 – Exemplificação da reta de regressão
Fonte: Elaborada pelo autor (2022)

Pronto, agora ficou simples! Como já temos os valores de y_i e x_i (que nos exemplos que estamos trabalhando será PIB e BRP, respectivamente) só falta calcular os valores λ, β e os ε_i. Ou seja, precisamos encontrar a reta!

Mas pensemos juntos: quantas retas que se aproximem dos pontos podem existir?

Pelo nosso conhecimento dos números Reais, sabemos que são infinitos números que existem no intervalo entre quaisquer 2 números reais. Precisamos de uma ferramenta, uma técnica que nos auxilie a encontrar qual é a reta que mais se aproxima do conjunto de pontos, certo? Ora, e a reta que mais se aproxima do conjunto de pontos será justamente aquela na qual os valores dos erros de aproximação serão menores, não é mesmo? Precisamos então minimizar o erro de aproximação.

Comecemos com uma operação algébrica para isolar o ε_i, ou seja, colocá-lo do lado "esquerdo" da equação e deixar os outros termos do lado "direito".

$$\varepsilon_i = y_i - \lambda x_i - \beta$$

Queremos minimizar o erro "geral", não somente o erro em um ponto. Então poderíamos calcular o somatório dos erros e tentar minimizar esse número, certo?

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Ficaria assim:

$\sum_{i=1}^{n} \varepsilon_i = \sum_{i=1}^{n} (y_i - \lambda x_i - \beta)$

Repare novamente no gráfico da Figura “Exemplificação da reta de regressão”, você poderá notar que alguns valores de ε são superiores à reta e outros inferiores. Isso significa que alguns erros são positivos e outros negativos.

É possível fazer a soma direta dos valores dos erros, então? Se o fizermos, os valores se anularão. Vamos então utilizar um mecanismo matemático para eliminar os valores negativos que é elevar à potência 2.

$\sum_{i=1}^{n} (\varepsilon_i)^2 = \sum_{i=1}^{n} (y_i - \lambda x_i - \beta)^2$

Pronto, temos agora o que chamamos de somatório de erros quadrados, que se dá pela fórmula no lado direito. Relembre que nós queremos encontrar os parâmetros λ e β (que são os coeficientes angular e intercepto). Se olharmos com atenção para a fórmula, veremos que temos agora estes elementos elevados ao quadrado (foi o artifício para conseguirmos somar os erros que nos trouxe o quadrado).

Ora, esta equação agora lembra algo parecido com:

$y = ax^2 + bx + c$

Não é mesmo?

E qual é o gráfico que uma equação quadrática (equação de segundo grau) gera? Relembrando novamente nossos estudos de matemática lá do ensino fundamental e do ensino médio, é uma parábola. Assim, se fizermos o gráfico da equação do erro quadrático, teremos algo parecido com o que apresenta a Figura “Gráfico do erro quadrático e ponto de mínimo”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

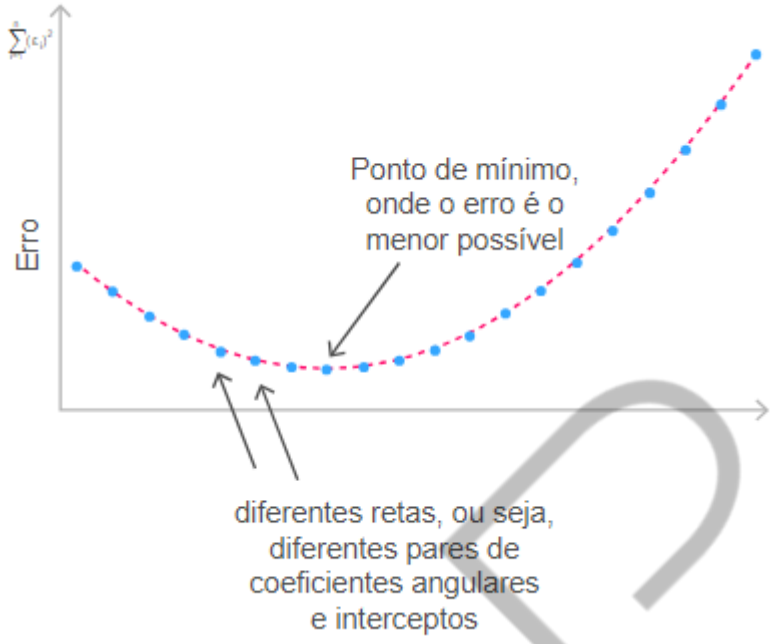

Figura 11 – Gráfico do erro quadrático e ponto de mínimo
Fonte: Elaborada pelo autor (2022)

Deixamos assinalada nesse gráfico a parte mais baixa da parábola, que é conhecida como ponto de mínimo desta função. Os valores no sentido vertical simbolizam a magnitude dos erros. O eixo horizontal corresponde à variação dos valores de λ e β. Ou seja, cada uma das posições horizontais representam um par λ e β, portanto, representam uma reta diferente (das infinitas que citamos anteriormente).

E qual dessas retas nos interessa? Aquela que tiver o menor erro de aproximação. E a reta que tem o menor erro de aproximação é aquela na qual a combinação λ e β gera o menor erro (justamente o ponto de mínimo assinalado no gráfico!)

Pronto! Só falta agora saber como encontramos este tal ponto de mínimo!

Queremos, agora, realizar esta operação:

$$\min[\sum_{i=1}^{n} (\varepsilon_i)^2] = \min [\sum_{i=1}^{n} (y_i - \lambda x_i - \beta)^2]$$

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3 COMO CALCULAR UMA REGRESSÃO LINEAR EM PYTHON

No capítulo anterior, sobre modelos preditivos, calculamos uma regressão linear em *Python*, no exemplo com dados sobre vinhos. Vamos relembrar aqui:

```
# 1 - Carga das bibliotecas
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

# 2 - Carga dos dados
df =
pd.read_csv("https://raw.githubusercontent.com/diogenesjusto/FIAP/mast
er/dados/wine/red_wine4_30.csv", encoding='latin-1')

# 3 - Preparação dos dados

# 4 - Separação das amostras de treino e teste
x_treino, x_teste, y_treino, y_teste =
train_test_split(df[['wine_year', 'wine_price']],
df['wine_rating'],test_size=0.3266, random_state=33)

# 5 - Construção do modelo
mod = LinearRegression()
mod.fit(x_treino,y_treino)

# 6 - Avaliação do modelo
y_prev = mod.predict(x_teste)
mean_squared_error(y_teste, y_prev)
```

Código-fonte 3 – Pipeline de um algoritmo preditivo em *Python* utilizando Regressão Linear
Fonte: Elaborado pelo autor (2022)

Vamos, agora, adaptar nosso código para o dataset utilizado neste capítulo sobre dados do PIB. No caso, nossa variável-alvo será o PIB mensal (que é na verdade um índice calculado) e as variáveis preditoras, os dados de tráfego do BR e dos estados.

```
# 1 - Carga das bibliotecas
import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error

# 2 - Carga dos dados
df =
pd.read_csv("https://raw.githubusercontent.com/diogenesjusto/FIAP-On-
Line-Graduation/main/datasets/pib.csv")

# 3 - Preparação dos dados
```

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
# 4 - Separação das amostras de treino e teste
x_treino, x_teste, y_treino, y_teste = train_test_split(df[['BRP']],
df['PIB'],test_size=0.3266, random_state=33)

# 5 - Construção do modelo
mod = LinearRegression()
mod.fit(x_treino,y_treino)

# Cálculo das estatísticas da regressão linear
import statsmodels.api as sm
mod = sm.OLS(y_treino, x_treino).fit()
print(mod.summary())

# 6 - Avaliação do modelo
y_prev = mod.predict(x_teste)
mean_squared_error(y_teste, y_prev)
```

Código-fonte 4 – Pipeline de um algoritmo preditivo em *Python* utilizando Regressão Linear para o PIB
Fonte: Elaborado pelo autor (2022)

A estrutura do código está adequada, porém com um problema de amostragem que citaremos. Vamos, primeiro, avaliar o que mudou no ajuste do Código-fonte "Carga e instalação de bibliotecas".

Podemos notar a inserção da statsmodels.api que é uma biblioteca para coletar estatísticas de uma regressão linear. O resultado gerado por ele aparece na figura abaixo.

```
                                 OLS Regression Results
=======================================================================================
Dep. Variable:                    PIB   R-squared (uncentered):              0.998
Model:                            OLS   Adj. R-squared (uncentered):         0.998
Method:                 Least Squares   F-statistic:                     4.858e+04
Date:                Thu, 04 Aug 2022   Prob (F-statistic):              6.14e-126
Time:                        01:34:06   Log-Likelihood:                    -290.86
No. Observations:                  92   AIC:                                 583.7
Df Residuals:                      91   BIC:                                 586.2
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
BRP            0.9399      0.004    220.402      0.000       0.931       0.948
==============================================================================
Omnibus:                        3.208   Durbin-Watson:                   2.029
Prob(Omnibus):                  0.201   Jarque-Bera (JB):                2.514
Skew:                           0.356   Prob(JB):                        0.285
Kurtosis:                       3.385   Cond. No.                         1.00
==============================================================================
```

Figura 12 – Estatísticas de uma Regressão Linear
Fonte: Elaborada pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Sinalizam-se, na Figura “Estatísticas de uma Regressão Linear”, algumas estatísticas da regressão, para que consigamos interpretar o quão o modelo de regressão linear está se ajustado aos dados em questão:

- R-squared: o R quadrado é uma métrica que sinaliza o quanto uma modelo linear está conseguindo representar os dados. O melhor valor de R2 seria mais próximo de 1 possível (que podemos interpretar como próximo a 100%). Neste caso 0,99 é um valor bem alto.
- Std err: o erro padrão é uma métrica que sinaliza qual é o erro médio (ou seja, a distância) do modelo para os pontos. Um erro baixo, pequeno, será mais adequado que um erro grande[8].
- P>|t|: o p-valor é a métrica que sinaliza quando menor, mais a significância estatística. A significância estatística será 1 (ou 100%) menos o p-valor. Um p-valor na ordem de 0,05 (5%) significa dizer que a significância estatística do meu modelo será da ordem de 0,95 (95%). Podemos interpretar da seguinte forma: se realizarmos 100 previsões, 95 estão dentro de uma faixa de erro médio, sendo que 5 poderão ser muito maiores ou muito menores.
- coef: Este é literalmente o coeficiente da regressão linear. Neste caso, temos uma regressão com somente uma variável preditora, portanto teremos somente um coeficiente.

O modelo aqui tem somente uma variável preditora e o chamaremos de regressão linear simples. Se incluirmos mais de uma variável preditora passaremos a chamar esse modelo de regressão linear multivariada. Vejamos no exemplo abaixo do Código-fonte “Inclusão de mais variáveis preditoras, tornando um Modelo Multivariado” e Figura “Estatísticas de uma Regressão Linear Multivariada”.

A linha alterada do código foi somente a sinalizada abaixo, ou seja, simplesmente escolhemos incluir BRL como nova variável preditora.

```
# 4 - Separação das amostras de treino e teste
x_treino, x_teste, y_treino, y_teste =
train_test_split(df[['BRP','BRL']], df['PIB'],test_size=0.3266,
random_state=33)
```

Código-fonte 5 – Inclusão de mais variáveis preditoras, tornando um Modelo Multivariado

[8] Note que o erro padrão está na mesma ordem de grandeza dos dados. Isto é, se a variável é expressa em dezenas, o erro deverá ser pequeno. Se estiver na ordem de grande de milhões, o erro padrão será proporcional.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Fonte: Elaborado pelo autor (2022)

A hipótese que estamos levantando neste caso é que para explicar o PIB, além do tráfego de veículos pesados (BRP, ou seja, caminhões), podemos também incluir o tráfego de veículos leves (BRL, ou seja, carros). E isso parece fazer sentido, visto que cada componente pode sinalizar uma alavanca para a economia, expressa pelo PIB:

- BRP: bens produzidos em indústria, grãos colhidos, entre outros, precisam ser transportados. No Brasil, o maior modal de transporte é o rodoviário.
- BRL: se a população está num nível de renda crescente, pode ter um excedente para ser utilizado em lazer, na forma de viagens rodoviárias.

```
                                 OLS Regression Results
=======================================================================================
Dep. Variable:                    PIB   R-squared (uncentered):              0.999
Model:                            OLS   Adj. R-squared (uncentered):         0.999
Method:                 Least Squares   F-statistic:                     4.205e+04
Date:                Thu, 04 Aug 2022   Prob (F-statistic):              2.01e-134
Time:                        01:48:50   Log-Likelihood:                    -265.14
No. Observations:                  92   AIC:                                 534.3
Df Residuals:                      90   BIC:                                 539.3
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
BRP            0.7076      0.028     24.848      0.000       0.651       0.764
BRL            0.2616      0.032      8.211      0.000       0.198       0.325
==============================================================================
Omnibus:                        1.144   Durbin-Watson:                   2.051
Prob(Omnibus):                  0.564   Jarque-Bera (JB):                1.231
Skew:                           0.228   Prob(JB):                        0.540
Kurtosis:                       2.663   Cond. No.                         17.6
==============================================================================
```

Figura 13 – Estatísticas de uma Regressão Linear Multivariada
Fonte: Elaborada do autor (2022)

Neste caso, podemos observar que:

- R2 ficou um pouco mais alto que o modelo anterior, sinalizando uma regressão um pouco "melhor" ajustada aos dados.
- Std Err e P valor adequadamente baixos.
- Coef: podemos notar que o coeficiente de BRP é maior que o de BRL. Isto denota que o "peso" da variável BRP é maior que BRL. E parece fazer sentido, inclusive, pelas hipóteses levantadas.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Experimente executar diferentes modelos de regressão linear, com diferentes conjuntos de variáveis.

Não analisamos ainda o erro de previsão de uma regressão linear. A última linha de código traz o cálculo do MSE. Se compararmos o MSE de ambos os modelos, poderemos ver:

- Regressão Linear Simples com BRP preditora: 28,7.
- Regressão Linear Multivariada com BRP e BRL preditoras: 19,4.

Um erro menor é sinal de que o nosso segundo modelo tem uma performance melhor que o primeiro modelo. De uma forma geral, se conseguimos incluir mais "conhecimento" no modelo de dados, na forma de novas variáveis, que façam sentido para o problema em questão, temos uma grande chance de melhorar seus resultados. Evitando-se, com isso, uma sobrecarga, tornando o modelo complexo demais e extrapolando o erro de previsão para o fenômeno que chamamos de overfit. Vamos fazer uma simulação desse fenômeno.

```
# 4 - Separação das amostras de treino e teste
x_treino, x_teste, y_treino, y_teste =
train_test_split(df[['BRP','BRL','BRL','SLP','SPP','SPT','RJL','RJP','
RJT']], df['PIB'],test_size=0.3266, random_state=33)
```

Código-fonte 6 – Simulação do Overfit
Fonte: Elaborado pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                    PIB   R-squared (uncentered):          0.999
Model:                            OLS   Adj. R-squared (uncentered):     0.999
Method:                 Least Squares   F-statistic:                 1.226e+04
Date:                Thu, 04 Aug 2022   Prob (F-statistic):          2.04e-125
Time:                        02:19:04   Log-Likelihood:                -254.90
No. Observations:                  92   AIC:                             525.8
Df Residuals:                      84   BIC:                             546.0
Df Model:                           8
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
BRP            0.2551      0.277      0.921      0.360      -0.296       0.806
BRL            0.2199      0.168      1.313      0.193      -0.113       0.553
BRL            0.2199      0.168      1.313      0.193      -0.113       0.553
SLP            0.2468      2.351      0.105      0.917      -4.428       4.922
SPP            0.6877      0.792      0.869      0.387      -0.886       2.262
SPT           -0.8626      3.104     -0.278      0.782      -7.034       5.309
RJL           -2.9675      4.514     -0.657      0.513     -11.944       6.009
RJP           -1.0828      0.958     -1.130      0.262      -2.988       0.822
RJT            4.1782      5.457      0.766      0.446      -6.674      15.031
==============================================================================
Omnibus:                        1.739   Durbin-Watson:                   2.128
Prob(Omnibus):                  0.419   Jarque-Bera (JB):                1.531
Skew:                           0.180   Prob(JB):                        0.465
Kurtosis:                       2.481   Cond. No.                     6.37e+16
==============================================================================
```

Figura 14 – P-valor ao simular um modelo complexo
Fonte: Elaborada pelo autor (2022)

Repare que, nesse caso, temos diversas variáveis com p-valor bem alto, o que já é um sinal de que o modelo não está adequado, apesar do R2 alto, quando analisamos o MSE de 19,89 e verificamos que ele aumentou em relação ao modelo anterior. Não foi um aumento significativo, mas se continuarmos a sobrecarregar o modelo, esse erro continuará subindo e demonstrando de forma mais evidente o fenômeno do overfit.

Anteriormente, citamos um problema com a amostragem desses dados, correto? Note que essa base de dados tem uma característica de temporalidade e, se analisarmos com mais detalhe, conseguiremos verificar que se trata de uma série temporal. Assim sendo, a separação de bases de treino e teste mais adequada não seria uma amostragem aleatória, e sim uma janela temporal. Assim sendo, precisaremos utilizar da seguinte forma:

- Base Treino: dados do início escolhido da série até um conjunto preferencialmente de um período sazonal anterior (neste caso, como são dados mensais, 12 meses antes).
- Base Teste: o restante dos 12 meses mais atuais, como validação.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Dado que já estudamos séries temporais anteriormente no curso, será que você consegue realizar essa separação como exercício?

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

4 REGRESSÃO LOGÍSTICA EM PYTHON

De forma similar a uma aproximação por uma reta, a regressão logística implementa uma aproximação, também, porém ao invés de se utilizar uma reta, aqui é utilizada uma função chamada logística acumulada. Vejamos o formato desta curva na figura 15.

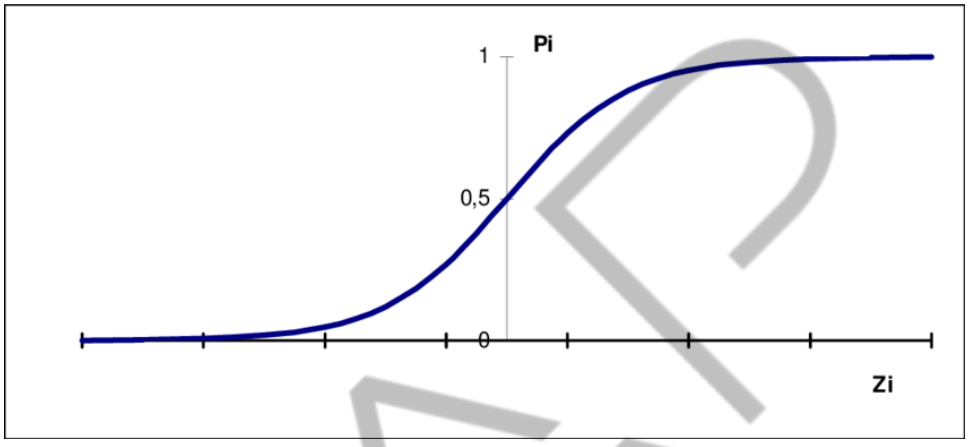

Figura 15 – Função Logística Acumulada
Fonte: Scarpel & Milioni (2002)

Ora, esta função tem como resposta (eixo vertical) muitos valores 0 (infinito a esquerda) e muitos valores 1 (infinito a direita), sendo que há uma faixa de conversão entre 0 e 1.

Se esta transformação for aplicada a variável resposta (y), podemos entender que teríamos uma série de 0 e 1, como resposta. E esta é uma característica exatamente de um classificador binário (veremos mais a frente classificadores, por enquanto basta que entendamos que a variável y seja composta por 0 e 1 para podermos utilizar esta técnica).

Vejamos como é a equação de uma regressão linear:

$y_i = \lambda x_i + \beta + \varepsilon_i$

Agora, aplicando a transformação da função logística acumulada a variável resposta y, teremos:

$\ln [y_i / (1- y_i)]= \lambda x_i + \beta + \varepsilon_i$

É uma função "linear" no lado direito da equação, porém no lado esquerdo não é. Para encontrar a melhor curva (coeficientes) que se adaptem a esta função, não se

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

aplica o método dos mínimos quadrados, e sim, o método da máxima verossimilhança. Este método está presente nos algoritmos que constroem regressões logísticas. Veremos como aplicar em python, no "Código-fonte 7".

```
import pandas as pd
from sklearn.linear_model import LogisticRegression

df =
pd.read_csv('https://raw.githubusercontent.com/diogenesjusto/FIAP-On-
Line-Graduation/main/datasets/arvore_titanic.csv')

model = LogisticRegression(solver='liblinear', random_state=0)

x_treino = df[['SibSp']]
y_treino = df['Survived']

model.fit(x_treino, y_treino)
```

Código-fonte 7 – Regressão Logística em Python
Fonte: Elaborado pelo autor (2023)

Note que a estrutura do código é muito similar a utilização de uma regressão linear. Para realizarmos uma previsão, basta seguir a mesma sintaxe utilizada na regressão linear, com o método predict.

O que vai mudar bastante é a avaliação de erro de uma regressão logística: como este algoritmo se aplicada como um bom classificador binário devemos considerar as métricas adequadas para um classificador. Isto será visto um pouco mais a frente, em um novo capítulo.

Para finalizar, podemos dizer que regressões logísticas têm sido aplicadas em modelos de análise de crédito com sucesso há vários anos; vocês podem encontrar referências e evidências facilmente fazendo uma pesquisa em seu buscador preferido.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

KELLEHER J. D.; TIERNEY B. **Machine Learning**. New Jersey: MIT Press, 2018.

SMOLA A.; VISHWANATHAN S.V.N. **Introduction to Machine Learning**. Cambridge: Cambridge University Press, 2008.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com