FIAP ON

DATA VIZ & DATA SCIENCE

ÁRVORES DE DECISÃO

12

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 – Probabilidades em uma moeda.....6
Figura 2 – Exemplo árvore de probabilidades.....7
Figura 3 – Aplicação de árvore para análise de conversão.....8
Figura 4 – Axiomas de probabilidades 11
Figura 5 – Teorema de Bayes.....14
Figura 6 – Árvore de decisão 16
Figura 7 – Diagrama exemplo Random Forest.....17
Figura 8 – Árvore de decisão e Random Forest.....18
Figura 9 – Árvore de decisão em formato texto.....20
Figura 10 – Árvore de decisão em formato gráfico.....21
Figura 11 – Random Forest em formato gráfico.....28

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE TABELAS

Tabela 1 – Matriz de contingência para intenção de compra e conversão.....12
Tabela 2 – Matriz de contingência para probabilidades 13
Tabela 3 – Matriz de contingência com evidência para P(A U B).....13

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Carga de dados e bibliotecas (1) 19
Código-fonte 2 – Carga de dados e bibliotecas (2) 19
Código-fonte 3 – Visualização simplificada de uma árvore de decisão.....20
Código-fonte 4 – Construção de uma Random Forest.....27

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 ÁRVORES DE DECISÃO.....6
2 TEORIA DAS PROBABILIDADES 9
2.1 Probabilidade a priori (clássica) 9
2.2 Probabilidade empírica.....10
2.3 Propriedades de probabilidades.....10
2.4 Regras ou fórmulas de probabilidades.....11
2.5 Probabilidade condicional.....14
2.6 Árvores de decisão.....15
3 RANDOM FOREST.....17
4 APLICAÇÕES 19

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 ÁRVORES DE DECISÃO

Para entendermos o funcionamento e as aplicações de algoritmos baseados em árvores, é de suma importância que tenhamos a compreensão clara do conceito de teoria de probabilidades, que é base para os cálculos dos algoritmos de árvores.

IMPORTANTE: Apresentaremos aqui um algoritmo básico de árvores de decisão e também um algoritmo mais avançado, chamado de Random Forest. Porém é importante ressaltar que existem muitos algoritmos que se baseiam em conceitos de árvores além desses.

Começaremos, portanto, revisando o conceito de teoria de probabilidades que é apresentado em disciplinas de matemática no ensino médio no Brasil. Os conceitos básicos de probabilidades, no entanto, são muitas vezes fáceis de entender. Um exemplo que é corriqueiramente utilizado em exercícios no ensino médio é analisar a probabilidade de, ao jogar uma moeda para o alto, ela cair no lado cara ou lado coroa. Tecnicamente é o que chamamos de probabilidade a priori, pois calculamos antes de o evento acontecer; observamos uma moeda, avaliamos que tem dois lados e a partir daí chegamos à conclusão de que a resposta é 50%. Aqui veremos outra abordagem de teoria de probabilidades, o que chamamos de probabilidade clássica empírica.

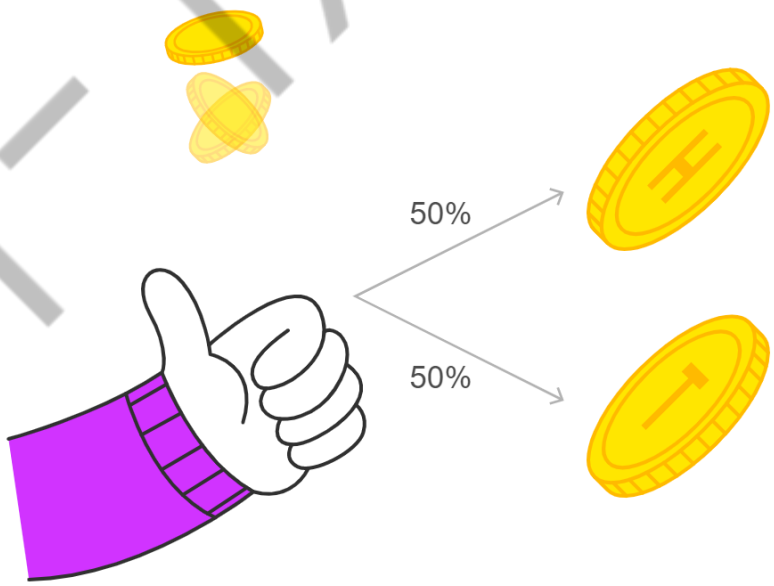

Figura 1 – Probabilidades em uma moeda
Fonte: Towards Data Science (2018)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

A partir dos conceitos de probabilidades, podemos expressar visualmente cálculos de probabilidades por meio de um gráfico ou diagrama de árvore, tal como na Figura “Exemplo árvore de probabilidades”.

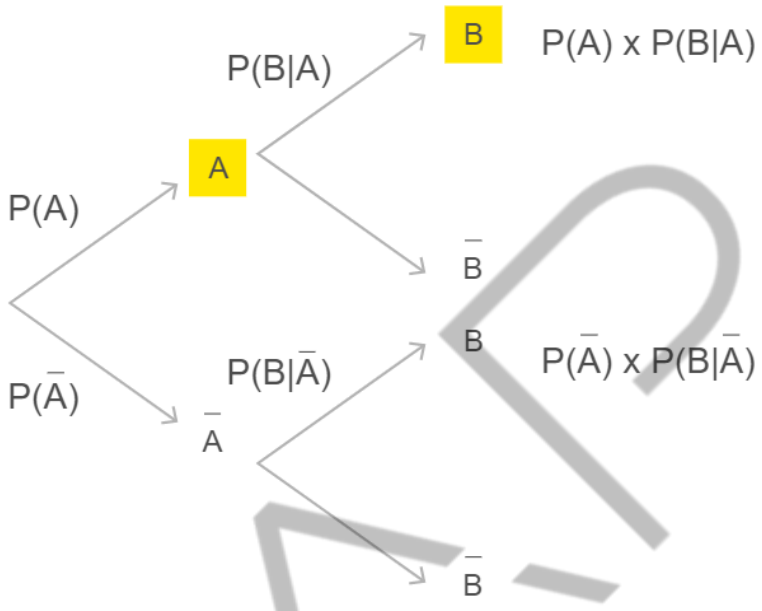

Figura 2 – Exemplo árvore de probabilidades
Fonte: Sonia Vieira (2015)

Utilizar um diagrama de árvore em análise de dados tem muitas vantagens, tais como:

- Por se utilizar de níveis hierárquicos, auxilia a organizar as etapas de análise.
- É um gráfico de fácil interpretação visual, sendo uma ferramenta simples e poderosa para comunicar resultados, análise etc.
- Permite, por meio da sua navegação em diferente níveis, compreender diferentes contribuições de cada “ramo” da árvore para o todo que está sendo analisado.
- Permite que utilizemos muitos níveis, podendo “abrir” somente os ramos que interessam.

Vejamos no exemplo a seguir, na Figura “Aplicação de árvore para análise de conversão”, uma árvore de decisão que nos permite entender, para o caso de um e-

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

commerce, a probabilidade de conversão (visita sucedida de compra) a partir do histórico de visitação.

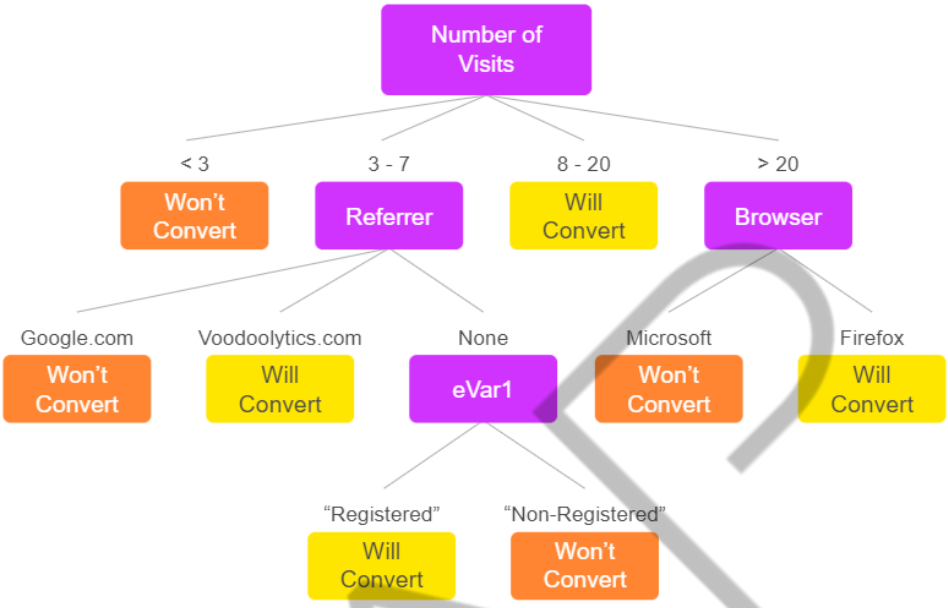

Figura 3 – Aplicação de árvore para análise de conversão
Fonte: Adobe, Trevor Paulsen (2012)

Quais são as conclusões a que podemos chegar ao analisar esta árvore? Basta "ler" adequadamente cada um dos "caminhos" desde a raiz, ou melhor, os ramos.

- Se o número de visitas for entre 3 e 7, e o cliente vier do site Voodoolytics.com ou for registrado, tem alta probabilidade de conversão.
- Se o número de visitas for entre 8 e 20, tem alta probabilidade de conversão.
- Se o número de visitas for maior que 20, sendo que o cliente está navegando pelo Firefox, também tem alta probabilidade de conversão.

Você consegue aplicar um gráfico desse tipo para inúmeras situações em que quer entender alavancas ou fatores que influenciam determinado evento. É fácil compreendê-lo com um mínimo de explicações. Porém, nem sempre as probabilidades são altas ou conseguimos definir claramente uma distinção entre probabilidades.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 TEORIA DAS PROBABILIDADES

A teoria das probabilidades foi formalizada a partir de estudos contemporâneos dos matemáticos Fermat e Pascal (1654), entre outros. No entanto, estima-se que a observação empírica se dê há séculos ou milênios, desde que o homem criou os jogos chamados “de azar”.

Calculamos a probabilidade de um evento ocorrer a partir da análise das maneiras possíveis de ele ocorrer e do número total de resultados possíveis:

P=x/t , em que x são as maneiras possíveis de um evento ocorrer, e t, o número total de resultados possíveis.

2.1 Probabilidade a priori (clássica)

Chamamos de probabilidade a priori quando analisamos o formato da moeda e constatamos que tem dois lados. E se cara é um dos lados somente, é fácil chegar à conclusão de que:

P(cara) = ½ = 0,5 = 50%

Dando outro exemplo, um dado comum de seis lados, com números de 1 a 6 gravados em seus lados. Se quisermos calcular a probabilidade de sair o número 3, basta fazer:

P(3) = ⅙ = 0,16666…

Nos livros clássicos de estatística, você encontrará teoremas e diversos exemplos que exemplificam muito bem esses fenômenos. Nós nos concentraremos aqui, então, em aplicações práticas com dados (não dados de 6 lados de jogos de mesa, e sim dados oriundos de tabelas e bancos de dados).

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2.2 Probabilidade empírica

De outra abordagem, a probabilidade empírica utiliza-se do empirismo, isto é, de experiências realizadas em campo. Uma forma simples de entender é retornando ao caso da moeda.

Se jogarmos uma moeda cem vezes para o alto, teremos uma sequência de cem caras ou coroas. Pelo nosso conhecimento de probabilidade a priori, chegaremos à conclusão de que provavelmente 50 vezes a moeda cairá com o lado cara voltado para cima, não é mesmo? Pode acontecer de 49 ou 51 com uma probabilidade menor, 48 ou 52 com uma probabilidade menor ainda e assim por diante.

Mas como calcularemos a probabilidade clássica empírica? Simples, basta contar, depois de cem lançamentos, quantas vezes tivemos cara como lado superior. Assim:

P(cara) = 50/100 = 0,5 = 50%

Na grande maioria das aplicações práticas, a solução é bem mais complexa que uma moeda de dois lados e, nesse caso, o uso da probabilidade empírica será mais adequado.

IMPORTANTE: Foi justamente o que vimos anteriormente na Figura “Aplicação de árvore para análise de conversão”, inúmeros “ramos” da árvore.

2.3 Propriedades de probabilidades

Para nossos cálculos básicos de probabilidades, precisamos conhecer um conjunto mínimo de propriedades que tecnicamente chamamos de axiomas de probabilidades.

SAIBA MAIS: Para quem gosta de definições matemáticas, um axioma é uma verdade aceita, isto é, que não necessita (ou não tem) uma prova ou demonstração por meio de um teorema. Os axiomas são espécies de premissas aceitas para se construir todo o conhecimento matemático sobre estes pilares. E assim o é na teoria de probabilidades – todo o conceito é desenvolvido sobre esses pilares.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1. Let Ω be a sample space. The axioms of probability are:

   Axiom 1 $P(A) \geq 0$, for all events $A \subseteq \Omega$.

   Axiom 2 $P(\Omega) = 1$.

   Axiom 3 If events A and B satisfy $A \cap B = \emptyset$, then $P(A \cup B) = P(A) + P(B)$.

   Let $A, B \subseteq \Omega$ be events.

   (a) Prove that $P(A^c) = 1 - P(A)$.

   (b) Prove that if $A \subseteq B$ then $P(A) \leq P(B)$.

Figura 4 – Axiomas de probabilidades
Fonte: Chegg (2022)

Podemos traduzir os axiomas em:

- A probabilidade de um evento qualquer acontecer é maior ou igual a 0.
- A probabilidade de todos os eventos ocorrerem é 1 ou 100%.
- A probabilidade de todos os eventos, exceto 1 específico, é igual a 1-P(evento específico).

Basicamente todo o conceito de teoria de probabilidades foi construído a partir desses três pilares, utilizando-se uma série de experimentações, derivações de teoremas, ao longo de muitos anos de pesquisas.

2.4 Regras ou fórmulas de probabilidades

É bastante interessante estudar a probabilidade de um evento isolado acontecer (como “qual é a probabilidade de um cliente converter uma compra?”, por exemplo). Porém, sem analisar outros eventos em conjunto (cliques anteriores, quantas visitas o cliente fez etc.), não temos muita ação sobre um fenômeno. Veja uma discussão de negócios habitual:

“Ontem tivemos uma taxa de conversão de 3%. Porém hoje caiu para 1,8%!!!”

A próxima pergunta será:

“E por que tivemos essa queda? O que podemos fazer para retomar a um nível mais alto de taxa de conversão?”

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Conseguiremos responder a esse evento (evento A) se entendermos no mínimo mais um fator (evento B) ou vários e analisarmos a probabilidade de eventos combinados.

Para conseguirmos calcular as probabilidades básicas de eventos combinados ocorrerem, vamos lançar mão de algumas regras (ou fórmulas) bem conhecidas de estudantes de ensino médio.

Regra geral da multiplicação (intersecção):

$$P(A \cap B) = P(A|B)*P(B)$$

Regra geral da adição (união):

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Não é tão trivial entender esta fórmula somente pela equação apresentada acima ou ainda por cálculos. Vamos então elaborar uma matriz para isso, apresentada na Tabela “Matriz de contingência para intenção de compra e conversão”.

		Cliente converteu?		
		Sim	**Não**	
Cliente disse que quer comprar?	**Sim**	180	20	200
	Não	120	680	800
		300	700	1000

Tabela 1 – Matriz de contingência para intenção de compra e conversão
Fonte: Elaborada pelo autor (2022)

A situação demonstrada na tabela é um experimento realizado com mil clientes em que perguntamos inicialmente se o cliente tinha intenção de compra (linhas) e, posteriormente, avaliamos se o cliente realizou a compra de fato. Chamamos essa matriz ou tabela de contingência, onde cruzamos dois eventos distintos e comparamos suas ocorrências.

Pelo exemplo acima, podemos fazer algumas constatações:

- O experimento foi realizado com mil clientes.
- Sobre intenção de compra, 20% disse que desejava comprar, contra 80% que não desejava.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

- Na prática, o que se observou foi uma probabilidade de conversão maior do que a intenção, ou seja, convertemos 30% contra 70% que não comprou. Isso pode nos levar a perguntas como “e o que nos fez ir tão bem?”
- Dos 800 clientes que não queriam comprar (vamos definir uma nova base como sendo 800 = 100%), 120 mudaram de ideia porque fizemos promoções interessantes e nossos vendedores atuaram (e qual é essa probabilidade?).

Podemos ver as regras ou fórmulas de probabilidades nesta tabela também, da seguinte forma expressa na Tabela “Matriz de contingência para probabilidades”.

		Evento B		
		P(B)	**P(B')**	
Evento A	**P(A)**	P(A ∩ B)	P(A ∩ B')	P(A)
	P(A')	P(A' ∩ B)	P(A' ∩ B')	P(A')
		P(B)	P(B')	P = 1

Tabela 2 – Matriz de contingência para probabilidades
Fonte: Elaborada pelo autor (2022)

A regra da adição fica fácil de ver na tabela, basta olhar a intersecção das linhas e colunas e justamente na célula onde há uma intersecção é que temos a probabilidade. Mas e a regra da adição? Vejamos na Tabela “Matriz de contingência com evidência para P(A U B)” um exemplo do cálculo de P(A U B).

		Evento B		
		P(B)	P(B')	
Evento A	P(A)	P(A ∩ B)	P(A ∩ B')	P(A)
	P(A')	P(A' ∩ B)	P(A' ∩ B')	P(A')
		P(B)	P(B')	P = 1

Tabela 3 – Matriz de contingência com evidência para P(A U B)
Fonte: Elaborada pelo autor (2022)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Nesse gráfico, onde ressaltaram-se a primeira linha e primeira coluna, fica claro que, quando avaliamos P(A) + P(B), ocorreu que estamos incluindo P(A ∩ B) duas vezes, daí a razão de esse elemento ser subtraído na fórmula da regra da adição.

Porém o resultado mais relevante, que é entender o que ocorre com um evento quando ele foi antecedido de outro evento (relações entre eventos), é que não temos ainda uma resposta. Para isso, vamos lançar mão de um dos teoremas mais importantes para estudo de dados: teorema de Bayes.

2.5 Probabilidade condicional

Um resultado relativo, todavia, extremamente poderoso, nos foi apresentado por Thomas Bayes (1701-1761), porém formatado em sua formulação moderna somente em 1812 por Pierre de Laplace no livro *Teoria analítica da probabilidade*.

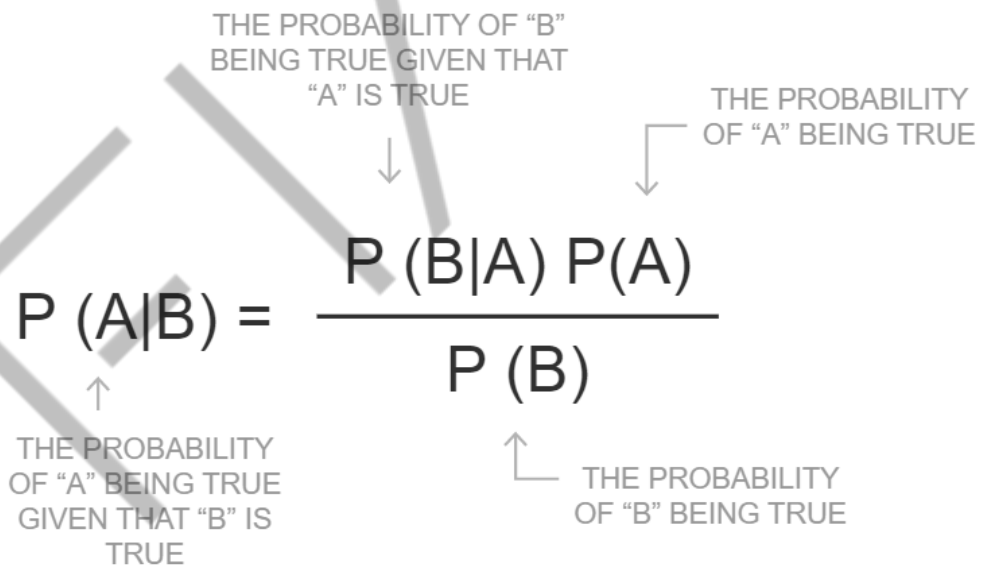

Figura 5 – Teorema de Bayes
Fonte: Frederick DenBleyker (2022)

Vamos exemplificar com uma situação em que temos teste para uma determinada doença e, posteriormente, a constatação se a doença de fato estava instalada. Analisando inicialmente o evento A ("has the cancer"), temos a probabilidade 0,04. E seu complemento (ou seja, "NO does not have the cancer") com probabilidade 0,96.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Posteriormente, analisaremos para cada um dos casos qual é a probabilidade de somente os que tiveram câncer terem resultado positivo ou negativo do teste. Para os casos de teste positivo, temos 0,79. E no seu complementar (teste negativo), a probabilidade de 0,21.

A esta última probabilidade é que temos:

- P(Positive Test|Yes, has the cancer) = 0,79
- P(Negative Test|Yes, has the cancer) = 0,21

E para os pacientes que não tiveram câncer, teremos:

- P(Positive Test|NO does not have the cancer) = 0,05
- P(Negative Test|NO does not have the cancer) = 0,95

Para as quatro probabilidades acima, podemos convencionar que, se uma probabilidade é maior que 0,5, assumimos como condição positiva. No caso complementar (menor que 0,5), condição negativa.

Veremos agora como analisar essas probabilidades condicionais de uma forma que chamamos de extensa, em que poderíamos ter uma construção com mais elementos (não somente dois, que é o que comporta uma tabela simples).

2.6 Árvores de decisão

Uma árvore de decisão nada mais é do que a demonstração de uma árvore de probabilidades (condicionais) de combinações de variáveis. Especificamente a construção da árvore segue um algoritmo e existem vários que podem ser utilizados. O caso mais comum é de uma árvore binária (ou seja, onde em cada nó temos somente duas ramificações) e um dos algoritmos mais comuns é o C4.5.

Na Figura “Árvore de decisão”, temos a exemplificação gráfica de uma árvore de decisão.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

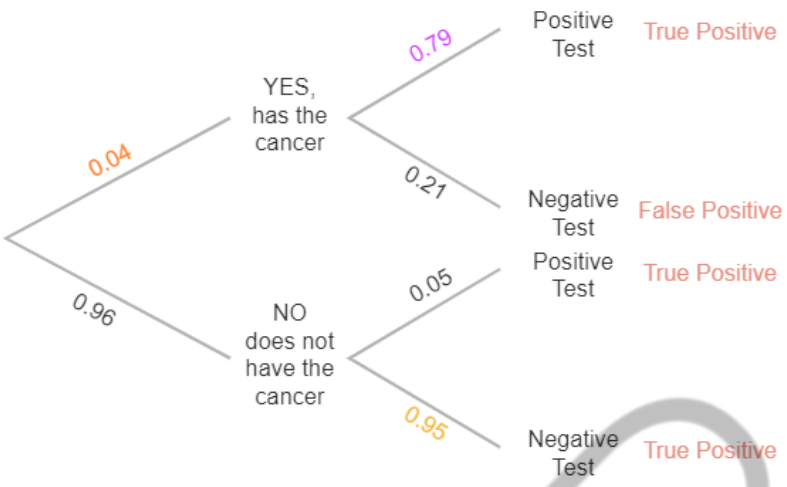

$$P(\text{patient has cancer} \mid \text{positive test}) = \frac{\text{true positives}}{(\text{true positives}) + (\text{false positives})}$$

$$P(\text{patient has cancer} \mid \text{positive test}) = \frac{(0.04)(0.79)}{(0.04)(0.79) + (0.96)(0.05)} = 0.397$$

Figura 6 – Árvore de decisão
Fonte: Calcworkshop (2022)

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

3 RANDOM FOREST

Quando trabalhamos com árvores de decisão, normalmente estamos procurando encontrar uma árvore que melhor descreva o problema que estamos tentando solucionar. Ocorre que, muitas vezes, encontramos mais de uma árvore que pode explicar o nosso problema, sendo que cada uma pode ter pontos positivos e negativos. Por que, então, não só procurar uma árvore, mas sim um conjunto de árvores (uma floresta) em que escolhemos cada uma que deverá ser utilizada, de acordo com seus pontos fortes?

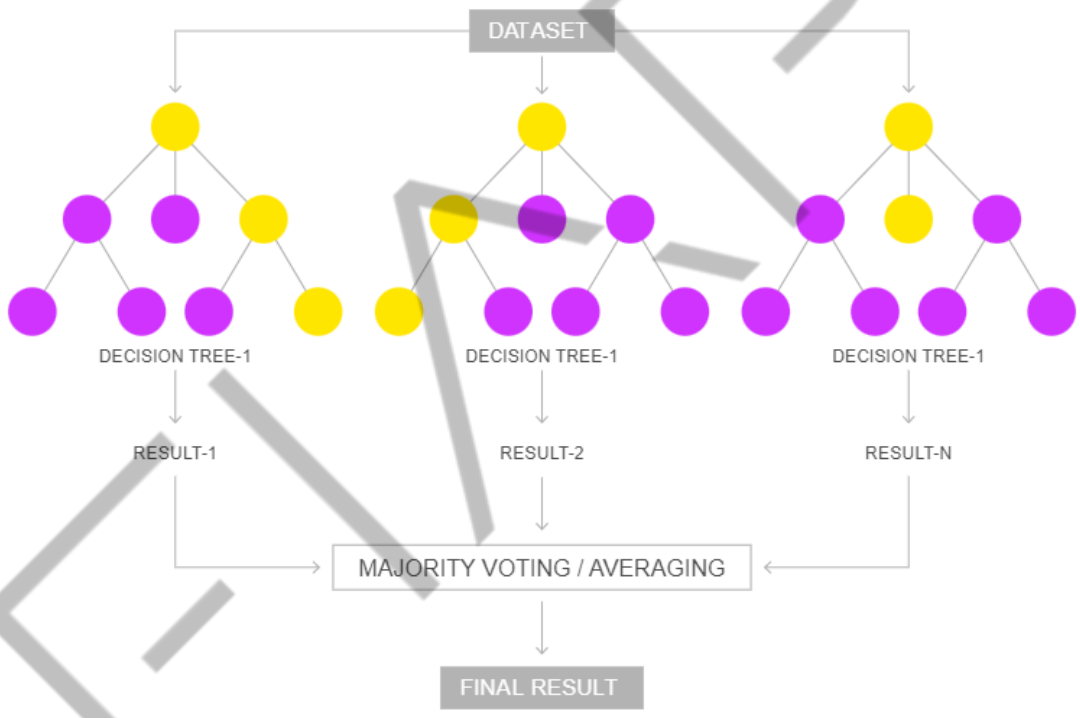

Figura 7 – Diagrama exemplo Random Forest
Fonte: TIBCO (2022)

A ideia parece lógica, porém o problema é como fazer isso de uma forma razoável, que não demande tanto tempo de um analista, ou melhor, que otimize o tempo do analista de forma que ele possa se concentrar nos aspectos mais relevantes da análise. O algoritmo de Random Forest não responde somente a esta questão como tem uma série de características, funções implementadas nativamente e que notadamente trazem uma robustez grande para soluções.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

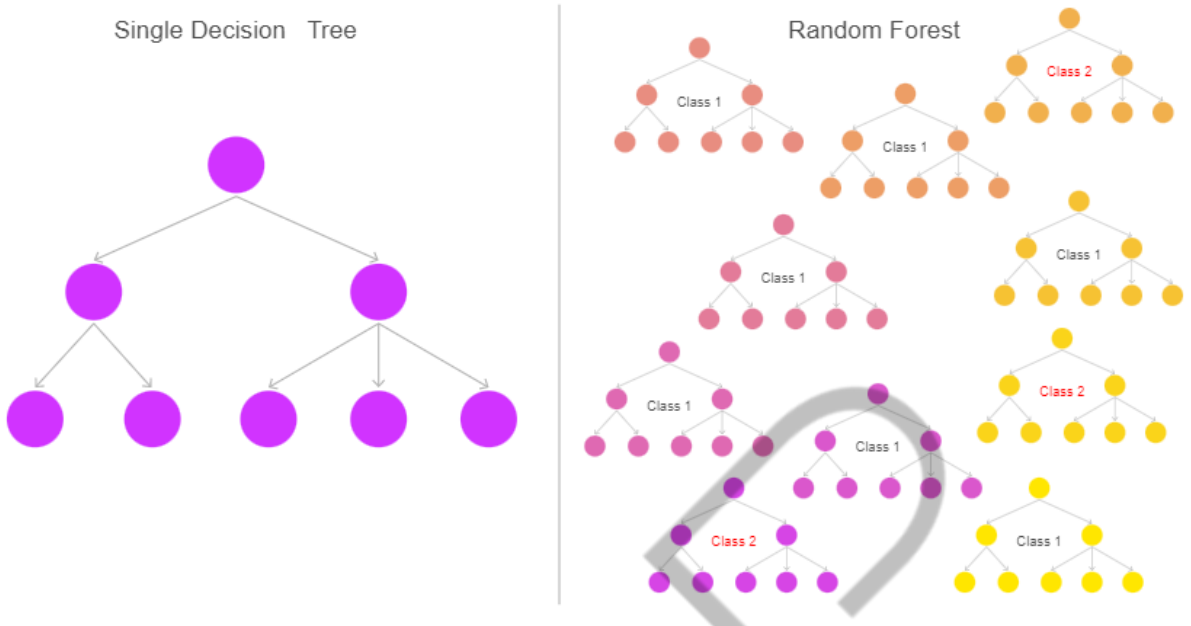

Figura 8 – Árvore de decisão e Random Forest
Fonte: Towards Data Science (2022)

Sugestivamente, o nome do algoritmo denota que temos uma característica de aleatoriedade (randômica); de fato, as árvores que compõem a floresta são selecionadas de forma aleatória, contudo são muitas. Assim, probabilisticamente, é bem provável que encontremos algumas árvores ótimas no meio de uma floresta. Claro que, após “construir a floresta”, será necessário encontrar tais árvores no meio da floresta. A beleza do algoritmo está justamente nesta solução já implementada.

Pela composição desse conjunto de técnicas, este algoritmo é denominado um método ensemble, pois ele não aplica somente uma técnica “pura”. Algumas características da implementação do algoritmo que podemos citar:

- Verificação de outliers.
- Evita overfit.
- Separação de dados usando técnica de out-of-bag.
- Análise de hierarquia para importância.
- Esquema de votos para escolhas das árvores preferenciais.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

4 APLICAÇÕES

Veremos agora um exemplo de aplicação de árvores de decisão e Random Forest utilizando Python. Inicialmente carregamos os dados e as bibliotecas.

```
import pandas as pd
from sklearn import tree
from matplotlib import pyplot as plt

df =
pd.read_csv('https://raw.githubusercontent.com/diogenesjusto/FIAP-On-
Line-Graduation/main/datasets/arvore_titanic.csv')


df.head()
```

Código-fonte 1 – Carga de dados e bibliotecas (1)
Fonte: Elaborado pelo autor (2022)

Para construir uma árvore de decisão, é importante entendermos qual será a variável que utilizaremos na análise e quais também são os fatores, as potenciais causas que estamos buscando relacionar. Neste caso, utilizaremos a variável Survived como análise e SibSp como causa.

```
# Definição dos dados da árvore
x_treino = df[['SibSp']]
y_treino = df['Survived']

# Construção da árvore
mod = tree.DecisionTreeClassifier()
mod = mod.fit(x_treino, y_treino)

# Visualização da árvore em formato de texto
text_representation = tree.export_text(mod)
print(text_representation)
```

Código-fonte 2 – Carga de dados e bibliotecas (2)
Fonte: Elaborado pelo autor (2022)

No Código-fonte “Carga de dados e bibliotecas (2)”, além de construirmos a árvore de decisão, utilizamos o comando export_text para visualizar a estrutura da árvore em formato texto apresentada na Figura “Árvore de decisão e Random Forest”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
|--- feature_0 <= 0.50
|   |--- class: 0
|--- feature_0 >  0.50
|   |--- feature_0 <= 2.50
|   |   |--- feature_0 <= 1.50
|   |   |   |--- class: 1
|   |   |--- feature_0 >  1.50
|   |   |   |--- class: 0
|   |--- feature_0 >  2.50
|   |   |--- feature_0 <= 4.50
|   |   |   |--- feature_0 <= 3.50
|   |   |   |   |--- class: 0
|   |   |   |--- feature_0 >  3.50
|   |   |   |   |--- class: 0
|   |   |--- feature_0 >  4.50
|   |   |   |--- class: 0
```

Figura 9 – Árvore de decisão em formato texto
Fonte: Elaborada pelo autor (2022)

Há um recurso de análise gráfica de árvores que é bastante útil dada sua estética, mas também a simplicidade.

Em Python e outras linguagens, temos inúmeras ferramentas para gerar gráficos de árvores de decisão, desde as mais simples até as mais sofisticadas que permitem interação e navegação.

```
# Visualização da árvore em formato gráfico
tree.plot_tree(mod)
plt.show()
```

Código-fonte 3 – Visualização simplificada de uma árvore de decisão
Fonte: Elaborado pelo autor (2022)

Este código gera o gráfico visualizado na Figura “Árvore de decisão em formato texto”, que ainda poderia ser formatado para uma melhor apresentação.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

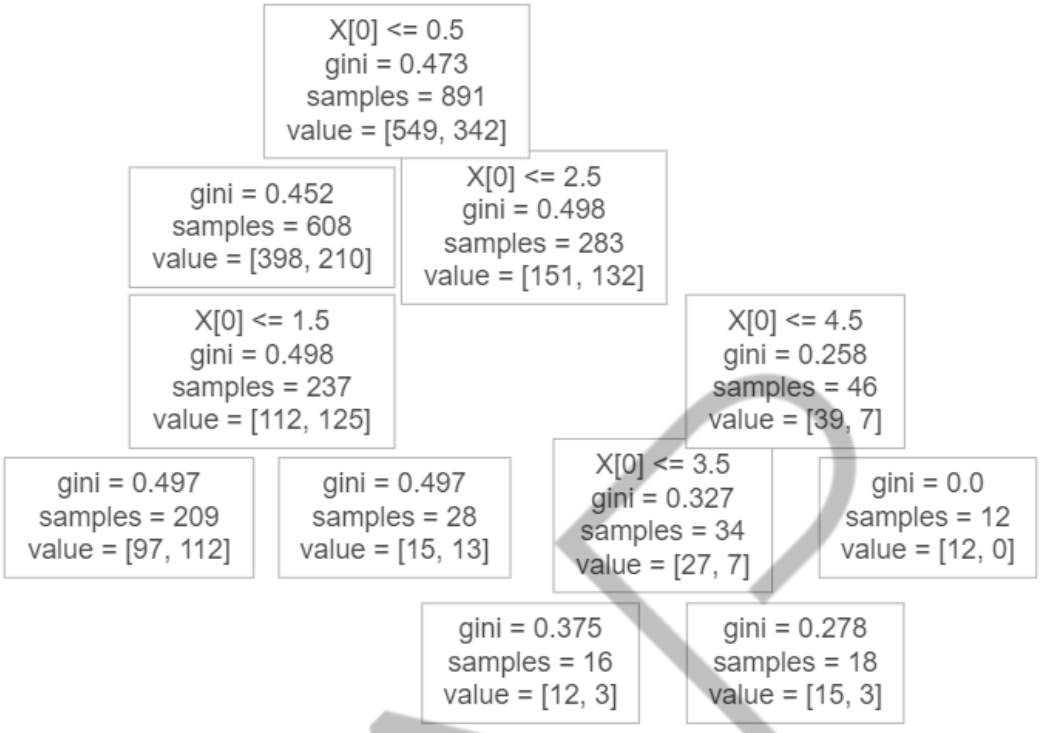

Figura 10 – Árvore de decisão em formato gráfico
Fonte: Elaborada pelo autor (2022)

Você achou fácil analisar as árvores nas figuras 9 ou 10? Pois é, aí está um recurso que, até hoje, eu não encontrei de forma visual fácil e útil para analisar no python. Vamos então utilizar outro recurso do Colab para a visualização de árvores que considero bastante interessante.

Acesse o menu "Ambiente de Execução" e clique na opção "Alterar o tipo de ambiente de execução", conforme Figura 11.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

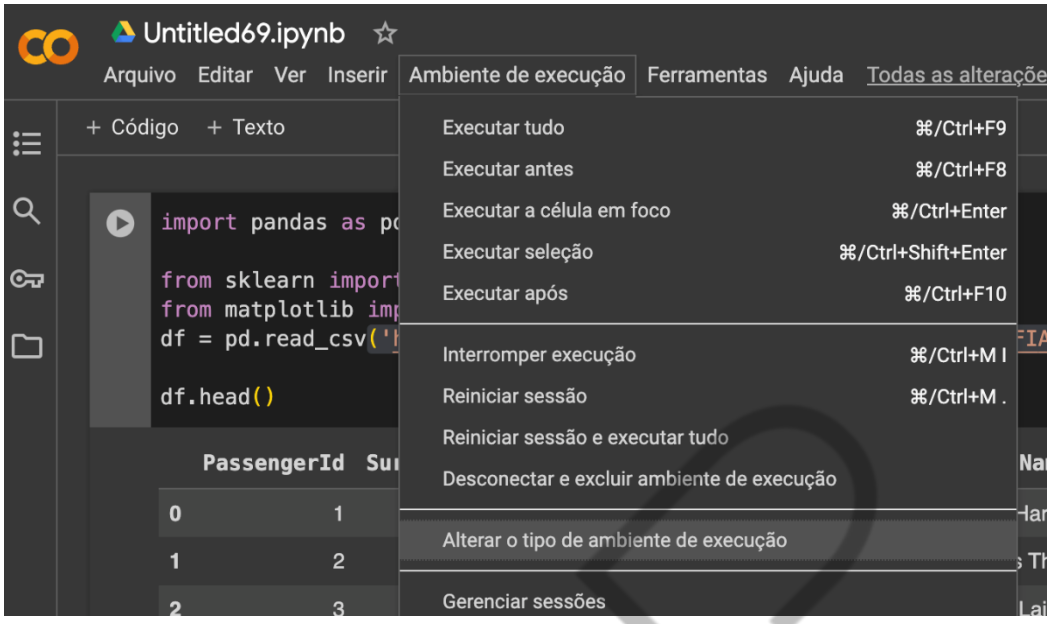

Figura 11 – Alteração do ambiente de execução
Fonte: Elaborada pelo autor (2023)

Posteriormente, na janela que se abrirá, escolha a opção R, em "Tipo de ambiente de execução". O que estamos fazendo agora é escolher que executaremos o código em outra linguagem de análise de dados, a linguagem R – e o faremos somente para analisar visualmente árvores de decisão.

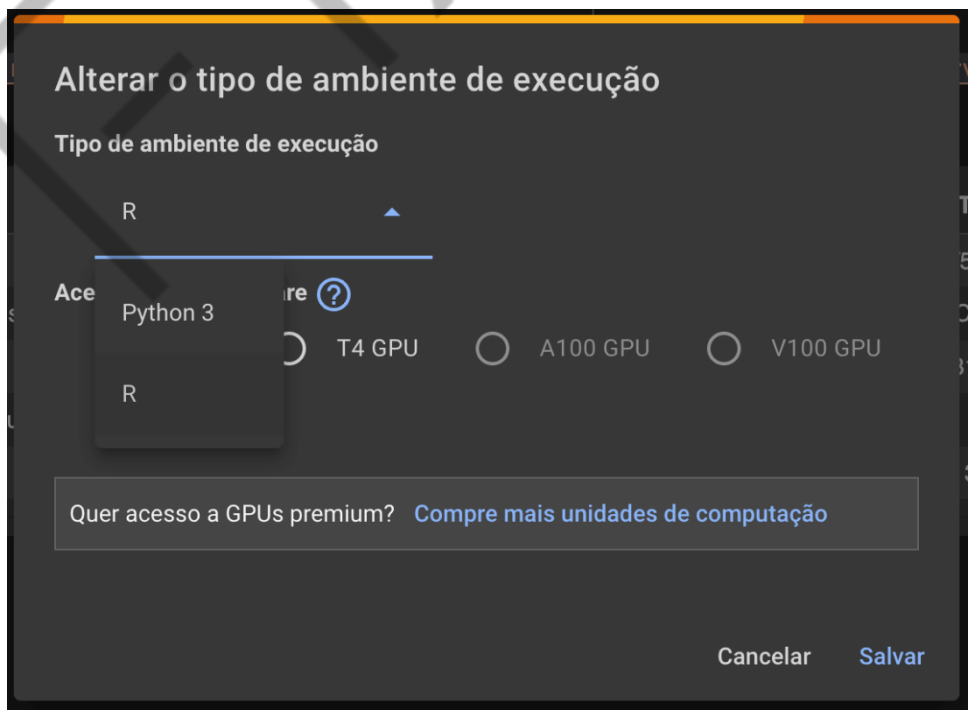

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Figura 12 – Ambiente de execução em R
Fonte: Elaborada pelo autor (2023)

Agora vamos instalar e carregar a biblioteca "Party" que utilizaremos no ambiente R, dentro do colab. O comando "install.packages" (do R) é similar ao comando "!pip install" do python. Ou seja, arquivos serão copiados de um repositório da internet, no computador local. Já o comando "library" do R é equivalente ao comando "import" do python.

```
[4] install.packages("party")
    library(party)

    Loading required package: grid

    Loading required package: mvtnorm

    Loading required package: modeltools

    Loading required package: stats4

    Loading required package: strucchange

    Loading required package: zoo

    Attaching package: 'zoo'

    The following objects are masked from 'package:base':

        as.Date, as.Date.numeric

    Loading required package: sandwich
```

Figura 13 – Instalação e carga de biblioteca R no Colab
Fonte: Elaborada pelo autor (2023)

Agora vamos carregar os mesmos dados do titanic, porém no ambiente R, e construir nossa árvore de decisão. Utilizaremos 3 comandos:

- read.csv : equivalente ao pd.read_csv no python (neste caso utilizou-se a função paste somente para exibir uma *string* longa em duas linhas, com efeito visual melhor para captura da tela);
- ctree: é a função, presente na biblioteca party, que realiza a construção da árvore. Neste caso também utilizou-se a função as.factor que transforma uma variável texto (Sex) em categórica;
- plot: função que apresenta o gráfico da árvore.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

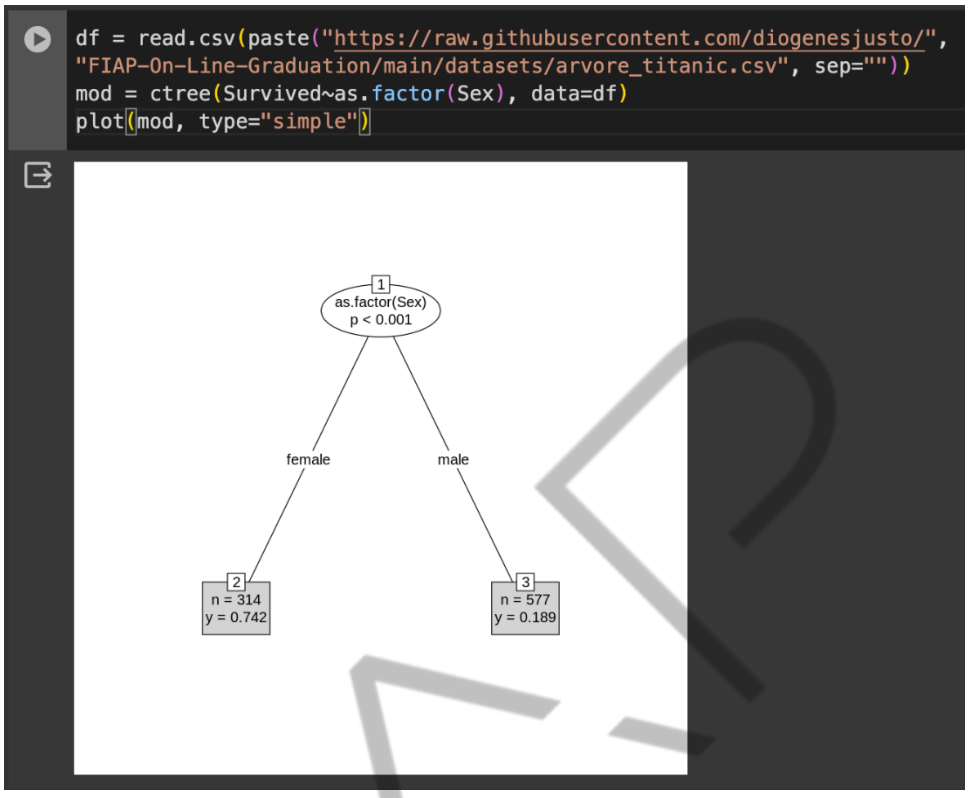

Figura 14 – Construção da árvore de decisão no R
Fonte: Elaborada pelo autor (2023)

Vamos ler juntos os elementos deste gráfico de árvore:

- A primeira ramificação é através da variável Sex (neste caso há somente 1 variável);
- No ramo esquerdo, n=314 indica que em todo dataset, de um total de 891 linhas, 314 correspondem a passageiros do gênero feminino;
- Ainda neste ramo y=0,742 (74,2%) é a probabilidade condicional de sobrevivência de um passageiro do gênero feminino.
- O mesmo ocorre no ramo direito, onde estão classificados os homens, porém com probabilidade de sobrevivência muito menor: 18,9%.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

A interpretação desta árvore nos diz que a variável Sex consegue separar os passageiros entre sobreviventes e mortos relativamente bem. Isto porque nas "folhas" da árvore, isto é, no último segmento (que neste é somente um nível) tem probabilidades condicionais próximas a 1 ou 0. Se os ramos ficassem com probabilidade próximos de 50%, nada poderíamos afirmar sobre sobrevivência de mulheres ou homens.

Traçando um paralelo para uma aplicação em marketing: imagine que você queria enviar uma campanha com desconto agressivo para trazer retorno de venda, conversão de compra. Se você encontrar um ramo no qual a probabilidade condicional é próxima de 1, significa que aquele "grupo" de clientes responderão melhor do que enviar para toda a base de clientes.

Vamos incluir mais variáveis e ver o que acontece com a árvore?

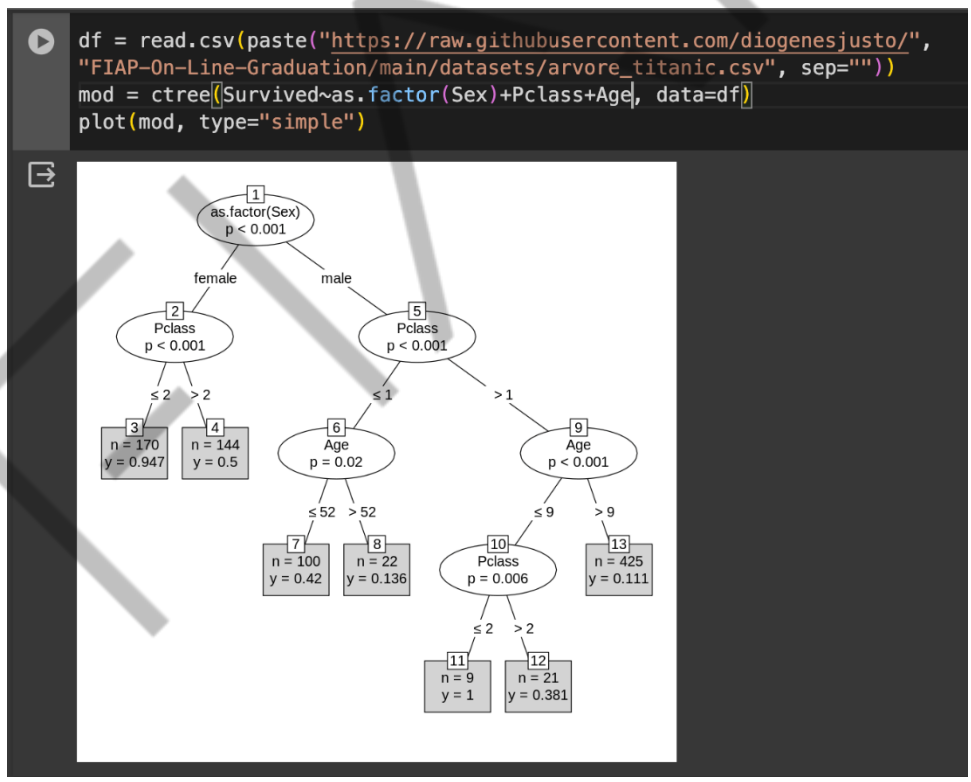

Figura 15 - Árvore de decisão com mais variáveis
Fonte: Elaborada pelo autor (2023)

Veja como a árvore se alterou com um número maior de variáveis, onde podemos observar:

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

- O ramo esquerdo, onde constam os passageiros do gênero feminino, foi segregado em 2 sub-ramos, onde as mulheres que estava na 1a e 2a classe, tem probabilidade de sobrevivência de 94,7%.
- Já as mulheres da 3a classe estão com probabilidade de sobrevivência de 50%. E se assim o é, também 50% é a probabilidade de morte, correto? Ou seja, para uma mulher na 3a, se quiséssemos tentar "adivinhar" se sobreviveu ou morreu, tanto faz dizer qualquer um dos estados. Podemos entender que este ramo da árvore não "segmenta bem" este fenômeno.
- Olhando para o lado direito, você pode estar se perguntando: e a idade para as mulheres? Por que não aparece? O algoritmo calculou as probabilidades e chegou a conclusão que não é significativo incluir esta variável para as mulheres.
- Já no ramo dos homens, a idade parece ser significativa. Até por que, de todas as "folhas" do ramo dos homens (veja que há um número dentro de um pequeno quadrado no topo de cada nó ou nodo da árvore, inclusive no nó "folha") somente a folha (ou nodo) 11 é que apresenta probabilidade maior do que 50% para algum sub-conjunto dos homens.
- Neste caso podemos "ler" este ramo como sendo 9 passageiros, que são meninos (idade <=9) e estão numa classe > 1 e <=2, portanto, 2a classe.

Para que utilizemos um algoritmo de árvore de decisão para realizar previsões, basta que "apliquemos" esta árvore em um novo conjunto de dados e a "previsão" será justamente a probabilidade condicional daquele ramo-folha da árvore.

Por exemplo: qual é a previsão de sobrevivência de um passageiro homem, na 1a classe, com 42 anos de idade? Basta olhar o nodo 7: 42%.

Podemos notar também aqui que várias folhas de uma árvore apresentam probabilidades condicionais que estão longe de 0 ou de 1. É fácil de notar. E isto significa que, para previsões, estas "folhas" serão "ruins", ou seja, nos trarão um erro de previsão alto. Como resolver esta questão, ou seja, encontrar uma árvore "próxima

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

a perfeição", que tenha todas as folhas com probabilidade condicional próximas a 1 ou 0? Muitas vezes isto nem é possível. Uma saída foi encontrada por alguns pesquisadores: por que utilizar somente uma árvore? Por que não utilizar uma floresta?

Por fim, veremos como construir uma floresta randômica de árvores de decisão com o algoritmo implementado na popular biblioteca sklearn (voltamos o kernel aqui para Python), no Código-fonte “Construção de uma Random Forest”.

```
from sklearn.ensemble import RandomForestClassifier
mod = RandomForestClassifier(n_estimators = 1000, random_state = 42)
# Train the model on training data
mod = mod.fit(x_treino, y_treino)

fn = 'SibSp'
cn = 'Survived'
fig, axes = plt.subplots(nrows = 1,ncols = 1,figsize = (4,4), dpi=800)
tree.plot_tree(mod.estimators_[0],
               feature_names = fn,
               class_names=cn,
               filled = True);
fig.savefig('rf_individualtree.png')
```

Código-fonte 4 – Construção de uma Random Forest
Fonte: Elaborado pelo autor (2022)

Sua visualização gráfica pode ser vista na Figura “Árvore de decisão em formato gráfico”, onde se nota uma semelhança com a árvore de decisão gerada. Faz sentido neste caso, pois utilizamos somente uma variável para “explicar” a árvore ou floresta (SibSp). Com a inserção de mais variáveis, teremos bastantes variações entre ambas.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

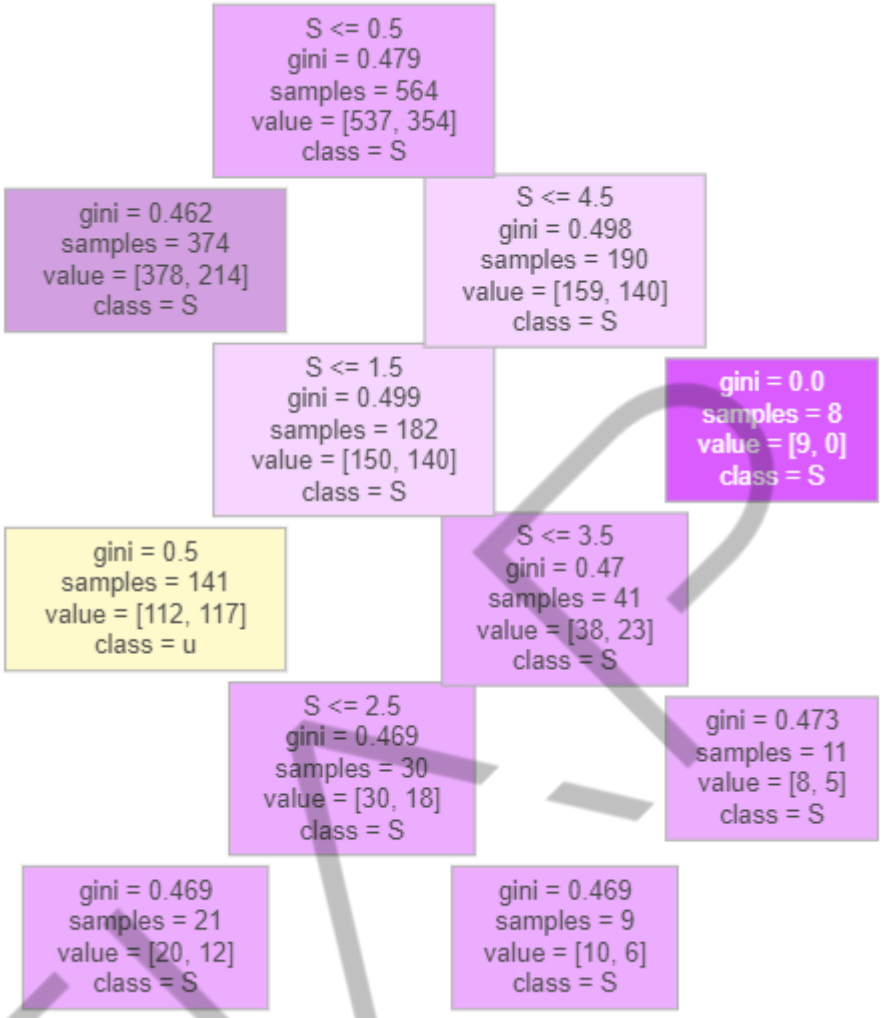

Figura 11 – Random Forest em formato gráfico
Fonte: Elaborado pelo autor (2022)

O algoritmo RandomForest faz parte de uma família de algoritmos que passaram a ser chamados de métodos "ensemble", que é uma alusão a uma combinação de técnicas, muitas das quais implementadas através de recursos computacionais. A partir de resultados notáveis em comparação com o algoritmo de árvores de decisão, o RandomForest tem sido aplicado a diversos tipos de problemas com diferentes abordagens.

Também a ideia básica de "um grande número de modelos fracos podem, juntos, ser um 'grande modelo' forte", foi aplicada em uma série de algoritmos que foram desenvolvidos posteriormente.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

REFERÊNCIAS

ROSS, S. **Probabilidade:** um curso moderno com aplicações. 8. ed. Porto Alegre: Bookman, 2010.

SHEPPARD, C. **Tree-based Machine Learning Algorithms:** decision trees, Random Forests, and boosting. [s.l.]: Createspace Independent Publishing Platform, 2017.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com