BUILDING STATISTICAL MODELS

HOW TO - GOOGLE COLAB

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE FIGURAS

Figura 1 – Dados Excel 7
Figura 2 – Salvando em .csv 8
Figura 3 – Verificar o .csv 9
Figura 4 – Tela Colab notebook 10
Figura 5 – Tela inicial Colab 10
Figura 6 – Colab exemplo inicial 11
Figura 7 – Carregar dados no Colab 12
Figura 8 – Selecionar dados no Colab 12
Figura 9 – Dados carregados no Colab 12
Figura 10 – Resultados leitura inicial dos dados 13
Figura 11 – Resultados do resumo das estatísticas descritivas 14
Figura 12 – Renomear arquivo 14
Figura 13 – Fazer download do Colab 15

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

LISTA DE CÓDIGOS-FONTE

Código-fonte 1 – Importar módulos iniciais e dados.....13
Código-fonte 2 – Obtenção das estatísticas descritivas.....14

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

SUMÁRIO

1 HOW TO – GOOGLE COLAB 5
1.1 Introdução 5
1.2 Principais preparações 5
2 PREPARAÇÃO DO AMBIENTE 7
2.1 Do Excel para o .csv 7
2.2 Primeiro contato com Colab 9
2.3 Dados e códigos iniciais 11
2.4 Salvar os resultados 14

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

1 HOW TO – GOOGLE COLAB

1.1 Introdução

Existem diversas ferramentas existentes no mercado voltadas às atividades de *Data Analytics*. Diante disto, iniciantes na área podem sentir grandes dificuldades para escolher qual a ferramenta para começar sua jornada na área de análise de dados. A utilização de ferramentas como Python e Google Colaboratory (Colab) facilitam o caminhar dessa jornada.

O objetivo deste texto é preparar o ambiente necessário para carregamento, preparação e análise dos dados. Quanto ao carregamento, iremos entregar um arquivo .csv e apresentar os processos e as funções necessárias para *upload* e armazenamento de objeto denominado *dataframe*.

Quanto à preparação, iremos tanto apresentar o manuseio do Colab (criação de textos e códigos), assim como importar os módulos do *Python*. Por fim, faremos uma análise simples utilizando algumas funções básicas do *Python* para apresentar as saídas gráficas e tabelas no *Colab*.

1.2 Principais preparações

Imagine-se em uma situação em que seja necessário realizar uma análise de crédito, mas a única ferramenta utilizada até o momento foi o Microsoft Excel. Diante disto, pode-se abrir o arquivo, verificar as colunas e os dados existentes e utilizar as ferramentas analíticas que o software permite.

Contudo, após horas de análises, seu computador começa a travar, você não consegue mexer seu mouse, a opção de salvamento não funciona e, para finalizar, o Windows apresenta uma tela azul desconfortável. Podemos observar esse cenário em diversas mesas de empresas ou *home office*; isso acontece porque o Excel ainda não é uma ferramenta preparada para analisar quantidades massivas de dados.

Diante desse cenário, podemos indagar como poderíamos analisar nossos dados de forma mais eficiente. Para responder a essa questão, vamos demonstrar como utilizar uma ferramenta na nuvem (Colab) combinada com uma linguagem de

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

programação simples (Python) para realizarmos análise de dados de forma confortável, eficiente e sem riscos de travamentos da máquina dos usuários.

Nos próximos tópicos, realizaremos uma jornada do começo ao fim para preparar os leitores na realização de análises complexas e aplicação de algoritmos de *Machine Learning* para resolver diversos problemas de negócios. As seguintes atividades serão apresentadas:

- Do Excel para o .csv.
- O ambiente Colab.
- Carregar dados do seu computador para o Colab.
- Importação de módulos Python.
- Obter uma tabela de resultados no Colab.
- Obter um gráfico no Colab.

FIAP

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

2 PREPARAÇÃO DO AMBIENTE

Sabemos que existe uma certa ansiedade para aplicar algoritmos complexos de aprendizagem de máquina, agrupar indivíduos em *clusters* ou realizar projeções inteligentes para a próxima semana ou o próximo mês. Contudo, todo desafio precisa ser iniciado com passos curtos; em nossos próximos exemplos, iniciaremos nossa jornada.

2.1 Do Excel para o .csv

Utilizar um arquivo Excel é bastante simples para realizar análise de dados, porém, o processo se torna bastante ineficiente quando a quantidade de dados aumenta. Para resolver esse problema, podemos transformar nossos arquivos em Excel (.xlsx) para um formato denominado "*Comma-separated values*" (.csv); por meio desse formato, conseguimos ler os dados no Python e iniciar as análises.

Na Figura "Dados Excel", apresentamos os dados que utilizaremos no exemplo, o objetivo é transformar esse arquivo com formato. xlsx para .csv. Disponibilizamos esses dados com nome "dados_credito.xlsx".

	A	B	C	D	E	F	G	H
1	id	idade	educacao	tipo_emprego	renda	divida	outras_div	default
2	1	41	3	18	176	10,3	5,01	nao_pagou
3	2	27	1	10	31	17,3	4	pagou
4	3	40	1	15	55	5,5	2,17	pagou
5	4	41	1	15	120	2,9	0,82	pagou
6	5	24	2	2	28	17,3	3,06	nao_pagou
7	6	41	2	5	25	10,2	2,16	pagou
8	7	39	1	20	67	30,6	16,67	pagou

Figura 1 – Dados Excel
Fonte: Elaborado pelo autor (2021)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Vamos iniciar o processo de transformação do formato dos dados. Seguir os seguintes passos: clicar em “Arquivo”

, depois “Salvar como”

, depois “Procurar” 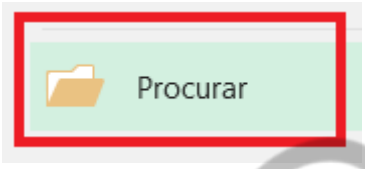

.

Após esses passos, vamos salvar nosso arquivo no formato .csv, conforme apresentado na Figura “Salvando em .csv”. Definimos “Tipo” como “CSV (separado por vírgulas)”, também recomendamos salvar o arquivo com o nome “dados_credito_exemplo_inicial.csv”.

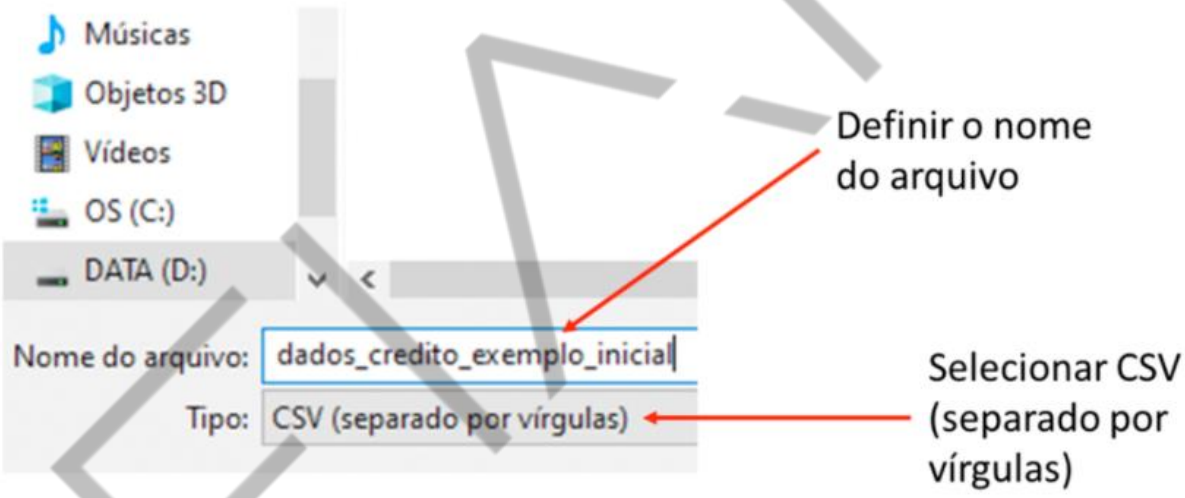

Figura 2 – Salvando em .csv
Fonte: Elaborado pelo autor (2021)

Agora que conseguimos salvar o arquivo no formato .csv, precisamos apresentar um último detalhe. Vamos clicar com o botão direito no arquivo “dados_credito_exemplo_inicial.csv”, selecionar “Abrir com” e clicar em “Bloco de notas”. Será possível verificar seu arquivo conforme a Figura “Verificar o .csv”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

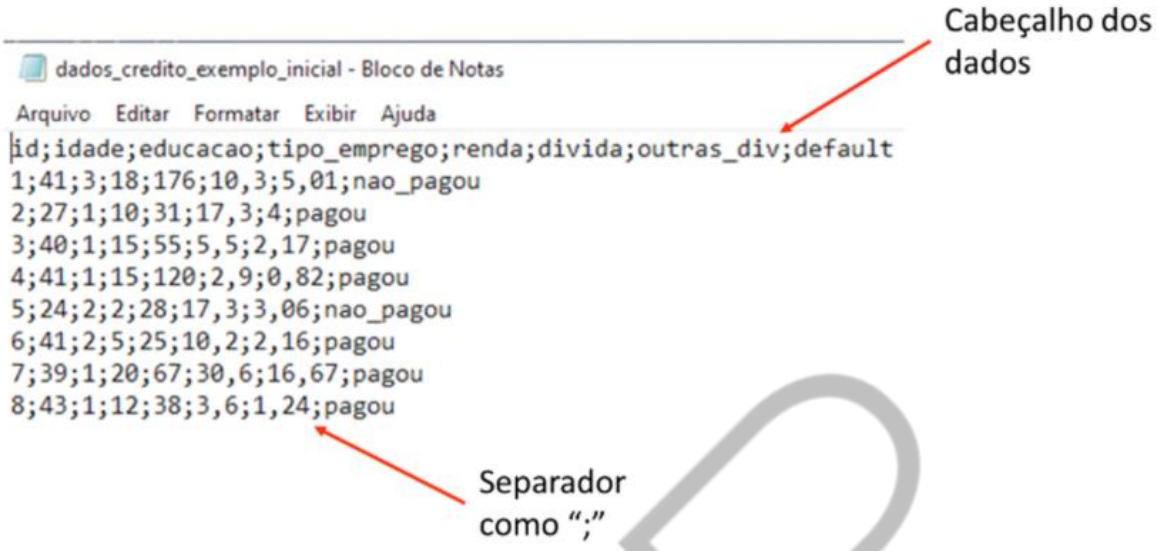

Figura 3 – Verificar o .csv
Fonte: Elaborado pelo autor (2021)

Vale ressaltar que na primeira linha temos o cabeçalho, no Python será considerado como nome das colunas; o ponto e vírgula (";") será o separador para indicar a qual coluna os valores estão relacionados, e a vírgula (",") indicará os decimais.

2.2 Primeiro contato com Colab

Agora que temos nossos dados no formato .csv, conheceremos a nossa principal ferramenta de programação, o Google Colaboratory (Colab); um serviço em nuvem gratuito hospedado pelo Google.

Essa ferramenta é uma iniciativa da empresa visando incentivar estudos na área de Aprendizado de Máquina, uma vez que, nessa ferramenta, alguns módulos importantes para realização das atividades estão previamente instalados. O Colab é uma lista de células que podem conter textos explicativos ou códigos executáveis e suas respectivas saídas.

Vamos iniciar no uso do Colab; primeiramente, ao digitar no navegador (Chrome ou Firefox, por exemplo) https://colab.research.google.com/, será apresentada uma tela conforme a Figura "Tela Colab notebook".

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

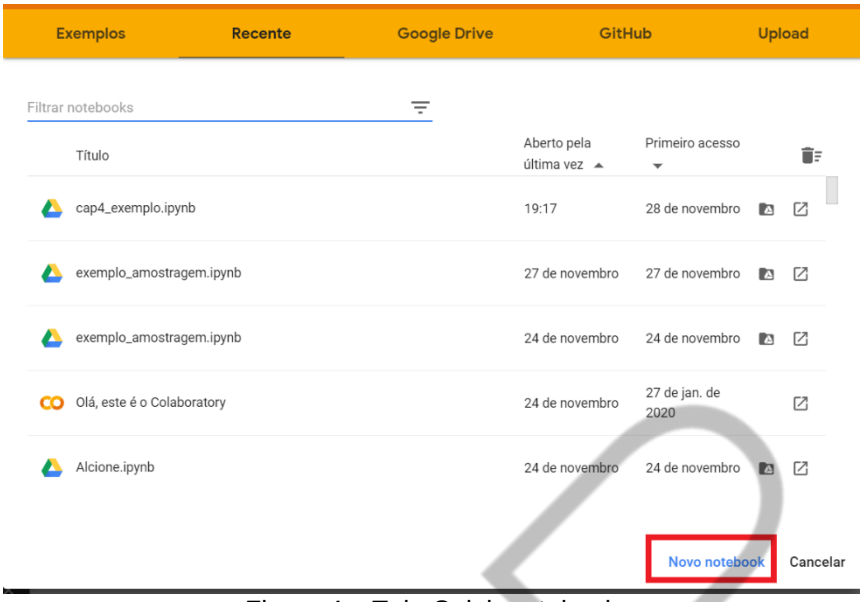

Figura 4 – Tela Colab notebook
Fonte: Elaborado pelo autor (2021)

Ao selecionar a opção “Novo notebook”, será aberto um arquivo “*python notebook”* para realizarmos nossas análises. Será apresentada a tela que pode ser visualizada na Figura “Tela inicial Colab”.

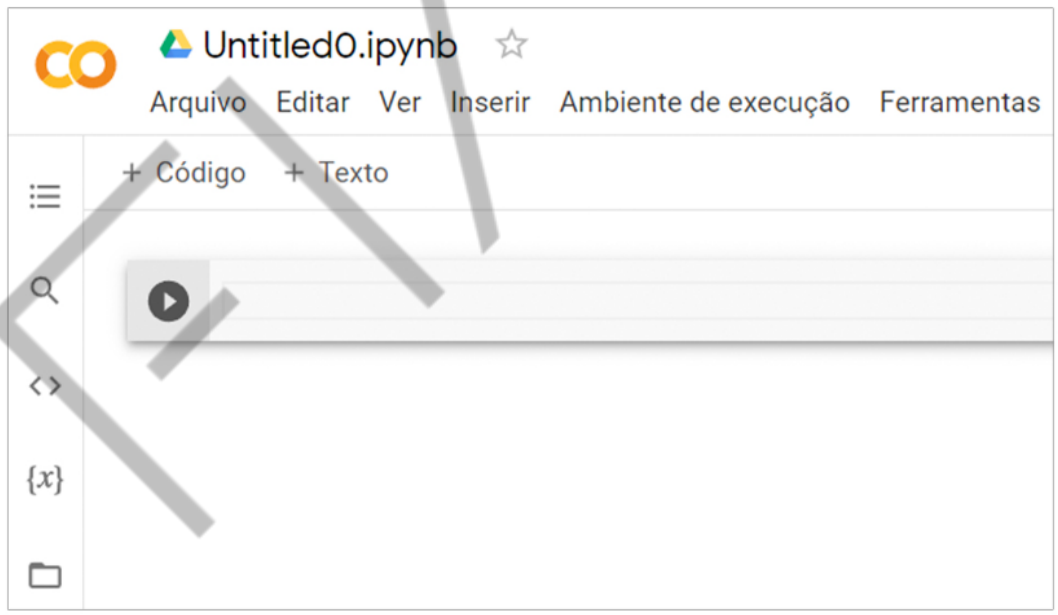

Figura 5 – Tela inicial Colab
Fonte: Elaborado pelo autor (2021)

Vamos agora conhecer alguns atalhos essenciais do Colab. Ao ver a tela inicial, você terá somente um bloco de códigos. Para criar mais blocos, pode-se clicar em “+ Código” (+ Código) ou executar o comando “Ctrl+M+B”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Também podemos criar blocos para escrever texto, podemos clicar em "+ Texto" (+ Texto) ou executar o comando "Ctrl+M+M". Caso queira voltar para o bloco de código, existe o comando "Ctrl+M+Y" e, caso queira apagar um bloco, "Ctrl+M+D".

Utilizando os comandos apresentados, vamos deixar nosso arquivo Colab conforme a figura "Colab exemplo inicial".

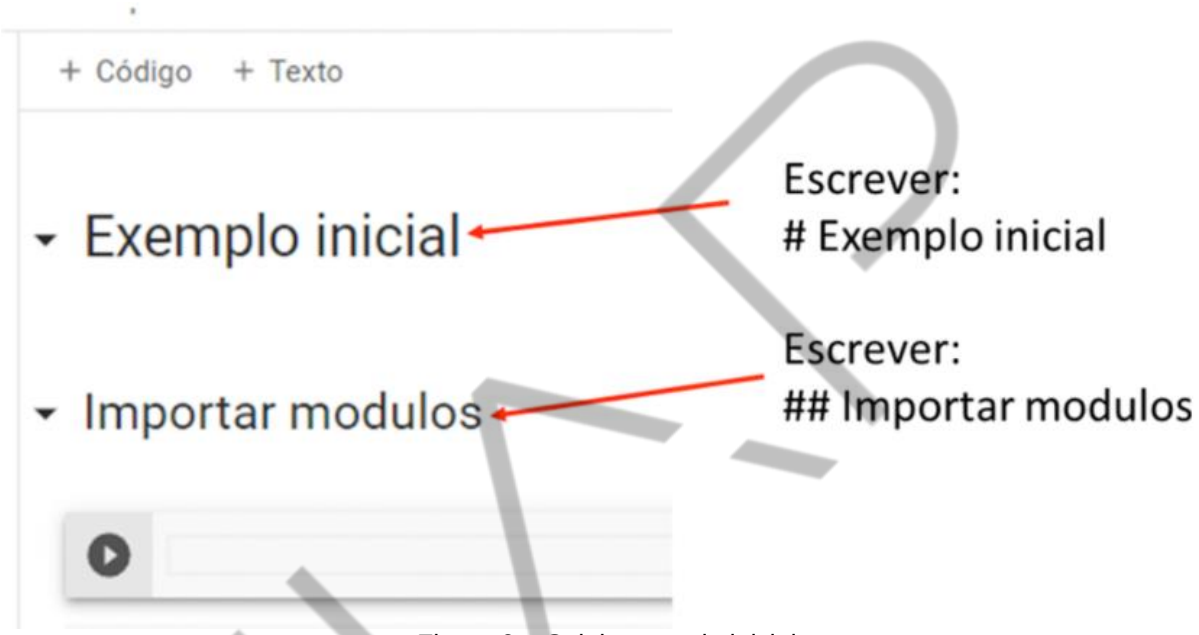

Figura 6 – Colab exemplo inicial
Fonte: Elaborado pelo autor (2021)

2.3 Dados e códigos iniciais

Tivemos nosso primeiro contato com o Colab; chegou o momento de realizar o upload dos dados, importar os módulos, carregar os dados no Python e gerar algumas análises.

Vamos aos seguintes dados no Colab: "dados_credito_exemplo_inicial.csv". Para fazer isso, siga os passos:

1. Clicar no botão apresentado na Figura "Carregar dados no Colab":

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

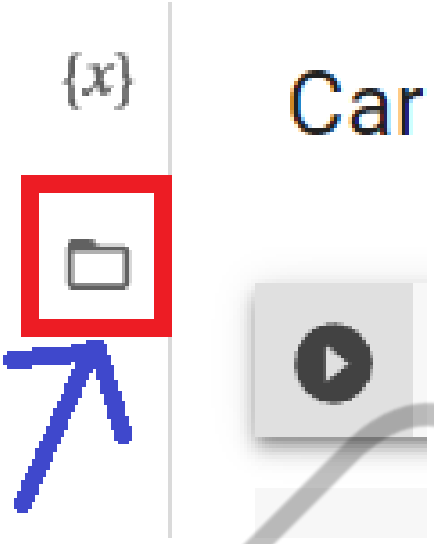

Figura 7 – Carregar dados no Colab
Fonte: Elaborado pelo autor (2021)

2. Clicar no botão da Figura “Selecionar dados no Colab” e selecionar o arquivo “dados_credito_exemplo_inicial” para iniciar nossas análises.

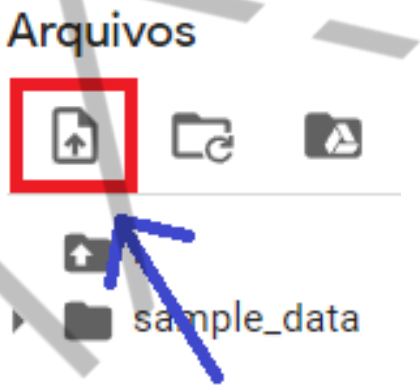

Figura 8 – Selecionar dados no Colab
Fonte: Elaborado pelo autor (2021)

Será possível visualizar o arquivo de dados na tela, conforme pode ser visto na Figura “Dados carregados no Colab”.

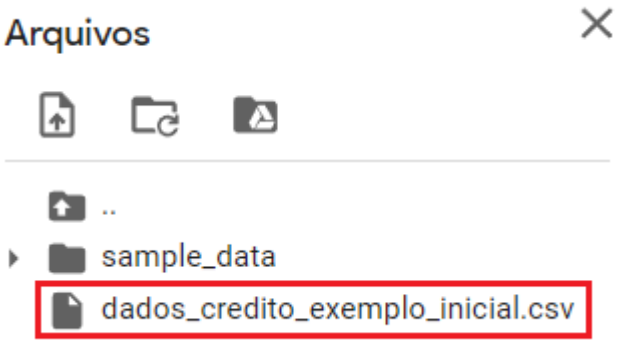

Figura 9 – Dados carregados no Colab
Fonte: Elaborado pelo autor (2021)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Agora que os dados foram carregados, digitar o Código-fonte “Importar módulos iniciais e dados” na tela do Colab.

```
# modulos
import numpy as np
import pandas as pd

# dados
dados = pd.read_csv('dados_credito_exemplo_inicial.csv',
                    sep = ';',
                    encoding='latin1',
                    decimal=',')
dados.head()
```

Código-fonte 1 – Importar módulos iniciais e dados
Fonte: Elaborado pelo autor (2021)

Uma vez que o código foi digitado, pode-se rodá-lo clicando no botão ou realizando no teclado os comandos “Shift + Enter”.

Após a execução do código, será possível ver o resultado apresentado na Figura “Resultados leitura inicial dos dados”. Será possível observar as cinco primeiras linhas e todas as oito colunas presentes no arquivo de dados.

	id	idade	educacao	tipo_emprego	renda	divida	outras_div	default
0	1	41	3	18	176	10.3	5.01	nao_pagou
1	2	27	1	10	31	17.3	4.00	pagou
2	3	40	1	15	55	5.5	2.17	pagou
3	4	41	1	15	120	2.9	0.82	pagou
4	5	24	2	2	28	17.3	3.06	nao_pagou

Figura 10 – Resultados leitura inicial dos dados
Fonte: Elaborado pelo autor (2021)

Para finalizar nosso exemplo, obteremos algumas estatísticas descritivas de média, mínimo e máximo. No Código-fonte “Obtenção das estatísticas descritivas”, apresentamos como obter as métricas para os grupos que “pagou” e “não pagou” a dívida quanto à variável renda.

```
# estatisticas descritivas
dados.groupby('default') \
      .agg(minimo_renda = pd.NamedAgg('renda', 'min'),
```

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

```
            maximo_renda = pd.NamedAgg('renda', 'max'),
            media_renda = pd.NamedAgg('renda', 'mean'))
```

Código-fonte 2 – Obtenção das estatísticas descritivas
Fonte: Elaborado pelo autor (2021)

Após a execução do código, será possível ver o resultado apresentado na Figura “Resultados do resumo das estatísticas descritivas”. Esses resultados nos fornecem uma forma de comparar os grupos quanto à renda.

default	minimo_renda	maximo_renda	media_renda
nao_pagou	14	446	44.612403
pagou	14	277	45.641509

Figura 11 – Resultados do resumo das estatísticas descritivas
Fonte: Elaborado pelo autor (2021)

2.4 Salvar os resultados

Como últimas etapas, apresentaremos as opções de salvamento no Colab e como reabrir um arquivo. As opções de salvamento são bastante simples, para renomear um arquivo, pode-se selecionar a parte da página contendo o nome do arquivo, renomear e apertar “Enter”, conforme é apresentado na Figura “Renomear arquivo”. Em nosso exemplo, o arquivo foi renomeado de “Untitled.ipynb” para “cap0_exemplo_inicial.ipynb”.

Figura 12 – Renomear arquivo
Fonte: Elaborado pelo autor (2021)

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com

Após realizar mudanças no arquivo Colab, a ferramenta gera salvamentos automáticos, porém, caso não tenha confiança nesse processo, pode-se utilizar o comando “Ctrl+S” para salvar as mudanças.

Outro ponto importante é como realizar o download do arquivo, esse processo pode ser realizado selecionando as opções “Arquivo”, “Fazer Download”, “Fazer Download do .ipynb”, conforme pode ser visto na Figura “Fazer download do Colab”.

Figura 13 – Fazer download do Colab
Fonte: Elaborado pelo autor (2021)

Para finalizar, vamos apresentar o processo de reabertura do arquivo .ipynb baixado anteriormente. Para realizar essa tarefa, novamente abrir uma nova aba no navegador, inserir https://colab.research.google.com/ e selecionar a opção “Upload”; abrirá uma caixa de seleção e poderá ser escolhido o arquivo “cap0_exemplo_inicial.ipynb”.

PDF exclusivo para Marcos Antonio Vieira de Almeida - rm559875
marcosdaguealmeida@outlook.com